

MA1A015 Notes de cours en français

Enseignants du cours de Probabilités M1 ISIFAR

2025-09-15

Résumé

Résumé du cours de Probabilités M1 ISIFAR en français

Table des matières

Table des matières	i
Mise en route	1
Un court cours de licence sur la théorie des probabilités dans un cursus de mathématiques appliquées	1
Prérequis	1
1 Introduction	3
1.1 Hachage	3
1.2 Un espace probabilisé	4
1.3 Variables aléatoires et indépendance	5
1.4 Convergences	7
1.5 Synthèse	10
2 Un minimum de théorie de la mesure	13
2.1 Feuille de route	13
2.2 Univers, partie et σ -algèbres	13
σ -algèbre engendrée	15
2.3 Lois de probabilité	16
2.4 Mesure de Lebesgue	18

TABLE DES MATIÈRES

2.5	Fonctions mesurables et variables aléatoires	20
2.6	Le théorème des classes monotones	22
2.7	Lois de probabilité sur la droite réelle	24
2.8	Variables aléatoires générales	25
2.9	Remarques bibliographiques	26
3	Un minimum d'intégration	29
3.1	Feuille de route	29
3.2	Fonctions simples	29
3.3	Intégration	32
3.4	Théorèmes limites	33
3.5	Lois de probabilité définies par une densité	36
3.6	Remarques bibliographiques	37
4	Des intégrales à l'espérance et aux moments	39
4.1	Feuille de route	39
4.2	Espérance	39
4.3	Inégalité de Jensen	40
4.4	Variance	44
4.5	Moments d'ordre supérieur	45
4.6	Médiane et écart interquartile	48
4.7	Espaces $\mathcal{L}_p$ et L_p	49
4.8	Remarques bibliographiques	52
5	Familles de lois discrètes	53
5.1	Bernoulli et binomiale	53
5.2	Poisson	54
5.3	Géométrie	57
6	Caractérisations des lois de probabilité discrètes	59
6.1	Motivation	59
6.2	Fonction génératrice de probabilité	60
6.3	Formule d'inversion	61
6.4	Sommes de variables aléatoires indépendantes et fonctions génératrices de probabilité	63
6.5	Régularité et intégrabilité	65
6.6	FGP pour les lois jointes {#sec-multivariate=pgfs}	65
6.7	Lois composées	65
7	Lois produit	67
7.1	σ -algèbres produit	67
7.2	Mesures produit	68
7.3	Théorème de Tonelli-Fubini	69
7.4	Lois jointes, indépendance et lois produit	70

TABLE DES MATIÈRES

7.5	Indépendance de collections de σ -algèbres	71
7.6	Espaces produits infinis	71
7.7	Remarques bibliographiques	72
8	Indépendance et espaces produits	73
8.1	Feuille de route	73
8.2	Indépendance de deux événements	74
	Indépendance de deux événements	74
8.3	Indépendance de σ -algèbres et de variables aléatoires	74
	Indépendance de σ -algèbres	74
9	Lois de probabilité absolument continues	77
9.1	Densités et continuité absolue	77
9.2	Loi exponentielle	78
9.3	Loi gamma	79
9.4	Lois gaussiennes univariées	80
9.5	Fonctions de répartition et continuité absolue	81
9.6	Calcul de la densité d'une loi image	82
9.7	Application : calcul gamma-bêta	85
9.8	Remarques bibliographiques	86
10	Conditionnement discret	87
10.1	Feuille de route	87
10.2	Conditionnement par rapport à un événement	87
10.3	Formule de Bayes	89
10.4	Espérance conditionnelle par rapport à une σ -algèbre discrète	89
10.5	Espérance conditionnelle comme prédiction	91
10.6	Propriétés de l'espérance conditionnelle	92
10.7	Application : processus de Galton-Watson I	92
11	Conditionnement	95
11.1	Définition de l'espérance conditionnelle	95
11.2	Espérance conditionnelle dans $\mathcal{L}_2(\Omega, \mathcal{F}, P)$	98
11.3	Espérance conditionnelle dans $\mathcal{L}_1(\Omega, \mathcal{F}, P)$	101
11.4	Propriétés de l'espérance conditionnelle (générale)	103
11.5	Théorèmes de convergence conditionnelle	104
	Convergence dominée	105
	Inégalité de Jensen	105
	Indépendance	106
11.6	Lois conditionnelles	106
	Cas simple : conditionnement par rapport à une tribu discrète	106
	Obstacles	107
	Cadre des densités jointes	108
	Probabilités conditionnelles régulières, noyaux	110

TABLE DES MATIÈRES

	Noyau de probabilité conditionnelle	II0
	Probabilité conditionnelle régulière	II0
	Existence de lois conditionnelles régulières lorsque $\Omega = \mathbb{R}$	III
II.7	Inégalités d'Efron-Stein-Steele	II3
II.8	Inégalités des différences bornées	II5
	Inégalités des différences bornées	II6
II.9	Remarques bibliographiques	II7
12	Caractérisations des lois de probabilité	119
12.1	Motivation	119
12.2	Transformée de Laplace	120
	Définition et propriétés élémentaires	120
	Injectivité des transformées de Laplace et formule d'inversion	121
	Régularité de la transformée de Laplace et intégrabilité	123
12.3	Fonctions caractéristiques et transformées de Fourier	123
	Fonction caractéristique	124
	Fonction caractéristique d'une loi gaussienne univariée	125
	Sommes de variables aléatoires indépendantes et convolutions	126
	Théorème d'injectivité et formule d'inversion	128
	Dérivabilité et intégrabilité	131
	Autre application : comprendre la loi de Cauchy	133
12.4	Remarques bibliographiques	134
13	Fonctions quantiles	137
13.1	Définition	137
13.2	Fonctions quantiles et simulation stochastique	138
13.3	Statistiques d'ordre	141
13.4	Remarques bibliographiques	141
14	Convergences I : presque sûre, L_2, L_1, en probabilité	143
14.1	Motivations	143
14.2	Convergence presque sûre	143
14.3	Convergence en L_p	144
14.4	Convergence en probabilité	145
14.5	Loi faible des grands nombres	147
14.6	Loi forte des grands nombres	148
14.7	Inégalités exponentielles	154
	Lemme de Hoeffding	154
14.8	Remarques bibliographiques	157
15	Convergence en loi	159
15.1	Motivation	159
15.2	Convergence faible, convergence vague	160
15.3	Convergence en loi	160

TABLE DES MATIÈRES

15.4	Théorème de Portmanteau	161
15.5	Théorème de continuité de Lévy	164
15.6	Affiner le théorème de continuité	165
15.7	Relations entre convergences	168
15.8	Théorème central limite	169
15.9	Dispositif de Cramér-Wold	169
15.10	Convergence faible et transformations	170
15.11	Remarques bibliographiques	170
16	Vecteurs gaussiens	173
16.1	Loi gaussienne univariée	173
16.2	Vecteurs gaussiens	176
16.3	Convergence des vecteurs gaussiens	181
16.4	Conditionnement gaussien	182
16.5	À propos des lois Gamma	186
16.6	Normes de vecteurs gaussiens centrés	188
16.7	Norme de vecteurs gaussiens non centrés	188
16.8	Théorème de Cochran et conséquences	190
16.9	Concentration gaussienne	191
16.10	Remarques bibliographiques	193
Annexes		195

Mise en route



2026-06-13

Un court cours de licence sur la théorie des probabilités dans un cursus de mathématiques appliquées

Ce cours de *Probabilités* fait partie intégrante du [Master ISIFAR](#), une formation en statistique, finance mathématique et informatique à l'[Université Paris Cité](#). Il est lié à d'autres cours du même cursus.

1. [Statistique M1](#)
2. [Mathématiques financières M1](#)
3. [Mathématiques financières M2](#)
4. [Apprentissage statistique M2](#)

Cette liste n'est pas exhaustive.

Ce cours est orienté vers les applications. Nous empruntons des exemples et des applications de la théorie des probabilités à la statistique, à l'informatique et à l'ingénierie des données massives. Comme le temps est limité, nous passons sous silence de nombreux points techniques. Nous supposons acquis des résultats clés de l'intégration et de la théorie de la mesure. Néanmoins, nous nous appuyons sur des définitions rigoureuses et énonçons et utilisons les théorèmes de manière cohérente.

-  [Page d'accueil du cours.](#)
-  [Page Moodle du cours.](#)

Prérequis

Ce cours s'appuie sur deux cours de niveau licence :

- [Probabilités Licence 3](#)
- [Intégration](#)

Chapitre 1

Introduction

Dans ce chapitre, nous passons en revue les définitions de base de la théorie des probabilités en partant d'un simple problème de modélisation issu de l'informatique. Les notions seront définies formellement dans les chapitres suivants. Ce contexte simple nous permet d'effectuer des calculs et d'esquisser le type de résultats que nous rechercherons au cours du semestre : moments, majorations de queue, loi des grands nombres, théorèmes centraux limites, et éventuellement d'autres formes de convergence faible.

1.1 Hachage

Le hachage est une technique de calcul utilisée dans presque tous les domaines de l'informatique, des bases de données aux compilateurs en passant par les entrepôts de données (big data). Tout ouvrage sur les algorithmes contient une discussion sur le hachage; voir par exemple [Introduction to Hashing by Jeff Erickson](#).

Dans des conditions idéalisées, hacher n éléments vers m valeurs consiste à appliquer une fonction choisie uniformément au hasard parmi les m^n fonctions de $1, \dots, n$ vers $1, \dots, m$. Les performances d'une méthode de hachage (combien de cases faut-il examiner lors d'une recherche ?) dépendent des propriétés typiques d'une telle fonction aléatoire.

Il est commode de penser aux valeurs dans $1, \dots, m$ comme des urnes numérotées et aux éléments comme n boules numérotées. Choisir une fonction aléatoire revient à lancer indépendamment les n boules dans les m urnes. La probabilité qu'une boule donnée tombe dans une urne donnée est $1/m$.

Les questions portant sur les fonctions aléatoires peuvent être reformulées.

- Combien d'urnes vides en moyenne ?
- Quelle est la loi du nombre d'urnes vides ?
- Combien d'urnes contiennent r boules ?
- Quel est le nombre maximal de boules dans une seule urne ?

Consultez <http://stephane-v-boucheron.fr/post/2019-09-02-idealizedhashing/> et téléchargez le notebook qui s'y trouve.

Ce modèle jouet mais utile est l'occasion de rappeler les notions de base de la théorie des probabilités.

TABLE 1.1

index	1	2	3	4	5	6	7	8	9	10
position	2	3	1	2	4	4	2	3	2	5

Dans la suite, nous appelons ce cadre l'expérience des *allocations aléatoires*.

Dans Table 1.1, la ligne ω représente le résultat d'une allocation aléatoire avec $n = 10$, $m = 5$: $\omega_4 = 2$, $\omega_5 = 4$, ...

1.2 Un espace probabilisé

L'ensemble des issues est appelé l'*univers*. Dans le cadre des allocations aléatoires, c'est l'ensemble des suites de longueur n à valeurs dans $1, \dots, m$. C'est aussi une fonction de $\{1, \dots, n\}$ vers $\{1, \dots, m\}$. Nous notons une issue générique par ω . Le i^{e} élément de ω est noté ω_i . Cet univers est noté Ω ; ici il est fini, de cardinal m^n .

Dans ce cadre simple, la loi uniforme sur l'univers attribue à chaque sous-ensemble A de Ω la probabilité $|A|/|\Omega|$. Lorsque l'univers est fini ou dénombrable, tous les sous-ensembles de l'univers sont des *événements*; attribuer une probabilité à tout sous-ensemble de l'univers ne pose pas de difficulté.

Rappelons qu'une *loi de probabilité* P associe à une collection $\mathcal{F}$ de sous-ensembles de l'univers ($\mathcal{F} \subseteq 2^\Omega$) des valeurs dans $[0, 1]$ et satisfait :

1. $P(\emptyset) = 0$
2. $P(\Omega) = 1$
3. pour toute collection dénombrable d'événements deux à deux disjoints $A_1, A_2, \dots, A_n, \dots$, $P(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} P(A_n)$

Voir Section 2.3.

Il en découle que $P(A_1 \cup A_2 \cup \dots \cup A_k) = \sum_{i=1}^k P(A_i)$ pour toute collection finie de sous-ensembles deux à deux disjoints $A_1, \dots, A_k$.

Pour que le domaine de P soit bien défini, la collection de sous-ensembles $\mathcal{F}$ doit être stable par unions dénombrables, intersections dénombrables et passage au complémentaire, et contenir l'ensemble vide $\emptyset$ et l'univers Ω . En d'autres termes, elle doit être une *σ -algèbre*, voir Section 2.2.

Notez que d'autres lois de probabilité ont du sens sur cet univers simple. Voir par exemple le scénario des *allocations équilibrées*.

Dans le scénario des allocations équilibrées, les fonctions aléatoires de $1, \dots, n$ vers $1, \dots, m$ sont construites séquentiellement. Nous construisons d'abord ω_1 en tirant un nombre uniformément au hasard dans $1, \dots, n$. Supposons maintenant que nous ayons construit $\omega_1, \dots, \omega_i$ pour un certain $i < n$. Pour déterminer ω_{i+1} , nous tirons uniformément au hasard deux nombres dans $1, \dots, n$, disons j et k . Nous calculons

$$c_j = \left| \{ \ell : 1 \leq \ell \leq i, \omega_\ell = j \} \right| \quad \text{et} \quad c_k = \left| \{ \ell : 1 \leq \ell \leq i, \omega_\ell = k \} \right|.$$

Si $c_j < c_k$, $\omega_{i+1} = j$, sinon $\omega_{i+1} = k$.

Cette construction itérative définit une loi de probabilité (unique) sur $\{1, \dots, m\}^n$ qui diffère de la loi uniforme. Il n'est pas trivial de montrer qu'elle réalise une garantie d'équilibrage non triviale pour la taille des préimages induites par ω .

1.3 Variables aléatoires et indépendance

Considérons les fonctions à valeurs réelles de Ω vers $\mathbb{R}$ définies par :

$$X_{i,j}(\omega) = \begin{cases} 1 & \text{if } \omega_i = j \\ 0 & \text{otherwise.} \end{cases}$$

Cette fonction est un cas particulier de *variable aléatoire*, voir Section 2.5.

Dans l'exemple jouet décrit dans Tableau 1.1, nous avons $X_{4,1}(\omega) = 1$, $X_{5,1}(\omega) = 0$, ...

Notez que la définition de la variable aléatoire n'a rien à voir avec la loi de probabilité que nous avons considérée jusqu'ici. Il n'y a rien d'aléatoire dans une variable aléatoire. De plus, une variable aléatoire n'est pas une variable, c'est une fonction. Vous pouvez questionner cette terminologie, mais elle est consacrée par la tradition.

Dans l'espace probabilisé $(\Omega, 2^\Omega, \Pr)$, la loi de la variable aléatoire $X_{i,j}$ est une loi *de Bernoulli* de paramètre $1/m$.

$$\Pr \{X_{i,j} = 1\} = \frac{1}{m} \quad \Pr \{X_{i,j} = 0\} = 1 - \frac{1}{m},$$

voir Section 5.1 pour plus de détails sur les lois de Bernoulli. Cela vient de

$$\Pr \{\omega : X_{i,j}(\omega) = 1\} = \frac{|\{\omega : X_{i,j}(\omega) = 1\}|}{m^n} = \frac{m^{n-1}}{m^n} = \frac{1}{m}.$$

Rappelons que $\Pr \{X_{i,j} = 1\}$ est une abréviation pour $\Pr \{\omega : X_{i,j}(\omega) = 1\}$.

Pour un moment, nous fixons un $j \in \{1, \dots, m\}$ et considérons la collection de variables aléatoires $(X_{i,j})_{i \leq n}$.

Pour chaque i , nous pouvons définir des événements (sous-ensembles de Ω) à partir de la valeur de $X_{i,j}$:

$$\begin{aligned} &\{\omega : X_{i,j}(\omega) = 1\} \\ &\{\omega : X_{i,j}(\omega) = 0\} \end{aligned}$$

et, avec Ω et $\emptyset$, ils forment la collection $\sigma(X_{i,j})$ d'événements définissables à partir de $X_{i,j}$.

Rappelons la définition d'*événements indépendants*, ou plutôt la définition d'une *collection d'événements indépendants*.

TABLE 1.2

Occupancy score	1	2	3	4	5
Number of bins	1	4	2	2	1
Occupancy scores					

Une collection d'événements $E_1, E_2, \dots, E_k$ de $(\Omega, 2^\Omega)$ est indépendante au sens de Pr si, pour tout $I \subseteq \{1, \dots, n\}$,

$$\Pr \left\{ \bigcap_{i \in I} E_i \right\} = \prod_{i \in I} \Pr \{E_i\}$$

On peut vérifier que, pour chaque j fixé, $(X_{i,j})_{i \leq n}$ est une *collection de variables aléatoires indépendantes* sous Pr. Par cela, nous entendons que toute collection $E_1, E_2, \dots, E_n$ d'événements où $E_i \in \sigma(X_{i,j})$ pour chaque $i \in \{1, \dots, n\}$ est une collection d'événements indépendants sous Pr.

La notion d'*indépendance* est une pierre angulaire de la théorie des probabilités, voir le chapitre Chapitre 8.

Concrètement, cela signifie que pour toute suite $b_1, \dots, b_n \in \{0, 1\}^n$ (une issue possible de la suite de variables aléatoires $X_{1,j}, X_{2,j}, \dots, X_{n,j}$), nous avons

$$\begin{aligned} \Pr \left\{ \bigwedge_{i=1}^n X_{i,j}(\omega) = b_i \right\} &= \prod_{i=1}^n \Pr \left\{ X_{i,j}(\omega) = b_i \right\} \\ &= \prod_{i=1}^n \left(\frac{1}{m} \right)^{b_i} \left(1 - \frac{1}{m} \right)^{1-b_i} \\ &= \left(\frac{1}{m} \right)^{\sum_{i=1}^n b_i} \left(1 - \frac{1}{m} \right)^{n - \sum_{i=1}^n b_i}. \end{aligned}$$

Observez que l'issue de la suite $X_{i,j}$ pour $i \in 1, \dots, n$ vaut $b_1, \dots, b_n$ seulement si $\sum_{i=1}^n b_i = Y_j$. Cela simplifie grandement les calculs.

Nous nous intéressons au nombre d'éléments de $1, \dots, n$ qui sont envoyés (alloués) vers j par la fonction aléatoire ω . Définissons

$$Y_j(\omega) = \sum_{i=1}^n X_{i,j}(\omega).$$

Dans l'exemple jouet décrit dans Tableau 1.1, $Y_3(\omega) = 4$ tandis que $Y_5(\omega) = 1$ et $Y_4(\omega) = 0$:

Dans l'espace probabilisé $(\Omega, 2^\Omega, \Pr)$, la variable aléatoire Y_j suit une loi binomiale, comme somme de variables aléatoires de Bernoulli indépendantes et de même loi, voir Section 5.1.

$$\Pr \{Y_j = r\} = \binom{n}{r} p^r (1-p)^{n-r} \quad \text{with } p = \frac{1}{m}$$

pour $r \in 0, \dots, n$.

En effet, rappelons

$$\begin{aligned}
 \Pr\{Y_j = r\} &= \sum_{\omega: Y_j(\omega)=r} \Pr\{\omega\} \\
 &= \sum_{\omega: Y_j(\omega)=r} \left(\frac{1}{m}\right)^r \left(1 - \frac{1}{m}\right)^{n-r} \\
 &= \left|\left\{\omega : \omega \in \Omega, Y_j(\omega) = r\right\}\right| \times \left(\frac{1}{m}\right)^r \left(1 - \frac{1}{m}\right)^{n-r} \\
 &= \binom{n}{r} \left(\frac{1}{m}\right)^r \left(1 - \frac{1}{m}\right)^{n-r}.
 \end{aligned}$$

Pour n et m grands, cette loi binomiale tend à se concentrer autour de sa valeur moyenne ou *espérance*

$$\mathbb{E}Y_j = \sum_{r=0}^n r \times \Pr\{Y_j = r\} = \frac{n}{m}.$$

Voir Chapitre 3 pour une approche systématique de l'espérance, de la variance et des moments d'ordre supérieur, fondée sur la théorie de l'intégration.

Le dernier chapitre **sec-chapConcentration** est consacré au développement de *majorations de queue* pour des variables aléatoires comme Y_j qui sont des *fonctions lisses de variables aléatoires indépendantes*.

Pour l'instant, rappelons que sur un espace probabilisé dénombrable, l'espérance d'une variable aléatoire Z peut être définie par

$$\mathbb{E}Z = \sum_{\omega \in \Omega} \Pr\{\omega\} \times Z(\omega)$$

pourvu que la série soit absolument convergente.

Cela est illustré par Figure 1.1. En principe, une variable aléatoire binomiale de paramètres $n = 5000$ et $p = .001$ peut prendre toute valeur entre 0 et 5000. Cependant, la plus grande partie (plus de 95 %) de la masse de probabilité est supportée par $\{1, \dots, 10\}$.

1.4 Convergences

Si nous faisons tendre n et m vers l'infini tandis que n/m tend vers $c > 0$, nous observons que, pour chaque $r \geq 0$ fixé, la suite $\Pr\{Y_j = r\} = \binom{n}{r} (1/m)^r (1 - 1/m)^{n-r}$ tend vers

$$e^{-c} \frac{c^r}{r!}$$

qui est la probabilité qu'une variable aléatoire de Poisson d'espérance c prenne la valeur r (voir Section 5.2 pour plus de détails sur les lois de Poisson).




FIGURE 1.1 : Probability mass function of Binomial(5000,0.001)

C'est un cas de la *loi des événements rares*, un cas particulier de *convergence en loi*, voir Chapitre 15.

La possibilité d'approcher une loi de Poisson à l'aide d'une loi binomiale appropriée est illustrée dans Figure 1.2. La différence entre les fonctions de masse des lois binomiales de paramètres $n = 250, m = 0.02$ et $n = 2500, m = 0.002$ et la loi de Poisson de paramètre 5 est faible. Si nous choisissons les paramètres $n = 2500, m = 0.002$, la différence entre binomiale et Poisson est à peine visible.

La proximité entre Binomial($n, \lambda/n$) et Poisson(λ) peut être quantifiée de différentes manières. Une approche simple consiste à calculer

$$\sum_{x \in \mathbb{N}} |p_{n, \lambda/n}(x) - q_{\lambda}(x)|$$

où $p_{n, \lambda/n}$ (resp. q_{λ}) désigne la loi binomiale (resp. de Poisson). Cette quantité est appelée la distance en variation totale entre les deux lois de probabilité. Une définition générale est fournie dans Chapitre 15. Dans Figure 1.3, cette distance entre la loi binomiale de paramètres $n, 5/n$ et Poisson(5) est tracée en fonction de n (attention aux échelles logarithmiques). Ce graphique suggère que la distance en variation totale décroît comme $1/n$. Cela est vérifié dans Chapitre 15.

Dans l'espace probabilisé $(\Omega, 2^{\Omega}, \Pr)$, les variables aléatoires $Y_j, Y_{j'}, j \neq j'$, ne sont pas indépendantes. Pour montrer que $Y_j, Y_{j'}, j \neq j'$, ne sont pas indépendantes, il suffit de vérifier que deux événements $E_j, E_{j'}$ ne sont pas indépendants, avec $\omega \in E_j$ fonction de Y_j et $\omega \in E_{j'}$ fonction de $Y_{j'}$ (plus tard, nous dirons brièvement $E_j \in \sigma(X_j)$ ou que E_j est Y_j -mesurable). Choisissons $E_j = \{\omega : Y_j(\omega) = r\}$ et $E_{j'} = \{\omega : Y_{j'}(\omega) = r\}$.




FIGURE 1.2 : Probability mass functions of $\text{Binomial}(250, 0.02)$ (left), $\text{Binomial}(2500, 0.002)$ (middle) and $\text{Poisson}(5)$ (right)




FIGURE 1.3 : Law of rare events : distance between $\text{Binomial}(n, 5/n)$ and $\text{Poisson}(5)$ as a function of n

$\$K_{\{n,1\}}\$$	$\$K_{\{n,2\}}\$$	$\$K_{\{n,4\}}\$$
2	2	1

$$\Pr(E_j) = \binom{n}{r} \left(\frac{1}{m}\right)^r \left(1 - \frac{1}{m}\right)^{n-r}$$

$$\Pr(E_j \cap E_{j'}) = \binom{n}{r} \times \binom{n-r}{r} \left(\frac{1}{m}\right)^{2r} \left(1 - \frac{2}{m}\right)^{n-2r}$$

$$\frac{\Pr(E_j \cap E_{j'})}{\Pr(E_j) \times \Pr(E_{j'})} = \frac{\left(1 - \frac{2}{m}\right)^{n-2r} ((n-r)!)^2}{\left(1 - \frac{1}{m}\right)^{2n-2r} n!(n-2r)!} \neq 1.$$

Par conséquent, si nous définissons

$$K_{n,r}(\omega) = \sum_{j=1}^m \mathbb{I}_{Y_j(\omega)=r}$$

comme le nombre d'éléments de $1, \dots, m$ qui apparaissent exactement r fois dans ω , la variable aléatoire $K_{n,r}$ n'est pas décrite comme une somme de variables aléatoires indépendantes. Néanmoins, il est possible d'obtenir beaucoup d'informations sur ses moments et sa loi. Si nous faisons à nouveau tendre n et m vers l'infini tandis que n/m tend vers $c > 0$, nous observons que la loi de $K_{n,r}/m$ tend à se concentrer autour de $e^{-c} \frac{c^r}{r!}$. C'est un exemple de *convergence en probabilité*, voir Chapitre 14.

Maintenant, si nous considérons la suite de variables aléatoires recentrées et renormalisées $(K_{n,r} - \mathbb{E}K_{n,r})/\sqrt{\text{var}(K_{n,r})}$, nous observons que sa *fonction de répartition* (voir Section 2.7) converge ponctuellement vers la fonction de répartition de la loi gaussienne.

1.5 Synthèse

Dans ce chapitre, nous avons étudié un modèle stochastique jouet : les *allocations aléatoires*. Ce modèle jouet était motivé par l'analyse du hachage, une technique largement utilisée en informatique. Pour mener cette analyse, nous avons introduit des notations et des notions de théorie des probabilités :

- Univers,
- Événements,
- σ -algèbres,
- Lois de probabilité,
- Préimages,
- Variables aléatoires,
- Espérance,
- Variance,
- Indépendance d'événements,

- Indépendance de variables aléatoires,
- Loi binomiale,
- Loi de Poisson.

Par des simulations numériques, nous avons pris conscience de plusieurs phénomènes importants :

- Loi des événements rares : approximation de la loi de Poisson par certaines lois binomiales.
- Loi des grands nombres pour des sommes normalisées de variables aléatoires de même loi qui ne sont pas indépendantes.
- Théorèmes centraux limites pour des sommes normalisées et recentrées de variables aléatoires de même loi qui ne sont pas indépendantes.

À ce stade, notre approche élémentaire ne nous a pas fourni les notions et outils qui rendent possible l'analyse rigoureuse de ces phénomènes.

Chapitre 2

Un minimum de théorie de la mesure

2.1 Feuille de route

Pour faire de la modélisation stochastique de manière confortable, il faut des fondements et une notation cohérents. Dans ce chapitre, nous posons les bases du développement à venir. La théorie des probabilités est née de l'interaction entre la combinatoire et les jeux de hasard (XVIIe siècle). À cette époque, l'ensemble des issues était fini, et il était légitime de penser que tout ensemble d'issues avait une probabilité bien définie. Lorsque les mathématiciens ont commencé à faire de la modélisation stochastique dans différentes branches des sciences (astronomie, thermodynamique, génétique, ...), ils ont dû traiter des ensembles d'issues non dénombrables. Concevoir une définition rigoureuse de ce qu'est une loi de probabilité a pris du temps. Les progrès de l'intégration et de la théorie de la mesure au cours du XIXe siècle et des premières décennies du XXe siècle ont conduit aux fondements modernes de la théorie des probabilités, fondés sur la théorie de la mesure.

2.2 Univers, partie et σ -algèbres

Un *univers* est un ensemble (d'*issues* possibles) que nous décidons d'appeler univers. L'univers est souvent noté Ω . Les éléments génériques de Ω (les issues) sont notés ω .

Exemple 2.1. Si l'on considère le lancer d'un dé comme un phénomène aléatoire, l'ensemble des issues est l'ensemble des étiquettes sur les faces $\Omega = \{1, 2, 3, 4, 5, 6\}$. Si l'on lance deux dés, l'ensemble des issues est constitué de couples d'étiquettes $\Omega' = \{(1, 1), (1, 2), (1, 3), \dots, (6, 6)\} = \Omega^2$.

Exemple 2.2. Dans le problème idéalisé de hachage (Section 1.1), l'univers est l'ensemble des fonctions de $1, \dots, n$ vers $1, \dots, m$. La taille de l'univers est m^n .

Un univers peut être fini ou dénombrable, ou non. Si l'univers est dénombrable, tous ses sous-ensembles peuvent être appelés *événements*. Des probabilités sont attribuées aux

événements. Si l'univers est dénombrable, il est possible d'attribuer une probabilité à chacun de ses sous-ensembles. Lorsque l'univers n'est pas dénombrable (par exemple $\mathbb{R}$), attribuer une probabilité à tous les sous-ensembles n'est pas possible. Il faut restreindre la collection de sous-ensembles afin d'attribuer des probabilités aux éléments de la collection de manière cohérente.

Dans la suite, 2^Ω désigne la collection de tous les sous-ensembles de Ω (la partie de Ω). Une collection raisonnable d'événements doit être une σ -algèbre.

Définition 2.1 (σ -algèbre"). Étant donné un ensemble Ω , une collection $\mathcal{G}$ de sous-ensembles de Ω ($\mathcal{G} \subseteq 2^\Omega$) est appelée une σ -algèbre (une sigma-algèbre) si et seulement si

- $\mathcal{G}$ est stable par union dénombrable
- $\emptyset \in \mathcal{G}$
- $\mathcal{G}$ est stable par passage au complémentaire ($A \in \mathcal{G} \Rightarrow A^c = \Omega \setminus A \in \mathcal{G}$)

Quelle est la plus petite σ -algèbre (au sens de l'inclusion) qui contient le sous-ensemble A de Ω ?

La proposition suivante montre que les σ -algèbres sont stables sous les opérations ensemblistes dénombrables. On aurait pu remplacer l'union dénombrable par l'intersection dénombrable dans la définition des σ -algèbres. C'est une conséquence des lois de De Morgan :

$$(A \cup B)^c = A^c \cap B^c \quad \text{and} \quad (A \cap B)^c = A^c \cup B^c$$

Une σ -algèbre de sous-ensembles est stable par intersections dénombrables.

Preuve. Pour $A \subseteq \Omega$, posons $A^c = \Omega \setminus A$. Soient $A_1, \dots, A_n, \dots$ des éléments de la σ -algèbre $\mathcal{G}$ de sous-ensembles de Ω . Pour chaque n , $A_n^c \in \mathcal{G}$, par définition de σ -algèbre,

$$\begin{aligned} \bigcap_n A_n &= \left(\left(\bigcap_n A_n \right)^c \right)^c \\ &= \left(\bigcup_n A_n^c \right)^c \quad \text{De Morgan.} \end{aligned}$$

Par définition d'une σ -algèbre, $\bigcup_n A_n^c \in \mathcal{G}$, et pour la même raison, $\left(\bigcup_n A_n^c \right)^c \in \mathcal{G}$. $\square$

La proposition suivante nous permet de parler de la plus petite σ -algèbre contenant une collection de sous-ensembles; cela conduit à la notion de σ -algèbre engendrée.

L'intersection de deux σ -algèbres de sous-ensembles de Ω est une σ -algèbre de sous-ensembles de Ω .

Preuve. Soient $\mathcal{G}$ et $\mathcal{G}'$ deux σ -algèbres de sous-ensembles de Ω . L'intersection des deux σ -algèbres est

$$\left\{ A : A \subseteq \Omega, A \in \mathcal{G}, A \in \mathcal{G}' \right\}.$$

$\square$

En effet, l'intersection d'une collection éventuellement non dénombrable de σ -algèbres est une σ -algèbre (vérifier cela). Grâce à cette propriété, la notion de σ -algèbre engendrée par une collection de sous-ensembles est bien fondée.

σ -algèbre engendrée

Étant donné une collection $\mathcal{C}$ de sous-ensembles de Ω , il existe une *plus petite σ -algèbre unique* contenant tous les sous-ensembles de $\mathcal{C}$; elle est appelée la σ -algèbre engendrée par $\mathcal{H}$ et notée $\sigma(\mathcal{C})$.

Exercice 2.1. Vérifier la proposition précédente.

Exemple 2.3. Considérons le lancer d'un dé, $\Omega = \{1, \dots, 6\}$, et posons

$$\mathcal{H} = \left\{ \{1, 3, 5\} \right\}.$$

Il s'agit d'une collection constituée d'un seul événement (l'issue est impaire). L'algèbre engendrée par $\mathcal{H}$ est

$$\sigma(\mathcal{H}) = \left\{ \{1, 3, 5\}, \{2, 4, 6\}, \emptyset, \Omega \right\}.$$

Deux types de σ -algèbres jouent un rôle central dans un cours de probabilités de base :

1. la partie des ensembles dénombrables ou finis.
2. les σ -algèbres boréliennes des espaces topologiques.

Définition 2.2 (σ -algèbre borélienne). La σ -algèbre borélienne sur $\mathbb{R}$ est la σ -algèbre engendrée par les ensembles *ouverts*. Elle est notée $\mathcal{B}(\mathbb{R})$.

Cette définition s'applique à tout espace topologique. Rappelons qu'une topologie sur un ensemble E est définie par une collection $\mathcal{E}$ d'*ensembles ouverts*. Cette collection est caractérisée par les propriétés suivantes :

- $\emptyset, E \in \mathcal{E}$
- Une union (*éventuellement non dénombrable*) d'éléments de $\mathcal{E}$ (ensembles ouverts) appartient à $\mathcal{E}$ (est un ensemble ouvert)
- Une intersection finie d'ensembles ouverts est un ensemble ouvert.

Dans la topologie usuelle sur $\mathbb{R}$, un ensemble A est ouvert si pour tout $x \in A$, il existe un $r > 0$ tel que $]x - r, x + r[\subseteq A$. Tout intervalle de la forme $]a, b[$ est ouvert (ce sont les intervalles ouverts).

Cette topologie se généralise à toute dimension finie $\mathbb{R}^d$.

Exercice 2.2. Considérer la σ -algèbre engendrée par les intervalles ouverts de $\mathbb{R}$. S'agit-il de la σ -algèbre borélienne ?

Exercice 2.3. Considérer la σ -algèbre engendrée par les intervalles ouverts de $\mathbb{R}$ à bornes rationnelles. S'agit-il de la σ -algèbre borélienne ?

Exercice 2.4. Considérer un espace métrique (E, d) quelconque. La métrique d définit une topologie sur E . La σ -algèbre borélienne sur (E, d) coïncide-t-elle avec la σ -algèbre engendrée par les boules ouvertes $B(x, r) = \{y : y \in E, d(x, y) < r\}$?

Nous sommes maintenant prêts à poser le cadre de la modélisation stochastique. Le terrain de jeu consiste toujours en un espace mesurable.

Définition 2.3 (Espace mesurable). Un univers Ω muni d'une σ -algèbre de sous-ensembles $\mathcal{F}$ est appelé un espace mesurable. Il est noté $(\Omega, \mathcal{F})$.

Exemple 2.4.

- Si Ω est un ensemble dénombrable ou fini, alors $(\Omega, 2^\Omega)$ est un espace mesurable.
- Si $\Omega = \mathbb{R}$, alors $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ est un espace mesurable.

Jusqu'ici, nous n'avons pas parlé de théorie des probabilités, mais nous sommes maintenant équipés pour définir des lois de probabilité et pour les manipuler.

2.3 Lois de probabilité

Une *loi de probabilité* associe une σ -algèbre à $[0, 1]$. C'est un cas particulier d'un concept plus général appelé *mesure*. Nous énonçons ou rappelons des notions importantes de la théorie de la mesure. L'idée clé qui sous-tend l'élaboration de la théorie de la mesure est que l'on doit s'abstenir d'essayer de mesurer *tous* les sous-ensembles d'un univers (sauf si cet univers est dénombrable). Les tentatives de mesurer tous les sous-ensembles de $\mathbb{R}$ conduisent à des paradoxes et sont de peu d'utilité pratique. La théorie de la mesure commence par reconnaître les propriétés souhaitables que toute mesure utile devrait posséder, puis elle construit des objets satisfaisant ces propriétés sur des σ -algèbres d'événements aussi larges que possible, par exemple sur les σ -algèbres boréliennes.

Cela motive la définition de la σ -additivité.

Définition 2.4 (σ -additivité). Étant donné Ω et $\mathcal{A} \subseteq 2^\Omega$, une fonction μ de $\mathcal{A}$ vers $[0, \infty)$ est dite σ -additive sur $\mathcal{A}$ si pour toute collection dénombrable de sous-ensembles deux à deux disjoints $(A_n)_{n \in \mathbb{N}} \in \mathcal{A}$, avec $\bigcup_n A_n \in \mathcal{A}$, on a

$$\mu\left(\bigcup_{n \in \mathbb{N}} A_n\right) = \sum_{n \in \mathbb{N}} \mu(A_n).$$

Notons que si $\mathcal{F}$ est une σ -algèbre, $\left(\bigcup_{n \in \mathbb{N}} A_n\right) \in \mathcal{F}$. La σ -additivité s'accorde bien avec les σ -algèbres, mais il est pertinent de définir la σ -additivité par rapport à des collections de sous-ensembles plus générales.

Proposition 2.1. *Étant donné Ω , une σ -algèbre $\mathcal{A} \subseteq 2^\Omega$, une fonction σ -additive μ de $\mathcal{A}$ vers $[0, \infty)$ satisfait*

a. *pour toute suite croissante $(A_n)_{n \in \mathbb{N}}$ d'éléments de $\mathcal{A}$*

$$\lim_n \mu(A_n) = \mu\left(\bigcup_n A_n\right)$$

b. *pour toute suite décroissante $(A_n)_{n \in \mathbb{N}}$ d'éléments de $\mathcal{A}$*

$$\lim_n \mu(A_n) = \mu\left(\bigcap_n A_n\right)$$

c.

$$\mu(\emptyset) = 0$$

Preuve. a.) Posons $B_1 = A_1$, et $B_{n+1} = A_{n+1} \setminus A_n$ pour chaque n ; alors $(B_n)_n$ est une suite d'éléments de $\mathcal{A}$ deux à deux disjoints. On a $\bigcup_n B_n = \bigcup_n A_n$ et, par σ -additivité, $\mu(\bigcup_n A_n) = \sum_n \mu(B_n)$

$$\sum_{n \leq m} \mu(B_n) = \mu\left(\bigcup_{n \leq m} B_n\right) = \mu(A_m)$$

D'où $\lim_{m \rightarrow \infty} \mu(A_m) = \sum_{n \in \mathbb{N}} \mu(B_n) = \mu\left(\bigcup_n A_n\right)$

b.) Le second énoncé se démontre de manière analogue.

c.) Soit $(A_n)_n$ telle que $A_n = \emptyset$ pour chaque n ; c'est une suite d'éléments de $\mathcal{A}$ deux à deux disjoints; par σ -additivité, on a

$$\sum_{n \in \mathbb{N}} \mu(\emptyset) = \mu(\emptyset)$$

ce qui implique $\mu(\emptyset) = 0$. □

Définition 2.5 (Mesure positive). Étant donné un espace mesurable $(\Omega, \mathcal{F})$, une fonction σ -additive μ de $\mathcal{F}$ vers $[0, \infty)$ est appelée une *mesure positive* sur $(\Omega, \mathcal{F})$. Le triplet $(\Omega, \mathcal{F}, \mu)$ est appelé un espace mesuré.

Par Proposition 2.1, pour toute mesure positive μ , on a $\mu(\emptyset) = 0$. Lorsque $\mu(\Omega)$ est fini, on dit que μ est une mesure positive *finie*.

Exercice 2.5. Soit $\Omega = \{0, 1\}^*$ l'ensemble des suites infinies de 0 et 1 (indexées à partir de 1). Soit $\mathcal{F}_n \subseteq 2^\Omega$ la σ -algèbre engendrée par les événements de la forme suivante : $\{\omega : \omega \in \Omega, \omega_i = 1\}$ pour $1 \leq i \leq n$.

— Définir une fonction σ -additive sur $(\Omega, \mathcal{F}_n)$.

- Quelle est la σ -algèbre engendrée par $\cup_{n \geq 1} \mathcal{F}_n$?
- Peut-on définir une fonction σ -additive sur $(\Omega, \sigma(\cup_{n \geq 1} \mathcal{F}_n))$?

Une mesure positive μ n'est pas nécessairement une loi de probabilité. Par exemple, la *mesure de comptage* μ sur $\mathbb{N}$ satisfait $\mu(A) = |A|$ pour tout $A \subseteq \mathbb{N}$, donc on a $\mu(\mathbb{N}) = \infty$.

Définition 2.6 (Loi de probabilité). Étant donné un espace mesurable $(\Omega, \mathcal{F})$, une fonction μ de $\mathcal{F}$ vers $[0, \infty)$ est une loi de probabilité sur $(\Omega, \mathcal{F})$ si

1. μ est une mesure positive sur $(\Omega, \mathcal{F})$ et
2. $\mu(\Omega) = 1$.

Exercice 2.6. Si l'on pense que $(\mathbb{R}, 2^{\mathbb{R}})$ est un espace mesurable, définir une mesure σ -additive sur celui-ci. Essayer même de définir une mesure de probabilité.

Remarque 2.1. La notion de σ -additivité est strictement plus forte que l'additivité finie. En supposant l'*axiome du choix* (comme d'usage en analyse ou en probabilités), il existe une fonction μ qui associe à $2^{\mathbb{N}}$ des valeurs dans $[0, 1]$, qui est additive ($\mu(A \cup B) = \mu(A) + \mu(B)$) pour tous A, B tels que $A \cap B = \emptyset$, nulle sur tous les sous-ensembles finis de $\mathbb{N}$ et telle que $\mu(\mathbb{N}) = 1$. Une telle fonction n'est pas σ -additive.

2.4 Mesure de Lebesgue

Nous admettons l'existence de la mesure de Lebesgue. C'est le contenu du théorème suivant.

Théorème 2.1 (Existence de la mesure de Lebesgue). *Il existe une mesure σ -additive unique ℓ sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ telle que $\ell((a, b]) = b - a$ pour tous $a < b$ finis.*

Le théorème 2.1 est typique des énoncés de la théorie de la mesure. Il définit un objet complexe (une mesure) par sa trace sur une collection simple d'ensembles (les intervalles).

La démonstration de le théorème 2.1 peut être découpée en plusieurs étapes significatives. D'abord définir une fonction de longueur sur les intervalles. Montrer que cette fonction peut être prolongée en une fonction additive sur les unions finies, intersections finies et complémentaires d'intervalles. Puis vérifier que le prolongement est en fait σ -additif sur la fermeture des intervalles sous les opérations ensemblistes finies (qui n'est pas une σ -algèbre).

Une fois ce prolongement additif construit, utiliser le théorème de prolongement de Carathéodory ci-dessous pour prouver que la fonction de longueur peut être prolongée en une fonction σ -additive sur la σ -algèbre engendrée par les intervalles (la σ -algèbre borélienne).

Il reste alors à vérifier que le prolongement est unique. Cela peut se faire par un argument de classe engendrante, par exemple le *lemme des classes monotones* lemme 2.4.

Théorème 2.2 (Théorème de prolongement de Carathéodory). *Soit $\mathcal{A} \subseteq 2^\Omega$. Supposons que $\mathcal{A}$ contient $\emptyset, \Omega$, et est stable par unions finies et par passage au complémentaire. Supposons que $\rho : \mathcal{A} \rightarrow [0, \infty]$ est σ -additive sur $\mathcal{A}$. Alors il existe une mesure μ sur $\sigma(\mathcal{A})$ telle que $\mu(A) = \rho(A)$ pour tout $A \in \mathcal{A}$.*

Le théorème d'existence de la mesure de Lebesgue garantit que l'on peut définir la loi de probabilité uniforme sur un intervalle fini $[a, b]$. Si l'on note ℓ la mesure de Lebesgue, la loi de probabilité uniforme sur $[a, b]$ attribue la probabilité

$$P(A) = \frac{\ell(A)}{b - a} = \frac{\ell(A)}{\ell([a, b])}$$

à tout $A \in \mathcal{B}(\mathbb{R}) \cap [a, b]$.

La loi uniforme sur $([0, 1], \mathcal{B}([0, 1]))$ peut sembler une curiosité académique sans utilité pratique. Cette opinion superficielle doit être écartée. À l'aide d'un générateur pour la loi uniforme, il est possible de construire un générateur pour toute loi de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Cela peut se faire à l'aide d'un procédé appelé la *transformation quantile*. En ce sens, la loi uniforme est la mère de toutes les lois.

Une issue ω de la loi uniforme est un nombre réel. À quoi ressemble une issue typique ? Un nombre réel $\omega \in [0, 1]$ admet des développements binaires : $\omega = \sum_{i=1}^{\infty} b_i 2^{-i}$ avec $b_i \in \{0, 1\}$. Quelle est la probabilité qu'il existe un développement binaire unique ? D'abord, vérifier si cette probabilité est bien définie. En supposant que le développement binaire est unique, on dit que ω est *normal* si $\lim_n \frac{1}{n} \sum_{i=1}^n b_i(\omega) = 1/2$. La probabilité d'obtenir un nombre normal est-elle bien définie ? Si oui, la calculer.

Exercice 2.7. Vérifier que $\mathcal{B}(\mathbb{R}) \cap [a, b] = \{A \cap [a, b] : A \in \mathcal{B}(\mathbb{R})\}$ est la σ -algèbre engendrée par la trace de la topologie usuelle de $\mathbb{R}$ sur $[a, b]$.

Le théorème d'existence de Lebesgue peut être prolongé. En effet, toute définition raisonnable de la longueur d'un intervalle peut servir de point de départ.

Rappelons qu'une fonction réelle est CADLAG si elle est continue à droite partout, et possède des limites à gauche partout.

Le théorème suivant peut être établi d'une manière parallèle à la construction de la mesure de Lebesgue.

Théorème 2.3. *Toute fonction CADLAG non décroissante F sur $\mathbb{R}$ définit une mesure σ -additive μ sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ qui satisfait :*

$$\mu((a, b]) = F(b) - F(a)$$

On retrouve le théorème d'existence de Lebesgue en prenant $F(x) = x$.

Si l'on se restreint aux fonctions F qui satisfont $\lim_{x \rightarrow -\infty} F(x) = 0$ et $\lim_{x \rightarrow \infty} F(x) = 1$, le théorème Théorème 2.3 définit des lois de probabilité par leurs *fonctions de répartition* (plus de détails à ce sujet dans Section 2.7).

Exercice 2.8. Faut-il vraiment supposer que la fonction F possède des limites à gauche dans le théorème Théorème 2.3?

2.5 Fonctions mesurables et variables aléatoires

Jusqu'ici, nous n'avons parlé que de probabilités et de mesures d'ensembles (événements). Comme la modélisation stochastique est à la base de l'analyse quantitative, nous introduisons la notion de fonction mesurable. Cela nous permet de traiter des fonctions numériques qui associent des issues à $\mathbb{R}$ ou $\mathbb{R}^d$.

Toute fonction numérique n'est pas mesurable. Pour définir ce qu'on appelle une fonction mesurable, il faut la notion d'*image réciproque* ou de *préimage*.

Définition 2.7 (Préimage). Soit f une fonction de $\mathcal{X}$ vers $\mathcal{Y}$; on note f^{-1} la fonction qui associe à $2^{\mathcal{Y}}$ un élément de $2^{\mathcal{X}}$ définie par

$$f^{-1} : 2^{\mathcal{Y}} \rightarrow 2^{\mathcal{X}}$$

$$B \mapsto f^{-1}(B) = \{x : x \in \mathcal{X}, f(x) \in B\}.$$

L'ensemble $f^{-1}(B)$ est appelé la *préimage* ou l'*image réciproque* de B sous f .

Notons que f^{-1} ne désigne pas l'inverse de la fonction f , qui peut ne pas être injective. Dans ce cours, f^{-1} est une fonction d'ensembles de la partie du codomaine de f vers la partie du domaine de f . La fonction inverse, si elle existe (ou la fonction inverse généralisée), est notée $f^{\leftarrow}$. La fonction inverse, lorsqu'elle existe, associe $f(\mathcal{X}) \subseteq \mathcal{Y}$ à $\mathcal{X}$.

Exemple 2.5. Rappelons le cadre idéalisé du hachage de Section 1.1. Soit Ω l'ensemble des fonctions de $1, \dots, n$ vers $1, \dots, m$ (supposons $n \leq m$). Pour $\omega \in \Omega$ (ω est une fonction, mais c'est aussi une suite de longueur n à valeurs dans $1, \dots, m$), posons $f(\omega)$ égal au nombre de valeurs dans $1, \dots, m$ qui n'apparaissent pas dans ω (le nombre de cases vides dans l'allocation définie par ω). La fonction f est une fonction numérique qui associe à $\Omega = \{1, \dots, m\}^n$. Pour $B \in \mathbb{N}$, $f^{-1}(B)$ est le sous-ensemble des allocations qui ont k cases vides, $k \in B$.

L'opération de préimage s'accorde bien avec les opérations ensemblistes.

Les propriétés élémentaires des fonctions mesurables découlent des propriétés des images réciproques. L'image réciproque préserve les opérations ensemblistes.

Proposition 2.2. Soit $f : E \mapsto F$; pour $A, B, A_1, \dots, A_n, \dots \subseteq F$,

$$\begin{aligned}
f^{-1}(A \cup B) &= f^{-1}(A) \cup f^{-1}(B) \\
f^{-1}(A \cap B) &= f^{-1}(A) \cap f^{-1}(B) \\
f^{-1}(\cup_{n \in \mathbb{N}} A_n) &= \cup_{n \in \mathbb{N}} f^{-1}(A_n) \\
f^{-1}(\cap_{n \in \mathbb{N}} A_n) &= \cap_{n \in \mathbb{N}} f^{-1}(A_n) \\
f^{-1}(F \setminus A) &= f^{-1}(F) \setminus f^{-1}(A)
\end{aligned}$$

Exercice 2.9. Vérifier la proposition Proposition 2.2 de Section 2.7

Prendre les préimages des éléments d'une σ -algèbre définit une σ -algèbre.

Exercice 2.10. Soient $(\Omega, \mathcal{F})$ et $(\Omega', \mathcal{G})$ deux espaces mesurables. Soit f une application de Ω vers Ω' ; prouver que

$$\mathcal{H} = \{f^{-1}(B) : B \in \mathcal{G}\}$$

est une σ -algèbre de sous-ensembles de $f^{-1}(\Omega')$.

Définition 2.8 (Fonctions mesurables). Soient $(\Omega, \mathcal{F})$ et $(\Omega', \mathcal{G})$ deux espaces mesurables. Une fonction $f : \Omega \rightarrow \Omega'$ est dite $\mathcal{F}/\mathcal{G}$ -mesurable si et seulement si pour tout $B \in \mathcal{G}$, $f^{-1}(B) \in \mathcal{F}$.

Sous quelle condition sur $\mathcal{H}$ la fonction f est-elle $\mathcal{F}/\mathcal{G}$ -mesurable ?

Exemple 2.6. Rappelons le scénario idéalisé du hachage de Section 1.1.

Exercice 2.11. Vérifier que si Ω est un espace topologique et $\mathcal{F}$ la σ -algèbre borélienne associée, alors toute fonction continue de Ω vers $\mathbb{R}$ est mesurable.

Exercice 2.12. Si $\Omega = \mathbb{R}^d$ est muni de la σ -algèbre borélienne, s'agit-il de la plus petite σ -algèbre qui rend mesurables toutes les fonctions continues ?

Proposition 2.3. La limite ponctuelle de fonctions mesurables est une fonction mesurable : si $(f_n)_n$ est une suite de fonctions mesurables de $(\Omega, \mathcal{F})$ vers $(X, \mathcal{G})$, et $f_n \rightarrow f$ ponctuellement, alors f est une fonction mesurable.

Exercice 2.13. Démontrer la proposition Proposition 2.3

Proposition 2.4. *La somme de fonctions mesurables est une fonction mesurable : si f, g sont des fonctions mesurables de $(\Omega, \mathcal{F})$ vers $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, alors $af + bg$ est une fonction mesurable pour tous $a, b \in \mathbb{R}$.*

Exercice 2.14. Démontrer la proposition Proposition 2.4

Proposition 2.5. *La composition de fonctions mesurables est une fonction mesurable : si f est une fonction mesurable de $(\Omega, \mathcal{F})$ vers $(\mathcal{X}, \mathcal{G})$, et g est une fonction mesurable de $(\mathcal{X}, \mathcal{G})$ vers $(\mathcal{Y}, \mathcal{H})$, alors $g \circ f$ ($g \circ f(\omega) = g(f(\omega))$ pour tout ω) est une fonction mesurable de $(\Omega, \mathcal{F})$ vers $(\mathcal{Y}, \mathcal{H})$.*

Exercice 2.15. Démontrer la proposition Proposition 2.5

2.6 Le théorème des classes monotones

Le théorème (ou lemme) des classes monotones est un exemple puissant des arguments de classe engendrant qui peuvent servir à prouver que deux lois de probabilité, voire deux mesures σ -finies, sont égales.

Définition 2.9 (Classe π). Une collection $\mathcal{G}$ de sous-ensembles de Ω est dite être une classe π si :

- $\Omega \in \mathcal{G}$
- elle est stable / fermée par intersection finie

$$A, B \in \mathcal{G} \Rightarrow A \cap B \in \mathcal{G}.$$

Une σ -algèbre est une classe π , mais la réciproque est fausse.

Définition 2.10 (Classe monotone). Une collection $\mathcal{M}$ de sous-ensembles de Ω est dite être une classe monotone ou un système λ si elle satisfait les propriétés suivantes :

- $\Omega \in \mathcal{M}$
- Si $A, B \in \mathcal{M}$, et $A \subseteq B$, alors $B \setminus A \in \mathcal{M}$
- Si $A_n \in \mathcal{M}$ et $A_n \subseteq A_{n+1}$ pour tout $n \in \mathbb{N}$, alors $\lim_n A_n = \bigcup_{n \in \mathbb{N}} A_n \in \mathcal{M}$.

Une σ -algèbre est un système λ .

L'intersection d'une collection de systèmes λ est un système λ . Il est donc pertinent de parler de la plus petite classe λ contenant une collection d'ensembles.

La proposition facile suivante rend les systèmes λ très utiles lorsque l'on veut vérifier que deux lois de probabilité sont égales.

Proposition 2.6. *La classe d'ensembles sur laquelle deux lois de probabilité coïncident est un système λ .*

Preuve. Soit $(\Omega, \mathcal{F})$ un espace mesurable. Soient P, Q deux lois de probabilité sur $(\Omega, \mathcal{F})$. Posons $\mathcal{C} \subseteq \mathcal{F}$ définie par

$$\mathcal{C} = \left\{ A : A \in \mathcal{F}, P(A) = Q(A) \right\}.$$

Par la définition même des mesures, on a $P(\Omega) = Q(\Omega)$, donc $\Omega \in \mathcal{C}$.

Si $A \subseteq B$ appartiennent tous deux à $\mathcal{C}$, encore par la définition même des mesures,

$$P(B \setminus A) = P(B) - P(A) = Q(B) - Q(A) = Q(B \setminus A),$$

donc $B \setminus A \in \mathcal{C}$.

Soit $A_1 \subseteq A_2 \subseteq A_n \subseteq \dots$ une suite croissante d'éléments de $\mathcal{C}$; encore par la définition même des mesures,

$$P(\cup_n A_n) = \lim_n \uparrow P(A_n) = \lim_n \uparrow Q(A_n) = Q(\cup_n A_n).$$

Donc $\mathcal{C}$ est fermée par limites monotones. □

Exercice 2.16. Que se passe-t-il si l'on considère les collections d'ensembles mesurables sur lesquels deux mesures sont égales? Que se passe-t-il si l'on suppose que les deux mesures sont finies?

Définition 2.11 (Mesures σ -finies). Une mesure μ sur $(\Omega, \mathcal{F})$ est σ -finie si et seulement s'il existe $(A_n)_n$ avec $\Omega \subseteq \cup_n A_n$ et $\mu(A_n) < \infty$ pour chaque n .

Les mesures finies (ce qui inclut les mesures de probabilité) sont σ -finies. La mesure de Lebesgue est σ -finie. La mesure de comptage sur $\mathbb{R}$ n'est pas σ -finie.

Que se passe-t-il si l'on suppose seulement que les deux mesures sont σ -finies?

Théorème 2.4 (Lemme des classes monotones). *Si $\mathcal{A}$ est un système π dans Ω et $\mathcal{M}$ un système λ dans Ω tels que $\mathcal{A} \subseteq \mathcal{M}$, alors la σ -algèbre engendrée par $\mathcal{A}$, $\sigma(\mathcal{A})$, est la plus petite classe λ contenant $\mathcal{A}$:*

$$\sigma(\mathcal{A}) \subseteq \mathcal{M}.$$

Preuve. Soit $\mathcal{M}$ l'intersection de toutes les classes monotones qui contiennent le système π $\mathcal{A}$. Comme une σ -algèbre est une classe monotone (un système λ), on a $\mathcal{M} \subseteq \sigma(\mathcal{A})$; le seul point à vérifier est $\sigma(\mathcal{A}) \subseteq \mathcal{M}$. Il suffit de vérifier que $\mathcal{M}$ est bien une σ -algèbre.

Pour vérifier que $\mathcal{M}$ est une σ -algèbre, il suffit de vérifier qu'elle est stable par union finie, ou de façon équivalente par intersection finie.

Pour chaque $A \in \mathcal{A}$, posons $\mathcal{M}_A$ définie par

$$\mathcal{M}_A = \left\{ B : B \in \mathcal{M}, A \cap B \in \mathcal{M} \right\}.$$

Rappelons que $\mathcal{A}$ est un système π , et $\mathcal{A} \subseteq \mathcal{M}$; on a $\mathcal{A} \subseteq \mathcal{M}_A$. Pour montrer que $\mathcal{M} = \mathcal{M}_A$, il suffit de montrer que $\mathcal{M}_A$ est une classe monotone.

Si $(B_n)_n$ est une suite croissante d'éléments de $\mathcal{M}_A$, alors

$$(\cup_n B_n) \cap A = \cup_n \left(\underbrace{B_n \cap A}_{\in \mathcal{M}} \right),$$

le membre de droite appartient à $\mathcal{M}$ puisque $\mathcal{M}$ est monotone. Donc $\mathcal{M}_A$ est fermée par limite croissante monotone.

Pour vérifier la stabilité par complémentaire, soient $B \subseteq C$ avec $B, C \in \mathcal{M}_A$. Comme

$$A \cap (C \setminus B) = \left(\underbrace{A \cap C}_{\in \mathcal{M}} \right) \setminus \left(\underbrace{A \cap B}_{\in \mathcal{M}} \right)$$

la stabilité de $\mathcal{M}$ par complémentaire implique $A \cap (C \setminus B) \in \mathcal{M}$ et $C \setminus B \in \mathcal{M}_A$.

Maintenant, posons $\mathcal{M}^\circ$ définie par

$$\mathcal{M}^\circ = \left\{ A : A \in \mathcal{M}, \forall B \in \mathcal{M}, A \cap B \in \mathcal{M} \right\}.$$

Nous venons d'établir que $\mathcal{A} \subseteq \mathcal{M}^\circ$. Le même raisonnement permet de vérifier que $\mathcal{M}^\circ$ est aussi une classe monotone. Cela montre que $\mathcal{M}^\circ = \mathcal{M}$.

C'est terminé. □

En combinant la proposition 2.6 et le lemme des classes monotones (théorème 2.4), on obtient le corollaire utile suivant.

Si deux probabilités P, Q sur $(\Omega, \mathcal{F})$ coïncident sur un système π $\mathcal{A}$ qui engendre $\mathcal{F}$:

$$\mathcal{A} \subseteq \{A : A \in \mathcal{F} \text{ and } P(A) = Q(A)\} \quad \text{and} \quad \mathcal{F} \subseteq \sigma(\mathcal{A})$$

alors P, Q coïncident sur $\mathcal{F}$.

2.7 Lois de probabilité sur la droite réelle

Une loi de probabilité est un objet complexe : elle associe une grande collection d'ensembles (une σ -algèbre) à $[0, 1]$. Heureusement, il est possible de caractériser une loi de probabilité par un objet plus simple. Si l'on se restreint aux lois de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, elles peuvent être caractérisées par des fonctions réelles sur $\mathbb{R}$.

Définition 2.12 (Fonction de répartition). Étant donné une loi de probabilité P sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, la fonction de répartition F de P associe $\mathbb{R}$ à $[0, 1]$; elle est définie par

$$x \mapsto F(x) = P(-\infty, x].$$

Une loi de probabilité définit une fonction de répartition unique. Ce qui est peut-être surprenant, c'est qu'une fonction de répartition définit une loi de probabilité unique.

Proposition 2.7. Soit F une fonction de $\mathbb{R}$ vers $[0, 1]$.

La fonction F est la fonction de répartition d'une loi de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ si et seulement si les cinq propriétés suivantes sont satisfaites :

1. F est non décroissante,
2. F est continue à droite
3. $\lim_{y \nearrow x} F(y)$ existe pour tout $x \in \mathbb{R}$ (F possède des limites à gauche partout)
4. $\lim_{x \rightarrow -\infty} F(x) = 0$
5. $\lim_{x \rightarrow \infty} F(x) = 1$.

Il s'agit d'une reformulation de Théorème 2.3.

La figure Figure 2.1 montre la fonction de répartition des lois de Poisson pour différentes valeurs du paramètre (voir les sections Section 1.4 et Section 5.2 pour plus de détails sur les lois de Poisson). Pour le paramètre μ , $F_\mu(x) = \sum_{k \leq x} e^{-\mu} \frac{\mu^k}{k!}$.




FIGURE 2.1 : Cumulative distribution functions for Poisson distributions with different parameters. Observe that, apparently, $\mu \leq \nu \Rightarrow F_\mu \geq F_\nu$. How would you establish this domination property?

2.8 Variables aléatoires générales

Une variable aléatoire réelle n'est ni une variable, ni aléatoire. Une variable aléatoire réelle est une fonction mesurable d'un espace mesurable vers la droite réelle munie de la

σ -algèbre borélienne. Il n'y a rien d'aléatoire dans une variable aléatoire.

Définition 2.13 (Variable aléatoire réelle). Étant donné un espace mesurable $(\Omega, \mathcal{F})$, une application X de Ω vers $\mathbb{R}$ est une variable aléatoire réelle si pour tout $B \in \mathcal{B}(\mathbb{R})$ l'image réciproque de B :

$$X^{-1}(B) = \{\omega : \omega \in \Omega, X(\omega) \in B\}$$

appartient à $\mathcal{F}$

Une fois qu'un espace mesurable est muni d'une loi de probabilité, il est possible de définir la loi (de probabilité) d'une variable aléatoire.

Définition 2.14. Étant donné $(\Omega, \mathcal{F}, P)$ et une variable aléatoire réelle X , la loi ou loi de probabilité de X , notée $P \circ X^{-1}$, est la loi de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ définie par

$$(P \circ X^{-1})(B) = P(X^{-1}(B)) \quad \text{for all } B \in \mathcal{B}(\mathbb{R}).$$

Les variables aléatoires peuvent être à valeurs vectorielles, à valeurs fonctionnelles, *etc.* Les variables aléatoires générales sont définies comme des fonctions mesurables entre espaces mesurables.

Définition 2.15 (Variable aléatoire). Étant donné deux espaces mesurables $(\Omega, \mathcal{F})$ et $(\Omega', \mathcal{G})$, une application X de Ω vers Ω' est une variable aléatoire $\mathcal{F}/\mathcal{G}$ si pour tout $B \in \mathcal{G}$ l'image réciproque de B :

$$X^{-1}(B) = \{\omega : \omega \in \Omega, X(\omega) \in B\}$$

appartient à $\mathcal{F}$.

2.9 Remarques bibliographiques

Il existe de nombreux beaux ouvrages sur la théorie des probabilités. Ils s'adressent à des publics différents. Certains peuvent convenir davantage aux étudiants du double cursus [Mathématiques-Informatique](#). J'ai trouvé les ouvrages suivants particulièrement utiles.

[Youssef \(2019\)](#) est une collection claire et concise de notes de cours conçues pour un cours de probabilités de niveau Master 1 nettement plus ambitieux que ce cours minimal.

Dudley ([2002](#)) propose un cours autonome d'analyse et de probabilités. L'ouvrage peut servir à la fois d'introduction et d'ouvrage de référence. Au-delà de démonstrations prudentes et transparentes, il contient des notes historiques qui aident à comprendre les liens entre les résultats fondamentaux.

2.9. REMARQUES BIBLIOGRAPHIQUES

Pollard ([2002](#)) introduit la théorie de la mesure et de l'intégration à un public qui a été exposé à la théorie des probabilités discrètes et qui est familier du raisonnement probabiliste.

Chapitre 3

Un minimum d'intégration

3.1 Feuille de route

Nous commençons par passer en revue les définitions et résultats de base de la théorie de l'intégration. Nous suivons l'approche de la théorie de la mesure. D'abord, nous définissons les *fonctions simples*, une sous-classe de fonctions mesurables par morceaux dans Section 3.2). Définir l'intégrale d'une fonction simple par rapport à une mesure dans Section 3.3) est direct. Un peu plus de travail nous permet d'obtenir des propriétés utiles : linéarité, monotonie, pour n'en citer que quelques-unes. Dans Section 3.3), nous définissons l'intégrale d'une fonction mesurable non négative comme une borne supérieure d'intégrales de fonctions simples. Cette définition est théoriquement solide et elle se prête aux calculs. La Section 3.4) énonce trois théorèmes de convergence culminant avec le *théorème de convergence dominée*.

3.2 Fonctions simples

L'intégrale d'une fonction mesurable à valeurs dans $\{0, 1\}$ par rapport à une mesure μ est définie par

$$\int_{\Omega} f d\mu = \mu(f^{-1}(\{1\})),$$

ou encore

$$\int_{\Omega} \mathbb{1}_A d\mu = \mu(A) \quad \text{for any measurable set } A.$$

L'étape suivante consiste à définir l'intégrale des combinaisons linéaires finies de fonctions mesurables à valeurs dans $\{0, 1\}$.

Définition 3.1 (Fonction simple). Soit $(\Omega, \mathcal{F})$ un espace mesurable. La fonction $f : \Omega \rightarrow \mathbb{R}$ est dite *simple* si et seulement si

- f prend un nombre fini de valeurs : $|\{f(x) : x \in \Omega\}| < \infty$
- Pour chaque $y \in f(\Omega) \subset \mathbb{R}$, $f^{-1}(\{y\}) \in \mathcal{F}$.

CHAPITRE 3. UN MINIMUM D'INTÉGRATION

Une fonction simple définit une partition de Ω en un nombre fini de classes mesurables. La fonction simple est constante sur chaque classe.

Si f est une fonction simple, alors la σ -algèbre $f^{-1}(\mathcal{B}(\mathbb{R}))$ est finie.

Les fonctions simples sont des combinaisons linéaires finies de fonctions indicatrices d'ensembles.

- Pour chaque $A \in \mathcal{F}$, $\mathbb{1}_A$ est simple
- Pour toute collection finie $A_1, \dots, A_n$ de sous-ensembles mesurables de Ω , toute suite $c_1, \dots, c_n$ de nombres réels, $\sum_{i \leq n} c_i \mathbb{1}_{A_i}$ est une fonction simple
- Pour toute fonction mesurable $f : \Omega \rightarrow \mathbb{R}$ et tout $n \in \mathbb{N}$, la fonction g_n définie par

$$g_n(\omega) = n \wedge (-n \vee \lfloor f(\omega) \rfloor)$$

est simple.

La définition de l'intégrale d'une fonction simple par rapport à une mesure est directe : c'est une somme finie.

Définition 3.2 (Intégrale d'une fonction simple). Soit $(\Omega, \mathcal{F}, \mu)$ un espace mesuré. Soit $f : \Omega \rightarrow \mathbb{R}$ une fonction simple non négative définie par une partition finie de Ω en ensembles mesurables $A_1, A_2, \dots, A_n$ et des nombres $f_1, \dots, f_n$:

$$f(\omega) = \sum_{i \leq n} f_i \mathbb{1}_{A_i}(\omega).$$

L'intégrale de f par rapport à μ est définie par

$$\int_{\Omega} f d\mu = \sum_{i \leq n} f_i \mu(A_i).$$

Notez que si la mesure μ n'est pas finie, l'intégrale d'une fonction simple non négative peut être infinie.

Si $\mu(A_i) = \infty$ et $f_i = 0$, nous convenons que $f_i \mu(A_i) = 0$.

Pour les fonctions simples à signe, il suffit de remarquer que si f est simple, il en est de même de $(f)_+$ et $(f)_-$ et de définir $\int_{\Omega} f d\mu$ par

$$\int_{\Omega} (f)_+ d\mu - \int_{\Omega} (f)_- d\mu$$

pourvu qu'au moins l'un des deux termes soit fini.

Bien qu'elles soient simples, les fonctions simples ont d'intéressantes capacités d'approximation. Toute fonction mesurable non négative peut être approchée par le bas par des fonctions simples non négatives.

Proposition 3.1 (Approximation des fonctions mesurables). Soit $(\Omega, \mathcal{F})$ un espace mesurable. Toute fonction mesurable non négative $f : \Omega \rightarrow \mathbb{R}$ est la limite ponctuelle monotone de fonctions simples : il existe une suite de fonctions simples $f_1, \dots, f_n, \dots$ telle

que, pour chaque $\omega \in \Omega$, on ait :

$$f_1(\omega) \leq f_2(\omega) \leq \dots \leq f_n(\omega) \leq \dots \leq f(\omega)$$

et

$$\lim_n f_n(\omega) = f(\omega).$$

Preuve. Définissons f_n par

$$f_n(\omega) = n \wedge \left(2^{-n} \lfloor 2^n f(\omega) \rfloor \right).$$

Comme

$$\lfloor 2^n f(\omega) \rfloor \leq 2^n f(\omega)$$

nous avons $f_n(\omega) \leq f(\omega)$ pour tout ω .

L'image de la fonction f_n est $i \times 2^{-n}$ pour $i = 0, \dots, n \times 2^n$. Pour chaque $i \in 0, \dots, (n-1) \times 2^n$

$$f_n^{-1}(\{i \times 2^{-n}\}) = f^{-1}\left(\left[\frac{i}{2^n}, \frac{i+1}{2^n}\right)\right)$$

qui appartient à $\mathcal{F}$ car f est mesurable et $\left[\frac{i}{2^n}, \frac{i+1}{2^n}\right) \in \mathcal{B}(\mathbb{R})$.

De même $f_n^{-1}(\{n\}) = f^{-1}([n, \infty))$ appartient à $\mathcal{F}$.

Pour vérifier que $f_n \leq f_{n+1}$, nous considérons deux cas.

1. $f_{n+1}(\omega) \geq n$. Cela implique $f(\omega) \geq n$ et donc $f_n(\omega) = n < f_{n+1}(\omega)$
2. $f_{n+1}(\omega) = k + i2^{-n-1}$ pour $k < n$ et $i < 2^{n+1}$. Cela implique $f_n(\omega) = k + \lfloor i/2 \rfloor 2^{-n} \leq f_{n+1}(\omega)$.

Enfin, si $f(\omega) \leq n$, $0 \leq f(\omega) - f_n(\omega) \leq 2^{-n}$. Cela implique que $\lim_n f_n(\omega) = f(\omega)$ pour tout ω . $\square$

La figure Figure 3.1 illustre les capacités d'approximation des fonctions simples.

Proposition 3.2. Si f, g sont deux fonctions simples non négatives sur $(\Omega, \mathcal{F})$, alors pour tout $a, b \in [0, \infty)$, $af + bg$ et fg sont des fonctions simples non négatives.

Exercice 3.1. Vérifier la proposition.

Proposition 3.3 (Monotonie de l'intégration des fonctions simples). Si f, g sont deux fonctions simples non négatives et μ une mesure non négative sur $(\Omega, \mathcal{F})$ telle que

$$\mu\{\omega : f(\omega) > g(\omega)\} = 0.$$




FIGURE 3.1 : Approximation of the exponential function by simple functions $n \wedge (2^{-n} \lfloor 2^n \exp(\omega) \rfloor)$ for $n = 2, 3, 4$.

(f est inférieure ou égale à g μ -presque partout), alors

$$\int f \, d\mu \leq \int g \, d\mu.$$

Exercice 3.2. Vérifier Proposition 3.3

Proposition 3.4 (Linéarité de l'intégration des fonctions simples). *Si f, g sont deux fonctions simples non négatives et μ une mesure non négative sur $(\Omega, \mathcal{F})$, alors pour tout $a, b \in [0, \infty)$,*

$$\int af + bg \, d\mu = a \int f \, d\mu + b \int g \, d\mu.$$

Exercice 3.3. Vérifier la Proposition Proposition 3.4

3.3 Intégration

Soit $\mathcal{S}_+$ l'ensemble des fonctions simples non négatives sur $(\Omega, \mathcal{F})$.

Définition 3.3 (Intégration par rapport à une mesure). Soit f une fonction mesurable non négative sur $(\Omega, \mathcal{F}, \mu)$. Pour tout $A \in \mathcal{F}$, l'intégrale de f sur A par rapport à la mesure μ est définie par :

$$\int_A f d\mu = \sup_{s \in \mathcal{S}_+ : s \leq f} \int_A s d\mu$$

Si la borne supérieure est finie, la fonction est dite *intégrable* par rapport à μ , ou μ -intégrable.

Proposition 3.5 (Monotonie de l'intégration). Si f, g sont deux fonctions mesurables non négatives et μ une mesure non négative sur $(\Omega, \mathcal{F})$ telle que

$$\mu\{\omega : f(\omega) > g(\omega)\} = 0.$$

(f est inférieure ou égale à g μ -presque partout), alors

$$\int f d\mu \leq \int g d\mu.$$

Démontrer la Proposition Proposition 3.5.

Proposition 3.6 (Linéarité de l'intégration). Si f, g sont deux fonctions mesurables non négatives et μ une mesure non négative sur $(\Omega, \mathcal{F})$, alors pour tout $a, b \in [0, \infty)$,

$$\int af + bg d\mu = a \int f d\mu + b \int g d\mu.$$

Démontrer la Proposition Proposition 3.6.

L'intégrale d'une fonction mesurable à signe est définie par un argument de décomposition. Soit f une fonction mesurable et $f = (f)_+ - (f)_-$. Alors

$$\int_{\Omega} f d\mu = \int_{\Omega} (f)_+ d\mu - \int_{\Omega} (f)_- d\mu$$

pourvu qu'au moins l'une des intégrales $\int_{\Omega} (f)_+ d\mu$ et $\int_{\Omega} (f)_- d\mu$ soit finie.

3.4 Théorèmes limites

Dans cette section, les fonctions mesurables sont à valeurs réelles, et $\mathbb{R}$ est muni de la σ -algèbre borélienne $(\mathcal{B}(\mathbb{R}))$.

Les théorèmes Théorème 3.1, Théorème 3.2, Théorème 3.3 ci-dessous sont les trois piliers du calcul intégral.

Théorème 3.1 (Théorème de convergence monotone). *Soit $(\Omega, \mathcal{F}, \mu)$ un espace mesuré. Soit $(f_n)_n$ une suite croissante de fonctions mesurables non négatives convergeant vers f . Alors*

$$\int \lim_n \uparrow f_n \, d\mu = \lim_n \uparrow \int f_n \, d\mu.$$

La preuve du théorème de convergence monotone se réduit à la définition d'une mesure positive et à la propriété $\mu(\lim_n \uparrow A_n) = \lim_n \uparrow \mu(A_n)$.

Preuve. Définissons la fonction f par $f(\omega) = \lim_n \uparrow f_n(\omega)$ pour tout $\omega \in \Omega$. Notez que si $f(\omega) = 0$, alors $f_n(\omega) = 0$ pour tout $n \in \mathbb{N}$.

La fonction f est mesurable positive. Pour prouver le théorème de convergence monotone, il suffit de vérifier que, pour toute fonction simple non négative g telle que $g \leq f$ partout, pour tout $a \in [0, 1)$, on ait :

$$a \int g \, d\mu \leq \lim_n \uparrow \int f_n \, d\mu. \quad (3.1)$$

Pour chaque $n \in \mathbb{N}$, définissons

$$E_n = \{\omega : f_n(\omega) \geq ag(\omega)\}.$$

Notez que, comme $(f_n)_n$ est croissante, la suite (E_n) est croissante. De plus, si $f(\omega) > 0$, comme $\lim_n \uparrow f_n(\omega) = f(\omega) > af(\omega) \geq ag(\omega)$. Pour tout $\omega \in \Omega$, $\mathbb{1}_{E_n}(\omega) = 1$ pour tout n assez grand (attention, il n'y a pas de garantie d'uniformité). Nous avons

$$\lim_n \uparrow E_n = \Omega.$$

En combinant ces remarques, nous avons pour tout n , $\mathbb{1}_{E_n} ag \leq f_n$ partout. La monotonie de l'intégration entraîne, pour tout n ,

$$\int \mathbb{1}_{E_n} ag \, d\mu \leq \int f_n \, d\mu \quad \forall n.$$

Maintenant, pour chaque n , $\mathbb{1}_{E_n} ag$ est une fonction simple non négative, et la suite $(\mathbb{1}_{E_n} ag)_n$ est une suite croissante de fonctions simples non négatives convergeant vers la fonction simple ag .

Soit $g = \sum_{i \leq k} c_i \mathbb{1}_{A_i}$ où $(A_i)_{i \leq k}$ est une partition finie de Ω en sous-ensembles mesurables.

$$\mathbb{1}_{E_n} g = \sum_{i \leq k} c_i \mathbb{1}_{A_i \cap E_n}.$$

D'où

$$\begin{aligned} \int \mathbb{1}_{E_n} ag \, d\mu &= \sum_{i \leq k} c_i \int \mathbb{1}_{A_i \cap E_n} \, d\mu \\ &= \sum_{i \leq k} c_i \mu(A_i \cap E_n). \end{aligned}$$

Pour chaque $i \leq k$, nous avons $\lim_n \uparrow c_i \mu(A_i \cap E_n) = c_i \mu(A_i)$. Nous avons :

$$\int \lim_n \uparrow \mathbb{I}_{E_n} a g \, d\mu = \lim_n \uparrow \int \mathbb{I}_{E_n} a g \, d\mu.$$

Cela prouve que Équation 3.1 est vérifiée pour tout $a \in [0, 1)$ et $g \in \mathcal{S}_+$ avec $g \leq f$:

$$\forall g \in \mathcal{S}_+ \text{ with } \forall a \in [0, 1),$$

□

L'hypothèse de non-négativité sur f_n n'est pas nécessaire. Il suffit de supposer $\int f_1 \, d\mu > -\infty$. Le démontrer.

Soit $(f_n)_n$ une suite décroissante de fonctions mesurables non négatives. Soit $f = \lim_n \downarrow f_n$ (vérifier l'existence de f).

Est-il vrai que $\int \lim_n \downarrow f_n \, d\mu = \lim_n \downarrow \int f_n \, d\mu$?

Répondre à la même question en supposant $\int f_1 \, d\mu < \infty$.

Répondre à la même question si μ est supposée être une loi de probabilité.

Théorème 3.2 (Lemme de Fatou). *Soit $(\Omega, \mathcal{F}, \mu)$ un espace mesuré. Soit $(f_n)_n$ une suite de fonctions mesurables non négatives. Alors*

$$\int \lim_n \inf f_n \, d\mu \leq \lim_n \inf \int f_n \, d\mu.$$

Preuve. Définissons $h_n(\omega) = \inf_{m \geq n} f_m(\omega)$. Chaque h_n est aussi non négative et mesurable. Par monotonie,

$$\int h_n \, d\mu \leq \inf_{m \geq n} \int f_m \, d\mu.$$

La suite h_n est croissante. Et $\lim \uparrow h_n(\omega) = \lim \inf f_n(\omega)$ pour tout $\omega \in \Omega$. Pour chaque n , par le théorème de convergence monotone (Théorème 3.1) :

$$\int \lim_n \uparrow h_n \, d\mu = \lim_n \uparrow \int h_n \, d\mu$$

donc

$$\int \lim_n \inf f_n \, d\mu = \lim_n \uparrow \int h_n \, d\mu$$

et

$$\int \lim_n \inf f_n \, d\mu \leq \lim_n \inf_{m \geq n} \int f_m \, d\mu = \lim_n \inf \int f_n \, d\mu$$

□

Théorème 3.3 (Théorème de convergence dominée). *Soit $(\Omega, \mathcal{F}, \mu)$ un espace mesuré. Soit $(f_n)_n$ une suite de fonctions mesurables convergeant ponctuellement vers la fonction f . Supposons qu'il existe une fonction intégrable g qui domine $(f_n)_n$: pour tout n , tout $\omega \in \Omega$, $|f_n(\omega)| \leq g(\omega)$. Alors f est intégrable et*

$$\int f d\mu = \int \lim_n f_n d\mu = \lim_n \int f_n d\mu.$$

Preuve. Vérifions d'abord que f est intégrable.

Observez que $\lim_n |f_n| = |f|$ et donc $\liminf |f_n| = |f|$.

Par Théorème 3.2,

$$\int |f| d\mu = \int \liminf_n |f_n| d\mu \leq \liminf_n \int |f_n| d\mu = \int |g| d\mu < \infty.$$

Définissons maintenant $h_n = \inf_{m \geq n} f_m$ et $j_n = \sup_{m \geq n} f_m$. Nous avons $\lim_n \uparrow h_n = f$ et $\lim_n \downarrow j_n = f$.

Notez aussi que

$$\int h_n d\mu \leq \int f d\mu \leq \int j_n d\mu.$$

Par convergence monotone, $\int h_n d\mu \uparrow \int f d\mu$ et $\int j_n d\mu \downarrow \int f d\mu$. Il en découle que $\lim \int f_n d\mu$ existe et coïncide avec $\int f d\mu$. $\square$

Soit $g : \Omega \times \mathbb{R} \rightarrow \mathbb{R}$ une fonction de deux variables telle que, pour chaque $t \in \mathbb{R}$, $g(\cdot, t)$ soit mesurable. Supposons que, pour chaque $t \in \mathbb{R}$, $g(\cdot, t)$ soit μ -intégrable et que, pour chaque $\omega \in \Omega$, $g(\omega, \cdot)$ soit dérivable. Définissons $G(t) = \int_{\Omega} g(\omega, t) d\mu(\omega)$.

G est-elle toujours dérivable en tout t ?

Donner des conditions suffisantes pour que G soit dérivable et

$$G'(t) = \int \frac{\partial g}{\partial s}(\omega, s)|_{s=t} d\mu(\omega).$$

3.5 Lois de probabilité définies par une densité

Proposition 3.7. Soient $(\Omega, \mathcal{F})$ un espace mesurable et μ une mesure σ -finie sur $(\Omega, \mathcal{F})$. Soit f une fonction réelle mesurable non négative sur $(\Omega, \mathcal{F})$.

Définissons $\nu : \mathcal{F} \rightarrow [0, \infty)$ par

$$\nu(A) = \int_A f d\mu = \int_A f d\mu.$$

ν est une mesure sur $(\Omega, \mathcal{F})$. La fonction f est dite densité de ν par rapport à μ .

Preuve. Le fait que $\nu(\emptyset) = 0$ est immédiat.

Le fait que ν soit σ -additive découle du théorème de convergence monotone (Théorème 3.1).

Si $A_1, \dots, A_n, \dots$ est une collection d'ensembles mesurables deux à deux disjoints,

$$\begin{aligned}
\nu(\cup_n A_n) &= \int \mathbb{I}_{\cup_n A} f \, d\mu \\
&= \int \left(\lim_n \sum_{k \leq n} \mathbb{I}_{A_k} \right) f \, d\mu \\
&= \int \left(\lim_n \sum_{k \leq n} \mathbb{I}_{A_k} f \right) d\mu \\
&= \lim_n \sum_{k \leq n} \int \mathbb{I}_{A_k} f \, d\mu \\
&= \lim_n \sum_{k \leq n} \int \mathbb{I}_{A_k} f \, d\mu \\
&= \lim_n \sum_{k \leq n} \nu(A_k) \\
&= \sum_{k=1}^{\infty} \nu(A_k).
\end{aligned}$$

La quatrième égalité est justifiée par le théorème de convergence monotone; les autres égalités découlent du fait que nous traitons des séries non négatives. $\square$

Soit $(A_n)_n$ tel que $A_n \in \mathcal{F}$, $\mu(A_n) < \infty$ pour chaque n et $\cup_n A_n = \Omega$. Pour chaque n , nous avons $\nu(A_n) = \int_{A_n} f \, d\mu \leq \int_{\Omega} f \, d\mu < \infty$. Cela prouve que si μ est σ -finie, il en est de même de ν .

Exercice 3.4. Vérifier que si $\mu(A) = 0$, alors $\nu(A) = 0$ pour tout $A \in \mathcal{F}$.

3.6 Remarques bibliographiques

Dudley (2002) offre un traitement autonome et approfondi de la théorie de la mesure et de l'intégration avec la théorie des probabilités à l'esprit.

Hiriart-Urruty & Lemaréchal (1993) est une excellente référence accessible sur la convexité.

Chapitre 4

Des intégrales à l'espérance et aux moments

4.1 Feuille de route

Dans Section 4.2, nous relierons la notion d'*espérance* d'une variable aléatoire à celle d'intégrale. Le *théorème de transfert* (Théorème 4.1) est un outil essentiel pour caractériser les lois images.

Dans Section 4.3, nous énonçons, démontrons et illustrons l'inégalité de Jensen. Cette inégalité permet d'obtenir facilement des majorations de l'espérance de fonctions convexes de variables aléatoires réelles. C'est l'occasion de rappeler les bases de la convexité.

Dans Section 4.4, nous portons une attention particulière à la *variance*. Nous énonçons plusieurs caractérisations de la variance.

Dans Section 4.5

Dans Section 4.7

4.2 Espérance

L'espérance d'une variable aléatoire réelle est une intégrale (au sens de Lebesgue) par rapport à une mesure de probabilité. Il faut se familiariser avec la notation probabiliste.

Définition 4.1. Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé. La variable aléatoire X définie sur $(\Omega, \mathcal{F})$ est P -intégrable si la fonction mesurable $|X| : \omega \mapsto |X(\omega)|$ est P -intégrable : on convient de poser

$$\mathbb{E}X = \mathbb{E}_P X = \int_{\Omega} X(\omega) dP(\omega) = \int X dP.$$

Exercice 4.1. Vérifier la cohérence de cette définition avec celle utilisée dans le cadre discret.

L'énoncé suivant, appelé *formule de transfert*, permet de calculer la densité d'une loi image ou de simplifier le calcul d'une espérance.

Théorème 4.1 (Formule de transfert). *Soit $(\mathcal{X}, \mathcal{F}, P)$ un espace probabilisé, $(\mathcal{Y}, \mathcal{G})$ un espace mesurable, f une fonction mesurable de $(\mathcal{X}, \mathcal{F})$ vers $(\mathcal{Y}, \mathcal{G})$. Notons Q la loi de probabilité image de P par $f: Q = P \circ f^{-1}$.*

Alors, pour toute fonction mesurable h de $(\mathcal{Y}, \mathcal{G})$ vers $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$

$$\mathbb{E}[h(Y)] = \int_{\mathcal{Y}} h(y) dQ(y) = \int_{\mathcal{X}} h \circ f(x) dP(x) = \mathbb{E}h \circ f(X)$$

si l'une au moins des intégrales est définie.

Preuve. Supposons d'abord que $h = \mathbb{1}_B$ où $B \in \mathcal{G}$. Alors

$$\begin{aligned} \mathbb{E}h(Y) &= \int_{\mathcal{Y}} \mathbb{1}_B(y) dQ(y) \\ &= Q(B) \\ &= P \circ f^{-1}(B) \\ &= P\{x : f(x) \in B\} \\ &= P\{x : h \circ f(x) = 1\} \\ &= \int_{\mathcal{X}} h \circ f(x) dP(x) \\ &= \mathbb{E}h \circ f(X). \end{aligned}$$

Par linéarité, la formule de transfert vaut alors pour toutes les fonctions simples de $\mathcal{Y}$ vers $\mathbb{R}$. Par la définition de l'intégrale de Lebesgue, elle vaut pour les fonctions mesurables non négatives. L'argument de décomposition habituel achève la preuve. $\square$

Il est clair que l'espérance d'une variable aléatoire ne dépend que de la loi de cette variable.

4.3 Inégalité de Jensen

Les outils de théorie de l'intégration que nous avons revus servent à calculer ou approximer des intégrales et des espérances. Le théorème suivant évite les calculs et permet de comparer des espérances.

L'inégalité de Jensen est un outil central en théorie de l'information, en statistique et dans une large part de la théorie des probabilités. Elle traduit l'interaction entre convexité et espérance.

Nous introduisons d'abord un minimum de théorie et de notation sur la convexité.

Définition 4.2 (Semi-continuité inférieure). Une fonction f d'un espace métrique $\mathcal{X}$ vers $\mathbb{R}$ est semi-continue inférieurement en $x \in \mathcal{X}$ si

$$\liminf_{x_n \rightarrow x} f(x_n) \geq f(x).$$

Une fonction continue est semi-continue inférieurement. La réciproque est fausse. Si $A \subseteq \mathcal{X}$ est un ouvert, alors $\mathbb{I}_A$ est semi-continue inférieurement mais, sauf si elle est constante, elle n'est pas continue au bord de A .

Définition 4.3 (Partie convexe). Soit $\mathcal{X}$ un espace vectoriel. Une partie $C \subseteq \mathcal{X}$ est dite convexe si, pour tous $x, y \in C$ et tout $\lambda \in [0, 1]$:

$$\lambda x + (1 - \lambda)y \in C.$$

Soit C une partie convexe d'un espace vectoriel (topologique réel), et $\overline{C}$ l'adhérence de C . Montrer que $\overline{C}$ et $\overline{C} \setminus C$ sont convexes.

Une partie convexe peut n'être ni fermée ni ouverte. Donner des exemples.

Dans la définition suivante, nous considérons des fonctions d'un espace vectoriel vers $\mathbb{R} \cup \{+\infty\}$.

Définition 4.4 (Fonctions convexes). Soit $\mathcal{X}$ un espace vectoriel (topologique). Soit $C \subseteq \mathcal{X}$ une partie convexe. Une fonction f de $\mathcal{C}$ vers $\mathbb{R} \cup \{\infty\}$ est convexe si, pour $x, y \in C$ et tout $\lambda \in [0, 1]$,

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

Le domaine de f , $\text{Dom}(f)$, est la partie de C où f est finie.

Exercice 4.2. Vérifier qu'une fonction convexe f est semi-continue inférieurement si et seulement si les ensembles $\{x : f(x) \leq t\}$ sont des intervalles fermés pour tout $t \in \mathbb{R}$.

Le résultat suivant garantit que toute fonction convexe semi-continue inférieurement admet une représentation duale. Cette représentation duale est un outil précieux pour comparer les espérances de variables aléatoires.

Théorème 4.2 (Dualité de Fenchel-Legendre). Soit f une fonction convexe semi-continue inférieurement sur $\mathbb{R}$ à domaine fermé. La fonction duale f^* de f est définie sur $\mathbb{R}$ par

$$f^*(y) = \sup_{x \in \text{Dom}(f)} xy - f(x).$$

Alors

— f^* est convexe




FIGURE 4.1 : The function $f : x \mapsto \mathbb{I}_{x < 0}|x| + \mathbb{I}_{x \geq 0}x^2$ is convex, continuous. It is differentiable everywhere except at $x = 0$. The dotted lines define affine functions that are below the curve $y = f(x)$. The dotted lines define supporting hyperplanes for the epigraph of f .

- f^* est semi-continue inférieurement
- Si $f^*(y) = xy - f(x)$, alors y est un sous-gradient de f en x .
- Si y est un sous-gradient de f en x , $f^*(y) = xy - f(x)$.
- $f = (f^*)^*$: la fonction duale de la fonction duale coïncide avec la fonction d'origine, $f(x) = \sup_y xy - f^*(y)$.

Exemple 4.1. Les paires duales suivantes seront utilisées à plusieurs reprises.

- si $f(x) = \frac{|x|^p}{p}$ ($p > 1$), alors $f^*(y) = \frac{|y|^q}{q}$ où $q = p/(p-1)$.
- si $f(x) = |x|$, alors $f^*(y) = 0$ pour $y \in [-1, 1]$ et ∞ pour $|y| > 1$.
- si $f(x) = \exp(x)$, alors $f^*(y) = y \log y - y$ pour $y > 0$, $f^*(y) = \infty$ pour $y < 0$

Preuve. Le fait que f^* soit à valeurs dans $\mathbb{R} \cup \{\infty\}$ et convexe est immédiat.

Pour la semi-continuité inférieure, supposons $y_n \rightarrow y$, avec $y_n \in \text{Dom}(f^*)$ et $f^*(y) > \liminf_n f^*(y_n)$.

Supposons d'abord $y \in \text{Dom}(f^*)$. Alors, pour m assez grand et un certain $x \in \text{Dom}(f)$,

$$f^*(y) \geq xy - f(x) - \frac{1}{m} > \liminf_n f^*(y_n) \geq \liminf_n y_n x - f(x) = yx - f(x)$$

ce qui est contradictoire.

Supposons maintenant $y \notin \text{Dom}(f^*)$ et $\liminf_n f^*(y_n) < \infty$. Extrayons une sous-suite $(y_{m_n})_n$ telle que $\lim_n f^*(y_{m_n}) = \liminf_n f^*(y_n)$. Il existe $x \in \text{Dom}(f)$ tel que

$$f^*(y) > xy - f(x) > \liminf_n f^*(y_n) = \lim_n f^*(y_{m_n}) \geq \lim_n xy_{m_n} - f(x) = xy - f(x)$$

ce qui est encore contradictoire.

Le fait que y soit un sous-gradient de f en x si $f^*(y) = xy - f(x)$ est une reformulation de la définition des sous-gradients.

Notons que si $x \in \text{Dom}(f)$ et $y \in \text{Dom}(f^*)$, alors $f(x) + f^*(y) \geq xy$.

Cette observation entraîne $(f^*)^*(x) \leq f(x)$ pour tout $x \in \text{Dom}(f)$. S'il existait $x \in \text{Dom}(f)$ avec $(f^*)^*(x) > f(x)$, il existerait $y \in \text{Dom}(f^*)$ tel que $xy - f^*(y) > f(x)$, ce qui est impossible.

Pour prouver $(f^*)^*(x) \geq f(x)$ pour tout $x \in \text{Dom}(f)$, nous utilisons la convexité, la semi-continuité inférieure de f et f^* , et la fermeture de $\text{Dom}(f)$. Sous ces conditions, tout point x de $\text{Dom}(f)$ admet un sous-gradient y et cela entraîne $f(x) + f^*(y) = xy$. $\square$

Exercice 4.3. Étendre la notion de dualité de Fenchel-Legendre aux fonctions convexes semi-continues inférieurement sur $\mathbb{R}^k$.

Exercice 4.4. Toute fonction convexe est-elle semi-continue inférieurement ? mesurable ?

Toute fonction convexe semi-continue inférieurement est-elle mesurable ?

Remarque 4.1. Il est possible de définir f^* par $f^*(y) = \sup_x xy - f(x)$ même si f n'est pas convexe ni semi-continue inférieurement. La fonction f^* conserve la convexité et la semi-continuité inférieure. Mais $f \neq (f^*)^*$: on n'obtient que $f \geq (f^*)^*$. En effet, $(f^*)^*$ est la plus grande minorante convexe de f .

Théorème 4.3 (Inégalité de Jensen). *Soit X une variable aléatoire réelle et $f : \mathbb{R} \rightarrow \mathbb{R}$ une fonction convexe, semi-continue inférieurement telle que l'ensemble fermé $\text{Dom}(f) \subseteq \text{supp}(\mathcal{L}(X))$ et $\mathbb{E}|f(X)| < \infty$, alors*

$$f(\mathbb{E}X) \leq \mathbb{E}f(X).$$

Au regard de la définition de la convexité et du fait que prendre une espérance prolonge l'idée de combinaison convexe, l'inégalité de Jensen n'est pas surprenante.

Preuve.

$$\begin{aligned} \mathbb{E}f(X) &= \mathbb{E}(f^*)^*(X) \\ &= \mathbb{E}\left[\sup_y (yX - f^*(y))\right] \\ &\geq \sup_y (y\mathbb{E}X - f^*(y)) \\ &= (f^*)^*(\mathbb{E}X) \\ &= f(\mathbb{E}X). \end{aligned}$$

□

Exercice 4.5. Dans l'argument ci-dessus, il n'est pas *a priori* évident que $\sup_y (yX - f^*(y))$ soit mesurable, puisque le supremum est pris sur une collection non dénombrable. Vérifier que cela ne pose pas de problème.

Nous verrons de nombreuses applications de l'inégalité de Jensen :

- comparaison de l'échantillonnage avec remise et sans remise (comparaison des queues binomiale et hypergéométrique)
- inégalités de Cauchy-Schwarz et de Hölder
- dérivation d'inégalités maximales
- non-négativité de l'entropie relative
- dérivation des inégalités d'Efron-Stein-Steele
- ...

4.4 Variance

La variance (lorsqu'elle est définie) est un indice de dispersion de la loi d'une variable aléatoire.

Proposition 4.1 (Caractérisations de la variance). *Soit X une variable aléatoire sur un espace probabilisé. La variance de X est finie si et seulement si $\mathbb{E}X^2 < \infty$, et elle peut être définie par les trois égalités suivantes :*

$$\begin{aligned} \text{var}(X) &= \mathbb{E}[(X - \mathbb{E}X)^2] \\ &= \inf_{a \in \mathbb{R}} \mathbb{E}[(X - a)^2] \\ &= \mathbb{E}X^2 - (\mathbb{E}X)^2. \end{aligned}$$

Il reste à vérifier que les trois membres de droite sont finis si l'un d'eux l'est, et qu'ils sont tous égaux lorsqu'ils sont finis.

Preuve. Supposons $\mathbb{E}X^2 < \infty$. Comme $|X| \leq \frac{X^2}{2} + \frac{1}{2}$, cela entraîne $\mathbb{E}|X| < \infty$. Si $\mathbb{E}X^2 < \infty$, alors $\mathbb{E}|X|$ l'est aussi. Le membre de droite de la troisième ligne est fini si $\mathbb{E}X^2 < \infty$. Comme $(x - b)^2 \leq 2x^2 + 2b^2$ pour tous x, b , les membres de droite de la première ligne et l'infimum de la deuxième ligne sont finis lorsque $\mathbb{E}X^2 < \infty$.

Comme $X^2 \leq 2(X - \mathbb{E}X)^2 + 2(\mathbb{E}X)^2$, $\mathbb{E}X^2 < \infty$ si $\mathbb{E}[(X - \mathbb{E}X)^2] < \infty$.

Supposons maintenant $\mathbb{E}X^2 < \infty$.

$$\begin{aligned} \mathbb{E}[(X - a)^2] &= \mathbb{E}[(X - \mathbb{E}X - (a - \mathbb{E}X))^2] \\ &= \mathbb{E}[(X - \mathbb{E}X)^2 - 2\mathbb{E}[(X - \mathbb{E}X)](a - \mathbb{E}X) + (a - \mathbb{E}X)^2] \\ &= \mathbb{E}[(X - \mathbb{E}X)^2] + (a - \mathbb{E}X)^2. \end{aligned}$$

Comme $(a - \mathbb{E}X)^2 \geq 0$, nous avons établi que $\mathbb{E}[(X - \mathbb{E}X)^2] = \inf_{a \in \mathbb{R}} \mathbb{E}[(X - a)^2]$. De plus, l'infimum est un minimum, atteint en un unique point $\mathbb{E}X$. □

Remarque 4.2. Les première et deuxième caractérisations de la variance affirment que l'espérance minimise l'erreur quadratique moyenne. Un fait d'une grande importance en statistique.

Exercice 4.6. Vérifier que si $P\{X \in [a, b]\} = 1$, alors $\text{var}(X) \leq \frac{(b-a)^2}{4}$.

4.5 Moments d'ordre supérieur

Dans cette section, nous relierons $\mathbb{E}|X|^p$ et $\mathbb{E}|X|^q$ pour différentes valeurs de $p, q \in \mathbb{R}_+$. Notre point de départ est un petit résultat technique d'analyse réelle.

Proposition 4.2 (Inégalité de Young). *Soient $p, q > 1$ conjugués ($1/p + 1/q = 1$), et $x, y > 0$. Alors*

$$xy \leq \frac{x^p}{p} + \frac{y^q}{q}.$$

Preuve. Si p et q sont conjugués, alors $q = p/(p-1)$ et $(p-1)(q-1) = 1$.

Il suffit de vérifier que, pour tous $x, y > 0$,

$$\frac{x^p}{p} \geq xy - \frac{y^q}{q}.$$

Fixons $x > 0$ et considérons la fonction sur $[0, \infty)$ définie par

$$z \mapsto xz - \frac{z^q}{q}.$$

Cette fonction est dérivable, de dérivée $x - z^{q-1} = x - z^{1/(p-1)}$. Elle atteint son maximum en $z = x^{p-1}$, et ce maximum vaut

$$xx^{p-1} - \frac{x^{q(p-1)}}{q} = x^p - \frac{x^p}{q} = \frac{x^p}{p}.$$

□

Figure 4.2 propose une preuve graphique de l'inégalité de Young.

Remarque 4.3. Un cas particulier de l'inégalité de Young s'obtient en prenant $p = q = 2$.

Nous sommes maintenant en mesure de démontrer trois inégalités fondamentales : Cauchy-Schwarz, Hölder et Minkowski.

Théorème 4.4 (Cauchy-Schwarz). *Soient X et Y deux variables aléatoires sur le même espace probabilisé. Supposons que $\mathbb{E}X^2$ et $\mathbb{E}Y^2$ sont finies. Alors*

$$\mathbb{E}[XY] \leq \sqrt{\mathbb{E}X^2} \times \sqrt{\mathbb{E}Y^2}.$$




FIGURE 4.2 : Graphical illustration of Young's inequality. We choose $p = \frac{r}{r-1}$ and $q = \frac{r}{r-1}$, $x = \frac{r}{r-1} s$ and $y = \frac{r}{r-1} t$. The black point is located at $(x, y)^T$. The product xy equals the area of the rectangle located between the origin and $(x, y)^T$ (delimited by the dashed segments). The dotted line represents function $s \mapsto s^{p-1}$, and interchanging the axes, the function $t \mapsto t^{q-1} = t^{1/(p-1)}$. The area of the light grey surface under the dotted line equals $\frac{x^p}{p} = \int_0^x s^{p-1} ds$, while the area of the darker grey surface below line $y = 1$ and above the dotted line, equals $\frac{y^q}{q} = \int_0^y t^{q-1} dt$. The union of the two disjoint surfaces covers the rectangle located between the origin and $(x, y)^T$. Equality occurs when the dotted line passes through $(x, y)^T$, that is when $y = x^{p-1}$.

Preuve. Si $\sqrt{\mathbb{E}X^2} = 0$ ou $\sqrt{\mathbb{E}Y^2} = 0$, l'inégalité est trivialement satisfaite.

Sans perte de généralité, supposons $\sqrt{\mathbb{E}X^2} > 0$ et $\sqrt{\mathbb{E}Y^2} > 0$. Alors, puisque $ab \leq a^2/2 + b^2/2$ pour tous réels a, b , partout,

$$\frac{|XY|}{\sqrt{\mathbb{E}X^2}\sqrt{\mathbb{E}Y^2}} \leq \frac{|X|^2}{2\mathbb{E}X^2} + \frac{|Y|^2}{2\mathbb{E}Y^2}.$$

En prenant l'espérance des deux côtés, on obtient le résultat voulu. $\square$

Exercice 4.7. Pourquoi l'inégalité est-elle trivialement satisfaite si $\sqrt{\mathbb{E}X^2} = 0$?

Théorème 4.4 nous dit que si X et Y sont de carré intégrables, alors XY est intégrable.

L'inégalité de Hölder généralise celle de Cauchy-Schwarz. En effet, l'inégalité de Cauchy-Schwarz n'est que l'inégalité de Hölder pour $p = q = 2$ (2 est son propre conjugué).

Théorème 4.5 (Inégalité de Hölder). *Soient X et Y deux variables aléatoires sur le même espace probabilisé. Soient $p, q > 1$ conjugués ($1/p + 1/q = 1$). Supposons que $\mathbb{E}|X|^p$ et $\mathbb{E}|Y|^q$ sont finies. Alors*

$$\mathbb{E}[XY] \leq (\mathbb{E}|X|^p)^{1/p} \times (\mathbb{E}|Y|^q)^{1/q}.$$

Preuve. Si $\mathbb{E}|X|^p = 0$ ou $\mathbb{E}|Y|^q = 0$, l'inégalité est trivialement satisfaite.

Supposons $\mathbb{E}|X|^p > 0$ et $\mathbb{E}|Y|^q > 0$.

Suivons la preuve de l'inégalité de Cauchy-Schwarz, en remplaçant $2ab \leq a^2 + b^2$ par l'inégalité de Young :

$$ab \leq \frac{|a|^p}{p} + \frac{|b|^q}{q} \quad \forall a, b \in \mathbb{R}$$

si $1/p + 1/q = 1$.

L'inégalité ci-dessous découle de l'inégalité de Young et de la monotonie de l'espérance :

$$\begin{aligned} \frac{\mathbb{E}|XY|}{\mathbb{E}|X|^p \mathbb{E}|Y|^q} &= \mathbb{E} \left[\frac{|X|}{\mathbb{E}|X|^p} \frac{|Y|}{\mathbb{E}|Y|^q} \right] \\ &\leq \mathbb{E} \left[\frac{|X|^p}{p \mathbb{E}|X|^p} + \frac{|Y|^q}{q \mathbb{E}|Y|^q} \right] \\ &= \frac{1}{p} + \frac{1}{q} \\ &= 1. \end{aligned}$$

□

Corollaire 4.1. *Pour $1 \leq p < q$,*

$$\mathbb{E}[|X|^p]^{1/p} \leq \mathbb{E}[|X|^q]^{1/q}.$$

Pour $p \in [0, \infty)$, $X \mapsto (\mathbb{E}|X|^p)^{1/p}$ définit une semi-norme sur l'ensemble des variables aléatoires pour lesquelles $(\mathbb{E}|X|^p)^{1/p}$ est fini. L'inégalité de Minkowski affirme que $X \mapsto (\mathbb{E}|X|^p)^{1/p}$ satisfait l'inégalité triangulaire.

Théorème 4.6 (Inégalité de Minkowski). *Soient X, Y deux variables aléatoires réelles définies sur le même espace probabilisé. Soit $p \in [1, \infty)$. Supposons $\mathbb{E}|X|^p < \infty$ et $\mathbb{E}|Y|^p < \infty$. Alors*

$$(\mathbb{E}|X + Y|^p)^{1/p} \leq (\mathbb{E}|X|^p)^{1/p} + (\mathbb{E}|Y|^p)^{1/p}$$

ce qui entraîne $\mathbb{E}|X + Y|^p < \infty$.

La preuve de Théorème 4.6 découle de l'inégalité de Hölder (Théorème 4.5).

Preuve. L'inégalité ci-dessous découle aussi de l'inégalité triangulaire sur $\mathbb{R}$ et de la monotonie. La dernière égalité vient de la linéarité de l'espérance :

$$\begin{aligned}\mathbb{E}[|X + Y|^p] &\leq \mathbb{E}[(|X| + |Y|) \times |X + Y|^{p-1}] \\ &= \mathbb{E}[|X| \times |X + Y|^{p-1}] + \mathbb{E}[|Y| \times |X + Y|^{p-1}].\end{aligned}$$

Cela suffit pour traiter le cas $p = 1$.

Désormais, supposons $p > 1$. L'inégalité de Hölder entraîne l'inégalité suivante, et une majoration analogue pour $\mathbb{E}[|Y| \times |X + Y|^{p-1}]$.

$$\mathbb{E}[|X| \times |X + Y|^{p-1}] \leq \mathbb{E}[|X|^p]^{1/p} \times \mathbb{E}[|X + Y|^p]^{(p-1)/p}$$

En sommant les deux majorations, nous obtenons

$$\mathbb{E}[|X + Y|^p] \leq \left(\mathbb{E}[|X|^p]^{1/p} + \mathbb{E}[|Y|^p]^{1/p} \right) \times \mathbb{E}[|X + Y|^p]^{(p-1)/p}.$$

Cela prouve l'inégalité de Minkowski pour $p > 1$.

square

□

4.6 Médiane et écart interquartile

Indices robustes et non robustes de position.

Définition 4.5. Soit X une variable aléatoire réelle sur un espace probabilisé. Soit F sa fonction de répartition. La médiane de la loi de X est $F^{\leftarrow}(1/2)$.

La médiane minimise l'écart absolu moyen.

Proposition 4.3. Si m est tel que $P\{X > m\} = P\{X < m\}$, alors m est une médiane de la loi de X , et si X est intégrable :

$$\mathbb{E}|X - m| = \min_{a \in \mathbb{R}} \mathbb{E}|X - a|$$

Preuve. Supposons $a < m$,

$$\begin{aligned}\mathbb{E}[|X - a| - |X - m|] &= -(m - a)P(-\infty, a] + \int_{(a, m]} (2X - (a + m))dP(x) + (m - a)P(m, \infty) \\ &\geq -(m - a)P(-\infty, a] - (m - a)P(a, m] + (m - a)P(m, \infty) \\ &= (m - a)(P(m, \infty) - P(-\infty, m]) \\ &= 0.\end{aligned}$$

Le même raisonnement traite le cas $a > m$ et permet de conclure.

□

En combinant trois des inégalités que nous venons de démontrer, nous pouvons établir un lien intéressant entre espérance, médiane et écart-type.

Théorème 4.7 (Inégalité de Lévy). *Soit m la médiane de la loi de X , variable aléatoire de carré intégrable sur un espace probabilisé. Alors*

$$|m - \mathbb{E}X| \leq \sqrt{\text{var}(X)}.$$

Les indices robustes et non robustes de position diffèrent au plus de l'écart-type, qui peut être infini.

Preuve. Par convexité de $x \mapsto |x|$, nous avons

$$\begin{aligned} |m - \mathbb{E}X| &\leq \mathbb{E}|m - X| \\ &\quad \text{by Jensen's inequality} \\ &\leq \mathbb{E}|\mathbb{E}X - X| \\ &\quad \text{the median minimizes the mean absolute error} \\ &\leq \left(\mathbb{E}|\mathbb{E}X - X|^2 \right)^{1/2} \\ &\quad \text{by Cauchy-Schwarz inequality.} \end{aligned}$$

□

Remarque 4.4. L'espérance et la médiane peuvent différer. D'abord, la médiane est toujours définie, tandis que l'espérance peut ne pas l'être. Pensez par exemple à la loi de Cauchy standard, de densité $\frac{1}{\pi} \frac{1}{1+x^2}$ sur $\mathbb{R}$. Si X suit une loi de Cauchy, alors $\mathbb{E}|X| = \infty$. L'espérance n'est pas définie. Mais comme la densité est paire, X est symétrique (X et $-X$ ont la même loi), ce qui implique que la médiane de (la loi de) X vaut 0.

Considérons la loi exponentielle de densité $\exp(-x)$ sur $[0, \infty)$: espérance 1, médiane $\log(2)$, variance 1. Pour la loi exponentielle de densité $\lambda \exp(-\lambda x)$, l'espérance vaut $1/\lambda$, la médiane $\log(2)/\lambda$, et la variance $1/\lambda^2$. L'inégalité de Lévy n'apporte pas plus que ce que l'on peut calculer directement.

Enfin, considérons les lois Gamma de paramètre de forme p et d'intensité λ . L'espérance vaut p/λ , la variance p/λ^2 . La médiane n'est pas facile à calculer, mais l'on vérifie aisément qu'elle vaut $g(p)/\lambda$, où $g(p)$ est la médiane de la loi Gamma de paramètres p et 1. L'inégalité de Lévy nous dit que $|g(p) - p| \leq \sqrt{p}$.

4.7 Espaces $\mathcal{L}_p$ et L_p

Soit $p \in [1, \infty)$. Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé. Définissons $\mathcal{L}_p(\Omega, \mathcal{F}, P)$ (souvent abrégé en $\mathcal{L}_p(P)$ ou même $\mathcal{L}_p$ s'il n'y a pas d'ambiguïté) par

$$\mathcal{L}_p(\Omega, \mathcal{F}, P) = \left\{ X : X \text{ is a real random variable over } (\Omega, \mathcal{F}, P), \quad \mathbb{E}|X|^p < \infty \right\}.$$

$$\text{Posons } \|X\|_p = \left(\mathbb{E}|X|^p \right)^{1/p}.$$

Notons $\mathcal{L}_0(\Omega, \mathcal{F}, P)$ l'espace vectoriel des variables aléatoires sur $(\Omega, \mathcal{F}, P)$.

Nous observons d'abord que les ensembles $\mathcal{L}_p(\Omega, \mathcal{F}, P)$ forment une suite emboîtée.

Proposition 4.4. *Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé. Alors, pour $1 \leq p \leq q < \infty$:*

1. $\|X\|_p \leq \|X\|_q$.
2. $\mathcal{L}_q(\Omega, \mathcal{F}, P) \subset \mathcal{L}_p(\Omega, \mathcal{F}, P)$.

Preuve. Supposons $1 \leq p \leq q < \infty$. Comme $x \mapsto x^{q/p}$ est convexe sur $[0, \infty)$, par l'inégalité de Jensen (Théorème 4.3), nous avons

$$\mathbb{E}[|X|^p]^{q/p} \leq \mathbb{E}[|X|^q].$$

Cela établit 1.) Et 2.) est une conséquence immédiate de 1. □

Proposition 4.4 porte sur l'inclusion d'ensembles. Le théorème suivant résume plusieurs points : les ensembles $\mathcal{L}_p$ sont des sous-espaces vectoriels de $\mathcal{L}_0$, et ils sont complets en tant qu'espaces pseudo-métriques (pseudo-normés).

Théorème 4.8. *Pour $p \in [1, \infty)$, soient $\mathcal{L}_p(\Omega, \mathcal{F}, P)$ et $\|\cdot\|_p$ définis comme ci-dessus. Alors,*

1. $\mathcal{L}_p(\Omega, \mathcal{F}, P)$ est un sous-espace vectoriel de l'espace des variables aléatoires réelles.
2. $\|\cdot\|_p$ est une pseudo-norme sur $\mathcal{L}_p(\Omega, \mathcal{F}, P)$.
3. Si $(X_n)_n$ est une suite dans $\mathcal{L}_p(\Omega, \mathcal{F}, P)$ telle que

$$\lim_n \sup_{m \geq n} \|X_n - X_m\|_p = 0$$

alors il existe $X \in \mathcal{L}_p(\Omega, \mathcal{F}, P)$ tel que $\lim_n \|X_n - X\|_p = 0$.

4. Il existe une sous-suite $(X_{m_n})_n$ telle que $X_{m_n} \rightarrow X$ P -presque sûrement.

Remarque 4.5. Dans un espace pseudo-métrique, pour prouver qu'une suite de Cauchy converge, il suffit de vérifier la convergence d'une sous-suite.

En choisissant une sous-suite convenable, et en renumérotant éventuellement, on peut supposer $\|X_n - X_m\|_p \leq 2^{-n \wedge m}$ pour tous n, m .

Lemme 4.1 (Premier lemme de Borel-Cantelli). *Soit $(A_n)_n$ une suite d'événements d'un espace probabilisé $(\Omega, \mathcal{F}, P)$. Supposons $\sum_n P(A_n) < \infty$. Alors, avec probabilité 1, seulement un nombre fini d'événements A_n se réalisent :*

$$P\left\{\omega : \sum_n \mathbb{1}_{A_n}(\omega) < \infty\right\} = 1.$$

Preuve. L'événement $\{\omega : \sum_n \mathbb{1}_{A_n}(\omega) = \infty\}$ coïncide avec $\bigcap_n \bigcup_{m \geq n} A_m$:

$$P\left\{\sum_n \mathbb{I}_{A_n}(\omega) = \infty\right\} = P(\cap_n \cup_{m \geq n} A_m).$$

La suite $(\cup_{m \geq n} A_m)_n$ est décroissante : $\lim_n \downarrow \cup_{m \geq n} A_m = \cap_n \cup_{m \geq n} A_m$.
Par le lemme de Fatou,

$$\begin{aligned} \mathbb{E} \lim_m \mathbb{I}_{\cup_{m \geq n} A_m} &= \mathbb{E} \liminf_n \mathbb{I}_{\cup_{m \geq n} A_m} \\ &\leq \liminf_n \mathbb{E} \mathbb{I}_{\cup_{m \geq n} A_m} \\ &\leq \liminf_n \sum_{m \geq n} P(A_m) \\ &= 0. \end{aligned}$$

La dernière égalité vient du fait que les restes d'une série convergente tendent vers 0. $\square$

Preuve. Les points 1) et 2) découlent de l'inégalité de Minkowski. Cela entraîne que $\|\cdot\|_p$ définit une pseudo-norme sur $\mathcal{L}_p$. Si deux variables aléatoires X, Y de $\mathcal{L}_p$ satisfont $\|X - Y\|_p = 0$, alors $X = Y$ p.s.

Pour établir 3), il faut vérifier que la suite converge presque sûrement, et qu'une limite presque sûre appartient à $\mathcal{L}_p$.

Définissons l'événement A_n par

$$A_n = \left\{ \omega : |X_n(\omega) - X_{n+1}(\omega)| > \frac{1}{n^2} \right\}.$$

Par l'inégalité de Markov,

$$P(A_n) \leq \mathbb{E} \left[n^{2p} |X_n - X_{n+1}|^p \right] \leq n^{2p} 2^{-np}.$$

Donc $\sum_{n \geq 1} P(A_n) < \infty$. Par le premier lemme de Borel-Cantelli, sur un événement E de probabilité 1, seulement un nombre fini de A_n se réalisent.

Si $\omega \in E$, la condition $|X_n(\omega) - X_{n+1}(\omega)| > \frac{1}{n^2}$ n'est réalisée que pour un nombre fini d'indices n . Ainsi la suite réelle $(X_n(\omega))_n$ est de Cauchy. Elle admet une limite que nous notons $X(\omega)$. Si $\omega \notin E$, convenons que $X(\omega) = 0$. Sur Ω , nous avons

$$X(\omega) = \lim_n \mathbb{I}_E(\omega) X(\omega).$$

Une limite de variables aléatoires est une variable aléatoire. Donc X est une variable aléatoire.

Il reste à vérifier que $X \in \mathcal{L}_p$. Notons d'abord que

$$\left| \|X_m\|_p - \|X_n\|_p \right| \leq \|X_m - X_n\|_p.$$

Ainsi $(\|X_n\|_p)_n$ est une suite de Cauchy et converge vers une limite finie. Comme

$$|X(\omega)| \leq \liminf |X_n(\omega)|$$

par le lemme de Fatou

$$\mathbb{E}|X|^p \leq \liminf \mathbb{E}|X_n|^p < \infty.$$

Donc $X \in \mathcal{L}_p$.

Enfin, vérifions que $\lim_m \|X_n - X\|_p = 0$. Par le lemme de Fatou encore,

$$\mathbb{E}|X - X_m|^p \leq \liminf_n \mathbb{E}|X_n - X_m|^p$$

d'où

$$\lim_m \mathbb{E}|X - X_m|^p \leq \lim_m \liminf_n \mathbb{E}|X_n - X_m|^p = 0.$$

□

Remarque 4.6. Peut-on étendre la convergence presque sûre à toute la suite ? Ce n'est pas le cas. Considérons $([0, 1], \mathcal{B}([0, 1]), P)$ où P est la loi uniforme. Pour $k = j + n(n-1)/2$, $1 \leq j \leq n$, posons $X_n = \mathbb{I}_{[(j-1)/n, j/n]}$. La suite X_n converge vers 0 dans $\mathcal{L}_p$ pour tout $p \in [1, \infty)$. En effet $\|X_k\|_p = n^{-p}$ pour $k = j + n(n-1)/2$, $1 \leq j \leq n$. Pour tout $\omega \in [0, 1]$, la suite $X_n(\omega)$ oscille entre 0 et 1 une infinité de fois.

Les espaces $\mathcal{L}_p$ nous offrent un pont entre probabilités et analyse. En analyse, le fait que $\|\cdot\|_p$ ne soit qu'une pseudo-norme conduit à considérer les espaces L_p . Les espaces L_p sont définis à partir des espaces $\mathcal{L}_p$ en prenant des classes d'équivalence de variables aléatoires. Définissons la relation $\equiv$ sur $\mathcal{L}_p(\Omega, \mathcal{F}, P)$ par $X \equiv X'$ ssi $P\{X = X'\} = 1$. Cette relation est une relation d'équivalence (réflexive, symétrique et transitive). Si $X \equiv X'$ et $Y \equiv Y'$, alors $\|X - Y\|_p = \|X' - Y\|_p = \|X' - Y'\|_p$. $L_p(\Omega, \mathcal{F}, P)$ est l'espace quotient de $\mathcal{L}_p$ par la relation $\equiv$. Nous avons le résultat fondamental suivant.

Théorème 4.9. *Pour $p \in [1, \infty)$, $L_p(\Omega, \mathcal{F}, P)$ muni de $\|\cdot\|_p$ est un espace vectoriel normé complet (espace de Banach).*

Cela permet finalement d'invoquer des théorèmes d'analyse fonctionnelle.

4.8 Remarques bibliographiques

Chapitre 5

Familles de lois discrètes

L'objectif de cette leçon est de se familiariser avec d'importantes familles de lois discrètes et de maîtriser le calcul sur les lois. Les lois de probabilité discrètes seront présentées via les fonctions de répartition et surtout les fonctions de masse.

Dans cette leçon, l'univers Ω est un sous-ensemble de $\mathbb{N}^d$, fini ou dénombrable; la σ -algèbre naturelle à considérer est la partie 2^Ω .

5.1 Bernoulli et binomiale

Définition 5.1. Une loi de Bernoulli est une loi de probabilité P sur $\Omega = \{0, 1\}$. Le paramètre de P est $P\{1\} \in [0, 1]$.

Une loi de Bernoulli est entièrement déterminée par son paramètre.
L'espérance d'une loi de Bernoulli de paramètre p vaut p .

Définition 5.2 (Loi binomiale). Une loi binomiale de paramètres $n \in \mathbb{N}, p \in [0, 1]$ (n est la taille et p la probabilité de succès) est une loi de probabilité P sur $\Omega = \{0, 1, 2, \dots, n\}$, définie par

$$P\{k\} = \binom{n}{k} p^k (1-p)^{n-k}$$

Le lien entre les lois de Bernoulli et binomiale est évident : une loi de Bernoulli est une loi binomiale de taille 1. Ce lien va plus loin : la somme de variables aléatoires de Bernoulli indépendantes de même paramètre de succès suit une loi binomiale.

Supposons maintenant $\Omega' = \{0, 1\}^n$.

Proposition 5.1. Soient $X_1, X_2, \dots, X_n$ des variables aléatoires de Bernoulli indépendantes et de même loi, de paramètre de succès $p \in [0, 1]$. Alors $Y = \sum_{i=1}^n X_i$ suit

une loi binomiale de taille n et de probabilité de succès p .

Preuve. Il suffit de vérifier que les fonctions de masse coïncident.

Pour $k \in 0, \dots, n$

$$\begin{aligned}
 P\left\{\sum_{i=1}^n X_i = k\right\} &= \sum_{x_1, \dots, x_n \in \{0,1\}^n} \mathbb{I}_{\sum_{i=1}^n x_i = k} P\left\{\bigwedge_{i=1}^n X_i = x_i\right\} \\
 &= \sum_{x_1, \dots, x_n \in \{0,1\}^n} \mathbb{I}_{\sum_{i=1}^n x_i = k} \prod_{i=1}^n P\{X_i = x_i\} \\
 &= \sum_{x_1, \dots, x_n \in \{0,1\}^n} \mathbb{I}_{\sum_{i=1}^n x_i = k} \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \\
 &= \sum_{x_1, \dots, x_n \in \{0,1\}^n} \mathbb{I}_{\sum_{i=1}^n x_i = k} p^k (1-p)^{n-k} \\
 &= \binom{n}{k} p^k (1-p)^{n-k}.
 \end{aligned}$$

□

Cette observation facilite le calcul des *moments* de la loi binomiale.

L'espérance d'une loi de Bernoulli de paramètre p vaut p ! Sa variance vaut $p(1-p)$.

Par linéarité de l'espérance, l'espérance de la loi binomiale de paramètres n et p vaut np .

La variance d'une somme de variables aléatoires indépendantes est la somme des variances ; la variance de la loi binomiale de paramètres n et p vaut donc $np(1-p)$.

Plus d'informations sur [wikipedia](https://fr.wikipedia.org/wiki/Loi_binomiale).

Lois binomiales de même paramètre de succès

Proposition 5.2. Soient X, Y indépendantes sur l'espace probabilisé $(\Omega, \mathcal{F}, P)$ et de lois $\text{Bin}(n_1, p)$ et $\text{Bin}(n_2, p)$.

Alors $X + Y$ suit la loi $\text{Bin}(n_1 + n_2, p)$.

Exercice 5.1. Vérifier la proposition précédente.

5.2 Poisson

La loi de Poisson apparaît comme limite de lois binomiales dans diverses circonstances liées aux phénomènes d'événements rares.

Définition 5.3. Une loi de Poisson de paramètre $\lambda > 0$ est une loi de probabilité P sur $\Omega = \mathbb{N}$ avec




FIGURE 5.1 : Binomial probability mass functions with $n = 20$ and different values of p : .5, .7, .2.

$$P\{k\} = e^{-\lambda} \frac{\lambda^k}{k!}$$

L'espérance de la loi de Poisson de paramètre λ vaut λ . La variance d'une loi de Poisson est égale à son espérance.

$$\begin{aligned} \mathbb{E}X &= \sum_{n=0}^{\infty} e^{-\lambda} \frac{\lambda^n}{n!} \times n \\ &= \lambda \times \sum_{n=1}^{\infty} e^{-\lambda} \frac{\lambda^{n-1}}{(n-1)!} \\ &= \lambda. \end{aligned}$$

Proposition 5.3. Soient X, Y indépendantes et de lois de Poisson sur l'espace probabilisé $(\Omega, \mathcal{F}, P)$. Alors $X + Y$ suit une loi de Poisson.

Preuve. Nous vérifions la proposition de la manière la plus simple et la plus fastidieuse. Nous calculons la fonction de masse de la loi de $X + Y$. Supposons $X \sim \text{Po}(\lambda)$, $Y \sim \text{Po}(\mu)$.




FIGURE 5.2 : Poisson probability mass functions with different values of parameter : 1, 5, 10. Recall that the parameter of a Poisson distribution equals its expectation and its variance. The probability mass function of a Poisson distribution achieves its maximum (called the mode) close to its expectation.

Pour chaque $k \in \mathbb{N}$:

$$\begin{aligned}
 \Pr\{X + Y = k\} &= \Pr\left\{\bigvee_{m=0}^k (X = m \wedge Y = k - m)\right\} \\
 &= \sum_{m=0}^k \Pr\{X = m \wedge Y = k - m\} \\
 &= \sum_{m=0}^k \Pr\{X = m\} \times \Pr\{Y = k - m\} \\
 &= \sum_{m=0}^k e^{-\lambda} \frac{\lambda^m}{m!} e^{-\mu} \frac{\mu^{k-m}}{(k-m)!} \\
 &= e^{-\lambda-\mu} \frac{(\lambda + \mu)^k}{k!} \sum_{m=0}^k \frac{k!}{m!(k-m)!} \left(\frac{\lambda}{\lambda + \mu}\right)^m \left(\frac{\mu}{\lambda + \mu}\right)^{k-m} \\
 &= e^{-\lambda-\mu} \frac{(\lambda + \mu)^k}{k!} \sum_{m=0}^k \binom{k}{m} \left(\frac{\lambda}{\lambda + \mu}\right)^m \left(\frac{\mu}{\lambda + \mu}\right)^{k-m} \\
 &= e^{-\lambda-\mu} \frac{(\lambda + \mu)^k}{k!} \left(\frac{\lambda}{\lambda + \mu} + \frac{\mu}{\lambda + \mu}\right)^k \\
 &= e^{-(\lambda+\mu)} \frac{(\lambda + \mu)^k}{k!}
 \end{aligned}$$

La dernière expression est la fonction de masse de $\text{Po}(\lambda + \mu)$ en k . □

Exercice 5.2. Vérifier que le *mode* (maximum) d'une fonction de masse de Poisson de paramètre λ est atteint en $k = \lfloor \lambda \rfloor$. Est-il toujours unique ?

Exercice 5.3. Vérifier que la médiane d'une loi de Poisson de paramètre entier λ n'est pas inférieure à λ .

5.3 Géométrie

Une loi géométrique est une loi de probabilité sur $\mathbb{N} \subset \{0, 1\}$. Elle dépend d'un paramètre $p > 0$.

Supposons que nous puissions lancer une pièce biaisée une infinité de fois. Le nombre de lancers nécessaires *jusqu'à* obtenir un *pile* suit une loi géométrique.

Soit X de loi géométrique de paramètre p . La loi géométrique se définit aisément par sa *fonction de queue*. Dans l'événement $X > k$, les k premiers résultats doivent être des *faces*.

$$P\{X > k\} = (1 - p)^k$$

La fonction de masse de la loi géométrique s'en déduit :

$$P\{X = k\} = (1 - p)^{k-1} - (1 - p)^k = p \times (1 - p)^{k-1} \quad \text{for } k = 1, 2, \dots$$

En moyenne, il faut lancer la pièce p fois jusqu'à obtenir un *pile* :

$$\mathbb{E}X = \sum_{k=0}^{\infty} P\{X > k\} = \frac{1}{p}$$

Il est aussi possible de définir les variables aléatoires géométriques comme le nombre de lancers nécessaires *avant* d'obtenir un *pile*. Cela nécessite de modifier la fonction quantile, la fonction de masse, l'espérance, et ainsi de suite. C'est la convention utilisée par R.




FIGURE 5.3 : Geometric probability mass functions with different values of parameter p : $1/2, 1/3, 1/5$. The probability mass function equals $p \times (1 - p)^{k-1}$ at $k \geq 1$. The mode is achieved at $k = 1$ whatever the value of p . The expectation equals $1/p$

Les sommes de variables aléatoires géométriques indépendantes ne suivent pas une loi géométrique.

Chapitre 6

Caractérisations des lois de probabilité discrètes

6.1 Motivation

En toute généralité, une loi de probabilité est un objet complexe. C'est une fonction à valeurs dans $[0, 1]$ définie sur une σ -algèbre de sous-ensembles. Une σ -algèbre concrète, sans parler de la notion abstraite de σ -algèbre, n'est pas facile à appréhender. Chercher des caractérisations plus simples des lois de probabilité est un objectif raisonnable. Face à des questions du type : « deux lois de probabilité sont-elles égales ? », nous savons qu'il suffit de vérifier qu'elles coïncident sur des familles engendrant des événements. Les fonctions de répartition cumulatives sont alors des outils précieux. Les fonctions de répartition cumulatives et leurs inverses généralisés (fonctions quantiles) sont très pratiques pour traiter des maxima, minima, ou plus généralement des statistiques d'ordre de collections de variables aléatoires indépendantes, mais lorsqu'il s'agit de traiter des sommes de variables aléatoires indépendantes ou des processus de branchement, les fonctions de répartition cumulatives sont d'une aide modérée.

Dans cette leçon, nous passons en revue une manière de caractériser les lois de probabilité sur $(\mathbb{N}, \mathcal{F} = 2^{\mathbb{N}})$ à l'aide de fonctions définies sur la droite réelle : les fonctions génératrices de probabilité (Section 6.2). Plus tard (Chapitre Chapitre 12), nous examinerons des outils plus généraux : les transformées de Laplace (Section 12.2) et les fonctions caractéristiques, qui étendent les transformées de Fourier aux lois de probabilité (Section 12.3)).

Ces trois méthodes diffèrent par leur portée, mais elles reposent sur la même idée et partagent des propriétés communes. En effet, les fonctions génératrices de probabilité peuvent être vues comme un cas particulier des transformées de Laplace. Ces dernières peuvent être vues comme des cas particuliers des transformées de Fourier.

Ces trois méthodes *caractérisent* les lois de probabilité. Elles sont munies de *formules d'inversion*. Elles nous offrent un traitement fluide des sommes de variables aléatoires indépendantes.

Ces trois méthodes relient l'intégrabilité des lois de probabilité et la régularité des transformées.

Les fonctions génératrices de probabilité, les transformées de Laplace et les fonctions caractéristiques apportent un important appareil analytique à la théorie des probabilités. De l'analyse, nous tirons des arguments prêts à l'emploi pour établir des propriétés de régularité des transformées, et avec un peu plus de travail, nous pouvons construire les formules d'inversion.

6.2 Fonction génératrice de probabilité

Dans cette section, X est une variable aléatoire à valeurs entières, de loi P , de fonction de répartition F et de fonction de masse p . Rappelons que P est entièrement caractérisée par les objets plus simples F et p . Soit maintenant Y une autre variable aléatoire à valeurs entières vivant sur le même espace probabilisé que X , indépendante de X , de loi Q , de fonction de répartition G et de fonction de masse q . Que pouvons-nous dire de la loi de $X + Y$? Est-il facile de déterminer sa fonction de répartition cumulative, sa fonction de masse ?

La fonction de masse de (la loi de) $X + Y$ est la *convolution* de p et q

$$\begin{aligned}\mathbb{P}\{X + Y = n\} &= \sum_{k=0}^n \mathbb{P}\{X + Y = n \wedge X = k\} \\ &= \sum_{k=0}^n \mathbb{P}\{Y = n - k \wedge X = k\} \\ &= \sum_{k=0}^n p(k)q(n - k) \\ &= p \star q(n) .\end{aligned}$$

Une autre fonction caractérise les lois de probabilité et fournit immédiatement des informations sur la loi des sommes de variables aléatoires à valeurs entières indépendantes et bien d'autres choses encore.

Définition 6.1 (Fonction génératrice de probabilité). La fonction génératrice de probabilité (FGP) d'une loi de probabilité sur $\mathbb{N}$, définie par sa fonction de masse (FM) f , est la fonction $G : [0, 1] \rightarrow \mathbb{R}$ définie par :

$$G(s) = \sum_{n=0}^{\infty} f(n)s^n .$$

Exemple 6.1. La fonction génératrice de probabilité des lois discrètes élémentaires se calcule aisément. Les résultats sont utiles et suggestifs.

— Loi de Bernoulli de paramètre p :

$$G(s) = (1 - p)s^0 + ps^1 = 1 + p(s - 1)$$

— Loi binomiale de paramètres n et p :

$$G(s) = \sum_{k=0}^n \binom{n}{k} p^k (1 - p)^{n-k} s^k = (ps + 1 - p)^n = (1 + p(s - 1))^n$$

— Loi de Poisson de paramètre μ :

$$G(s) = \sum_{n=0}^{\infty} e^{-\mu} \frac{\mu^n}{n!} s^n = e^{\mu(s-1)}.$$

Notez que si $p = \mu/n$ et $n \uparrow \infty$:

$$\lim_{n \uparrow \infty} \left(1 + \frac{\mu}{n}(s-1)\right)^n = e^{\mu(s-1)}.$$

Nous reviendrons sur cette observation plus tard.

L'observation suivante découle presque immédiatement de la définition des fonctions génératrices de probabilité.

Proposition 6.1. *Une fonction génératrice de probabilité G satisfait les conditions suivantes :*

- G est non négative sur $[0, 1]$;
- $G(0) = P\{0\}$, $G(1) = 1$;
- G est non décroissante sur $[0, 1]$;
- G est continue et convexe.

Preuve. Les propriétés 1), 2) et 3) sont évidentes : G est une combinaison convexe de fonctions non négatives, non décroissantes, continues et convexes. $\square$

6.3 Formule d'inversion

La *généralologie* se situe au carrefour de la combinatoire, de l'analyse réelle, de l'analyse complexe et de la théorie des probabilités. Définir la FGP comme une *série entière* introduit en théorie des probabilités un ensemble de théorèmes qui facilitent l'identification des lois de probabilité ou qui relient les propriétés d'intégrabilité de la loi aux propriétés de régularité de la FGP.

Gardez à l'esprit qu'une fonction génératrice définit une fonction de l'ensemble des nombres complexes $\mathbb{C}$ vers $\mathbb{C}$:

$$G(z) = \sum_{n=0}^{\infty} p(n)z^n \quad \text{for all } z \in \mathbb{C} \text{ such that the series converges.}$$

Caractériser le domaine d'une fonction définie de cette manière est crucial. La proposition suivante est au cœur de la théorie des séries entières.

Proposition 6.2. *Le rayon de convergence de la fonction génératrice G*

$$G(z) = \sum_{n \in \mathbb{N}} p(n)z^n, \quad z \in \mathbb{C}$$

est l'unique $R \in [0, \infty) \cup \{+\infty\}$ tel que :

- pour tout $z \in \mathbb{C}$ avec $|z| > R$, la série $\sum_{n \in \mathbb{N}} p(n)z^n$ diverge.
- pour tout $z \in \mathbb{C}$ avec $|z| < R$, la série $\sum_{n \in \mathbb{N}} p(n)z^n$ est absolument convergente.

Le disque ouvert $\{z : z \in \mathbb{C}, |z| < R\}$ est appelé le disque de convergence de G . Le cercle $\{z : z \in \mathbb{C}, |z| = R\}$ est appelé le cercle de convergence de G .

Preuve.

□

La règle d'Hadamard permet de déterminer rapidement le rayon de convergence :

Proposition 6.3 (Règle d'Hadamard). *Le rayon de convergence R de la fonction génératrice de probabilité $G(z) = \sum_{n \in \mathbb{N}} p(n)z^n$ satisfait*

$$\frac{1}{R} = \limsup_n (p(n))^{1/n}.$$

Le rayon de convergence d'une fonction génératrice de probabilité est toujours au moins 1.

Le rayon de convergence contient des informations qualitatives sur le comportement de la queue :

- Pour les lois de Poisson, le rayon de convergence est infini. Cela reflète la décroissance rapide des probabilités de queue des lois de Poisson.
- Pour les lois géométriques, $p(n) = q(1 - q)^{n-1}$, le rayon de convergence vaut $1/(1 - q)$.
- Pour des lois en loi de puissance comme $p(n) = n^{-r}/\zeta(r)$ avec $r > 1$, le rayon de convergence vaut exactement 1.

Preuve.

□

Le simple fait de connaître le rayon de convergence d'une fonction définie par un développement en série entière nous renseigne sur les propriétés de régularité de la fonction.

Si G est définie comme une série entière $G(z) = \sum_{n \in \mathbb{N}} a_n z^n$, sa dérivée (complexe) est $G'(z) = \sum_{n \in \mathbb{N}} (n + 1)a_{n+1} z^n$. La dérivée G' et G ont le même rayon de convergence.

Preuve.

□

Cette affirmation générale sur les séries entières entraîne un corollaire très utile pour les fonctions génératrices de probabilité.

Corollaire 6.1 (Formule d'inversion). *Soit g la fonction génératrice de probabilité associée à la fonction de masse f . Alors g est infiniment dérivable sur $[0, 1)$ avec des*

dérivées

$$g^{(n)}(s) = \sum_{k=n}^{\infty} \frac{k!}{(k-n)!} \times f(k) s^{k-n},$$

plus précisément :

$$g^{(n)}(0) = n! \times f(n).$$

Une loi de probabilité sur $\mathbb{N}$ est caractérisée par sa fonction génératrice de probabilité.

Preuve. La propriété est vraie pour $n = 0$.

Supposons qu'elle soit vraie pour tous les entiers jusqu'à n . Pour $s \in [0, 1)$ et $|h| < 1 - s - \delta$ où δ est un petit nombre positif,

$$\frac{g^{(n)}(s+h) - g^{(n)}(s)}{h} = \sum_{k=n}^{\infty} \frac{k!}{(k-n)!} \times f(k) \left(\sum_{j=0}^{k-n-1} (s+h)^{k-n-1-j} s^j \right)$$

La valeur absolue de la somme interne est inférieure à $(k-n)(1-\delta)^{k-n-1}$. Comme

$$\sum_{k=n}^{\infty} \frac{k!}{(k-n-1)!} \times p(k) \times (1-\delta)^{k-n-1} < \infty$$

pour tout $0 < \delta < 1$. Par le théorème de convergence dominée,

$$\lim_{h \rightarrow 0} \frac{g^{(n)}(s+h) - g^{(n)}(s)}{h} = \sum_{k=n+1}^{\infty} \frac{k!}{(k-n-1)!} \times f(k) \times s^{k-n-1}.$$

□

Exemple 6.2. La fonction génératrice de probabilité d'une loi de Poisson de paramètre μ vaut $\exp(\mu(s-1))$.

$$\begin{aligned} g(s) &= \sum_{k=0}^{\infty} e^{-\mu} \frac{\mu^k}{k!} s^k \\ &= e^{-\mu} \times e^{\mu s}. \end{aligned}$$

Si nous rencontrons une loi de probabilité avec une telle FGP, nous savons qu'il s'agit d'une loi de Poisson (de paramètre μ).

6.4 Sommes de variables aléatoires indépendantes et fonctions génératrices de probabilité

Les fonctions génératrices de probabilité nous offrent un outil pratique pour étudier les sommes de variables aléatoires indépendantes.

Proposition 6.4. Soient X, Y des variables aléatoires à valeurs entières indépendantes, de fonctions génératrices de probabilité G_X et G_Y . La fonction génératrice de probabilité G_{X+Y} de $X + Y$ vaut $G_X \times G_Y$:

$$G_{X+Y} = G_X \times G_Y.$$

Preuve. La preuve repose sur le fait que les séries convergentes non négatives sont commutativement convergentes.

Pour tout n :

$$\{\omega : X(\omega) + Y(\omega) = n\} = \cup_{k=0}^n \{\omega : X(\omega) = k \text{ et } Y(\omega) = n - k\}.$$

L'union au membre de droite est une union disjointe.

$$\begin{aligned} \sum_{n=0}^{\infty} \mathbb{P}\{X + Y = n\} \times s^n &= \sum_{n=0}^{\infty} \left(\sum_{k=0}^n \mathbb{P}\{X = k\} \times \mathbb{P}\{Y = n - k\} \right) s^n \\ &= \sum_{k=0}^{\infty} \mathbb{P}\{X = k\} s^k \sum_{n \geq k}^{\infty} \mathbb{P}\{Y = n - k\} s^{n-k} \\ &= G_X(s) \times G_Y(s). \end{aligned}$$

□

En langage de la théorie de la mesure, la proposition est une conséquence du théorème de Tonelli-Fubini :

$$\begin{aligned} G_{X+Y}(s) &= \mathbb{E}[s^{X+Y}] \\ &= \mathbb{E}[s^X \times s^Y] \\ &= \int_{\mathbb{R}^2} s^x s^y dP_X \otimes P_Y(x, y) \\ &= \int_{\mathbb{R}} \int_{\mathbb{R}} s^x s^y dP_X(x) dP_Y(y) \\ &= \int_{\mathbb{R}} s^y \int_{\mathbb{R}} s^x dP_X(x) dP_Y(y) \\ &= \int_{\mathbb{R}} s^y G_X(s) dP_Y(y) \\ &= G_X(s) \times G_Y(s). \end{aligned}$$

Exemple 6.3. Si X et Y sont des variables aléatoires de Poisson indépendantes de paramètres μ et ν , alors $G_{X+Y}(s) = \exp(\mu(s-1)) \times \exp(\nu(s-1)) = \exp((\mu + \nu)(s-1))$. C'est une autre preuve que $X + Y$ suit une loi de Poisson de paramètre $\mu + \nu$.

6.5 Régularité et intégrabilité

Une FGP est infiniment dérivable à l'intérieur du disque de convergence (ouvert). Si le rayon de convergence est strictement supérieur à 1 (comme pour les lois de Poisson ou géométriques), cela entraîne que la FGP est infiniment dérivable en 1. Si le rayon de convergence vaut exactement 1, la différentiabilité sur le cercle de convergence n'est pas prescrite par la théorie générale.

Théorème 6.1 (Intégrabilité et fonctions génératrices de probabilité). *Soit X une variable aléatoire à valeurs entières, de fonction génératrice de probabilité f . Alors $\mathbb{E}X^p < \infty$ si et seulement si f est p fois dérivable en 1 et*

$$f^{(p)}(1) = \mathbb{E}[X(X-1) \dots (X-p+1)] .$$

Preuve. Supposons que G soit p fois dérivable à gauche en 1.

Il faut établir que $|X|$ est p -intégrable.

Supposons que $|X|$ soit p -intégrable.

□

La question suivante se pose rapidement : quand une fonction de $[0, 1]$ vers $[0, \infty)$ est-elle une fonction génératrice de probabilité ? Cette question sera traitée plus tard dans une perspective plus large.

:::: : {content-hidden unless-profile="WIP"}

6.6 FGP pour les lois jointes {#sec-multivariate=pgfs}

Définition 6.2 (Fonction génératrice de probabilité multivariée).

$$G_{X,Y}(s, t) = \mathbb{E}[s^X t^Y] \quad \text{for } s, t \in [0, 1]$$

6.7 Lois composées

Définition 6.3 (Loi composée).

$$Y = \sum_{i=1}^X Z_i$$

$$G_Y(s) = G_X \circ G_Z(s)$$

Application : éclaircissement de Poisson

:::: :

Chapitre 7

Lois produit

Dans cette leçon, nous construisons des *mesures produit*. Nous partons de deux espaces mesurés $(\mathcal{X}, \mathcal{F}, \mu)$ et $(\mathcal{Y}, \mathcal{G}, \nu)$.

Notre objectif est de construire un espace mesuré $(\mathcal{X} \times \mathcal{Y}, \mathcal{H}, \rho)$ et deux fonctions mesurables $X : \mathcal{X} \times \mathcal{Y} \rightarrow \mathcal{X}$ et $Y : \mathcal{X} \times \mathcal{Y} \rightarrow \mathcal{Y}$ avec les propriétés supplémentaires

$$\mu = \rho \circ X^{-1} \quad \text{and} \quad \nu = \rho \circ Y^{-1}$$

ainsi que

$$\rho(A \times B) = \mu(A) \times \nu(B) \quad \forall A \in \mathcal{F}, B \in \mathcal{G}.$$

Notez qu'exiger que X et Y soient mesurables est prématuré : nous n'avons pas encore défini la σ -algèbre $\mathcal{H}$ sur $\mathcal{X} \times \mathcal{Y}$.

7.1 σ -algèbres produit

Pour atteindre notre objectif, nous définissons d'abord une σ -algèbre $\mathcal{H}$ de sous-ensembles de $\mathcal{X} \times \mathcal{Y}$. Nous utilisons la *σ -algèbre produit*.

Définition 7.1 (σ -algèbre produit). Soient $(\mathcal{X}, \mathcal{F})$ et $(\mathcal{Y}, \mathcal{G})$ deux espaces mesurables. La σ -algèbre produit $\mathcal{F} \otimes \mathcal{G}$ est la σ -algèbre de sous-ensembles de $2^{\mathcal{X} \times \mathcal{Y}}$ engendrée par les *rectangles* :

$$\{A \times B : A \in \mathcal{F}, B \in \mathcal{G}\}.$$

En d'autres termes,

$$\mathcal{F} \otimes \mathcal{G} = \sigma(\mathcal{F} \times \mathcal{G})$$

Proposition 7.1. La σ -algèbre produit rend les fonctions X et Y (parfois appelées projections coordonnées) mesurables.

Exercice 7.1. Vérifier Proposition 7.1.

Exercice 7.2. Vérifier que la σ -algèbre borélienne sur $\mathbb{R}^2$ (la σ -algèbre engendrée par les ouverts de $\mathbb{R}^2$) peut être décrite comme une σ -algèbre produit (la σ -algèbre engendrée par le produit cartésien de $\mathcal{B}(\mathbb{R})$ avec elle-même). En d'autres termes,

$$\mathcal{B}(\mathbb{R}^2) = \sigma(\mathcal{B}(\mathbb{R}) \times \mathcal{B}(\mathbb{R}))$$

7.2 Mesures produit

Une fois munis des σ -algèbres produit, nous pouvons passer à la définition des mesures produit.

Rappelons la définition des mesures σ -finies de Section 2.6).

Une mesure μ sur $(\Omega, \mathcal{F})$ est σ -finie si et seulement s'il existe $(A_n)_n$ avec $\Omega \subseteq \bigcup_n A_n$ et $\mu(A_n) < \infty$ pour chaque n .

Les mesures finies (ce qui englobe les lois de probabilité) sont σ -finies. La mesure de Lebesgue est σ -finie. La mesure de comptage sur $\mathbb{R}$ n'est pas σ -finie.

Théorème 7.1. Soient $(X, \mathcal{F}, \mu)$ et $(Y, \mathcal{G}, \nu)$ deux espaces mesurés où μ, ν sont σ -finies. Alors il existe une mesure unique σ -finie α sur $X \times Y$ muni de la σ -algèbre produit $\mathcal{F} \otimes \mathcal{G} = \sigma(\mathcal{F} \times \mathcal{G})$ qui satisfait

$$\alpha(A \times B) = \mu(A) \times \nu(B) \quad \forall A \in \mathcal{F}, B \in \mathcal{G}.$$

De plus, pour tout $E \in \mathcal{F} \otimes \mathcal{G}$,

1. pour chaque $x \in X$, $y \mapsto \mathbb{I}_E(x, y)$ est $\mathcal{G}$ -mesurable;
2. $x \mapsto \int_Y \mathbb{I}_E(x, y) d\nu(y)$ est $\mathcal{F}$ -mesurable;
3. pour chaque $y \in Y$, $x \mapsto \mathbb{I}_E(x, y)$ est $\mathcal{F}$ -mesurable;
4. $y \mapsto \int_X \mathbb{I}_E(x, y) d\mu(x)$ est $\mathcal{G}$ -mesurable,

et l'on a :

$$\begin{aligned} \int_{X \times Y} \mathbb{I}_E d\alpha &= \int_X \left(\int_Y \mathbb{I}_E(x, y) d\nu(y) \right) d\mu(x) \\ &= \int_Y \left(\int_X \mathbb{I}_E(x, y) d\mu(x) \right) d\nu(y) \end{aligned}$$

où les trois intégrales sont soit finies, soit infinies.

La mesure α est appelée une mesure produit; elle est parfois notée $\mu \otimes \nu$.

Remarque 7.1. L'hypothèse que μ et ν sont toutes deux σ -finies est essentielle. Choisissons μ comme la mesure de comptage sur $[0, 1]$ et ν comme la mesure de Lebesgue sur $[0, 1]$.

7.3. THÉORÈME DE TONELLI-FUBINI

Considérons la diagonale $E = \{(x, x) : x \in [0, 1]\}$. L'ensemble E appartient à $\mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R}) = \mathcal{B}(\mathbb{R}^2)$ (vérifier cela). Mais l'interversion de l'ordre d'intégration conduit à des résultats différents :

$$\begin{aligned} 1 &= \int_{[0,1]} \left(\int_{[0,1]} \mathbb{1}_E(x, y) \, d\mu(x) \right) d\nu(y) \\ 0 &= \int_{[0,1]} \left(\int_{[0,1]} \mathbb{1}_E(x, y) \, d\nu(y) \right) d\mu(x) \end{aligned}$$

Le Théorème 7.1 contient trois affirmations :

- existence d'une mesure sur $(\mathcal{X} \times \mathcal{Y}, \mathcal{F} \otimes \mathcal{G})$ qui satisfait la propriété produit sur les rectangles;
- unicité de cette mesure;
- la possibilité de calculer la mesure de $E \in \mathcal{F} \otimes \mathcal{G}$ par intégration itérée dans un ordre arbitraire.

La première affirmation (existence) est démontrée à l'aide d'un théorème de prolongement; la seconde (unicité) découle d'un argument de classe monotone (Théorème 2.4) : les rectangles forment une classe π engendrant, ce qui règle le cas où μ et ν sont des mesures finies. Si μ ou ν n'est que σ -finie, on considère des restrictions aux rectangles de mesure finie, puis on procède par approximation. La troisième affirmation est triviale pour les rectangles.

Remarque 7.2. Si μ, ν sont des lois de probabilité, alors la mesure produit $\mu \otimes \nu$ est une loi de probabilité; on l'appelle une loi de probabilité produit.

7.3 Théorème de Tonelli-Fubini

Dans cette section, nous considérons des mesures produit construites à partir de mesures σ -finies comme dans le Théorème 7.1). Le théorème de Tonelli-Fubini montre que (sous des conditions légères) l'intégration par rapport à une mesure produit se réduit à une intégration itérée sur les mesures composantes.

Théorème 7.2 (Tonelli-Fubini). Soient $(\mathcal{X}, \mathcal{A})$ et $(\mathcal{Y}, \mathcal{B})$ deux espaces mesurables, μ et ν deux mesures σ -finies sur ces espaces, $\mu \otimes \nu$ la mesure produit, et f une fonction réelle $\mathcal{A} \otimes \mathcal{B}$ -mesurable telle que $\int |f| d\mu \otimes \nu < \infty$. Les propriétés suivantes sont satisfaites :

- $\forall x \in \mathcal{X}, \quad y \mapsto f(x, y)$ est $\mathcal{B}$ -mesurable.
- La fonction $x \mapsto \int_{\mathcal{Y}} f(x, y) d\nu(y)$ est $\mathcal{A}$ -mesurable, finie μ -presque partout et

$$\int_{\mathcal{X} \times \mathcal{Y}} f d\mu \otimes \nu = \int_{\mathcal{X}} \left[\int_{\mathcal{Y}} f(x, y) d\nu(y) \right] d\mu(x)$$

Preuve. La preuve peut être trouvée dans

La preuve consiste à établir l'affirmation pour des classes de plus en plus larges de fonctions mesurables.

CHAPITRE 7. LOIS PRODUIT

Notez d'abord que Théorème 7.1 règle le cas des indicatrices de sous-ensembles mesurables de $\mathcal{X} \times \mathcal{Y}$.

À partir de cette observation, en utilisant la linéarité, on traite les fonctions simples positives. Puis le cas des fonctions mesurables non négatives sur $\mathcal{X} \times \mathcal{Y}$ utilise un argument de convergence monotone (Théorème 3.1).

Le cas général est traité en décomposant la fonction mesurable en somme d'une partie positive et d'une partie négative. $\square$

La caractérisation suivante de l'espérance de variables aléatoires non négatives comme intégrale de la fonction de queue est une conséquence simple du théorème de Tonelli-Fubini.

Proposition 7.2 (Formule IPP). *Soit X une variable aléatoire réelle non négative. Alors*

$$\mathbb{E}X = \int_0^\infty P\{X > t\} dt$$

Preuve.

$$\begin{aligned} \mathbb{E}X &= \int_{\Omega} X(\omega) dP(\omega) \\ &= \int_{\Omega} \left(\int_{[0, \infty)} \mathbb{1}_{X(\omega) > t} dt \right) dP(\omega) \\ &= \int_{[0, \infty)} \left(\int_{\Omega} \mathbb{1}_{X(\omega) > t} dP(\omega) \right) dt \\ &= \int_{[0, \infty)} \left(P\{\omega : X(\omega) > t\} \right) dt \end{aligned}$$

$\square$

7.4 Lois jointes, indépendance et lois produit

Soient les deux variables aléatoires X, Y de $(\Omega, \mathcal{F})$ vers $(\mathcal{X}, \mathcal{G})$ et $(\mathcal{Y}, \mathcal{H})$. Munissons $(\Omega, \mathcal{F})$ de la loi de probabilité P . Soient $Q_X = P \circ X^{-1}$ et $Q_Y = P \circ Y^{-1}$ les deux lois image (appelées les lois *marginales*). Nous pouvons définir une application $Z : \Omega \rightarrow \mathcal{X} \times \mathcal{Y}$ par $Z(\omega) = (X(\omega), Y(\omega))$; cette application est $\mathcal{F}/\sigma(\mathcal{G} \times \mathcal{H})$ mesurable.

Soit Q la *loi jointe* de $Z = (X, Y)$ sous P , c'est-à-dire la loi de probabilité sur $\mathcal{X} \times \mathcal{Y}$ muni de $\sigma(\mathcal{G} \times \mathcal{H})$ qui est uniquement définie par

$$Q(A \times B) = P\{\omega : X(\omega) \in A, Y(\omega) \in B\}.$$

Notez que Q n'est pas nécessairement une loi produit.

La proposition (triviale) suivante nous dit que deux variables aléatoires sont indépendantes si et seulement si leur loi jointe est une loi produit (en fait la loi produit définie par les deux lois marginales).

$$X \perp\!\!\!\perp Y \text{ under } P \iff Q = Q_X \otimes Q_Y,$$

en d'autres termes, X et Y sont indépendantes si et seulement si leur loi jointe est le produit de leurs lois marginales.

Preuve. TODO : FIX THIS □

7.5 Indépendance de collections de σ -algèbres

Dans de nombreuses applications, l'indépendance entre deux σ -algèbres ou une collection finie de σ -algèbres ne suffit pas. C'est le cas lorsque l'on démontre ou utilise des lois des grands nombres. Nous devons traiter une *collection dénombrable de variables aléatoires indépendantes*. En d'autres termes, nous devons travailler avec une collection dénombrable de σ -algèbres et élaborer une notion de collection dénombrable de σ -algèbres indépendantes.

Définition 7.2. Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé. Soient $\mathcal{G}_1, \dots, \mathcal{G}_n, \dots$ une collection dénombrable de sous- σ -algèbres.

La collection $\mathcal{G}_1, \dots, \mathcal{G}_n, \dots$ est dite indépendante au sens de P

si

toute sous-collection *finie* est indépendante au sens de P .

Exemple 7.1. Considérons la loi uniforme sur $[0, 1]$ et définissons $X_1, X_2, \dots$ par

$$X_n(\omega) = \text{sign} \left(\sin(2^{n+1}\pi\omega) \right)$$

alors $X_1, \dots, X_n, \dots$ forment une collection dénombrable de variables aléatoires indépendantes.

7.6 Espaces produits infinis

Dans de nombreux scénarios de modélisation (marches aléatoires, processus de branchement, statistique asymptotique, ...), nous nous appuyons sur la disponibilité d'une collection infinie de variables aléatoires indépendantes. Alors qu'il est (relativement) facile de concevoir la notion d'espaces probabilisés produits finis, la notion d'espaces probabilisés produits infinis est plus délicate. Et cela reste vrai même si les composantes individuelles sont des espaces probabilisés finis (par exemple $\{0, 1\}$, muni de la partie et de la loi uniforme).

Pensons à $\Omega_i = \{0, 1\}$ et supposons que chaque P_i suit la loi de Bernoulli équilibrée. Soit ω une suite infinie de 0 et 1; $\{\omega\} = \prod_{i=1}^{\infty} \{\omega_i\}$ est un produit cartésien infini d'événements de probabilité $1/2$. Quelle devrait être sa probabilité dans l'espace probabilisé produit infini? Existe-t-il un moyen d'attribuer des probabilités de manière cohérente? Si la réponse est positive, cette opération est-elle unique?

Définition 7.3 (σ -algèbre cylindrique). Soit $(\Omega_n, \mathcal{F}_n)_n$ une collection dénombrable d'espaces mesurables. La σ -algèbre cylindrique est la σ -algèbre de sous-ensembles de $\prod_{n=1}^{\infty} \Omega_n$ engendrée par les sous-ensembles de la forme :

$$\prod_{n=1}^m A_n \times \prod_{n=m+1}^{\infty} \Omega_n \quad \text{with } A_n \in \mathcal{F}_n \text{ for } n \leq m$$

où m est un entier quelconque. Ces sous-ensembles sont appelés *rectangles de dimension finie* ou *cylindres*.

Observez que les cylindres forment une classe π (vérifier la définition dans Section 2.6).

Si chaque $(\Omega_n, \mathcal{F}_n)$ est muni d'une loi de probabilité, attribuer une probabilité aux cylindres semble direct :

$$\mathbb{P} \left(\prod_{n=1}^m A_n \times \prod_{n=m+1}^{\infty} \Omega_n \right) = \prod_{n=1}^m P_n(A_n) \times \prod_{n=m+1}^{\infty} P_n(\Omega_n) = \prod_{n=1}^m P_n(A_n).$$

La question est : $\mathbb{P}$ se prolonge-t-elle à la σ -algèbre cylindrique ? Si un prolongement existe, est-il unique ? La réponse est oui.

Théorème 7.3 (Théorème de prolongement (version simple)). *Soit $(\Omega_n, \mathcal{F}_n, P_n)_n$ une collection dénombrable d'espaces probabilisés. Alors il existe une loi de probabilité unique $\mathbb{P}$ sur la σ -algèbre cylindrique qui satisfait :*

$$\mathbb{P} \left(\prod_{n=1}^m A_n \times \prod_{n=m+1}^{\infty} \Omega_n \right) = \prod_{n=1}^m P_n(A_n)$$

pour toute suite finie $A_1, \dots, A_m$ dans $\mathcal{F}_1 \times \dots \times \mathcal{F}_m$.

7.7 Remarques bibliographiques

Le matériel couvrant cette leçon se trouve dans tout ouvrage sur la théorie de la mesure et de l'intégration. La section 4.4 de (Dudley, 2002) est consacrée aux mesures produit.

Des preuves complètes du théorème de Tonelli-Fubini se trouvent dans (Dudley, 2002).

Le théorème d'existence pour les probabilités produit infinies provient de la section 8.2 de (Dudley, 2002). Une preuve complète du théorème s'y trouve.

Chapitre 8

Indépendance et espaces produits

8.1 Feuille de route

L'indépendance entre événements, variables aléatoires et, plus généralement, σ -algèbres est au cœur de nombreuses constructions et résultats en théorie des probabilités. Les lois des grands nombres, les théorèmes centraux limites et les inégalités de concentration sont d'abord énoncés et démontrés lorsque l'on traite des collections potentiellement infinies de variables aléatoires indépendantes. Les résultats que l'on peut établir pour des collections de variables aléatoires indépendantes constituent une référence. Une grande partie de la théorie des martingales ou de la théorie des chaînes de Markov est consacrée à l'extension des lois des grands nombres, des théorèmes centraux limites et des inégalités de concentration.

Nous rappelons d'abord la définition d'événements indépendants. Cette notion est élémentaire et utile. Dans Section 8.3, la notion d'indépendance est étendue aux σ -algèbres et aux variables aléatoires. Nous observons que la vérification de l'indépendance entre σ -algèbres est facilitée par le théorème de la classe monotone (Théorème 2.4). Enfin, nous étendons la notion d'indépendance aux collections dénombrables de σ -algèbres.

Dans de nombreuses circonstances, nous tenons pour acquis la disponibilité d'une collection dénombrable infinie de variables aléatoires indépendantes sur un espace probabilisé. Par exemple, nous envisageons la possibilité de lancer un dé une infinité de fois, et nous supposons que les résultats sont indépendants. C'est légitime. Mais vérifier que c'est légitime, c'est-à-dire prouver l'existence de tels espaces probabilisés riches, n'est pas trivial. La construction de mesures produit et de lois de probabilité produit est une première étape dans cette direction.

Dans Section 7.2, nous définissons les σ -algèbres produit et les mesures produit. Dans Section 7.3, nous énonçons le théorème de Tonelli-Fubini. Ce théorème est un outil fondamental pour traiter les intégrales multiples; il joue un rôle important dans le calcul des espérances dans les espaces produits. Dans Section 7.4, nous esquissons la manière dont la construction d'espaces produits permet de construire des collections de variables aléatoires indépendantes. Dans Section 7.5, nous considérons le produit de collections dénombrables d'espaces probabilisés. Nous introduisons la notion de σ -algèbre cylindrique et énonçons le théorème de cohérence de Kolmogorov. Cela définit le cadre des résultats limites classiques

de la théorie des probabilités.

8.2 Indépendance de deux événements

Nous rappelons les définitions de Leçon introductive Chapitre 1, § 2 (sec-random-variables-and-independence)

Indépendance de deux événements

Soit P une loi de probabilité sur $(\Omega, \mathcal{F})$. Soient $A, B \in \mathcal{F}$ deux événements.

Les événements A et B sont dits *indépendants au sens de P* ($A \perp\!\!\!\perp B$ au sens de P) si et seulement si $P(A \cap B) = P(A) \times P(B)$.

Exercice 8.1. Démontrer les affirmations suivantes :

- A et B sont indépendants si et seulement si $A^c = \Omega \setminus A$ et $B^c = \Omega \setminus B$ sont indépendants.
- A et B sont indépendants si et seulement si A et B^c sont indépendants.
- $\emptyset$ est indépendant de tout événement.

Exercice 8.2. Exprimer $P(A \cup B)$ en fonction de $P(A)$ et $P(B)$ lorsque $A \perp\!\!\!\perp B$.

Exercice 8.3. Dans une expérience d'allocation aléatoire poissonisée, nous tirons d'abord N selon une loi de Poisson de paramètre μ , puis nous lançons N boules indépendamment au hasard dans m urnes. La probabilité qu'une boule tombe dans l'urne j est p_j (nous avons $\sum_{j=1}^m p_j = 1$).

Notons par Y_j le nombre de boules dans l'urne j ($j \leq m$).

Vérifier que les événements $\{Y_j \leq r\}$ et $\{Y_k \leq s\}$ pour $j \neq k$ et $r, s \in \mathbb{N}$ sont indépendants.

Exercice 8.4. Exprimer $P(A \cup B)$ en fonction de $P(A)$ et $P(B)$ lorsque $A \perp\!\!\!\perp B$.

Exercice 8.5. Est-il possible d'avoir $A \perp\!\!\!\perp B$, $B \perp\!\!\!\perp C$, et $A \perp\!\!\!\perp C$ sans avoir $A \cap B \perp\!\!\!\perp C$?

8.3 Indépendance de σ -algèbres et de variables aléatoires

Indépendance de σ -algèbres

Soit P une loi de probabilité sur $(\Omega, \mathcal{F})$. Soient $\mathcal{G}$ et $\mathcal{H}$ deux sous- σ -algèbres de $\mathcal{F}$. Les sous- σ -algèbres $\mathcal{G}$ et $\mathcal{H}$ sont indépendantes au sens de P si et seulement si, pour tout couple $A \in \mathcal{G}, B \in \mathcal{H}$, A est indépendant de B au sens de P .

8.3. INDÉPENDANCE DE σ -ALGÈBRES ET DE VARIABLES ALÉATOIRES

Les deux définitions d'indépendance sont cohérentes. Cela doit être vérifié.

Exercice 8.6. Étant donné un espace probabilisé $(\Omega, \mathcal{F}, P)$ et deux événements A et B , vérifier que A et B sont indépendants au sens de P si et seulement si $\sigma(A)$ et $\sigma(B)$ sont indépendantes au sens de P .

Deux variables aléatoires X et Y sur le même espace probabilisé sont indépendantes si et seulement si les σ -algèbres engendrées par les deux variables sont indépendantes. Nous notons l'indépendance de X et Y par $X \perp\!\!\!\perp Y$. Là encore, c'est cohérent : deux événements sont indépendants si et seulement si leurs fonctions indicatrices sont indépendantes.

Exercice 8.7. Soit P une loi de probabilité sur $(\Omega, \mathcal{F})$. Soit B un événement de $\mathcal{G}$. Soit $\mathcal{A} \subseteq \mathcal{F}$ défini par

$$\mathcal{A} = \{A : A \in \mathcal{F}, A \text{ est indépendant de } B \text{ au sens de } P\}.$$

Prouver que $\mathcal{A}$ est une σ -algèbre.

Vérifier si deux sous- σ -algèbres $\mathcal{G}$ et $\mathcal{H}$ sont indépendantes ou non semble une tâche difficile. Heureusement, nous n'avons pas besoin de vérifier l'indépendance de toute paire d'événements de $\mathcal{G}$ et $\mathcal{H}$. Il suffit de vérifier l'indépendance par rapport à $\mathcal{H}$ pour une collection bien choisie d'événements qui engendrent $\mathcal{G}$.

Théorème 8.1. Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé. Soient $\mathcal{G}, \mathcal{H}$ deux sous- σ -algèbres de $\mathcal{F}$. Soient $\mathcal{C}$ et $\mathcal{C}'$ deux classes π telles que $\sigma(\mathcal{C}) = \mathcal{G}$ et $\sigma(\mathcal{C}') = \mathcal{H}$. Les deux affirmations sont équivalentes :

- $\mathcal{G} \perp\!\!\!\perp \mathcal{H}$ au sens de P ;
- pour tout $A \in \mathcal{C}$, tout $A' \in \mathcal{C}'$, $P(A \cap A') = P(A) \times P(A')$.

La preuve du Théorème 8.1 est une autre application du théorème de la classe monotone Théorème 2.4.

Preuve. Soit $A \in \mathcal{G}$. Définissons $\mathcal{E}$ par

$$\mathcal{E} = \{B : B \in \mathcal{H}, A \perp\!\!\!\perp B\}.$$

La définition de l'indépendance d'événements nous permet de vérifier que $\mathcal{E}$ est une classe λ (une classe monotone). Par conséquent, si $A \in \mathcal{C}$, A est indépendant de tout événement de la plus petite classe λ contenant $\mathcal{C}'$. Il en découle que tout événement de $\mathcal{C}$ est indépendant de tout événement de $\mathcal{H}$. De même, tout événement de $\mathcal{C}'$ est indépendant de tout événement de $\mathcal{G}$.

L'ensemble des événements de $\mathcal{G}$ qui sont indépendants de tout événement de $\mathcal{H}$ est une classe λ (par le même raisonnement qu'au-dessus). Comme cette classe λ contient $\mathcal{C}$, par le lemme de la classe monotone encore, elle contient $\sigma(\mathcal{C}) = \mathcal{G}$. $\square$

Pour vérifier l'indépendance de deux variables aléatoires à valeurs réelles, il suffit de vérifier que la fonction de répartition jointe est le produit des deux fonctions de répartition marginales.

Corollaire 8.1. Soient X et Y deux variables aléatoires réelles sur $(\Omega, \mathcal{F}, P)$. X et Y sont indépendantes ($X \perp\!\!\!\perp Y$) au sens de P si et seulement si l'événement $\{X \leq t\}$ est indépendant de l'événement $\{Y \leq s\}$ au sens de P pour tout $s, t \in \mathbb{Q}$.

Preuve. Les événements de la forme $\{X \leq t\}$, $t \in \mathbb{R}$, forment une classe π engendrant $\sigma(X)$. □

La notion d'indépendance s'étend aux collections dénombrables d'événements, de σ -algèbres et de variables aléatoires.

Définition 8.1 (Indépendance de collections dénombrables). Soit P une loi de probabilité sur $(\Omega, \mathcal{F})$. Soit $(\mathcal{G}_i)_{i \in I \subseteq \mathbb{N}}$ une collection de sous- σ -algèbres de $\mathcal{F}$. La collection $(\mathcal{G}_i)_{i \in I \subseteq \mathbb{N}}$ est indépendante dans $(\Omega, \mathcal{F}, P)$ si et seulement si, pour toute sous-collection finie $J \subseteq I$, pour toute suite d'événements $(A_j)_{j \in J}$ avec $A_j \in \mathcal{G}_j$ pour tout $j \in J$,

$$P(\cap_{j \in J} A_j) = \prod_{j \in J} P(A_j).$$

Chapitre 9

Lois de probabilité absolument continues

9.1 Densités et continuité absolue

Au-delà des lois discrètes, les lois de probabilité les plus simples sont définies par une fonction de densité par rapport à une mesure (σ -finie). Cela englobe les lois des soi-disant *variables aléatoires continues*.

Définition 9.1 (Continuité absolue). Soient μ, ν deux mesures positives sur l'espace mesurable $(\Omega, \mathcal{F})$. On dit que μ est absolument continue par rapport à ν (noté $\mu \leq \nu$) si et seulement si, pour tout $A \in \mathcal{F}$ avec $\nu(A) = 0$, on a aussi $\mu(A) = 0$.

Si μ, ν sont deux lois de probabilité et si $\mu \leq \nu$, alors tout événement impossible sous ν est aussi impossible sous μ .

Exercice 9.1. Répondre aux deux questions :

- La mesure de comptage sur $\mathbb{R}$ est-elle absolument continue par rapport à la mesure de Lebesgue ?
- La réciproque est-elle vraie ?

Exercice 9.2. Vérifier que la continuité absolue est une relation transitive.

Le théorème suivant a des conséquences pratiques de grande portée.

Théorème 9.1 (Radon-Nikodym). Soient μ, ν deux mesures positives sur l'espace mesurable $(\Omega, \mathcal{F})$. Supposons que ν soit σ -finie. Si $\mu \leq \nu$, alors il existe une fonction

mesurable f de Ω vers $[0, \infty)$ telle que, pour tout $A \in \mathcal{F}$,

$$\mu(A) = \int_A f(\omega) d\nu(\omega) = \int \mathbb{1}_A f d\nu.$$

La fonction f est appelée une version de la densité de μ par rapport à ν .

La densité est aussi appelée la dérivée de Radon-Nikodym de μ par rapport à ν . Elle est parfois notée $\frac{d\mu}{d\nu}$.

Remarque 9.1. L'hypothèse de σ -finité est cruciale. Si nous choisissons μ comme mesure de Lebesgue et ν comme mesure de comptage, ν n'est pas σ -finie; $\mu(A) > 0$ implique $\nu(A) = \infty$, que l'on peut considérer comme strictement supérieur à 0. Néanmoins, la mesure de Lebesgue n'a pas de densité par rapport à la mesure de comptage.

Dans les sections suivantes, nous étudions les lois de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ qui sont absolument continues par rapport à la mesure de Lebesgue.

Proposition 9.1. Si $\rho \leq \mu \leq \nu$, si f est une densité de ρ par rapport à μ tandis que g est une densité de μ par rapport à ν , alors fg est une densité de ρ par rapport à ν .

Exercice 9.3. Démontrer la proposition 9.1.

9.2 Loi exponentielle

La loi exponentielle apparaît dans plusieurs domaines des probabilités et de la statistique. En théorie de la fiabilité, sa propriété d'absence de mémoire en fait un cas limite. En théorie des processus ponctuels, la loi exponentielle est liée aux processus de Poisson. Elle est aussi importante en théorie des valeurs extrêmes.

La loi exponentielle de paramètre d'intensité $\lambda > 0$ est définie par sa densité par rapport à la mesure de Lebesgue sur $[0, \infty)$:

$$x \mapsto \lambda e^{-\lambda x}.$$

L'inverse du paramètre d'intensité est appelé le paramètre d'échelle.

Notez que les lois géométrique et exponentielle sont liées : si X suit une loi exponentielle, alors $\lceil X \rceil$ suit une loi géométrique. Pour $k \geq 1$:

$$P\{\lceil X \rceil \geq k\} = P\{X > k-1\} = e^{-\lambda(k-1)}.$$

Exercice 9.4. Vérifier que $x \mapsto \lambda e^{-\lambda x}$ est une densité de probabilité sur $[0, \infty)$.

Exercice 9.5. Calculer la fonction de queue et la fonction de répartition de la loi exponentielle de paramètre λ .

Exercice 9.6. Soient $X_1, \dots, X_n$ des variables i.i.d. de loi exponentielle. Caractériser la loi de $\min(X_1, \dots, X_n)$.

Si X suit une loi exponentielle de paramètre d'échelle σ , quelle est la loi de aX ?




FIGURE 9.1: Exponential densities with different parameters : scales 1, 2, 1/2 or equivalently intensities 1, 1/2, 2. Expectation equals scale, variance equals squared scale.

9.3 Loi gamma

Les sommes de variables aléatoires exponentielles indépendantes ne suivent pas une loi exponentielle. La famille des lois gamma englobe la famille des lois exponentielles. Elle est stable par addition et satisfait

Rappelons la fonction gamma d'Euler :

$$\Gamma(t) = \int_0^{\infty} x^{t-1} e^{-x} dx \quad \text{for } t > 0.$$

CHAPITRE 9. LOIS DE PROBABILITÉ ABSOLUMENT CONTINUES

La loi gamma de paramètre de forme $p > 0$ et de paramètre d'intensité $\lambda > 0$ est définie par sa densité par rapport à la mesure de Lebesgue sur $[0, \infty)$:

$$x \mapsto \lambda^p \frac{x^{p-1}}{\Gamma(p)} e^{-\lambda x}.$$

L'inverse du paramètre d'intensité est appelé le paramètre d'échelle.

Exercice 9.7. Vérifier que $x \mapsto \lambda^p \frac{x^{p-1}}{\Gamma(p)} e^{-\lambda x}$ est une densité de probabilité sur $[0, \infty)$.

Exercice 9.8. Si X suit une loi gamma de paramètre de forme p et de paramètre d'échelle σ , quelle est la loi de aX ?




FIGURE 9.2 : Gamma densities with different parameters : scales 1, 1, 1/3, 1, 2 and shapes 1, 2, 3, 5, 5/2. Expectation equals shape times scale, variance equals shape times squared scale.

9.4 Lois gaussiennes univariées

Les lois gaussiennes jouent un rôle central en théorie des probabilités, en statistique, en théorie de l'information et en analyse.

La loi gaussienne ou normale de moyenne $\mu \in \mathbb{R}$ et de variance σ^2 , $\sigma > 0$, a pour densité

$$x \mapsto \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad \text{for } x \in \mathbb{R}.$$

La densité gaussienne standard est définie par $\mu = 0, \sigma = 1$.

Exercice 9.9. Vérifier que $x \mapsto \frac{e^{-x^2/2}}{\sqrt{2\pi}}$ est une densité de probabilité sur $\mathbb{R}$.

Exercice 9.10. Si X suit une densité gaussienne standard, quelle est la loi de $\mu + \sigma X$?

Exercice 9.11. Si X suit une densité gaussienne standard, montrer que

$$\Pr\{X > t\} \leq \frac{1}{t} \frac{e^{-t^2/2}}{\sqrt{2\pi}} \quad \text{for } t > 0.$$




FIGURE 9.3 : Gaussian densities. The location parameter μ coincides with the mean and the median. The scale parameter is the standard deviation. The Inter-Quartile-Range (IQR) is proportional to the standard deviation. If $\Phi^{\leftarrow}$ denotes the quantile function of $\mathcal{N}(0, 1)$ then the interquartile range of $\mathcal{N}(\mu, \sigma^2)$ is $\sigma(\Phi^{\leftarrow}(3/4) - \Phi^{\leftarrow}(1/4)) = 2\sigma\Phi^{\leftarrow}(3/4)$.

9.5 Fonctions de répartition et continuité absolue

Si une fonction de répartition est définie comme l'intégrale d'une fonction Lebesgue-intégrable non négative, nous savons que la loi de probabilité correspondante est absolument continue par rapport à la mesure de Lebesgue.

Nous pouvons demander un critère qui caractérise la fonction de répartition d'une loi de probabilité absolument continue. Un tel critère est donné par la définition suivante. Nous surchargeons l'expression *absolument continue*.

Définition 9.2 (Fonctions absolument continues). Une fonction réelle F sur $[a, b]$ est dite *absolument continue* si et seulement si, pour tout $\delta > 0$, il existe $\epsilon > 0$ tel que, pour toute collection $([a_i, b_i])_{i \leq n}$ de sous-intervalles non chevauchants ($[a_i, b_i] \subseteq [a, b]$ pour tout $i \leq n$ et $\ell([a_i, b_i] \cap [a_j, b_j]) = 0$ pour $i \neq j$) avec $\sum_{i \leq n} |b_i - a_i| \leq \epsilon$,

$$\sum_{i \leq n} |F(b_i) - F(a_i)| \leq \delta$$

La continuité absolue, la différentiabilité et l'intégration des dérivées sont reliées par le théorème suivant. Ce théorème nous dit qu'une fonction de répartition est absolument continue au sens de la Définition 9.2 si et seulement si la loi de probabilité correspondante est absolument continue par rapport à la mesure de Lebesgue.

Théorème 9.2 (Théorème fondamental du calcul). Une fonction réelle F sur $[a, b]$ est absolument continue si et seulement si les trois conditions suivantes sont satisfaites :

1. La dérivée F' existe Lebesgue-presque partout sur $[a, b]$
2. La dérivée F' est Lebesgue-intégrable
3. Pour tout $x \in [a, b]$, $F(x) - F(a) = \int_{[a, x]} \mathbb{1}_{[a, x]}(t) F'(t) dt$

9.6 Calcul de la densité d'une loi image

Rappelons la formule de changement de variable du calcul élémentaire. Si ϕ est croissante strictement et différentiable de l'ouvert A vers B et si f est Riemann-intégrable sur B , alors

$$\int_B f(y) dy = \int_A f(\phi(x)) \phi'(x) dx$$

Exercice 9.12. Vérifier la formule élémentaire de changement de variable.

L'objectif de cette section est d'énoncer une généralisation multidimensionnelle de cette formule élémentaire. C'est le contenu du Théorème 9.4). Cette extension est ensuite utilisée pour établir une formule toute faite pour calculer la densité d'une loi image dans le Théorème 9.5).

Commençons par un échauffement unidimensionnel. En partant de la loi uniforme sur $[0, 1]$ et en appliquant une transformation monotone différentiable, la densité de la loi image se calcule aisément.

Exercice 9.13. Soit ϕ différentiable et croissante sur $[0, 1]$, et soit P la loi uniforme sur $[0, 1]$.

Vérifier que $P \circ \phi^{-1}$ a pour densité $\frac{1}{\phi' \circ \phi^{-1}}$ sur $\phi([0, 1])$.

La proposition suivante étend cette observation.

Si la variable aléatoire réelle X suit la loi P de densité f , et si ϕ est monotone croissante et différentiable sur $\text{supp}(P)$, alors la loi de probabilité de $Y = \phi(X)$ a pour densité

$$g = \frac{f \circ \phi^{-1}}{\phi' \circ \phi^{-1}}$$

sur $\phi(\text{supp}(P))$.

Preuve. Par le théorème fondamental du calcul, la densité f est presque partout la dérivée de la fonction de répartition F de P .

La fonction de répartition de $Y = \phi(X)$ satisfait :

$$\begin{aligned} P\{Y \leq y\} &= P\{\phi(X) \leq y\} \\ &= P\{X \leq \phi^{-1}(y)\} \\ &= F \circ \phi^{-1}(y) \end{aligned}$$

Presque partout, $F \circ \phi^{-1}$ est différentiable et a pour dérivée $\frac{f \circ \phi^{-1}}{\phi' \circ \phi^{-1}}$ dans $\phi(\text{supp}(P))$, et 0 ailleurs. Ainsi

$$P\{Y \leq y\} = \int_{(-\infty, y] \cap \phi(\text{supp}(P))} \frac{f \circ \phi^{-1}(u)}{\phi' \circ \phi^{-1}(u)} du$$

□

Le corollaire suivant est aussi utile que simple.

Corollaire 9.1. Si la loi de la variable aléatoire réelle X a pour densité f , alors la loi de $\sigma X + \mu$ a pour densité $\frac{1}{\sigma} f\left(\frac{\cdot - \mu}{\sigma}\right)$.

En calcul univarié, il est facile d'établir que si une fonction est continue et croissante sur un ouvert, elle est inversible et son inverse est continu et croissant. Si la fonction est différentiable avec dérivée strictement positive, son inverse est aussi différentiable. De plus, la différentielle et la différentielle de l'inverse sont reliées de manière transparente.

Le théorème d'inversion globale étend l'observation précédente au cadre multivarié.

Théorème 9.3 (Théorème d'inversion globale). Soient U et V deux ouverts non vides de $\mathbb{R}^d$. Soit ϕ une bijection continue de U vers V . Supposons de plus que ϕ soit continûment différentiable et que $D\phi_x$ soit non singulière en tout $x \in U$. Alors, la fonction inverse ϕ^{-1} est aussi continûment différentiable sur V et, pour tout

$y \in V$:

$$D\phi_y^{\leftarrow} = \left(D\phi_{\phi^{\leftarrow}(y)} \right)^{-1}.$$

Le déterminant jacobien de ϕ est le déterminant de la matrice qui représente la différentielle. Il est noté J_ϕ . Rappelons que :

$$J_{\phi^{\leftarrow}}(y) = \left(J_\phi(\phi^{\leftarrow}(y)) \right)^{-1}.$$

La version multidimensionnelle de la formule de changement de variable est énoncée sous les mêmes hypothèses que le théorème d'inversion globale. Nous admettons le théorème suivant.

Théorème 9.4 (Formule géométrique de changement de variable). *Soient U et V deux ouverts non vides de $\mathbb{R}^d$. Soit ϕ une bijection continue de U vers V . Supposons de plus que ϕ soit continûment différentiable et que $D\phi_x$ soit non singulière en tout $x \in U$. Soit ℓ la mesure de Lebesgue sur $\mathbb{R}^d$.*

Pour toute fonction borélienne mesurable f non négative :

$$\int_U f(x) d\ell(x) = \int f(\phi^{\leftarrow}(y)) |J_{\phi^{\leftarrow}}(y)| d\ell(y).$$

Le passage des coordonnées cartésiennes aux coordonnées polaires/sphériques est facilité par une application non triviale du Théorème 9.4).

La formule de densité image est un corollaire de la formule géométrique de changement de variable.

Théorème 9.5 (Formule de densité image). *Soit P de densité f sur l'ouvert $U \subseteq \mathbb{R}^d$. Soit ϕ bijective de U vers $\phi(U)$ et continûment différentiable sur U avec différentielle non singulière.*

La densité g de la loi image $P \circ \phi^{-1}$ sur $\phi(U)$ est donnée par

$$g(y) = f(\phi^{\leftarrow}(y)) \times |J_{\phi^{\leftarrow}}(y)| = f(\phi^{\leftarrow}(y)) \times |J_\phi(\phi^{\leftarrow}(y))|^{-1}.$$

La preuve du Théorème 9.5 à partir du Théorème 9.4) est une application routine de la formule de transfert.

Preuve. Soit B un sous-ensemble borélien de $\phi(U)$. Par la formule de transfert :

$$\begin{aligned} P\{Y \in B\} &= P\{\phi(X) \in B\} \\ &= \int_U \mathbb{1}_B(\phi(x)) f(x) d\ell(x). \end{aligned}$$

Invoquons maintenant le Théorème 9.4) :

$$\begin{aligned} \int_U \mathbb{I}_B(\phi(x)) f(x) d\ell(x) &= \int_{\phi(U)} \mathbb{I}_B(\phi(\phi^{\leftarrow}(y))) f(\phi^{\leftarrow}(y)) \left| J_{\phi^{\leftarrow}}(y) \right| d\ell(y) \\ &= \int_{\phi(U)} \mathbb{I}_B(y) f(\phi^{\leftarrow}(y)) \left| J_{\phi^{\leftarrow}}(y) \right| d\ell(y). \end{aligned}$$

Cela suffit pour conclure que $f \circ \phi^{\leftarrow} \left| J_{\phi^{\leftarrow}} \right|$ est une version de la densité de $P \circ \phi^{-1}$ par rapport à la mesure de Lebesgue sur $\phi(U)$. $\square$

9.7 Application : calcul gamma-bêta

La formule de densité image est appliquée pour montrer un lien remarquable entre les lois gamma et bêta.

Proposition 9.2. Soient X, Y des variables aléatoires indépendantes de lois $\Gamma(p, \lambda)$ et $\Gamma(q, \lambda)$ (les paramètres d'intensité sont identiques). Posons $U = X + Y$ et $V = X/(X + Y)$.

Alors

- Les variables aléatoires U et V sont indépendantes.
- La variable aléatoire U suit la loi $\Gamma(p + q, \lambda)$ tandis que
- V suit la loi Beta(p, q).

Preuve. L'application $f :]0, \infty)^2 \rightarrow]0, \infty) \times]0, 1[$ définie par

$$f(x, y) = \left(x + y, \frac{x}{x + y} \right)$$

est bijective, d'inverse $f^{\leftarrow}(u, v) = (uv, u(1 - v))$. La matrice jacobienne de $f^{\leftarrow}$ en (u, v) est

$$\begin{pmatrix} v & u \\ (1 - v) & -u \end{pmatrix}$$

de déterminant $-uv - u + uv = -u$. La densité jointe image en $(u, v) \in]0, \infty) \times]0, 1[$ vaut

$$\begin{aligned} &= \lambda^{p+q} \frac{(uv)^{p-1}}{\Gamma(p)} \frac{(u(1-v))^{q-1}}{\Gamma(q)} e^{-\lambda(uv+u(1-v))} u \\ &= \left(\lambda^{p+q} \frac{u^{p+q-1}}{\Gamma(p+q)} e^{-\lambda u} \right) \times \left(\frac{\Gamma(p+q)}{\Gamma(q)\Gamma(p)} v^{p-1} (1-v)^{q-1} \right). \end{aligned}$$

La factorisation de la densité jointe prouve que U et V sont indépendants. Nous reconnaissons que la densité de (la loi de) U est la densité gamma de paramètre de forme $p + q$ et de paramètre d'intensité λ . La densité de la loi de V est la densité bêta de paramètres p et q . $\square$

Exercice 9.14. Supposons que $X_1, X_2, \dots, X_n$ forment une famille indépendante, chaque X_i suivant la loi $\Gamma(p_i, \lambda)$. Déterminer la loi jointe de

$$\sum_{i=1}^n X_i, \frac{X_1}{\sum_{i=1}^n X_i}, \frac{X_2}{\sum_{i=1}^n X_i}, \dots, \frac{X_{n-1}}{\sum_{i=1}^n X_i}$$

9.8 Remarques bibliographiques

Dudley (2002) et Pollard (2002) fournissent un développement complet de la continuité absolue et des preuves autonomes du théorème de Radon-Nikodym.

Chapitre 10

Conditionnement discret

10.1 Feuille de route

Le conditionnement est central dans le raisonnement probabiliste. Dans cette leçon, nous étudions le conditionnement discret. Dans ce cadre, la définition de la probabilité conditionnelle ne pose pas de difficulté. La définition de l'espérance conditionnelle peut paraître déceptivement simple. Néanmoins, le cadre discret se prête à des définitions et manipulations intuitives.

La notion la plus simple que nous rencontrons est la probabilité conditionnelle par rapport à un événement de probabilité strictement positive (Section 10.2). La probabilité conditionnelle offre une interprétation intuitive de l'indépendance.

Dans Section 10.3, nous énonçons, vérifions et discutons la formule de Bayes.

Dans Section 10.4, nous définissons l'espérance conditionnelle par rapport à une σ -algèbre atomique. Cela définit l'espérance conditionnelle par rapport à une variable aléatoire discrète.

Dans Section 10.5, nous caractérisons l'espérance conditionnelle comme un prédicteur optimal. Cette caractérisation est très utile pour définir l'espérance conditionnelle dans le cadre général.

10.2 Conditionnement par rapport à un événement

Définition 10.1. Soit P une loi de probabilité sur $(\Omega, \mathcal{F})$. Soit $A \in \mathcal{F}$ tel que $P\{A\} > 0$. Soit B un autre événement ($B \in \mathcal{F}$). La *probabilité de B sachant A* est définie par

$$P\{B \mid A\} = \frac{P\{A \cap B\}}{P\{A\}}.$$

Si X est une variable aléatoire gaussienne standard sur $(\Omega, \mathcal{F})$, et si l'événement A est défini par $\{\omega : X(\omega) \geq t\}$ pour un certain $t \geq 0$, nous pouvons conditionner sur l'événement A et définir $P\{B \mid A\}$ pour $B = \{\omega : |X(\omega)| \geq 2t\}$.

Nous obtenons

$$P\{B \mid A\} = \frac{P\{X \geq 2t\}}{P\{X \geq t\}}.$$

Nous pouvons vérifier la proposition suivante en revenant à la définition des lois de probabilité.

Proposition 10.1. *Soit P une loi de probabilité sur $(\Omega, \mathcal{F})$. Soit $A \in \mathcal{F}$ tel que $P\{A\} > 0$. Alors $P\{\cdot \mid A\}$ (P sachant A) définit une loi de probabilité sur $(\Omega, \mathcal{F})$.*

Preuve. $P(\cdot \mid A)$ associe à $\mathcal{F}$ des valeurs dans $[0, 1]$.

Nous avons $P(\Omega \mid A) = P(A \cap \Omega)/P(A) = P(A)/P(A) = 1$

Soit $(B_n)_n$ une suite croissante d'événements. Alors

$$\begin{aligned} P(\cup_n B_n \mid A) &= \frac{P((\cup_n B_n) \cap A)}{P(A)} \\ &= \frac{P(\cup_n (B_n \cap A))}{P(A)} \\ &= \frac{\lim_n P(B_n \cap A)}{P(A)} \\ &= \lim_n P(B_n \mid A). \end{aligned}$$

□

Nous pouvons considérer la loi des variables aléatoires sur $(\Omega, \mathcal{F})$ sous $P\{\cdot \mid A\}$. Nous calculons l'espérance de X sous $P\{\cdot \mid A\}$:

$$\mathbb{E}_{P\{\cdot \mid A\}} X = \frac{\mathbb{E}[\mathbb{I}_A X]}{P\{A\}}.$$

Ceci est souvent noté $\mathbb{E}[X \mid A]$; nous essaierons d'éviter cette notation potentiellement trompeuse.

Exemple 10.1. Supposons que X suit une loi normale standard. On peut étudier la loi de X^2 conditionnellement à l'événement $A = \{\omega : X(\omega) \geq t\}$. Pour $t > 1$, nous avons

$$\begin{aligned} \mathbb{E}_{P\{\cdot \mid X \geq t\}} X^2 &= \frac{\int_t^\infty x^2 \phi(x) dx}{\int_t^\infty \phi(x) dx} \\ &\leq \frac{t^2}{1-1/t} + 1. \end{aligned}$$

où la majoration est obtenue par intégrations par parties répétées.

La loi de X sachant A n'est pas gaussienne. Sous A , X est très concentrée au voisinage de t et tend à l'être davantage lorsque t tend vers l'infini.

Connaître la loi de probabilité sachant l'événement A permet d'étudier l'indépendance d'événements par rapport à A . La proposition triviale suivante mérite d'être rappelée.

Proposition 10.2. *Si A et $B \in \mathcal{F}$ satisfont $P\{A\} > 0$, alors A et B sont indépendants au sens de P si et seulement si*

$$P\{B \mid A\} = P\{B\}.$$

10.3 Formule de Bayes

La formule de Bayes est parfois utilisée en théorie de la causalité probabiliste. C'est un sujet difficile. La causalité est une notion subtile et nous nous abstenons d'interprétations causales.

Proposition 10.3 (Formule de Bayes). *Soit P une loi de probabilité sur $(\Omega, \mathcal{F})$, soit $(A_i)_{i \in \mathcal{I} \subseteq \mathbb{N}}$ une collection d'événements deux à deux disjoints, de probabilité non nulle, telle que $\cup_{i \in \mathcal{I}} A_i = \Omega$ ($(A_i)_{i \in \mathcal{I}}$ forme un système complet d'événements). Soit B un événement de probabilité non nulle. Alors, pour tout $i \in \mathcal{I}$,*

$$P\{A_i \mid B\} = \frac{P\{A_i\} \times P\{B \mid A_i\}}{\sum_{j \in \mathcal{I}} P\{A_j\} \times P\{B \mid A_j\}}$$

Preuve. Par définition, $P\{A_i \mid B\} = P\{A_i \cap B\} / P\{B\} = P\{A_i\} \times P\{B \mid A_i\} / P\{B\}$.

De plus

$$\begin{aligned} P\{B\} &= P\{B \cap (\cup_{j \in \mathcal{I}} A_j)\} \\ &= P\{\cup_{j \in \mathcal{I}} (B \cap A_j)\} \\ &= \sum_{j \in \mathcal{I}} P\{B \cap A_j\} \\ &= \sum_{j \in \mathcal{I}} P\{A_j\} \times P\{B \mid A_j\}. \end{aligned}$$

□

Dans la proposition précédente, $P\{A_i\}$ est appelée la probabilité *a priori* de A_i et $P\{A_i \mid B\}$ la probabilité *a posteriori*.

10.4 Espérance conditionnelle par rapport à une σ -algèbre discrète

Alors que la notion générale d'espérance conditionnelle requiert un certain niveau d'abstraction, nous pouvons introduire le conditionnement par rapport à une σ -algèbre discrète à partir de la notion élémentaire de probabilité conditionnelle par rapport à un événement de probabilité strictement positive.

Définition 10.2. Soit Ω un univers, $\mathcal{F}$ une σ -algèbre d'événements sur Ω , P une loi de probabilité sur $(\Omega, \mathcal{F})$. Soient $(A_i)_{i \in \mathcal{I} \subseteq \mathbb{N}}$ des événements deux à deux disjoints, de probabilité non nulle, tels que $\cup_i A_i = \Omega$. Soit $\mathcal{G}$ la σ -algèbre atomique engendrée

par $(A_i)_{i \in \mathcal{I}}$.

Soit X une variable aléatoire de $(\Omega, \mathcal{F})$ vers $(\mathcal{X}, \mathcal{H})$. L'espérance conditionnelle de X par rapport à $\mathcal{G}$ est la variable aléatoire définie par

$$\mathbb{E}[X | \mathcal{G}] = \sum_{i \in \mathcal{I}} \mathbb{E}_{P_{\{A_i\}}} [X] \times \mathbf{1}_{A_i}.$$

Alors que $\mathbb{E}_{P_{\{A_i\}}} [X]$ est un nombre réel, $\mathbb{E}[X | \mathcal{G}]$ est une fonction $\mathcal{G}$ -mesurable de Ω vers $\mathcal{X}$:

$$\mathbb{E}[X | \mathcal{G}](\omega) = \sum_{i \in \mathcal{I}} \mathbb{E}_{P_{\{A_i\}}} [X] \times \mathbf{1}_{A_i}(\omega) \quad \forall \omega \in \Omega.$$

Ces deux types d'objets ne doivent pas être confondus. Nous nous abstenons d'utiliser la notation $\mathbb{E}[X | A_i]$ car elle peut prêter à confusion : $\mathbb{E}[X | A_i]$ pourrait désigner soit $\mathbb{E}_{P_{\{A_i\}}} [X]$, soit $\mathbb{E}[X | \sigma(A_i)]$ où $\sigma(A_i)$ est la σ -algèbre engendrée par $A_i : \{A_i, A_i^c, \Omega, \emptyset\}$.

Proposition 10.4. Soit P une loi de probabilité sur $(\Omega, \mathcal{F})$. Soit $(A_i)_{i \in \mathcal{I} \subseteq \mathbb{N}}$ une collection d'événements deux à deux disjoints, de probabilité non nulle, telle que $\cup_{i \in \mathcal{I}} A_i = \Omega$. Soit $\mathcal{G} = \sigma((A_i)_{i \in \mathcal{I}})$ la σ -algèbre engendrée par $(A_i)_{i \in \mathcal{I}}$. La variable aléatoire X est supposée P -intégrable.

1. L'espérance conditionnelle $\mathbb{E}[X | \mathcal{G}]$ est une variable aléatoire $\mathcal{G}$ -mesurable qui satisfait

$$\mathbb{E}[YX] = \mathbb{E}[Y\mathbb{E}[X | \mathcal{G}]] \quad \forall Y \in \sigma(\mathcal{G}), Y \text{ bounded.}$$

2. Si deux variables aléatoires $\mathcal{G}$ -mesurables Z, T satisfont $\mathbb{E}[YX] = \mathbb{E}[YZ] = \mathbb{E}[YT]$, pour tout $Y \in \sigma(\mathcal{G}), Y$ bounded, alors $Z = T$ presque sûrement.

Preuve. Il faut vérifier les points 1.) et 2.) :

1. $\mathbb{E}[X | \mathcal{G}]$ satisfait la première propriété de la Proposition Proposition 10.4.
2. Si Z satisfait Proposition 10.4, alors $Z = \mathbb{E}[X | \mathcal{G}]$ P -presque sûrement.

Vérification de i.)

Si Y est $\mathcal{G}$ -mesurable, alors $Y = \sum_{i \in \mathcal{I}} \lambda_i \mathbf{1}_{A_i}$ pour une certaine suite de réels $(\lambda_i)_{i \in \mathcal{I}}$. Alors

$$\begin{aligned} \mathbb{E}[Y\mathbb{E}[X | \mathcal{G}]] &= \mathbb{E}\left[\left(\sum_{i \in \mathcal{I}} \lambda_i \mathbf{1}_{A_i}\right) \left(\sum_{j \in \mathcal{I}} \mathbf{1}_{A_j} \frac{\mathbb{E}[\mathbf{1}_{A_j} X]}{P\{A_j\}}\right)\right] \\ &= \mathbb{E}\left[\sum_{i \in \mathcal{I}} \lambda_i \mathbf{1}_{A_i} \frac{\mathbb{E}[\mathbf{1}_{A_i} X]}{P\{A_i\}}\right] \\ &= \sum_{i \in \mathcal{I}} \lambda_i \mathbb{E}[\mathbf{1}_{A_i} X] \frac{\mathbb{E}[\mathbf{1}_{A_i}]}{P\{A_i\}} \quad \text{linearity of expectation} \\ &= \sum_{i \in \mathcal{I}} \lambda_i \mathbb{E}[\mathbf{1}_{A_i} X] \\ &= \mathbb{E}\left[\left(\sum_{i \in \mathcal{I}} \lambda_i \mathbf{1}_{A_i}\right) X\right] \\ &= \mathbb{E}[YX]. \end{aligned}$$

Vérification de ii.)

Supposons que Z satisfasse Proposition 10.4.

Définissons Y par $Y = \mathbf{1}_{A_i}$, pour un certain indice $i \in \mathcal{I}$.

Comme Z est $\mathcal{G}$ -mesurable, il existe une suite de réels $(\mu_j)_{j \in \mathcal{J}}$ telle que $Z = \sum_{j \in \mathcal{J}} \mu_j \mathbf{1}_{A_j}$.

Ainsi, en utilisant le fait que les événements A_j sont deux à deux disjoints :

$$\mathbb{E}[ZY] = \mathbb{E}\left[\sum_{j \in \mathcal{J}} \mu_j \mathbf{1}_{A_j} \mathbf{1}_{A_i}\right] = \mu_i P\{A_i\}$$

Par la propriété définissante de Z , nous avons

$$\mathbb{E}[ZY] = \mathbb{E}[XY] = \mathbb{E}[X \mathbf{1}_{A_i}].$$

Enfin, pour tout $i \in \mathcal{I}$, $\mu_i = \mathbb{E}[X \mathbf{1}_{A_i}] / P\{A_i\}$.

Nous pouvons maintenant conclure que $Z = \mathbb{E}[X | \mathcal{G}]$. □

10.5 Espérance conditionnelle comme prédiction

La proposition suivante révèle le rôle de l'espérance conditionnelle dans les problèmes de prédiction et d'approximation.

Proposition 10.5. *Soit Y une variable aléatoire de carré intégrable sur $(\Omega, \mathcal{F}, P)$ et $\mathcal{G}$ une sous- σ -algèbre discrète de $\mathcal{F}$. L'espérance conditionnelle de Y par rapport à $\mathcal{G}$ minimise*

$$\mathbb{E}[(Y - Z)^2]$$

parmi les variables aléatoires de carré intégrable $\mathcal{G}$ -mesurables.

Rappelons qu'une variable aléatoire $\mathcal{G}$ -mesurable est une fonction qui reste constante sur chaque A_i , $i \in \mathcal{I}$.

Preuve. Si Y est une variable aléatoire sur $(\Omega, \mathcal{F})$ et si nous cherchons à prédire au mieux Y à l'aide d'une variable aléatoire $\mathcal{G}$ -mesurable, nous cherchons une suite de coefficients $(b_i)_{i \in \mathcal{I}}$ qui minimise :

$$\begin{aligned} \mathbb{E}_P \left[\left(Y - \sum_{i \in \mathcal{I}} b_i \mathbf{1}_{A_i} \right)^2 \right] &= \mathbb{E}_P \left[\left(\sum_{i \in \mathcal{I}} (Y - b_i) \mathbf{1}_{A_i} \right)^2 \right] \\ &= \sum_{i \in \mathcal{I}} \mathbb{E}_P \left[(Y - b_i)^2 \mathbf{1}_{A_i} \right] \\ &= \sum_{i \in \mathcal{I}} P\{A_i\} \mathbb{E}_{P\{\cdot | A_i\}} \left[(Y - b_i)^2 \right] \end{aligned}$$

Ainsi, pour chaque i , b_i doit coïncider avec l'espérance de Y sous $P\{\cdot | A_i\}$. La meilleure prédiction de Y , au sens de l'erreur quadratique, parmi les fonctions $\mathcal{G}$ -mesurables est l'espérance conditionnelle de Y par rapport à $\mathcal{G}$. □

Les propriétés identifiées par les propositions Proposition 10.4 et @ref(prp:espercond-pred) serviront de définition à l'espérance conditionnelle par rapport à une σ -algèbre générale.

10.6 Propriétés de l'espérance conditionnelle

Nous énonçons sans preuve un certain nombre de propriétés utiles de l'espérance conditionnelle par rapport à des σ -algèbres discrètes. Nous les démontrerons en toute généralité plus tard.

Proposition 10.6. *Si $X \leq Y$, P -p.s., alors*

$$\mathbb{E}[X \mid \mathcal{G}] \leq \mathbb{E}[Y \mid \mathcal{G}] \quad P\text{-p.s.}$$

Proposition 10.7.

$$\mathbb{E}[aX + bY \mid \mathcal{G}] = a\mathbb{E}[X \mid \mathcal{G}] + b\mathbb{E}[Y \mid \mathcal{G}].$$

Proposition 10.8. *Si $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$*

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}] \mid \mathcal{H}] = \mathbb{E}[X \mid \mathcal{H}].$$

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{H}] \mid \mathcal{G}] = \mathbb{E}[X \mid \mathcal{H}].$$

Démontrer la proposition.

$$\mathbb{E}X = \mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]].$$

10.7 Application : processus de Galton-Watson I

La taille de la génération $k \geq 0$ est définie récursivement par

$$Z_0 = 1, \quad Z_{k+1} = \sum_{i=1}^{Z_k} X_i^k.$$

La σ -algèbre $\sigma(Z_k)$ est discrète/atomique; elle est engendrée par les événements deux à deux disjoints $\{Z_k = a\}$ pour $a \in \mathbb{N}$.

Proposition 10.9. *Dans un processus de branchement de Galton-Watson (homogène) de nombre de reproduction μ , l'espérance conditionnelle de la taille de la $k+1$ ^e génération par rapport à la taille de la k ^e génération est une fonction linéaire de la taille de la*

k^{e} génération :

$$\mathbb{E}[Z_{k+1} \mid \sigma(Z_k)] = \mathbb{E}X_1^0 \times Z_k = \mu \times Z_k$$

Preuve. Sur l'événement $\{Z_k = a\}$, nous pouvons déterminer la loi conditionnelle de Z_{k+1} .

$$\begin{aligned} \{Z_{k+1} = b \mid Z_k = a\} &= \left\{ \sum_{i=1}^a X_i^k = b \mid Z_k = a \right\} \\ &= \left\{ \sum_{i=1}^a X_i^k = b \right\} \cap \{Z_k = a\} \end{aligned}$$

nous avons

$$P\{Z_{k+1} = b \mid Z_k = a\} = P\left\{ \sum_{i=1}^a X_i^k = b \mid Z_k = a \right\} = P\left\{ \sum_{i=1}^a X_i^k = b \right\}$$

Sur l'événement $\{Z_k = a\}$, Z_{k+1} a la même loi que la somme de a copies indépendantes de X_1^0 :

$$\begin{aligned} \mathbb{E}[Z_{k+1} \mid \sigma(Z_k)] &= \sum_{a=0}^{\infty} \mathbb{E}_{P(\cdot \mid Z_k=a)}[Z_{k+1}] \times \mathbb{I}_{Z_k=a} \\ &= \sum_{a=0}^{\infty} \mathbb{E}_{P(\cdot \mid Z_k=a)}\left[\sum_{i=1}^a X_i^k\right] \times \mathbb{I}_{Z_k=a} \\ &= \sum_{a=0}^{\infty} \mathbb{E}\left[\sum_{i=1}^a X_i^k\right] \times \mathbb{I}_{Z_k=a} \\ &= \sum_{a=0}^{\infty} \sum_{i=1}^a \mathbb{E}[X_i^k] \times \mathbb{I}_{Z_k=a} \\ &= \sum_{a=0}^{\infty} a \mathbb{E}X_1^0 \times \mathbb{I}_{Z_k=a} \\ &= \mathbb{E}X_1^0 \times Z_k. \end{aligned}$$

□

Un corollaire immédiat est :

$$\mathbb{E}Z_k = (\mathbb{E}X_1^0)^k \quad \text{for all } k \geq 0.$$

La suite des tailles attendues des générations forme une suite géométrique.

Un processus de Galton-Watson est dit *sous-critique* si l'espérance de la loi de reproduction est strictement inférieure à 1.

Proposition 10.10 (Extinction sous loi de reproduction sous-critique). *La probabilité d'extinction d'un processus de branchement sous-critique est égale à 1.*

Preuve. Notons par E_k l'événement $\{Z_k = 0\}$. Observez que la suite $(E_k)_k$ est croissante. Notons par $E_{\infty} = \cup_{k=0}^{\infty} E_k$.

$$P\{E_k^c\} = P\{Z_k \geq 1\} \leq \mathbb{E}Z_k.$$

D'où $P\{E_k^c\} \downarrow 0$ et $P\{E_k\} \uparrow 1$. Par convergence monotone, $P(E_{\infty}) = 1$. □

L'espérance de la taille totale de la descendance d'un processus de branchement sous-critique vaut

$$\sum_{k=0}^{\infty} \mathbb{E}Z_k = \sum_{k=0}^{\infty} (\mathbb{E}X_1^0)^k = \frac{1}{1 - \mathbb{E}X_1^0}.$$

Travailler avec le conditionnement discret nous permet d'obtenir des résultats non triviaux sur le processus de Galton-Watson sans en savoir beaucoup sur la loi de reproduction au-delà du fait que son espérance est strictement inférieure à 1. Nous ignorons encore les détails de la loi de Z_k , sans parler de la loi de $\sum_{k=0}^{\infty} Z_k$.

Chapitre 11

Conditionnement

11.1 Définition de l'espérance conditionnelle

Dans cette section et les suivantes, $(\Omega, \mathcal{F}, P)$ désigne un espace de probabilité, et $\mathcal{G} \subseteq \mathcal{F}$ une sous-tribu. La sous-tribu n'a pas besoin d'être *atomique* comme dans Chapitre 10. On ne peut pas définir les probabilités conditionnelles en conditionnant par rapport aux atomes engendrant $\mathcal{G}$. Notre objectif est néanmoins de définir les espérances conditionnelles par rapport à la sous-tribu $\mathcal{G}$, tout en conservant les propriétés utiles passées en revue dans Chapitre 10.

La définition générale de l'espérance conditionnelle part de la propriété décrite dans Proposition 10.4.

Définition 11.1 (Espérance conditionnelle). Soient $X \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$ et $\mathcal{G}$ une sous-tribu de $\mathcal{F}$. Une variable aléatoire Y est une version de l'espérance conditionnelle de X par rapport à $\mathcal{G}$ si et seulement si

- i. Y est $\mathcal{G}$ -mesurable.
- ii. Pour tout événement B de $\mathcal{G}$:

$$\mathbb{E} [\mathbb{1}_B X] = \mathbb{E} [\mathbb{1}_B Y] .$$

En laissant de côté la question de l'existence d'une version de l'espérance conditionnelle de X , nous vérifions d'abord que s'il existe plusieurs versions, elles ne diffèrent que sur un événement négligeable.

Soient $X \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$ et $\mathcal{G}$ une sous-tribu de $\mathcal{F}$. Si Y' et Y sont deux versions de l'espérance conditionnelle de X par rapport à $\mathcal{G}$:

$$P\{Y = Y'\} = 1.$$

Preuve. Comme Y et Y' sont $\mathcal{G}$ -mesurables, l'événement

$$B = \{\omega : Y(\omega) > Y'(\omega)\}$$

CHAPITRE II. CONDITIONNEMENT

appartient à $\mathcal{G}$. De plus,

$$\begin{aligned}\mathbb{E}[\mathbb{I}_B X] &= \mathbb{E}[\mathbb{I}_B Y] \\ &= \mathbb{E}[\mathbb{I}_B Y'] .\end{aligned}$$

Ainsi

$$\mathbb{E}[\mathbb{I}_B(Y - Y')] = 0 .$$

Comme la variable aléatoire $\mathbb{I}_B(Y - Y')$ est positive, son espérance est nulle, elle est donc nulle avec probabilité 1. Ainsi

$$P\{Y > Y'\} = 0 .$$

On conclut en procédant de même pour l'événement $\{Y < Y'\}$. $\square$

En reportant encore la question de l'existence, vérifions maintenant quelques propriétés que devraient satisfaire les versions de l'espérance conditionnelle de X .

Soient $X_1, X_2 \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$, $\mathcal{G}$ une sous-tribu de $\mathcal{F}$, a_1, a_2 deux nombres réels. Si Y_1, Y_2 et Z sont respectivement des versions de l'espérance conditionnelle de X_1, X_2 et $a_1 X_1 + a_2 X_2$ par rapport à $\mathcal{G}$, on a

$$P\{a_1 Y_1 + a_2 Y_2 = Z\} = 1 .$$

Preuve. Soit B l'événement de $\mathcal{G}$ défini par

$$\{a_1 Y_1 + a_2 Y_2 > Z\} .$$

On obtient

$$\begin{aligned}\mathbb{E}[\mathbb{I}_B Z] &= \mathbb{E}[\mathbb{I}_B(a_1 X_1 + a_2 X_2)] \\ &= a_1 \mathbb{E}[\mathbb{I}_B X_1] + a_2 \mathbb{E}[\mathbb{I}_B X_2] \\ &= a_1 \mathbb{E}[\mathbb{I}_B Y_1] + a_2 \mathbb{E}[\mathbb{I}_B Y_2] \\ &= \mathbb{E}[\mathbb{I}_B(a_1 Y_1 + a_2 Y_2)] ,\end{aligned}$$

et donc

$$\mathbb{E}[\mathbb{I}_B(Z - (a_1 Y_1 + a_2 Y_2))] = 0 .$$

On conclut comme dans la démonstration précédente que $P\{B\} = 0$.

La démonstration se termine en traitant de même l'événement $\{a_1 Y_1 + a_2 Y_2 < Z\}$. $\square$

Proposition 11.1. *Si $X \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$, $\mathcal{G}$ une sous-tribu de $\mathcal{F}$. Si Z est une version de l'espérance conditionnelle de X par rapport à $\mathcal{G}$ et si X est P-p.s. positive, alors*

$$P\{Z \geq 0\} = 1 .$$

La démonstration reprend l'argument utilisé pour établir que des versions différentes de l'espérance conditionnelle sont presque sûrement égales.

II.1. DÉFINITION DE L'ESPÉRANCE CONDITIONNELLE

Preuve. Pour $n \in \mathbb{N}$, notons B_n l'événement (de $\mathcal{G}$) défini par

$$B_n = \left\{ \mathbb{E}[X | \mathcal{G}] < -\frac{1}{n} \right\}.$$

Pour démontrer la proposition, il suffit de vérifier

$$P\{\cup_n B_n\} = 0.$$

Comme $P\{\cup_n B_n\} = \lim_n P\{B_n\}$, il suffit de vérifier $P\{B_n\} = 0$ pour tout n . Pour tout n ,

$$\begin{aligned} 0 &\leq \mathbb{E}[\mathbb{I}_{B_n} X] \\ &= \mathbb{E}[\mathbb{I}_{B_n} \mathbb{E}[X | \mathcal{G}]] \\ &= \mathbb{E}[\mathbb{I}_{B_n} \mathbb{E}[X | \mathcal{G}]] \\ &\leq -\frac{P\{B_n\}}{n}. \end{aligned}$$

D'où, pour tout n , $P\{B_n\} = 0$. □

Le corollaire suivant est une conséquence de Proposition II.1.

Corollaire 11.1. *Si $(X_n)_{n \in \mathbb{N}}$ est une suite de variables aléatoires de $\mathcal{L}_1(\Omega, \mathcal{F}, P)$ telle que $X_{n+1} \geq X_n$ P-p.s., alors il existe une suite P-p.s. croissante de versions d'espérances conditionnelles*

$$\forall n \in \mathbb{N}, \quad \mathbb{E}[X_{n+1} | \mathcal{F}] \geq \mathbb{E}[X_n | \mathcal{F}].$$

Soit $\mathcal{E}$ un π -système engendrant $\mathcal{G}$ et contenant Ω . Vérifier que $\mathbb{E}[X | \mathcal{G}]$ est l'unique élément de $\mathcal{L}_1(\Omega, \mathcal{G}, P)$ qui satisfait

$$\forall B \in \mathcal{E}, \quad \mathbb{E}[\mathbb{I}_B X] = \mathbb{E}[\mathbb{I}_B \mathbb{E}[X | \mathcal{G}]].$$

Pour des sous-tribus emboîtées, les espérances conditionnelles satisfont la propriété de la tour :

Soient $(\Omega, \mathcal{F}, P)$ un espace de probabilité, et $\mathcal{G} \subseteq \mathcal{H} \subseteq \mathcal{F}$ deux sous-tribus emboîtées. Alors, pour toute $X \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$:

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[\mathbb{E}[X | \mathcal{H}] | \mathcal{G}] = \mathbb{E}[X | \mathcal{G}] \quad \text{a.s.}$$

Preuve. L'égalité presque sûre $\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{G}]$ est triviale : toute variable aléatoire $\mathcal{G}$ -mesurable est aussi $\mathcal{H}$ -mesurable.

Vérifions maintenant la seconde égalité.

Pour tout $B \in \mathcal{G}$,

$$\begin{aligned} \mathbb{E}[\mathbb{I}_B \mathbb{E}[\mathbb{E}[X | \mathcal{H}] | \mathcal{G}]] &= \mathbb{E}[\mathbb{I}_B \mathbb{E}[X | \mathcal{H}]] \\ &\quad \text{comme } B \in \mathcal{H} \\ &= \mathbb{E}[\mathbb{I}_B X]. \end{aligned}$$

□

11.2 Espérance conditionnelle dans $\mathcal{L}_2(\Omega, \mathcal{F}, P)$

Si l'on se restreint aux variables aléatoires de carré intégrable, construire des versions de l'espérance conditionnelle s'avère facile. Rappelons que lorsque la sous-tribu de conditionnement $\mathcal{G}$ est atomique, d'après Proposition 10.5, l'espérance conditionnelle $\mathbb{E}[X \mid \mathcal{G}]$ définit un prédicteur optimal de X au sens de l'erreur quadratique parmi les variables aléatoires $\mathcal{G}$ -mesurables. Cette caractérisation reste valide pour les variables de carré intégrable même lorsque la sous-tribu de conditionnement n'est plus atomique. C'est le contenu du théorème suivant.

Théorème 11.1 (Espérance conditionnelle pour les variables de carré intégrable).

Soient $X \in \mathcal{L}_2(\Omega, \mathcal{F}, P)$ et $\mathcal{G}$ une sous-tribu de $\mathcal{F}$.

Il existe $Y \in \mathcal{L}_2(\Omega, \mathcal{G}, P)$ qui minimise la distance L_2 à X :

$$\exists Y \in \mathcal{L}_2(\Omega, \mathcal{G}, P) \quad \mathbb{E}(Y - X)^2 = \inf \left\{ \mathbb{E}(Z - X)^2 : Z \in \mathcal{L}_2(\Omega, \mathcal{G}, P) \right\},$$

c'est-à-dire que Y représente une version de la projection orthogonale de X sur $\mathcal{L}_2(\Omega, \mathcal{G}, P)$.

Une version Y de la projection orthogonale de X sur $\mathcal{L}_2(\Omega, \mathcal{G}, P)$ est aussi une version de l'espérance conditionnelle de X par rapport à $\mathcal{G}$:

$$\forall B \in \mathcal{G}, \quad \mathbb{E}[\mathbb{I}_B X] = \mathbb{E}[\mathbb{I}_B Y].$$

Notons que le théorème contient deux énoncés : d'abord, il existe un minimiseur de $\mathbb{E}(X - Z)^2$ dans $\mathcal{L}_2(\Omega, \mathcal{F}, P)$; ensuite, un tel minimiseur est une version de l'espérance conditionnelle définie selon Définition 11.1. Vérifier le premier énoncé revient à invoquer les arguments appropriés de la théorie des espaces de Hilbert.

Pour référence, rappelons les bases de la théorie des espaces de Hilbert.

Définition 11.2 (Espace de Hilbert). Un espace vectoriel réel E muni d'une norme $\|\cdot\|$ est un espace de Hilbert si et seulement si $\langle \cdot, \cdot \rangle$ définie par

$$\forall x, y \in E, \langle x, y \rangle = \frac{1}{4} (\|x + y\|^2 + \|x - y\|^2)$$

est un *produit scalaire* et E est complet pour la topologie induite par la norme.

Soit $(\Omega, \mathcal{F}, P)$ un espace de probabilité. L'ensemble $L_2(\Omega, \mathcal{F}, P)$ des classes d'équivalence de variables de carré intégrable, muni de $\|X\|^2 = (\mathbb{E}X^2)^{1/2}$, est un espace de Hilbert.

Remarque 11.1. Dans ce contexte,

$$\langle X, Y \rangle = \mathbb{E}[XY].$$

De la théorie des espaces de Hilbert, l'outil essentiel que nous utiliserons est le théorème de projection ci-dessous. Notre point de départ est l'observation suivante (qui découle des résultats de Chapitre 3).

Soient $(\Omega, \mathcal{F}, P)$ un espace de probabilité, $\mathcal{G} \subseteq \mathcal{F}$ une sous-tribu. Alors $L_2(\Omega, \mathcal{G}, P)$ est un sous-espace convexe fermé de $L_2(\Omega, \mathcal{F}, P)$.

Nous cherchons l'élément de $L_2(\Omega, \mathcal{G}, P)$ le plus proche (au sens L_2) d'une variable aléatoire de $L_2(\Omega, \mathcal{F}, P)$. L'existence et l'unicité de cette variable aléatoire $\mathcal{G}$ -mesurable la plus proche sont garanties par le théorème de projection.

Théorème 11.2 (Théorème de projection). *Soient E un espace de Hilbert et F une partie convexe fermée de E . Pour tout $x \in E$, il existe un unique $y \in F$ tel que*

$$\|x - y\| = \inf_{z \in F} \|x - z\|.$$

Ce point unique le plus proche dans F s'appelle la projection (orthogonale) de x sur F . Pour tout $z \in F$,

$$\langle x - y, z - y \rangle \leq 0.$$

Si F est un sous-espace vectoriel de E , la relation de Pythagore s'écrit :

$$\|x\|^2 = \|y\|^2 + \|x - y\|^2$$

et pour tout $z \in F$, $\langle x - y, z \rangle = 0$.

Preuve. Soit $d = \inf_{z \in F} \|x - z\|$. Soit $(z_n)_n$ une suite d'éléments de F telle que

$$\lim_n \|x - z_n\| = d.$$

D'après la loi du parallélogramme,

$$2(\|x - z_n\|^2 + \|x - z_m\|^2) = \|2x - (z_n + z_m)\|^2 + \|z_n - z_m\|^2.$$

Comme F est convexe, $(z_n + z_m)/2 \in F$, donc

$$\|x - (z_n + z_m)/2\| \geq d.$$

Soit $\epsilon \in (0, 1]$ et n_0 tel que pour $n \geq n_0$, $\|x - z_n\| \leq d + \epsilon$. Pour $n, m \geq n_0$

$$4(d + \epsilon)^2 \geq 4d^2 + \|z_n - z_m\|^2$$

ou, de façon équivalente,

$$\|z_n - z_m\|^2 \leq 4(2d + 1)\epsilon.$$

Ainsi, la suite minimisante $(z_n)_n$ est de Cauchy. Comme F est fermé, elle admet une limite unique $y \in F$ et $d = \|x - y\|$.

Pour vérifier l'unicité, supposons qu'il existe $y' \in F$ tel que $\|x - y'\| = d$. Construisons une nouvelle suite $(z'_n)_{n \in \mathbb{N}}$ telle que $z'_{2n} = z_n$ et $z'_{2n+1} = y'$. Cette suite à valeurs dans F

CHAPITRE II. CONDITIONNEMENT

satisfait $\lim_n \|z'_n - x\| = d$. D'après l'argument ci-dessus, elle admet une limite y'' dans F . La limite y'' coïncide avec la limite de toute sous-suite, donc elle vaut y et y' .

Fixons $z \in F \setminus \{y\}$. Pour tout $u \in (0, 1]$, posons $z_u = y + u(z - y)$. Alors $z_u \in F$ et

$$\|x - z_u\|^2 - \|x - y\|^2 = -2u\langle x - y, z - y \rangle + u^2\|z - y\|^2.$$

Comme cette quantité est positive pour $u \in [0, 1]$, $\langle x - y, z - y \rangle$ doit être négative ou nulle.

Supposons maintenant que F est un sous-espace de E .

S'il existe $y \in F$ tel que $\langle x - y, z \rangle = 0$ pour tout $z \in F$, alors y est la projection orthogonale de x sur F , car pour tout $z \in F$:

$$\begin{aligned} \|x - z\|^2 &= \|x - y\|^2 - 2\langle x - y, z \rangle + \|z\|^2 \\ &\geq \|x - y\|^2. \end{aligned}$$

Réciproquement, si y est la projection orthogonale de x sur F , pour tout z de F et tout $\lambda \in \mathbb{R}$:

$$\begin{aligned} \|x - y\|^2 &\leq \|x - (y + \lambda z)\|^2 \\ &= \|x - y\|^2 - 2\lambda\langle x - y, z \rangle + \lambda^2\|z\|^2, \end{aligned}$$

so $0 \leq 2\lambda\langle x - y, z \rangle + \lambda^2\|z\|^2$. Pour que ce polynôme en λ soit de signe constant, il est nécessaire que $\langle x - y, z \rangle = 0$. $\square$

Comme $\mathcal{L}_2(\Omega, \mathcal{G}, P)$ est une partie convexe de $\mathcal{L}_2(\Omega, \mathcal{F}, P)$, l'existence et l'unicité de la projection sur une partie convexe fermée d'un espace de Hilbert donnent le corollaire suivant, qui correspond au premier énoncé du théorème 11.1.

Étant donné $X \in \mathcal{L}_2(\Omega, \mathcal{F}, P)$ et $\mathcal{G}$ une sous-tribu de $\mathcal{F}$, il existe $Y \in \mathcal{L}_2(\Omega, \mathcal{G}, P)$ qui minimise

$$\mathbb{E}[(X - Z)^2] \quad \text{pour } Z \in \mathcal{L}_2(\Omega, \mathcal{G}, P).$$

Tout autre minimiseur dans $\mathcal{L}_2(\Omega, \mathcal{G}, P)$ est P -presque sûrement égal à Y .

Preuve. Soit Y une version de la projection orthogonale de X sur $L_2(\Omega, \mathcal{G}, P)$ et B un élément de $\mathcal{G}$.

Le produit scalaire de $\mathbb{I}_B \in \mathcal{L}_2(\Omega, \mathcal{G}, P)$ et $X - Y$ vaut

$$\langle X - Y, \mathbb{I}_B \rangle = \mathbb{E}[(X - Y)\mathbb{I}_B].$$

Par Théorème 11.2, $\mathbb{E}[(X - Y)\mathbb{I}_B] = 0$. $\square$

Nous terminons cette section par un théorème de Pythagore pour la variance.

Définition 11.3 (Variance conditionnelle). Soient $X \in \mathcal{L}_2(\Omega, \mathcal{F}, P)$ et $\mathcal{G} \subseteq \mathcal{F}$ une sous-tribu. La *variance conditionnelle* de X par rapport à $\mathcal{G}$ est définie par

$$\text{Var}[X \mid \mathcal{G}] = \mathbb{E}[(X - \mathbb{E}[X \mid \mathcal{G}])^2 \mid \mathcal{G}].$$

La variance conditionnelle est une variable aléatoire ($\mathcal{G}$ -mesurable), tout comme l'espérance conditionnelle. C'est l'espérance conditionnelle de l'erreur de prédiction commise lorsqu'on cherche à prédire X à l'aide de $\mathbb{E}[X | \mathcal{G}]$.

Proposition 11.2. Soient $X \in \mathcal{L}_2(\Omega, \mathcal{F}, P)$ et $\mathcal{G} \subseteq \mathcal{F}$ une sous-tribu. Alors

$$\text{Var}[X] = \text{Var} \left[\mathbb{E}[X | \mathcal{G}] \right] + \mathbb{E} \left[\text{Var}[X | \mathcal{G}] \right].$$

Preuve. Rappelons que $\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[X]$.

$$\begin{aligned} \text{Var}[X] &= \mathbb{E}[(X - \mathbb{E}[X])^2] \\ &= \mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}] + \mathbb{E}[X | \mathcal{G}] - \mathbb{E}[X])^2] \\ &= \mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}])^2] \\ &\quad + 2\mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}]) (\mathbb{E}[X | \mathcal{G}] - \mathbb{E}[X])] \\ &\quad + \mathbb{E}[(\mathbb{E}[X | \mathcal{G}] - \mathbb{E}[X])^2] \\ &= \mathbb{E}[\mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}])^2 | \mathcal{G}]] \\ &\quad + 2\mathbb{E}[\mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}]) | \mathcal{G}] (\mathbb{E}[X | \mathcal{G}] - \mathbb{E}[X])] \\ &\quad + \text{Var}[\mathbb{E}[X | \mathcal{G}]] \\ &= \mathbb{E}[\text{Var}[X | \mathcal{G}]] + \text{Var}[\mathbb{E}[X | \mathcal{G}]]. \end{aligned}$$

□

11.3 Espérance conditionnelle dans $\mathcal{L}_1(\Omega, \mathcal{F}, P)$

Pour construire l'espérance conditionnelle d'une variable aléatoire, l'intégrabilité au carré n'est pas nécessaire. C'est le sens du théorème suivant.

Théorème 11.3. Si $Y \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$, alors il existe une variable aléatoire intégrable $\mathcal{G}$ -mesurable, notée $\mathbb{E}[Y | \mathcal{G}]$ telle que

$$\forall B \in \mathcal{G}, \mathbb{E}[\mathbb{I}_B Y] = \mathbb{E}[\mathbb{I}_B \mathbb{E}[Y | \mathcal{G}]].$$

En d'autres termes, les espérances conditionnelles au sens de Définition 11.1 existent pour toute variable intégrable et toute sous-tribu.

Exercice 11.1. Soit $\mathcal{G}'$ un π -système contenant Ω et engendrant $\mathcal{G}$. Si Z est une variable intégrable $\mathcal{G}$ -mesurable qui satisfait

$$\forall B \in \mathcal{G}', \mathbb{E}[\mathbb{I}_B Z] = \mathbb{E}[\mathbb{I}_B \mathbb{E}[Z | \mathcal{G}]]$$

alors $Z = \mathbb{E}[Y \mid \mathcal{G}]$.

Pour établir Théorème II.3, nous utilisons la *machinerie habituelle* des arguments limites.

Proposition 11.3. *Si $(Y_n)_n$ est une suite croissante de variables aléatoires positives de carré intégrable telle que $Y_n \uparrow Y$ p.s., alors il existe une variable aléatoire $\mathcal{G}$ -mesurable Z telle que*

$$\mathbb{E}[Y_n \mid \mathcal{G}] \uparrow Z \quad a.s.$$

Preuve. Comme $(Y_n)_n$ est croissante, d'après Proposition II.1, $(\mathbb{E}[Y_n \mid \mathcal{G}])_n$ est une suite (p.s.) croissante de variables aléatoires $\mathcal{G}$ -mesurables; elle admet une limite $\mathcal{G}$ -mesurable (finie ou non). $\square$

Passons maintenant à la démonstration de Théorème II.3.

Preuve. Sans perte de généralité, supposons $Y \geq 0$ (sinon, posons $Y = (Y)_+ - (Y)_-$ avec $(Y)_+ = |Y| \mathbb{1}_{Y \geq 0}$ et $(Y)_- = |Y| \mathbb{1}_{Y < 0}$, traitons $(Y)_+$ et $(Y)_-$ séparément et utilisons la linéarité de l'espérance conditionnelle).

Posons

$$Y_n = Y \mathbb{1}_{|Y| \leq n}$$

de sorte que $Y_n \nearrow Y$ partout. La variable aléatoire Y_n est bornée et donc de carré intégrable. La variable aléatoire $\mathbb{E}[Y_n \mid \mathcal{G}]$ est donc bien définie pour chaque n .

La suite $\mathbb{E}[Y_n \mid \mathcal{G}]$ est P-p.s. monotone. Elle converge monotone vers une variable aléatoire $\mathcal{G}$ -mesurable Z à valeurs dans $\mathbb{R}_+ \cup \{\infty\}$. Il reste à vérifier que cette variable aléatoire $Z \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$.

Par convergence monotone :

$$\begin{aligned} \mathbb{E}Y &= \mathbb{E}\left[\lim_n \uparrow Y_n\right] \\ &= \lim_n \uparrow \mathbb{E}[Y_n] \\ &= \lim_n \uparrow \mathbb{E}\left[\mathbb{E}[Y_n \mid \mathcal{G}]\right] \\ &= \mathbb{E}\left[\lim_n \uparrow \mathbb{E}[Y_n \mid \mathcal{G}]\right] \\ &= \mathbb{E}Z. \end{aligned}$$

Si $A \in \mathcal{G}$, par convergence monotone,

$$\lim_n \uparrow \mathbb{E}[\mathbb{1}_A Y_n] = \mathbb{E}[\mathbb{1}_A Y]$$

et donc

$$\lim_n \uparrow \mathbb{E}[\mathbb{1}_A \mathbb{E}[Y_n \mid \mathcal{G}]] = \mathbb{E}[\mathbb{1}_A Y].$$

Encore par convergence monotone :

$$\lim_n \uparrow \mathbb{E} \left[\mathbb{1}_A \lim_n \mathbb{E} [Y_n | \mathcal{G}] \right] = \mathbb{E} [\mathbb{1}_A Z]$$

□

11.4 Propriétés de l'espérance conditionnelle (générale)

Remarque 11.2. Dans cette section, $(\Omega, \mathcal{F}, P)$ est un espace de probabilité, $\mathcal{G}$ une sous-tribu de $\mathcal{F}$. Les variables aléatoires $(X_n)_n, (Y_n)_n, X, Y, Z$ sont supposées intégrables, et p.s. signifie *P*-p.s.

La propriété la plus simple est :

Si $X \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$, alors

$$\mathbb{E} [X] = \mathbb{E} [\mathbb{E} [X | \mathcal{G}]] .$$

Exercice 11.2. Le démontrer.

Si $X \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$ et X est $\mathcal{G}$ -mesurable, alors

$$X = \mathbb{E} [X | \mathcal{G}] \quad P\text{-a.s.}$$

Exercice 11.3. Le démontrer.

En utilisant la définition de l'espérance conditionnelle et l'approximation monotone par des fonctions simples (voir section 3.2), nous obtenons une caractérisation alternative de l'espérance conditionnelle.

Soient $X \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$ et $\mathcal{G} \subseteq \mathcal{F}$ une sous-tribu. Alors, pour toute $Y \in \mathcal{L}_1(\Omega, \mathcal{G}, P)$ telle que $\mathbb{E} [|XY|] < \infty$

$$\mathbb{E} [XY] = \mathbb{E} [Y \mathbb{E} [X | \mathcal{G}]] .$$

Exercice 11.4. Le démontrer.

Nous gardons la proposition suivante pour un usage futur et fréquent. On pourrait continuer à énumérer bien d'autres propriétés utiles de l'espérance conditionnelle. Elles se découvrent et s'établissent mieux au moment où l'on en a besoin.

Si $X, Y \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$ et Y est $\mathcal{G}$ -mesurable, alors

$$\mathbb{E} [XY | \mathcal{G}] = Y \mathbb{E} [X | \mathcal{G}] \quad P\text{-a.s.}$$

Preuve. Comme $Y \mathbb{E} [X | \mathcal{G}]$ est $\mathcal{G}$ -mesurable, il suffit de vérifier que pour tout $B \in \mathcal{G}$,

$$\mathbb{E} [\mathbb{1}_B XY] = \mathbb{E} [\mathbb{1}_B (Y \mathbb{E} [X | \mathcal{G}])] .$$

Or

$$\begin{aligned}
 \mathbb{E} [\mathbb{I}_B XY] &= \mathbb{E} [(\mathbb{I}_B Y) X] \\
 &= \mathbb{E} [(\mathbb{I}_B Y) \mathbb{E} [X \mid \mathcal{G}]] \\
 &= \mathbb{E} [\mathbb{I}_B (Y \mathbb{E} [X \mid \mathcal{G}])] .
 \end{aligned}$$

□

11.5 Théorèmes de convergence conditionnelle

Les théorèmes limites de la théorie de l'intégration (théorème de convergence monotone, lemme de Fatou, théorème de convergence dominée) peuvent être adaptés au cadre de l'espérance conditionnelle.

Théorème 11.4 (Convergence monotone). *Soit $(X_n)_n$ une suite de variables aléatoires positives convergeant monotone vers X ($X_n \uparrow X$ p.s.), avec X intégrable. Alors, pour toute suite de versions d'espérances conditionnelles :*

$$\lim_n \uparrow \mathbb{E} [X_n \mid \mathcal{G}] = \mathbb{E} [X \mid \mathcal{G}] \text{ a.s.}$$

Preuve. La suite $X - X_n$ est positive et décroît vers 0 p.s. Il suffit de montrer que $\lim_n \downarrow \mathbb{E} [X - X_n \mid \mathcal{G}] = 0$ p.s. Notons d'abord que la suite $\mathbb{E} [X - X_n \mid \mathcal{G}]$ converge p.s. vers une limite positive. Il reste à vérifier que cette limite est p.s. nulle.

Pour $A \in \mathcal{G}$:

$$\begin{aligned}
 \mathbb{E} \left[\mathbb{I}_A \lim_n \mathbb{E} [X - X_n \mid \mathcal{G}] \right] &= \lim_n \mathbb{E} [\mathbb{I}_A \mathbb{E} [X - X_n \mid \mathcal{G}]] \\
 &\quad \text{monotone convergence theorem} \\
 &= \lim_n \mathbb{E} [\mathbb{I}_A (X_n - X)] \\
 &\quad \text{monotone convergence theorem} \\
 &= 0 .
 \end{aligned}$$

□

Théorème 11.5 (Lemme de Fatou conditionnel). *Soit $(X_n)_n$ une suite de variables aléatoires positives. Alors*

$$\mathbb{E} \left[\liminf_n X_n \mid \mathcal{G} \right] \leq \liminf_n \mathbb{E} [X_n \mid \mathcal{G}] \text{ a.s.}$$

Comme pour la démonstration du lemme de Fatou, l'argument se réduit à des arguments de convergence monotone.

Preuve. Soit $B \in \mathcal{G}$. Posons $X = \liminf_n X_n$; X est une variable aléatoire positive. Posons $Y = \liminf_n \mathbb{E}[X_n | \mathcal{G}]$; Y est une variable aléatoire intégrable $\mathcal{G}$ -mesurable. Le théorème compare $\mathbb{E}[X | \mathcal{G}]$ et Y .

Posons $Z_k = \inf_{n \geq k} X_n$. Ainsi $\lim_k \uparrow Z_k = \liminf_n X_n = X$. D'après Théorème II.4,

$$\mathbb{E}[Z_k | \mathcal{G}] \uparrow_k \mathbb{E}\left[\liminf_n X_n | \mathcal{G}\right] \text{ a.s.}$$

Pour tout $n \geq k$, $X_n \geq Z_k$ p.s. D'où, par le théorème de comparaison (corollaire II.1),

$$\forall n \geq k \quad \mathbb{E}[Z_k | \mathcal{G}] \leq \mathbb{E}[X_n | \mathcal{G}] \text{ a.s.}$$

car une réunion dénombrable d'événements P -négligeables est P -négligeable. Ainsi, pour tout k ,

$$\mathbb{E}[Z_k | \mathcal{G}] \leq \liminf_n \mathbb{E}[X_n | \mathcal{G}] \text{ a.s.}$$

Il s'ensuit que

$$\lim_k \uparrow \mathbb{E}[Z_k | \mathcal{G}] \leq \liminf_n \mathbb{E}[X_n | \mathcal{G}] \text{ a.s.}$$

□

Convergence dominée

Soit $V \in \mathcal{L}_1(\Omega, \mathcal{F}, P)$. Supposons que la suite $(X_n)_n$ satisfasse $|X_n| \leq V$ pour tout n et $X_n \rightarrow X$ a.s.. Alors, pour toute suite de versions d'espérances conditionnelles de $(X_n)_n$ et de X ,

$$\mathbb{E}[X_n | \mathcal{G}] \rightarrow \mathbb{E}[X | \mathcal{G}] \text{ a.s.}$$

Preuve. Posons $Y_n = \inf_{m \geq n} X_m$ et $Z_n = \sup_{m \geq n} X_m$. Ainsi $-V \leq Y_n \leq Z_n \leq V$. Comme $Y_n \uparrow X$ et $Z_n \downarrow X$, par le théorème de convergence monotone conditionnelle (théorème II.4), $\mathbb{E}[Y_n | \mathcal{G}] \uparrow \mathbb{E}[X | \mathcal{G}]$ et $\mathbb{E}[Z_n | \mathcal{G}] \downarrow \mathbb{E}[X | \mathcal{G}]$ p.s. Observons que pour tout n

$$\mathbb{E}[Y_n | \mathcal{G}] \leq \mathbb{E}[X_n | \mathcal{G}] \leq \mathbb{E}[Z_n | \mathcal{G}] \text{ a.s.}$$

□

L'inégalité de Jensen possède aussi une version conditionnelle. La démonstration s'appuie encore sur la représentation variationnelle des fonctions convexes semi-continues inférieures et sur la propriété de monotonie de l'espérance conditionnelle (corollaire II.1).

Inégalité de Jensen

Si g est une fonction convexe semi-continue inférieure sur $\mathbb{R}$, avec $\mathbb{E}[|g(X)|] < \infty$, alors

$$g(\mathbb{E}[X | \mathcal{G}]) \leq \mathbb{E}[g(X) | \mathcal{G}] \text{ a.s..}$$

Preuve. Une fonction convexe semi-continue inférieure est un supremum dénombrable de fonctions affines : il existe une collection dénombrable $(a_n, b_n)_n$ telle que, pour tout x :

$$g(x) = \sup_n [a_n x + b_n].$$

$$\begin{aligned} g(\mathbb{E}[X | \mathcal{G}]) &= \sup_n [a_n \mathbb{E}[X | \mathcal{G}] + b_n] \\ &= \sup_n [\mathbb{E}[a_n X + b_n | \mathcal{G}]] \\ &\leq \mathbb{E}\left[\sup_n (a_n X + b_n) | \mathcal{G}\right] \text{ P-a.s.} \end{aligned}$$

□

Indépendance

Lorsque la tribu de conditionnement $\mathcal{G}$ est atomique, si la variable aléatoire conditionnée X est indépendante de la tribu de conditionnement, il est évident que l'espérance conditionnelle est une variable aléatoire p.s. constante dont la valeur vaut $\mathbb{E}X$. Cela reste vrai dans le cadre général. Une démonstration s'impose.

Proposition 11.4. *Si X est indépendante de $\mathcal{G}$, alors*

$$\mathbb{E}[X | \mathcal{G}] = \mathbb{E}[X].$$

Preuve. Notons que $\mathbb{E}[X]$ est $\mathcal{G}$ -mesurable. Soit $B \in \mathcal{G}$,

$$\begin{aligned} \mathbb{E}[\mathbb{I}_B X] &= \mathbb{E}[\mathbb{I}_B] \mathbb{E}[X] \\ &\quad \text{by independence} \\ &= \mathbb{E}[\mathbb{I}_B \times \mathbb{E}[X]]. \end{aligned}$$

D'où $\mathbb{E}[X] = \mathbb{E}[X | \mathcal{G}]$.

□

La proposition 11.4 peut être généralisée dans un cadre plus large.

Si la sous-tribu $\mathcal{H}$ est indépendante de $\sigma(\mathcal{G}, \sigma(X))$, alors

$$\mathbb{E}[X | \sigma(\mathcal{G}, \mathcal{H})] = \mathbb{E}[X | \mathcal{G}] \quad \text{a.s.}$$

Preuve. Rappelons que l'espérance conditionnelle par rapport à $\sigma(\mathcal{G}, \mathcal{H})$ peut se caractériser à l'aide d'un π -système contenant Ω et engendrant $\sigma(\mathcal{G}, \mathcal{H})$, par exemple $\mathcal{G} \times \mathcal{H}$. Soient $B \in \mathcal{G}$ et $C \in \mathcal{H}$,

$$\begin{aligned}
 \mathbb{E}[\mathbb{I}_B \mathbb{I}_C \mathbb{E}[X \mid \mathcal{G}]] &= \mathbb{E}[\mathbb{I}_B \mathbb{E}[X \mid \mathcal{G}]] \times \mathbb{E}[\mathbb{I}_C] \\
 &\quad C \text{ est indépendante de } \sigma(\mathcal{G}, \sigma(X)) \\
 &= \mathbb{E}[\mathbb{I}_B X] \times \mathbb{E}[\mathbb{I}_C] \\
 &= \mathbb{E}[\mathbb{I}_C \mathbb{I}_B X] \\
 &\quad C \text{ est indépendante de } \sigma(\mathcal{G}, \sigma(X)).
 \end{aligned}$$

□

11.6 Lois conditionnelles

Cas simple : conditionnement par rapport à une tribu discrète

Revenons au cadre de base : $(\Omega, \mathcal{F}, P)$ désigne un espace de probabilité, tandis que $\mathcal{G} \subseteq \mathcal{F}$ est une sous-tribu *atomique* engendrée par une partition dénombrable $(A_n)_n$ de Ω .

Que ce soit à partir des espérances conditionnelles par rapport à $\mathcal{G}$, ou à partir des probabilités conditionnelles sachant les événements A_n , on peut définir une fonction N de $\Omega \times \mathcal{F}$ par

$$N(\omega, B) = \mathbb{E}_P[\mathbb{I}_B \mid \mathcal{G}](\omega) = P\{B \mid A_n\} \text{ when } \omega \in A_n.$$

La fonction N possède deux propriétés remarquables :

- i. Pour tout $\omega \in \Omega$, $N(\omega, \cdot)$ définit une probabilité sur $(\Omega, \mathcal{F})$.
- ii. Pour tout événement $B \in \mathcal{F}$, la fonction $N(\cdot, B)$ est $\mathcal{G}$ -mesurable.

Dans ce cadre atomique simple, on observe que s'il est intuitif de définir l'espérance conditionnelle à partir des probabilités conditionnelles, on peut aussi procéder en sens inverse : construire des probabilités conditionnelles à partir des espérances conditionnelles.

Obstacles

Dans le cas général, on tente de construire des probabilités conditionnelles lorsque la tribu de conditionnement n'est pas atomique.

Pour chaque $B \in \mathcal{F}$, on peut s'appuyer sur l'existence d'une variable aléatoire $\sigma(X)$ -mesurable qui est P -p.s. une version de l'espérance conditionnelle de $\mathbb{I}_B$ par rapport à X . En effet, pour toute collection dénombrable d'événements $(B_n)_n$ de $\mathcal{F}$, on peut admettre qu'il existe une collection de variables aléatoires qui forment, presque sûrement, une collection cohérente de versions des espérances de $(\mathbb{I}_{B_n})_n$ par rapport à X . Si $(B_n)_n$ est croissante et tend vers B , d'après théorème 11.4, on a confiance dans le fait que l'égalité suivante vaut

$$\lim_n \uparrow \mathbb{E}[\mathbb{I}_{B_n} \mid X] = \mathbb{E}[\mathbb{I}_B \mid X] \quad \text{a.s.}$$

Il est donc tentant de définir une probabilité conditionnelle par rapport à $\sigma(X)$ comme une fonction

$$\begin{aligned}\Omega \times \mathcal{F} &\rightarrow [0, 1] \\ (\omega, B) &\mapsto \mathbb{E} [\mathbb{I}_B \mid \sigma(X)] (\omega).\end{aligned}$$

Malheureusement, on ne peut pas garantir que P -p.s., cet objet possède les propriétés d'une loi de probabilité sur $(\Omega, \mathcal{F})$. Le problème ne vient pas de la nature diffuse de la loi de X mais de la taille de $\mathcal{F}$. Comme $\mathcal{F}$ peut ne pas être dénombrable, il est possible de construire une suite croissante non dénombrable d'événements. Vérifier la monotonie p.s. de la suite des probabilités conditionnelles correspondantes dépasse notre portée (une réunion non dénombrable d'événements P -négligeables n'est pas nécessairement P -négligeable).

Heureusement, la situation n'est pas désespérée. Dans la plupart des cadres envisagés dans un cours introductif de probabilités, on peut admettre l'existence de probabilités conditionnelles.

Dans section 11.6), nous passons d'abord en revue le cas simple, où l'on peut définir des probabilités conditionnelles qui possèdent même une densité par rapport à une mesure de référence. Dans section 11.6), nous verrons que si Ω n'est pas trop grand, on peut s'appuyer sur l'existence de probabilités conditionnelles.

Cadre des densités jointes

Si $\Omega = \mathbb{R}^k$, $\mathcal{F} = \mathcal{B}(\mathbb{R}^k)$ et la loi de probabilité P est absolument continue par rapport à la mesure de Lebesgue (possède une densité notée p), définir une densité conditionnelle par rapport aux projections sur les coordonnées est presque aussi simple que le conditionnement par rapport à une tribu atomique.

Pour simplifier, nous nous limitons au cas $k = 2$. Un résultat générique est noté $\omega = (x, y)$ et les projections coordonnées définissent deux variables aléatoires $X(x, y) = x$ et $Y(x, y) = y$. Notons p_X la *densité marginale* de la loi de X :

$$p_X(x) = \int_{\mathbb{R}} p(x, y) dy.$$

Convenons que $D = \{x : p_X(x) > 0\}$. C'est le support de la densité p_X (attention, cela peut différer du support de la loi $P \circ X^{-1}$).

Exercice 11.5. Vérifier que p_X est la densité de $P \circ X^{-1}$.

Disposer d'une densité permet de calculer l'espérance conditionnelle et de définir aussi facilement ce que nous appellerons une probabilité conditionnelle de Y sachant X .

Théorème 11.6 (Densité conditionnelle). *Soient X, Y les coordonnées de projection sur $\mathbb{R}^2$. Soit P une loi absolument continue sur $(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2))$ de densité $p(\cdot, \cdot)$ par rapport à la mesure de Lebesgue. Notons p_X la première densité marginale (densité de $P \circ X^{-1}$). La fonction*

$$N : \mathbb{R}^2 \rightarrow [0, \infty)$$

$$(x, y) \mapsto N(x, y) = \begin{cases} \frac{p(x, y)}{p_X(x)} & \text{if } p_X(x) > 0 \\ 0 & \text{otherwise,} \end{cases}$$

satisfait les propriétés suivantes.

i. Pour chaque x tel que $p_X(x) > 0$, la fonction d'ensemble $P_{\cdot|X=x}$ définie par

$$\mathcal{B}(\mathbb{R}^2) \rightarrow [0, 1]$$

$$B \mapsto P_{\cdot|X=x}\{B\} = \int_{\mathbb{R}} \mathbb{I}_B(x, y) N(x, y) dy$$

est une mesure de probabilité sur $(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2))$. Cette loi de probabilité est portée par $\{x\} \times \mathbb{R}$.

ii. Pour tout $B \in \mathcal{B}(\mathbb{R}^2)$, la fonction

$$\omega \mapsto \int_{\mathbb{R}} \mathbb{I}_B(X(\omega), y) N(X(\omega), y) dy = \mathbb{E}_{P_{\cdot|X=X(\omega)}} \mathbb{I}_B$$

pour $\Omega = \mathbb{R}^2$, est $\sigma(X)$ -mesurable et peut être appelée une version de $\mathbb{E}[\mathbb{I}_B | \sigma(X)]$.

iii. Pour tout $B \in \mathcal{B}(\mathbb{R}^2)$

$$P(B) = \int \left(\int_{\mathbb{R}} \mathbb{I}_B(s, y) N(s, y) dy \right) p_X(s) ds = \int P_{\cdot|X=s}(B) p_X(s) ds.$$

iv. Pour toute fonction f P -intégrable sur $\mathbb{R}^2$, la variable aléatoire obtenue en appliquant

$$x \mapsto \int_{\mathbb{R}} f(x, y) N(x, y) dy$$

à X est une version de l'espérance conditionnelle de $f(X, Y)$ par rapport à $\sigma(X)$.

Remarque II.3. Pour chaque x tel que $p_X(x) > 0$, $P_{\cdot|X=x}$ est une probabilité sur $\mathbb{R}^2$. Mais cette mesure de probabilité est portée par $\{x\} \times \mathbb{R}$; c'est le produit de la masse de Dirac en $\{x\}$ par la loi de probabilité sur $\mathbb{R}$ définie par la densité $N(x, \cdot)$. C'est pourquoi $N(x, \cdot)$ est souvent appelée la densité conditionnelle de Y sachant $X = x$, et la loi sur $\mathbb{R}$ définie par cette densité est souvent appelée la loi conditionnelle de Y sachant X .

Exercice 11.6. $N(x, y)$ est-elle une densité de probabilité? Si oui, par rapport à quelle mesure σ -finie?

La démonstration du théorème II.6 consiste à exploiter le théorème de Tonelli-Fubini.

CHAPITRE II. CONDITIONNEMENT

Preuve. Démonstration de (i). Convenons des notations :

$$P_x\{B\} = \int_{\mathbb{R}} \mathbb{I}_B(x, y) N(x, y) dy.$$

Le fait que P_x soit à valeurs dans $[0, 1]$ est immédiat. Il en va de même pour $P_x(\{x\} \times \{\emptyset\}) = 0$ et $P_x(\{x\} \times \{\mathbb{R}\}) = 1$. Il en va de même pour l'additivité.

Il reste à vérifier que si (B_n) est une suite croissante de boréliens de $\mathbb{R}^2$ qui tend vers une limite B , alors

$$\lim_n \uparrow P_x(B_n) = P_x(B).$$

C'est une conséquence immédiate du théorème de convergence monotone : pour chaque (x', y') , $\lim_n \uparrow \mathbb{I}_{B_n}(x', y') N(x', y') = \mathbb{I}_B(x', y') N(x', y')$.

Démonstration de ii) Comme la fonction $(x, y) \mapsto p(x, y) \mathbb{I}_B(x, y)$ est $\mathcal{B}(\mathbb{R}^2)$ -mesurable et intégrable, d'après le théorème de Tonelli-Fubini,

$$x \mapsto \int_B p(x, y) \mathbb{I}_B(x, y) dy$$

est définie presque partout et borélienne.

Démonstration de iii) C'est aussi une conséquence immédiate du théorème de Tonelli-Fubini.

Démonstration de iv) Elle découle de i.), en utilisant l'argument habituel d'approximation par des fonctions simples. $\square$

Exercice 11.7. Nous considérons la loi uniforme sur la surface de $\mathbb{R}^2$ définie par $0 \leq x \leq y \leq 1$. Donner la densité jointe $p(\cdot)$, la densité marginale p_X et le noyau $N(\cdot, \cdot)$.

Probabilités conditionnelles régulières, noyaux

Nous esquissons quelques résultats qui permettent de travailler dans un cadre plus général. Nous introduisons deux nouvelles notions.

Noyau de probabilité conditionnelle

Soient $(\Omega, \mathcal{F})$ un espace mesurable, et $\mathcal{G}$ une sous-tribu de $\mathcal{F}$.

On appelle *noyau de probabilité conditionnelle par rapport à $\mathcal{G}$* une fonction $N : \Omega \times \mathcal{F} \rightarrow \mathbb{R}_+$ qui satisfait :

- i. Pour tout $\omega \in \Omega$, $N(\omega, \cdot)$ définit une probabilité sur $(\Omega, \mathcal{F})$.
- ii. Pour tout $A \in \mathcal{F}$, $N(\cdot, A)$ est $\mathcal{G}$ -mesurable

Si l'espace mesurable est muni d'une loi de probabilité P , nous nous intéressons aux noyaux de probabilité conditionnelle par rapport à $\mathcal{G}$ compatibles avec P . On les appelle *noyaux de probabilité conditionnelle régulière*.

Probabilité conditionnelle régulière

Soient $(\Omega, \mathcal{F}, P)$ un espace de probabilité et $\mathcal{G} \subseteq \mathcal{F}$ une sous-tribu. Un noyau $N : \Omega \times \mathcal{F} \rightarrow \mathbb{R}_+$ est une *probabilité conditionnelle régulière* par rapport à $\mathcal{G}$ si et seulement si

- i. Pour tout $B \in \mathcal{F}$, $\omega \mapsto N(\omega, B)$ est une version de l'espérance conditionnelle de $\mathbb{I}_B$ sachant $\mathcal{G}$ ($N(\cdot, B)$ est donc $\mathcal{G}$ -mesurable) :

$$N(\cdot, B) = \mathbb{E}[\mathbb{I}_B \mid \mathcal{G}] \quad P - \text{a.s.}$$

- ii. Pour P -presque tout $\omega \in \Omega$, $B \mapsto N(\omega, B)$ définit une probabilité sur $(\Omega, \mathcal{F})$.

Une probabilité conditionnelle régulière (lorsqu'elle existe) se définit à partir de versions d'espérances conditionnelles. Réciproquement, une probabilité conditionnelle régulière nous fournit un moyen de calculer les espérances conditionnelles.

Soient $(\Omega, \mathcal{F}, P)$ un espace de probabilité et $\mathcal{G} \subseteq \mathcal{F}$ une sous-tribu. Soit N un noyau de probabilité sur $(\Omega, \mathcal{F})$ par rapport à $\mathcal{G}$.

Les propriétés suivantes sont équivalentes

1. $N(\cdot, \cdot)$ définit un noyau de probabilité conditionnelle régulière par rapport à $\mathcal{G}$ pour $(\Omega, \mathcal{G}, P)$.
2. P -presque sûrement, pour toute fonction f P -intégrable sur $(\Omega, \mathcal{F})$:

$$\mathbb{E}[f \mid \mathcal{G}](\omega) = \mathbb{E}_{N(\omega, \cdot)}[f].$$

3. Pour toute variable aléatoire X P -intégrable sur $(\Omega, \mathcal{F})$

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}_{N(\omega, \cdot)}[X]].$$

Remarque II.4. La démonstration de 1) $\Rightarrow$ 2) s'appuie sur la machinerie habituelle : approximation des fonctions intégrables positives par des suites croissantes de fonctions simples, convergence monotone de l'espérance et de l'espérance conditionnelle.

2) $\Rightarrow$ 3) est trivial.

3) $\Rightarrow$ 1) est plus intéressant.

Existence de lois conditionnelles régulières lorsque $\Omega = \mathbb{R}$

Nous vérifions l'existence de probabilités conditionnelles dans au moins un cas non trivial.

Soit P une probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ et $\mathcal{G} \subseteq \mathcal{B}(\mathbb{R})$. Alors il existe un noyau de probabilité conditionnelle régulière par rapport à $\mathcal{G}$.

Nous profitons du fait que $\mathcal{B}(\mathbb{R})$ est engendrée de façon dénombrable.

Preuve. Soit $\mathcal{C}$ l'ensemble formé des demi-droites à extrémité rationnelle, de l'ensemble vide et de $\mathbb{R}$:

$$\mathcal{C} = \{(-\infty, q] : q \in \mathbb{Q}\} \cup \{\emptyset, \mathbb{R}\}.$$

Cette collection dénombrable de demi-droites est un π -système (voir section 2.6) qui engendre $\mathcal{B}(\mathbb{R})$.

CHAPITRE II. CONDITIONNEMENT

Pour $q < q' \in \mathbb{Q}$, nous pouvons choisir des versions de Y_q et $Y_{q'}$ des espérances conditionnelles de $\mathbb{I}_{(-\infty, q]}$ et $\mathbb{I}_{(-\infty, q']}$ telles que

$$Y_q < Y_{q'} \quad P\text{-a.s.}$$

Observons que $Y_{q'} - Y_q$ est aussi une version de l'espérance conditionnelle de $\mathbb{I}_{(q, q']}$.

Une réunion dénombrable d'événements P -négligeables est P -négligeable; comme $\mathbb{Q}^2$ est dénombrable, nous pouvons choisir des versions $(Y_q)_{q \in \mathbb{Q}}$ des espérances conditionnelles de $\mathbb{I}_{(-\infty, q]}$ telles que

$$P\text{-a.s.} \quad \forall q, q' \in \mathbb{Q}, \quad q < q' \Rightarrow Y_q < Y_{q'},$$

Soit Ω_0 l'événement P -presque sûr sur lequel tous les Y_q , $q \in \mathbb{Q}$, satisfont les bonnes propriétés.

Pour chaque $x \in \mathbb{R}$, définissons Z_x pour chaque $\omega \in \mathbb{R}$ par

$$Z_x(\omega) = \inf \{ Y_q(\omega) : q \in \mathbb{Q}, x < q \}$$

Sur Ω_0 , la fonction $x \mapsto Z_x(\omega)$ est croissante, possède une limite à gauche en chaque point et est continue à droite. La fonction $x \mapsto Z_x(\omega)$ tend vers 0 lorsque x tend vers $-\infty$, vers 1 lorsque x tend vers $+\infty$. En d'autres termes, sur Ω_0 , $x \mapsto Z_x(\omega)$ est une fonction de répartition; elle définit donc (uniquement) une mesure de probabilité sur $\mathbb{R}$. Nous la noterons $\nu(\omega, \cdot)$.

De plus, pour chaque x , Z_x est définie comme un infimum dénombrable de variables aléatoires $\mathcal{G}$ -mesurables; Z_x est donc $\mathcal{G}$ -mesurable.

Il reste à vérifier que, pour tout $B \in \mathcal{F}$, $\omega \mapsto \nu(\omega, B)$ pour $\omega \in \Omega_0$, 0 ailleurs, définit une version de l'espérance conditionnelle de $\mathbb{I}_B$ par rapport à $\mathcal{G}$.

Cette propriété est satisfaite pour $B \in \mathcal{C}$.

Appelons $\mathcal{D}$ l'ensemble de tous les événements pour lesquels $\omega \mapsto \nu(\omega, B)$ (sur Ω_0 , 0 ailleurs) définit une version de l'espérance conditionnelle de $\mathbb{I}_B$ par rapport à $\mathcal{G}$. Nous montrons que $\mathcal{D}$ est un λ -système, c'est-à-dire

- i. $\mathcal{D}$ contient $\emptyset$ et $\mathbb{R} = \Omega$.
- ii. Si B, B' appartiennent à $\mathcal{D}$ et $B \subseteq B'$, alors $B' \setminus B \in \mathcal{D}$.
- iii. Si $(B_n)_n$ est une suite croissante d'événements de $\mathcal{D}$, de limite B , alors $B \in \mathcal{D}$.

Le point i.) est garanti par construction.

Point ii.) Si $B' \subseteq B$ appartiennent à $\mathcal{D}$, alors, par linéarité des espérances conditionnelles, si $\mathbb{E}[\mathbb{I}_{B' \setminus B} | \mathcal{G}]$ est une version de l'espérance conditionnelle de $\mathbb{I}_{B' \setminus B}$ par rapport à $\mathcal{G}$, sur un événement presque sûr $\Omega_1 \subseteq \Omega_0$:

$$\begin{aligned} \mathbb{E}[\mathbb{I}_{B' \setminus B} | \mathcal{G}] &= \mathbb{E}[\mathbb{I}_{B'} - \mathbb{I}_B | \mathcal{G}] \\ &= \mathbb{E}[\mathbb{I}_{B'} | \mathcal{G}] - \mathbb{E}[\mathbb{I}_B | \mathcal{G}] \\ &= \nu(\omega, B') - \nu(\omega, B) \\ &= \nu(\omega, B' \setminus B). \end{aligned}$$

Point iii.) Si $(B_n)_n$ est une suite croissante d'événements de $\mathcal{D}$, avec $B_n \uparrow B$, si $\mathbb{E}[\mathbb{I}_B \mid \mathcal{G}]$ est une version de l'espérance conditionnelle de $\mathbb{I}_B$ par rapport à $\mathcal{G}$, sur un événement $\Omega_1 \subseteq \Omega_0$ de probabilité 1 :

$$\mathbb{E}[\mathbb{I}_B \mid \mathcal{G}] = \lim_n \mathbb{E}[\mathbb{I}_{B_n} \mid \mathcal{G}] = \lim_n \nu(\omega, B_n) = \nu(\omega, B).$$

Donc $B \in \mathcal{D}$.

Le théorème de la classe monotone (section 2.6) nous dit que $\mathcal{F} \subseteq \mathcal{D}$. $\square$

En travaillant davantage, on pourrait montrer que l'existence de probabilités conditionnelles régulières est garantie dès que Ω peut être muni d'une structure d'espace métrique complet séparable et que la tribu $\mathcal{F}$ est la tribu borélienne induite par cette métrique.

On définit souvent une loi de probabilité à partir d'une loi marginale et d'un noyau.

Soient $(\Omega, \mathcal{F})$ un espace mesurable, X une variable aléatoire sur $(\Omega, \mathcal{F})$, et N un noyau de probabilité conditionnelle par rapport à $\sigma(X)$. Soit P_X une mesure de probabilité sur $(\Omega\sigma(X))$.

Alors il existe une unique mesure de probabilité P sur $(\Omega, \mathcal{F})$ telle que $P_X = P \circ X^{-1}$ et N soit un noyau de probabilité conditionnelle régulière par rapport à $\sigma(X)$. On a, pour tout $B \in \mathcal{F}$:

$$P(B) = \int_{X(\Omega)} N(x, B) dP_x(x)$$

Le théorème suivant garantit l'existence d'une probabilité conditionnelle régulière dans tous les scénarios qui nous intéressent.

11.7 Inégalités d'Efron-Stein-Steele

Dans cette section, $X_1, \dots, X_n$ désignent des variables aléatoires indépendantes sur un espace de probabilité, à valeurs dans $\mathcal{X}_1, \dots, \mathcal{X}_n$, et f une fonction mesurable de $\mathcal{X}_1 \times \dots \times \mathcal{X}_n$ dans $\mathbb{R}$. Posons $Z = f(X_1, \dots, X_n)$. La variable aléatoire Z est une fonction générale de variables aléatoires indépendantes. Nous supposons Z intégrable.

Si nous avons $Z = \sum_{i=1}^n X_i$, nous pourrions écrire

$$\text{var}(Z) = \sum_{i=1}^n \text{var}(X_i) = \sum_{i=1}^n \mathbb{E} \left[\text{var}(Z \mid X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n) \right]$$

même si la dernière expression paraît pédante. L'objectif de cette section est de montrer que même si f n'est pas aussi simple que la somme de ses arguments, la dernière expression peut encore servir de majoration de la variance.

Il est naturel de majorer la variance d'une telle fonction générale en exprimant $Z - \mathbb{E}Z$ comme une somme de différences et en utilisant l'orthogonalité de ces différences.

Plus précisément, si nous notons $\mathbb{E}_i$ l'opérateur d'espérance conditionnelle, conditionné par $(X_1, \dots, X_i)$, et adoptons la convention $\mathbb{E}_0 = \mathbb{E}$, nous pouvons définir

$$\Delta_i = \mathbb{E}_i Z - \mathbb{E}_{i-1} Z$$

pour tout $i = 1, \dots, n$.

Exercice 11.8. Vérifier que $\mathbb{E}\Delta_i = 0$ et que, pour $j > i$, $\mathbb{E}_i\Delta_j = 0$ p.s.

À partir de la décomposition

$$Z - \mathbb{E}Z = \sum_{i=1}^n \Delta_i$$

on a

$$\text{var}(Z) = \mathbb{E} \left[\left(\sum_{i=1}^n \Delta_i \right)^2 \right] = \sum_{i=1}^n \mathbb{E} [\Delta_i^2] + 2 \sum_{j>i} \mathbb{E} [\Delta_i \Delta_j] .$$

Or, si $j > i$, $\mathbb{E}_i\Delta_j = 0$ implique que

$$\mathbb{E}_i [\Delta_j \Delta_i] = \Delta_i \mathbb{E}_i \Delta_j = 0 ,$$

et, a fortiori, $\mathbb{E} [\Delta_j \Delta_i] = 0$. Ainsi, nous obtenons l'analogue suivant de la formule d'additivité de la variance :

$$\text{var}(Z) = \mathbb{E} \left[\left(\sum_{i=1}^n \Delta_i \right)^2 \right] = \sum_{i=1}^n \mathbb{E} [\Delta_i^2] .$$

Observons que jusqu'ici, nous n'avons pas utilisé le fait que Z est une fonction de variables indépendantes $X_1, \dots, X_n$.

L'indépendance peut être utilisée comme dans l'argument suivant : pour toute fonction intégrable $Z = f(X_1, \dots, X_n)$, on peut écrire, d'après le théorème de Tonelli-Fubini,

$$\mathbb{E}_i Z = \int_{\mathcal{X}^{n-i}} f(X_1, \dots, X_i, x_{i+1}, \dots, x_n) d\mu_{i+1}(x_{i+1}) \dots d\mu_n(x_n) ,$$

où, pour tout $j = 1, \dots, n$, μ_j désigne la loi de probabilité de X_j . De plus, si nous notons $\mathbb{E}^{(i)}$ l'opérateur d'espérance conditionnelle conditionné par $X^{(i)} = (X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n)$, nous avons

$$\mathbb{E}^{(i)} Z = \int_{\mathcal{X}} f(X_1, \dots, X_{i-1}, x_i, X_{i+1}, \dots, X_n) d\mu_i(x_i) .$$

Alors, encore d'après le théorème de Tonelli-Fubini,

$$\mathbb{E}_i [\mathbb{E}^{(i)} Z] = \mathbb{E}_{i-1} Z. (\#eq : efundind) \tag{II.1}$$

Cette observation est la clé de la démonstration du résultat principal de cette section, que nous énonçons maintenant :

Théorème 11.7 (Inégalités d'Efron-Stein-Steele). *Soient $X_1, \dots, X_n$ des variables aléatoires indépendantes et $Z = f(X)$ une fonction de carré intégrable de $X =$*

$(X_1, \dots, X_n)$. Alors

$$\text{var}(Z) \leq \sum_{i=1}^n \mathbb{E} \left[(Z - \mathbb{E}^{(i)} Z)^2 \right] = v.$$

De plus, si $X'_1, \dots, X'_n$ sont des copies indépendantes de $X_1, \dots, X_n$ et si nous définissons, pour tout $i = 1, \dots, n$,

$$Z'_i = f(X_1, \dots, X_{i-1}, X'_i, X_{i+1}, \dots, X_n),$$

alors

$$v = \frac{1}{2} \sum_{i=1}^n \mathbb{E} [(Z - Z'_i)^2] = \sum_{i=1}^n \mathbb{E} [(Z - Z'_i)_+^2] = \sum_{i=1}^n \mathbb{E} [(Z - Z'_i)_-^2]$$

où $x_+ = \max(x, 0)$ et $x_- = \max(-x, 0)$ désignent les parties positive et négative d'un nombre réel x . En outre,

$$v = \inf_{Z_i} \sum_{i=1}^n \mathbb{E} [(Z - Z_i)^2],$$

où l'infimum est pris sur la classe de toutes les variables Z_i mesurables par rapport à $X^{(i)}$ et de carré intégrable, $i = 1, \dots, n$.

Preuve. Commençons par la démonstration du premier énoncé. Notons que, d'après @ref(eq:efundind), nous pouvons écrire

$$\Delta_i = \mathbb{E}_i [Z - \mathbb{E}^{(i)} Z].$$

Par l'inégalité de Jensen conditionnelle,

$$\Delta_i^2 \leq \mathbb{E}_i \left[(Z - \mathbb{E}^{(i)} Z)^2 \right].$$

En utilisant $\text{var}(Z) = \sum_{i=1}^n \mathbb{E} [\Delta_i^2]$, nous obtenons l'inégalité souhaitée. Pour démontrer les identités pour v , notons $\text{var}^{(i)}$ l'opérateur de variance conditionnelle conditionné par $X^{(i)}$. Nous pouvons écrire v sous la forme

$$v = \sum_{i=1}^n \mathbb{E} [\text{var}^{(i)}(Z)].$$

Observons que l'on peut simplement utiliser (conditionnellement) le fait élémentaire que, si X et Y sont indépendantes et identiquement distribuées, variables réelles, alors $\text{var}(X) = (1/2)\mathbb{E}[(X - Y)^2]$. Comme, conditionnellement à $X^{(i)}$, Z'_i est une copie indépendante de Z , nous pouvons écrire

$$\text{var}^{(i)}(Z) = \frac{1}{2} \mathbb{E}^{(i)} [(Z - Z'_i)^2] = \mathbb{E}^{(i)} [(Z - Z'_i)_+^2] = \mathbb{E}^{(i)} [(Z - Z'_i)_-^2]$$

où nous avons utilisé le fait que les lois conditionnelles de Z et Z'_i sont identiques. La dernière identité s'obtient en rappelant que, pour toute variable aléatoire réelle X , $\text{var}(X) = \inf_{a \in \mathbb{R}} \mathbb{E}[(X - a)^2]$. En utilisant ce fait conditionnellement, nous avons, pour tout $i = 1, \dots, n$,

$$\text{var}^{(i)}(Z) = \inf_{Z_i} \mathbb{E}^{(i)}[(Z - Z_i)^2] .$$

Notons que cet infimum est atteint lorsque $Z_i = \mathbb{E}^{(i)} Z$. □

Observons que dans le cas où $Z = \sum_{i=1}^n X_i$ est une somme de variables aléatoires indépendantes (de variance finie), l'inégalité d'Efron-Stein-Steele devient une égalité. Ainsi, la borne de l'inégalité d'Efron-Stein-Steele est, en un certain sens, non améliorable.

11.8 Inégalités des différences bornées

Dans cette section, nous combinons l'inégalité de Hoeffding et le conditionnement pour établir la *inégalité des différences bornées* (également connue sous le nom d'inégalité de McDiarmid). Cette inégalité est un premier exemple du *phénomène de concentration de la mesure*. Ce phénomène se résume ainsi :

Une fonction de nombreuses variables aléatoires indépendantes qui ne dépend pas trop de chacune d'elles est concentrée autour de sa moyenne ou de sa médiane.

Inégalités des différences bornées

Soient $X_1, \dots, X_n$ des variables aléatoires indépendantes sur un espace de probabilité, à valeurs dans $\mathcal{X}_1, \mathcal{X}_2, \dots, \mathcal{X}_n$. Soit $f : \mathcal{X}_1 \times \mathcal{X}_2 \times \dots \times \mathcal{X}_n \rightarrow \mathbb{R}$ une fonction mesurable telle qu'il existe des constantes non négatives $c_1, \dots, c_n$ satisfaisant $\forall x_1, \dots, x_n \in \prod_{i=1}^n \mathcal{X}_i$, $\forall y_1, \dots, y_n \in \prod_{i=1}^n \mathcal{X}_i$,

$$\left| f(x_1, \dots, x_n) - f(y_1, \dots, y_n) \right| \leq \sum_{i=1}^n c_i \mathbb{1}_{x_i \neq y_i} .$$

Posons $Z = f(X_1, \dots, X_n)$ et $v = \sum_{i=1}^n \frac{c_i^2}{4}$. Alors

$$\text{var}(Z) \leq v ,$$

$$\log \mathbb{E} e^{\lambda(Z - \mathbb{E} Z)} \leq \frac{\lambda^2 v}{2}$$

et

$$P\{Z \geq \mathbb{E} Z + t\} \leq e^{-\frac{t^2}{2v}} .$$

Preuve. La borne sur la variance est une conséquence immédiate des inégalités d'Efron-Stein-Steele.

La borne sur la queue découle de la majoration de la fonction génératrice des moments logarithmique par la méthode de Cramér-Chernoff.

Vérifions maintenant la majoration de la fonction génératrice des moments logarithmique.

Nous procédons par récurrence sur le nombre d'arguments n .

Si $n = 1$, la majoration de la fonction génératrice des moments logarithmique n'est autre que le lemme de Hoeffding (voir section 14.7).

Supposons la majoration valide jusqu'à $n - 1$.

Nous adoptons les mêmes notations que dans section 11.7).

$$\begin{aligned}\mathbb{E}e^{\lambda(Z-\mathbb{E}Z)} &= \mathbb{E}\left[\mathbb{E}_{n-1}e^{\lambda(Z-\mathbb{E}Z)}\right] \\ &= \mathbb{E}\left[\mathbb{E}_{n-1}\left[e^{\lambda(Z-\mathbb{E}_{n-1}Z)}\right] \times e^{\lambda(\mathbb{E}_{n-1}Z-\mathbb{E}Z)}\right].\end{aligned}$$

Or,

$$\mathbb{E}_{n-1}Z = \int_{\mathcal{X}_n} f(x_1, \dots, x_{n-1}, u) dP_{X_n}(u) \quad \text{a.s.}$$

et

$$\begin{aligned}&\mathbb{E}_{n-1}\left[e^{\lambda(Z-\mathbb{E}_{n-1}Z)}\right] \\ &= \int_{\mathcal{X}_n} \exp\left(\lambda \int_{\mathcal{X}_n} f(x_1, \dots, x_{n-1}, v) - f(x_1, \dots, x_{n-1}, u) dP_{X_n}(u)\right) dP_{X_n}(v).\end{aligned}$$

Pour tout $x_1, \dots, x_{n-1} \in \mathcal{X}_1 \times \dots \times \mathcal{X}_{n-1}$, pour tout $v, v' \in \mathcal{X}_n$,

$$\begin{aligned}&\left| \int_{\mathcal{X}_n} f(x_1, \dots, x_{n-1}, v) - f(x_1, \dots, x_{n-1}, u) dP_{X_n}(u) \right. \\ &\quad \left. - \int_{\mathcal{X}_n} f(x_1, \dots, x_{n-1}, v') - f(x_1, \dots, x_{n-1}, u) dP_{X_n}(u) \right| \leq c_n\end{aligned}$$

d'où, par le lemme de Hoeffding,

$$\mathbb{E}_{n-1}\left[e^{\lambda(Z-\mathbb{E}_{n-1}Z)}\right] \leq e^{\frac{\lambda^2 c_n^2}{8}}.$$

$$\mathbb{E}e^{\lambda(Z-\mathbb{E}Z)} \leq \mathbb{E}\left[e^{\lambda(\mathbb{E}_{n-1}Z-\mathbb{E}Z)}\right] \times e^{\frac{\lambda^2 c_n^2}{8}}.$$

Or, si $X_1 = x_1, \dots, X_{n-1} = x_{n-1}$,

$$e^{\lambda(\mathbb{E}_{n-1}Z-\mathbb{E}Z)} = \int_{\mathcal{X}_n} f(x_1, \dots, x_{n-1}, v) dP_{X_n}(v) - \mathbb{E}Z,$$

c'est une fonction de $n - 1$ variables aléatoires indépendantes qui satisfait les conditions de différences bornées avec les constantes $c_1, \dots, c_{n-1}$. Par hypothèse de récurrence :

$$\mathbb{E}\left[e^{\lambda(\mathbb{E}_{n-1}Z-\mathbb{E}Z)}\right] \leq e^{\frac{\lambda^2}{2} \sum_{i=1}^{n-1} \frac{c_i^2}{4}}.$$

□

11.9 Remarques bibliographiques

Les espérances conditionnelles peuvent être construites à partir du théorème de Radon-Nikodym, voir ([Dudley, 2002](#)).

Il est aussi possible de démontrer le théorème de Radon-Nikodym à partir de la construction de l'espérance conditionnelle dans $\mathcal{L}_2$, voir ([Williams, 1991](#)).

La section sur les inégalités d'Efron-Stein-Steele est tirée de ([Boucheron, Lugosi, & Massart, 2013](#))

L'inégalité des différences bornées est due à C. McDiarmid. Elle est devenue populaire en informatique (théorique) dans les années 1990. Voir ([McDiarmid, 1998](#))

Chapitre 12

Caractérisations des lois de probabilité

12.1 Motivation

En toute généralité, une loi de probabilité est un objet complexe et opaque. Il s'agit d'une fonction à valeurs dans $[0, 1]$ définie sur une σ -algèbre de parties d'un certain univers. Une σ -algèbre concrète, sans parler de la notion abstraite de σ -algèbre, n'est pas facile à appréhender. Il est donc naturel de chercher des caractérisations plus simples des lois de probabilité. Lorsqu'on se pose des questions du type : *deux lois de probabilité sont-elles égales ?*, nous savons qu'il suffit de vérifier que les deux lois coïncident sur des classes π génératrices (voir Théorème 11.4 et ses conséquences). Les fonctions de répartition (FDR) sont ainsi des outils précieux. Les fonctions de répartition et leurs inverses généralisés (fonctions quantiles, voir Chapitre 13) sont très pratiques pour traiter les maxima, minima, ou plus généralement les statistiques d'ordre de collections de variables aléatoires indépendantes ; en revanche, pour les sommes de variables aléatoires indépendantes ou les processus de branchement, les fonctions de répartition ne sont d'une aide que modérée.

Dans cette leçon, nous passons en revue deux façons liées de caractériser les lois de probabilité par des fonctions définies sur la droite réelle : les transformées de Laplace (Section 12.2) et les fonctions caractéristiques, qui étendent les transformées de Fourier aux lois de probabilité (Section 12.3). Ces deux méthodes diffèrent par leur portée, mais reposent sur la même idée que les fonctions génératrices des probabilités (Chapitre 6) et partagent des propriétés communes.

En effet, les fonctions génératrices des probabilités peuvent être vues comme des cas particuliers des transformées de Laplace, qui elles-mêmes sont des cas particuliers des transformées de Fourier. Ces trois méthodes caractérisent bien les lois de probabilité. Elles sont munies de formules d'inversion. Elles permettent un traitement unifié des sommes de variables aléatoires indépendantes. Elles relient l'intégrabilité des lois de probabilité et la régularité des transformées.

Dans les leçons suivantes ([?@sec-chaprevisiCLT](#)), nous verrons que les trois transformées caractérisent également la *convergence en loi*.

Les fonctions génératrices des probabilités, les transformées de Laplace et les fonctions caractéristiques fournissent un important appareil analytique à la théorie des probabilités. De l'analyse, nous tirons des arguments tout faits pour établir la régularité des transformées, et avec un peu plus de travail, nous pouvons construire les formules d'inversion.

12.2 Transformée de Laplace

Les transformées de Laplace caractérisent les lois de probabilité sur $[0, \infty)$.

Définition et propriétés élémentaires

Définition 12.1. Soit P une loi de probabilité sur $[0, \infty]$ de fonction de répartition F . La transformée de Laplace de P est la fonction U de $[0, \infty)$ dans $[0, 1]$ définie par

$$U(\lambda) = \mathbb{E}[e^{-\lambda X}] = \int_{[0, \infty)} e^{-\lambda x} dF(x)$$

où $X \sim P$.

Une loi de probabilité P sur $\mathbb{N}$ est aussi une loi de probabilité sur $[0, \infty)$; elle possède donc à la fois une fonction génératrice des probabilités G et une transformée de Laplace U . Elles sont reliées par

$$U(\lambda) = G(e^{-\lambda}).$$

Quelles propriétés des fonctions génératrices des probabilités sont également satisfaites par les transformées de Laplace?

Proposition 12.1. Si $U : [0, \infty) \rightarrow [0, 1]$ est la transformée de Laplace d'une loi de probabilité P sur $[0, \infty)$, alors

- $U(0) = 1$;
- U est continue;
- U est non croissante.
- U est convexe.

Exercice 12.1. Vérifier les assertions de la proposition.

Peut-on reconnaître la transformée de Laplace d'une loi de probabilité sur $[0, \infty)$? C'est l'objet du théorème suivant (dont la preuve dépasse le cadre de ce cours).

Théorème 12.1 (Théorème de Bernstein). Une fonction $U : (0, \infty) \rightarrow (0, \infty)$ est la transformée de Laplace d'une loi de probabilité sur $[0, \infty)$ si et seulement si

- U est infiniment dérivable sur $(0, \infty)$

- $U(0) = 1$
- U est complètement monotone : $(-1)^k U^{(k)} \geq 0$ sur $(0, \infty)$

En utilisant le lien entre fonctions génératrices des probabilités et transformées de Laplace, nous sommes en mesure de caractériser les séries entières qui sont des fonctions génératrices des probabilités.

Corollaire 12.1. *Une fonction $G : [0, 1] \rightarrow [0, 1]$ est la fonction génératrice des probabilités d'une loi de probabilité sur $\mathbb{N}$ si et seulement si*

- G est infiniment dérivable sur $(0, 1)$
- $G(1) = 1$
- G est complètement monotone : $(-1)^k G^{(k)} \geq 0$ sur $(0, 1)$

Exemple 12.1. Soit X de loi Gamma(p, ν). La transformée de Laplace de (la loi de) X est

$$\begin{aligned} U(\lambda) &= \int_0^\infty \nu e^{-\lambda x} e^{-\nu x} \frac{(\nu x)^{p-1}}{\Gamma(p)} dx \\ &= \frac{\nu^p}{(\lambda + \nu)^p} \int_0^\infty (\lambda + \nu) e^{-(\lambda + \nu)x} \frac{((\nu + \lambda)x)^{p-1}}{\Gamma(p)} dx \\ &= \frac{\nu^p}{(\lambda + \nu)^p}. \end{aligned}$$

Injectivité des transformées de Laplace et formule d'inversion

Théorème 12.2 (Théorème de Widder). *Une loi de probabilité sur $[0, \infty)$ est caractérisée par sa transformée de Laplace.*

La construction de la formule d'inversion repose sur des inégalités de déviation pour la loi de Poisson. La proposition suivante se vérifie facilement en utilisant l'inégalité de Markov avec des fonctions exponentielles et une optimisation.

Théorème 12.3 (Majorations de queue pour la loi de Poisson). *Soit Z de loi de Poisson. Posons $h(x) = e^x - x - 1$ et $h^*(x) = (x + 1) \log(x + 1) - x$, $x \geq -1$, son conjugué convexe. Alors, pour tout $\lambda \in \mathbb{R}$*

$$\log \mathbb{E} e^{\lambda(Z - \mathbb{E}Z)} = \mathbb{E} Z h(\lambda).$$

Pour $t \geq 0$

$$\Pr \left\{ Z \geq \mathbb{E}Z + t \right\} \leq e^{-\mathbb{E}Z h^*\left(\frac{t}{\mathbb{E}Z}\right)}$$

et pour $0 \leq t \leq \mathbb{E}Z$

$$\Pr \left\{ Z \leq \mathbb{E}Z - t \right\} \leq e^{-\mathbb{E}Z h^*\left(\frac{-t}{\mathbb{E}Z}\right)}.$$

Remarque 12.1.

- Voir Section 4.3) pour la notion de conjugaison convexe.
- Les majorations suivantes de h^* fournissent des bornes de queue plus grossières mais plus simples

$$\begin{aligned} h^*(t) &\geq \frac{t^2}{2(1+t/3)} \quad \text{for } t > 0 \\ h^*(t) &\geq \frac{t^2}{2} \quad \text{for } t < 0. \end{aligned}$$

Corollaire 12.2. Pour tous x, y positifs, $y \neq x$,

$$\lim_{n \rightarrow \infty} \sum_{k=0}^{nx} e^{-ny} \frac{(ny)^k}{k!} = \mathbb{I}_{y < x}.$$

Nous vérifierons dans une des prochaines leçons que, pour $x > 0$:

$$\lim_{n \rightarrow \infty} \sum_{k=0}^{\lfloor nx \rfloor} e^{-nx} \frac{(nx)^k}{k!} = \frac{1}{2}.$$

Preuve. Soit F la fonction de répartition de P et U sa transformée de Laplace. Soit $X \sim P$.

Il suffit de montrer que $F(x)$ peut être calculée à partir de U en tout point x où F est continue.

La fonction U est infiniment dérivable sur $(0, \infty)$. Pour $k \in \mathbb{N}$,

$$\frac{d^k U}{d\lambda^k} = (-1)^k \int_{(0, \infty)} x^k e^{-\lambda x} dF(x).$$

et U admet un développement en série entière en tout $\lambda \in (0, 1)$, pour $\lambda' \in (0, 1)$:

$$U(\lambda') = \sum_{k=0}^{\infty} \frac{(\lambda' - \lambda)^k}{k!} \frac{d^k U}{d\lambda^k}.$$

D'après [Corollaire 12.2], pour tout $0 < y \neq x$, $\lim_{n \rightarrow \infty} \sum_{k=0}^{nx} e^{-ny} \frac{(ny)^k}{k!} = \mathbb{I}_{y < x}$.

$$\begin{aligned} F(x) &= \int_{\mathbb{R}_+} \mathbb{I}_{y \leq x} dF(y) \\ &= \int_{\mathbb{R}_+} \mathbb{I}_{y < x} dF(y) \\ &= \int_{(-\infty, x)} \mathbb{I}_{y < x} dF(y) + \int_{\{x\}} 1 dF(y) + \int_{(x, \infty)} \mathbb{I}_{y < x} dF(y) \\ &= \int_{(-\infty, x)} \mathbb{I}_{y < x} dF(y) + \int_{\{x\}} 1 dF(y) + \int_{(x, \infty)} \mathbb{I}_{y < x} dF(y) \\ &= \int_{(-\infty, x) \cup (x, \infty)} \lim_{n \rightarrow \infty} \sum_{k=0}^{nx} e^{-ny} \frac{(ny)^k}{k!} dF(y) + \int_{\{x\}} 1 dF(y) \\ &= \lim_{n \rightarrow \infty} \sum_{k=0}^{nx} \frac{(-n)^k}{k!} \int_{(-\infty, x) \cup (x, \infty)} e^{-ny} (-y)^k dF(y) + \int_{\{x\}} 1 dF(y) \\ &\quad \text{by dominated convergence} \\ &= \lim_{n \rightarrow \infty} \sum_{k=0}^{nx} \frac{(-n)^k}{k!} \frac{d^k U}{d\lambda^k} \Big|_{\lambda=n}. \end{aligned}$$

Si F est continue en x ,

$$F(x) = \lim_{n \rightarrow \infty} \sum_{k=0}^{nx} \frac{(-n)^k}{k!} \frac{d^k U}{d\lambda^k} \Big|_{\lambda=n}.$$

Si F saute en x ,

$$F(x) - \frac{P\{X=x\}}{2} = \lim_{n \rightarrow \infty} \sum_{k=0}^{nx} \frac{(-n)^k}{k!} \frac{d^k U}{d\lambda^k} \Big|_{\lambda=n}.$$

Ce procédé montre que la transformée de Laplace contient assez d'information pour reconstruire la fonction de répartition, qui caractérise à son tour la loi de probabilité. $\square$

Les transformées de Laplace des sommes de variables aléatoires indépendantes non négatives s'obtiennent facilement à partir des transformées de Laplace des termes.

Proposition 12.2. *Soient X et Y deux variables aléatoires indépendantes à valeurs dans $[0, \infty)$, de transformées de Laplace U_X et U_Y . La transformée de Laplace de (la loi de) $X + Y$ est*

$$G_{X+Y} = G_X \times G_Y.$$

Preuve.

$$\begin{aligned} G_{X+Y}(\lambda) &= \mathbb{E} \left[e^{\lambda(X+Y)} \right] \\ &= \mathbb{E} \left[e^{\lambda X} \times e^{\lambda Y} \right] \\ &= \mathbb{E} \left[e^{\lambda X} \right] \times \mathbb{E} \left[e^{\lambda Y} \right] \\ &\quad \text{indépendance} \\ &= G_X(\lambda) \times G_Y(\lambda). \end{aligned}$$

$\square$

En combinant le théorème d'inversion et la formule explicite de la transformée de Laplace des lois gamma, nous retrouvons le fait que la somme de variables aléatoires indépendantes de loi gamma de même paramètre d'intensité est encore de loi gamma.

Corollaire 12.3. *Si $X \sim \text{Gamma}(p, \lambda)$ est indépendante de $Y \sim \text{Gamma}(q, \lambda)$, alors $X + Y$ a pour transformée de Laplace $\left(\frac{\nu}{\lambda + \nu}\right)^{p+q}$ et suit la loi $\text{Gamma}(p + q, \lambda)$.*

Régularité de la transformée de Laplace et intégrabilité

12.3 Fonctions caractéristiques et transformées de Fourier

La transformée de Laplace caractérise les lois de probabilité à support dans $[0, \infty)$. Les fonctions caractéristiques traitent des lois de probabilité générales. Elles s'étendent aux lois multivariées.

Fonction caractéristique

La transformée suivante peut être définie pour toute loi de probabilité sur $\mathbb{R}$. La définition peut être étendue aux lois sur $\mathbb{R}^k$, $k \geq 1$.

Définition 12.2 (Fonction caractéristique). Soit la variable aléatoire réelle X de loi P et de fonction de répartition F . La *fonction caractéristique* de la loi P est la fonction de $\mathbb{R}$ dans $\mathbb{C}$ définie par

$$\hat{F}(t) = \mathbb{E}[e^{itX}] = \int_{\mathbb{R}} e^{itx} dF(x) = \int_{\mathbb{R}} \cos(tx) dF(x) + i \int_{\mathbb{R}} \sin(tx) dF(x).$$

Remarque 12.2. Si F est absolument continue de densité f , alors $\hat{F}$ est (à une constante multiplicative près) la transformée de Fourier de f .

Proposition 12.3. Soit la variable aléatoire réelle X de loi P et de fonction caractéristique $\hat{F}$.

- $\hat{F}$ est (uniformément) continue sur $\mathbb{R}$
- $\hat{F}(0) = 1$
- Si X est symétrique, $\hat{F}$ est à valeurs réelles
- La fonction caractéristique de la loi de $aX + b$ est

$$e^{itb} \hat{F}(at).$$

Preuve. Vérifions la propriété de continuité. Les trois autres sont laissées en exercice.

Le calcul trigonométrique donne

$$\begin{aligned} |e^{i(t+\delta)x} - e^{itx}| &= |e^{itx}| \times |e^{i\delta x} - 1| \\ &\leq |e^{i\delta x} - 1| \\ &\leq 2(1 \wedge |\delta x|) \end{aligned}$$

pour tout $t \in \mathbb{R}$, $\delta \in \mathbb{R}$, $x \in \mathbb{R}$. En intégrant par rapport à F ,

$$|\hat{F}(t+\delta) - \hat{F}(t)| \leq \int 2(1 \wedge |\delta x|) dF(x).$$

Par le théorème de convergence dominée, nous concluons

$$\lim_{\delta \rightarrow 0} |\hat{F}(t+\delta) - \hat{F}(t)| = 0$$

uniformément en t . □

Exercice 12.2. Les propriétés suivantes se vérifient facilement :

- $|\hat{F}(t)| \leq 1$ pour tout $t \in \mathbb{R}$;
-

Exercice 12.3. Calculer la fonction caractéristique de :

- la loi de Poisson de paramètre $\lambda > 0$;
- la loi uniforme sur $[-1, 1]$;
- la loi triangulaire sur $[-1, 1]$ (densité : $1 - |x|$ sur $[-1, 1]$);
- la loi de Laplace, de densité $1/2 \exp(-|x|)$;
- la loi exponentielle de densité $\exp(-x)$ sur $[0, +\infty)$;

Comme pour les fonctions génératrices des probabilités et les transformées de Laplace, les fonctions caractéristiques des sommes de variables aléatoires indépendantes ont une structure simple.

Proposition 12.4. Soient X et Y des variables aléatoires indépendantes de fonctions de répartition F_X et F_Y , alors

$$\hat{F}_{X+Y}(t) = \hat{F}_X(t) \times \hat{F}_Y(t)$$

pour tout $t \in \mathbb{R}$.

Preuve. La troisième égalité découle de l'indépendance de X et Y :

$$\begin{aligned} \hat{F}_{X+Y}(t) &= \mathbb{E} \left[e^{it(X+Y)} \right] \\ &= \mathbb{E} \left[e^{itX} e^{itY} \right] \\ &= \mathbb{E} \left[e^{itX} \right] \times \mathbb{E} \left[e^{itY} \right] \\ &= \hat{F}_X(t) \times \hat{F}_Y(t). \end{aligned}$$

□

Exercice 12.4. Donner un contre-exemple pour montrer que

$$\left(\forall t \in \mathbb{R}, \quad \hat{F}_{X+Y}(t) = \hat{F}_X(t) \times \hat{F}_Y(t) \right) \not\Rightarrow X \perp\!\!\!\perp Y.$$

Fonction caractéristique d'une loi gaussienne univariée

Il est possible de calculer les fonctions caractéristiques en recourant à l'analyse complexe. Mais nous nous abstenons d'y recourir pour calculer la fonction caractéristique la plus importante, celle de la loi gaussienne centrée réduite.

Proposition 12.5. Soit $\hat{\Phi}$ la fonction caractéristique de la loi gaussienne univariée centrée réduite $\mathcal{N}(0, 1)$. On a

$$\hat{\Phi}(t) = e^{-\frac{t^2}{2}}.$$

Preuve. Rappelons que, la densité gaussienne centrée réduite étant paire, la fonction caractéristique est réelle et paire.

De plus, $\widehat{\Phi}$ est dérivable et la dérivée s'obtient en intervertissant espérance et dérivation par rapport à t .

$$\begin{aligned}\widehat{\Phi}'(t) &= -\mathbb{E}[X \sin(tX)] \\ &= -\frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x \sin(tx) e^{-\frac{x^2}{2}} dx \\ &= \frac{1}{\sqrt{2\pi}} \left[\sin(tx) e^{-\frac{x^2}{2}} \right]_{-\infty}^{\infty} - t \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \cos(tx) e^{-\frac{x^2}{2}} dx \\ &= -t \widehat{\Phi}(t).\end{aligned}$$

Ainsi, $\widehat{F}$ est solution de l'équation différentielle : $g'(t) = -tg(t)$ avec $g(0) = 1$.

Cette équation différentielle se résout immédiatement, et la solution est $g(t) = e^{-\frac{t^2}{2}}$. $\square$

Exercice 12.5. Pourquoi $\widehat{\Phi}$ est-elle dérivable ? Pourquoi peut-on intervertir espérance et dérivation ?

Notons qu'un sous-produit de Proposition 12.5 est la représentation intégrale suivante de la densité gaussienne.

$$\phi(x) = \frac{1}{2\pi} \int_{\mathbb{R}} \widehat{\Phi}(t) e^{-itx} dt.$$

Elle ne paraît pas intéressante en soi, mais elle constitue une étape clé pour l'établissement de la formule générale d'inversion ci-dessous.

Sommes de variables aléatoires indépendantes et convolutions

L'interaction entre fonctions caractéristiques/transformées de Fourier et sommation de variables aléatoires indépendantes est l'une des propriétés les plus attrayantes de cette transformation. Pour la comprendre, nous aurons besoin d'une opération issue de l'analyse. Rappelons que si f et g sont deux fonctions intégrables, la convolution de f et g est définie par

$$f \star g(x) = \int_{\mathbb{R}} f(x-y)g(y)dy = \int_{\mathbb{R}} g(x-y)f(y)dy.$$

Notons que $f \star g$ est également intégrable. Il n'est pas difficile de vérifier que si f et g sont deux densités de probabilité, alors $f \star g$ l'est aussi ; de plus, $f \star g$ est la densité de la loi de $X + Y$ où $X \sim f$ est indépendante de $Y \sim g$. La proposition suivante étend cette observation.

Proposition 12.6. Soient X, Y deux variables aléatoires indépendantes de lois P_X et P_Y . Supposons que P_X est absolument continue de densité p_X . Alors la loi de $X + Y$ est

absolument continue et admet pour densité

$$p_x \star P_Y(z) = \int_{\mathbb{R}} p_X(z-y) dP_Y(y).$$

Preuve. Soit B une partie borélienne de $\mathbb{R}$.

$$\begin{aligned} P\{X+Y \in B\} &= \int_{\mathbb{R}} \left(\int_{\mathbb{R}} \mathbb{I}_B(x+y) p_X(x) dx \right) dP_Y(y) \\ &= \int_{\mathbb{R}} \left(\int_{\mathbb{R}} \mathbb{I}_B(z) p_X(z-y) dz \right) dP_Y(y) \\ &= \int_{\mathbb{R}} \mathbb{I}_B(z) \left(\int_{\mathbb{R}} p_X(z-y) dP_Y(y) \right) dz \\ &= \int_{\mathbb{R}} \mathbb{I}_B(z) p_x \star P_Y(z) dz \end{aligned}$$

où la première égalité suit du théorème de Tonelli-Fubini, la seconde s'obtient par le changement de variable $x \mapsto z = x + y$ pour tout y , et la troisième suit encore du théorème de Tonelli-Fubini. $\square$

Remarque 12.3. La convolution n'est pas propre à la théorie des probabilités.

- En analyse, la convolution est connue pour être une opération régularisante (lissante). Il en va de même en probabilités : si la loi de X ou de Y admet une densité et $X \perp\!\!\!\perp Y$, alors la loi de $X + Y$ admet une densité.
- La convolution avec des lois régulières joue un rôle important en statistique non paramétrique ; elle est à l'origine de l'estimation par noyau.
- La convolution est un outil important en traitement du signal.

Exercice 12.6. Vérifier que si X et Y sont indépendantes de densités f_X et f_Y , alors $f_X \star f_Y$ est une densité de la loi de $X + Y$.

Si $Y = 0$ presque sûrement (sa loi est δ_0), alors $p_X \star \delta_0 = p_X$.

Que se passe-t-il dans Proposition 12.6 si l'on considère les lois de $\sigma X + Y$ et que l'on fait tendre σ vers 0 ? C'est l'objet de la proposition suivante.

Proposition 12.7. Soient X, Y deux variables aléatoires indépendantes de lois P_X et P_Y . Supposons que P_X est absolument continue de densité p_X et que $P_X(-\infty, 0] = \alpha \in (0, 1)$. Alors

$$\lim_{\sigma \downarrow 0} \mathbb{P}\{Y + \sigma X \leq a\} = P_Y(-\infty, a) + \alpha P_Y\{a\}.$$

Preuve.

$$\begin{aligned} \mathbb{P}\{Y + \sigma X \leq a\} &= \int_{\mathbb{R}} \int_{\mathbb{R}} \mathbb{I}_{x \leq \frac{a-y}{\sigma}} p_X(x) dx dP_Y(y) \\ &= \int_{(-\infty, a)} \int_{\mathbb{R}} \mathbb{I}_{x \leq \frac{a-y}{\sigma}} p_X(x) dx dP_Y(y) \\ &\quad + \int_{\mathbb{R}} \mathbb{I}_{x \leq \frac{a-a}{\sigma}} p_X(x) dx P_Y\{a\} \\ &\quad + \int_{(a, \infty)} \int_{\mathbb{R}} \mathbb{I}_{x \leq \frac{a-y}{\sigma}} p_X(x) dx dP_Y(y) \end{aligned}$$

Par convergence monotone, les premier et troisième intégrales convergent respectivement vers $P_Y(-\infty, a)$ et 0, tandis que le second terme vaut $\alpha P_Y\{a\}$. $\square$

Théorème d'injectivité et formule d'inversion

La fonction caractéristique associe à chaque mesure de probabilité une fonction à valeurs dans $\mathbb{C}$. Le résultat principal de cette section est que les fonctions caractéristiques/transformées de Fourier définissent un opérateur injectif sur l'ensemble des mesures de probabilité sur la droite réelle.

Théorème 12.4. *Si deux lois de probabilité P et Q ont la même fonction caractéristique, elles sont égales.*

La propriété d'injectivité découle d'une formule d'inversion explicite. La fonction caractéristique permet de retrouver la fonction de répartition en tous ses points de continuité (comme le faisait la transformée de Laplace). Comme les points de continuité des fonctions de répartition sont denses dans $\mathbb{R}$, cela suffit.

Proposition 12.8. *Soient $X \sim F$ et $Z \sim \mathcal{N}(0, 1)$ indépendantes. Alors :*

— *la loi de $X + \sigma Z$ a pour fonction caractéristique*

$$\hat{F}_\sigma(t) = \hat{\Phi}(t\sigma) \times \hat{F}(t) = e^{-\frac{t^2\sigma^2}{2}} \hat{F}(t)$$

— *la loi de $X + \sigma Z$ est absolument continue par rapport à la mesure de Lebesgue*

— *une version de la densité de la loi de $X + \sigma Z$ est donnée par*

$$y \mapsto \frac{1}{2\pi} \int_{\mathbb{R}} e^{-\frac{t^2\sigma^2}{2}} \hat{F}(t) e^{-ity} dt = \frac{1}{2\pi} \int_{\mathbb{R}} \hat{F}_\sigma(t) e^{-ity} dt.$$

Exercice 12.7. Pourquoi peut-on admettre l'existence d'un espace de probabilité portant deux variables aléatoires indépendantes X, Z distribuées comme ci-dessus ?

La proposition affirme qu'une densité de la loi de $X + \sigma Z$ peut être retrouvée à partir de la fonction caractéristique de la loi de $X + \sigma Z$ par la formule d'inversion de Fourier pour les fonctions à transformée de Fourier intégrable.

Preuve. Le fait que, pour tout $\sigma > 0$, la loi de $Y = X + \sigma Z$ est absolument continue par rapport à la mesure de Lebesgue découle de Proposition 12.6.

Une densité de la loi de $X + \sigma Z$ est donnée par

$$\int_{\mathbb{R}} \frac{1}{\sigma} \phi\left(\frac{y-x}{\sigma}\right) dF(x)$$

La fonction caractéristique de $X + \sigma Z$ en t vaut $e^{-\frac{t^2\sigma^2}{2}} \hat{F}(t)$.

$$\begin{aligned}
\mathbb{P}\{X + \sigma Z \leq u\} &= \int_{-\infty}^u \int_{\mathbb{R}} \frac{1}{\sigma} \phi\left(\frac{y-x}{\sigma}\right) dF(x) dy \\
&= \int_{-\infty}^u \int_{\mathbb{R}} \frac{1}{\sigma} \left(\frac{1}{2\pi} \int_{\mathbb{R}} e^{-\frac{t^2}{2}} e^{-it\frac{y-x}{\sigma}} dt \right) dF(x) dy \\
&= \int_{-\infty}^u \left(\int_{\mathbb{R}} \frac{1}{\sigma} \frac{1}{2\pi} e^{-\frac{t^2}{2}} e^{-\frac{ity}{\sigma}} \left(\int_{\mathbb{R}} e^{\frac{itx}{\sigma}} dF(x) \right) dt \right) dy \\
&= \int_{-\infty}^u \left(\int_{\mathbb{R}} \frac{1}{\sigma} \frac{1}{2\pi} e^{-\frac{t^2}{2}} e^{-\frac{ity}{\sigma}} \hat{F}(t/\sigma) dt \right) dy \\
&= \int_{-\infty}^u \left(\frac{1}{2\pi} \int_{\mathbb{R}} e^{-\frac{t^2\sigma^2}{2}} e^{-ity} \hat{F}(t) dt \right) dy
\end{aligned}$$

où

- la première égalité suit du théorème de Tonelli-Fubini
- la seconde égalité suit de la représentation intégrale de la densité gaussienne
- la troisième égalité suit encore du théorème de Tonelli-Fubini
- la dernière égalité suit d'un changement de variable dans l'intégrale intérieure.

La quantité $\left(\frac{1}{2\pi} \int_{\mathbb{R}} e^{-\frac{t^2\sigma^2}{2}} e^{-ity} \hat{F}(t) dt \right)$ est une version de la densité de la loi de $Y = X + \sigma Z$ (pourquoi ?). Notons qu'elle s'obtient par la même formule d'inversion qui fonctionnait déjà pour la densité gaussienne. $\square$

Il reste à montrer qu'une formule d'inversion fonctionne pour toute loi de probabilité, et pas seulement pour les lois régulières obtenues en ajoutant un bruit gaussien. Nous vérifierons que l'on peut retrouver la fonction de répartition à partir de la transformée de Fourier.

Théorème 12.5. *Soit X de loi P , de fonction de répartition F et de fonction caractéristique $\hat{F}$.*

Alors :

$$\lim_{\sigma \downarrow 0} \int_{-\infty}^u \left(\frac{1}{2\pi} \int_{\mathbb{R}} e^{-ity} e^{-\frac{t^2\sigma^2}{2}} \hat{F}(t) dt \right) dy = F(u_-) + \frac{1}{2} P\{u\}$$

où

$$F(u_-) = \lim_{v \uparrow u} F(v) = P(-\infty, u).$$

Preuve. La preuve consiste à combiner Proposition 12.7 et Proposition 12.8. $\square$

Notons que Théorème 12.5 ne fournit pas directement la fonction de répartition F . En effet, si F n'est pas continue, l'application $u \mapsto \tilde{F}(u) = F(u_-) + \frac{1}{2} P\{u\}$ n'est pas une fonction de répartition. Mais la modification à droite de $\tilde{F}$: $u \mapsto \lim_{v \downarrow u} \tilde{F}(v)$ coïncide avec F . Nous avons établi Théorème 12.4).

Lorsque la fonction de répartition est absolument continue, l'inversion de Fourier est plus simple.

Théorème 12.6. *Soit X de loi P , de fonction de répartition F et de fonction caractéristique $\hat{F}$. Supposons que $\hat{F}$ est intégrable (par rapport à la mesure de Lebesgue).*

Alors :

- P est absolument continue par rapport à la mesure de Lebesgue;
- $y \mapsto \frac{1}{2\pi} \int_{\mathbb{R}} \hat{F}(t) e^{-ity} dt$ est une version uniformément continue de la densité de P .

Preuve. Soit X de loi P , de fonction de répartition F et de fonction caractéristique $\hat{F}$. Soit Z indépendante de X et de loi $\mathcal{N}(0, 1)$. Soit x un point de continuité de F .

$$\lim_{\sigma \downarrow 0} P\{X + \sigma Z \leq x\} = F(x)$$

$$\begin{aligned} \lim_{\sigma \downarrow 0} P\{X + \sigma Z \leq x\} &= \lim_{\sigma \downarrow 0} \int_{-\infty}^x \left(\frac{1}{2\pi} \int_{\mathbb{R}} e^{-\frac{t^2 \sigma^2}{2}} e^{-ity} \hat{F}(t) dt \right) dy \\ &= \int_{-\infty}^x \frac{1}{2\pi} \int_{\mathbb{R}} \lim_{\sigma \downarrow 0} e^{-\frac{t^2 \sigma^2}{2}} e^{-ity} \hat{F}(t) dt dy \\ &= \int_{-\infty}^x \frac{1}{2\pi} \int_{\mathbb{R}} e^{-ity} \hat{F}(t) dt dy \end{aligned}$$

où l'interversion limite-intégration est justifiée par convergence dominée. $\square$

Nous terminons cette section par une formule d'inversion alternative.

Théorème 12.7 (Formule d'inversion). *Soit P une loi de probabilité sur $\mathbb{R}$ de fonction de répartition F , alors*

$$\lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \hat{F}(t) dt = F(b_-) - F(a) + \frac{1}{2} (P\{b\} + P\{a\}).$$

La preuve du Théorème 12.7) se trouve dans des ouvrages comme (Durrett, 2010) ou (Billingsley, 2012).

Corollaire 12.4. *Soit $\hat{F}$ la fonction caractéristique de la loi de probabilité P . Si $\hat{F}(t) = e^{-\frac{t^2}{2}}$, alors P est la loi gaussienne univariée centrée réduite ($\mathcal{N}(0, 1)$).*

Corollaire 12.5. *Soit $\hat{F}$ la fonction caractéristique de la loi de probabilité P . Si $\hat{F}(t) = e^{i\mu t - \frac{\sigma^2 t^2}{2}}$, alors P est la loi gaussienne ($\mathcal{N}(\mu, \sigma^2)$).*

Un autre sous-produit important de la preuve d'injectivité de la fonction caractéristique est l'identité de Stein, propriété fondamentale de la loi gaussienne centrée réduite.

Théorème 12.8 (Identité de Stein). *Soit $X \sim \mathcal{N}(0, 1)$, et g une fonction dérivable telle que $\mathbb{E}[g'(X)] < \infty$. Alors*

$$\mathbb{E}[g'(X)] = \mathbb{E}[Xg(X)].$$

Réciproquement, si X est une variable aléatoire telle que

$$\mathbb{E}[g'(X)] = \mathbb{E}[Xg(X)]$$

pour toute fonction dérivable g telle que g' est intégrable, alors $X \sim \mathcal{N}(0, 1)$.

Preuve. La partie directe suit par intégration par parties.

Pour la réciproque, notons que si X satisfait l'identité du théorème, alors, pour tout $t \in \mathbb{R}$, les fonctions $t \mapsto \mathbb{E} \cos(tX)$ et $t \mapsto \mathbb{E} \sin(tX)$ satisfont l'équation différentielle $g'(t) = tg(t)$ avec les conditions $\mathbb{E} \cos(0X) = 1$ et $\mathbb{E} \sin(0X) = 0$. Il s'ensuit que $\mathbb{E} e^{itX} = \exp\left(-\frac{t^2}{2}\right)$, c'est-à-dire que $X \sim \mathcal{N}(0, 1)$ $\square$

Dérivabilité et intégrabilité

La dérivabilité de la transformée de Fourier en 0 et l'intégrabilité sont intimement liées.

Théorème 12.9. Si X est p -intégrable pour un certain $p \in \mathbb{N}$, alors la transformée de Fourier de la loi de X est p fois dérivable en 0 et la dérivée d'ordre p vaut $i^p \mathbb{E} X^p$.

Preuve. La preuve repose sur un développement de Taylor avec reste de $x \mapsto e^{ix}$ en $x = 0$:

$$e^{ix} - \sum_{k=0}^n \frac{(ix)^k}{k!} = \frac{i^{n+1}}{n!} \int_0^x (x-s)^n e^{is} ds.$$

Le module du membre de droite peut être majoré de deux façons différentes.

$$\frac{1}{n!} \left| \int_0^x (x-s)^n e^{is} ds \right| \leq \frac{|x|^{n+1}}{(n+1)!}$$

ce qui convient lorsque $|x|$ est petit. Pour les grandes valeurs de $|x|$, une intégration par parties donne

$$\frac{i^{n+1}}{n!} \int_0^x (x-s)^n e^{is} ds = \frac{i^n}{(n-1)!} \int_0^x (x-s)^{n-1} (e^{is} - 1) ds.$$

Le module du membre de droite peut être majoré par $2|x|^n/n!$.

En appliquant ce développement de Taylor à $x = tX$, en utilisant les majorations ponctuelles et en prenant l'espérance, on obtient

$$\begin{aligned} \left| \hat{F}(t) - \sum_{k=0}^n \frac{\mathbb{E}(itX)^k}{k!} \right| &\leq \mathbb{E} \left[\min \left(\frac{|tX|^{n+1}}{(n+1)!}, 2 \frac{|tX|^n}{n!} \right) \right] \\ &= \frac{|t|^n}{(n+1)!} \mathbb{E} \left[\min \left(|t||X|^{n+1}, 2(n+1)|X|^n \right) \right]. \end{aligned}$$

Notons que le membre de droite est bien défini dès que $\mathbb{E}|X|^n < \infty$. Par convergence dominée (Théorème 3.3),

$$\lim_{t \rightarrow 0} \mathbb{E} \left[\min \left(|t||X|^{n+1}, 2(n+1)|X|^n \right) \right] = 0$$

Nous avons donc établi que, si $\mathbb{E}|X|^n < \infty$,

$$\hat{F}(t) = \sum_{k=0}^n i^k \mathbb{E}X^k \frac{t^k}{k!} + o(|t|^n).$$

□

Remarque 12.4. Théorème 12.9 affirme que l'intégrabilité de X suffit pour garantir que $\hat{F}^{(1)}(0)$ est bien définie et qu'en $t = 0$

$$\hat{F}^{(1)}(t) = \frac{d\mathbb{E}e^{itX}}{dt} \Big|_{t=0} = \mathbb{E} \frac{de^{itX}}{dt} \Big|_{t=0} = \mathbb{E}[iX]$$

et qu'une formule analogue vaut pour les dérivées d'ordre supérieur.

Comme beaucoup d'autres résultats de ce domaine, Théorème 12.9 porte sur l'interversion dérivation et espérance. Le fait que la preuve repose sur le théorème de convergence dominée (Théorème 3.3) n'est pas surprenant.

Dans l'autre sens, le lien est moins simple : la dérivabilité de la transformée de Fourier n'implique pas l'intégrabilité. Mais le résultat suivant reste vrai.

Théorème 12.10. *Si la transformée de Fourier $\hat{F}$ de la loi de X satisfait*

$$\lim_{h \downarrow 0} \frac{2 - \hat{F}(h) - \hat{F}(-h)}{h^2} = \sigma^2 < \infty$$

alors $\mathbb{E}X^2 = \sigma^2$.

Preuve. Notons que

$$2 - \hat{F}(h) - \hat{F}(-h) = 2\mathbb{E}[1 - \cos(hX)],$$

et utilisons la formule de Taylor avec reste pour $\cos$ en 0 :

$$1 - \cos x = \int_0^x \cos(s)(x-s)ds = x^2 \int_0^1 \cos(sx)(1-s)ds$$

Notons que $\int_0^1 \cos(sx)(1-s)ds \geq 0$ pour tout $x \in \mathbb{R}$.

$$\begin{aligned} \frac{2\mathbb{E}[1 - \cos(hX)]}{h^2} &= 2 \frac{\mathbb{E}\left[h^2 X^2 \int_0^1 \cos(shX)(1-s)ds\right]}{h^2} \\ &= 2\mathbb{E}\left[X^2 \int_0^1 \cos(shX)(1-s)ds\right]. \end{aligned}$$

Par le lemme de Fatou :

$$\sigma^2 = \lim_{h \downarrow 0} 2\mathbb{E}\left[X^2 \int_0^1 \cos(shX)(1-s)ds\right] \geq 2\mathbb{E}\left[\liminf_{h \downarrow 0} X^2 \int_0^1 \cos(shX)(1-s)ds\right]$$

mais, pour tout $x \in \mathbb{R}$, par convergence dominée (Théorème 3.3),

$$\liminf_{h \downarrow 0} x^2 \int_0^1 \cos(shx)(1-s)ds = \frac{x^2}{2}.$$

Donc

$$\sigma^2 \geq \mathbb{E}X^2.$$

La preuve s'achève en invoquant Théorème 12.9). $\square$

Remark 12.4 est à nouveau pertinent ici.

Autre application : comprendre la loi de Cauchy

Supposons que U suit la loi uniforme sur $]0, 1[$, et définissons la variable aléatoire réelle X par

$$X = \tan\left(\frac{\pi}{2}(2 \times U - 1)\right).$$

Comme $\tan$ est strictement croissante et continue de $-\pi/2$ à $\pi/2$, la fonction de répartition de la loi de X est

$$\begin{aligned} \mathbb{P}\{X \leq x\} &= \mathbb{P}\left\{\tan\left(\frac{\pi}{2}(2U - 1)\right) \leq x\right\} \\ &= \mathbb{P}\left\{U \leq \frac{1}{2} + \frac{1}{\pi} \arctan(x)\right\} \\ &= \frac{1}{2} + \frac{1}{\pi} \arctan(x) \end{aligned}$$

pour $x \in \mathbb{R}$.

Comme $\arctan$ a pour dérivée $x \mapsto \frac{1}{1+x^2}$, la fonction de répartition est absolument continue de densité :

$$\frac{1}{\pi} \frac{1}{1+x^2}$$

Il s'agit de la densité de la loi de Cauchy.

Notons que $\mathbb{E}(X)_+ = \mathbb{E}(X)_- = \mathbb{E}|X| = \infty$. La loi de Cauchy n'est pas intégrable.

Supposons maintenant que $X_1, X_2, \dots, X_n$ sont i.i.d. de loi de Cauchy. Posons $Z = \sum_{i=1}^n X_i/n$. Quelle est la loi de Z ? On pourrait calculer la puissance de convolution de la densité de Cauchy. Il s'avère qu'il est bien plus simple de partir de la fonction caractéristique.

Nous nous abstenons de calculer directement la fonction caractéristique de la loi de Cauchy. Nous emprunterons un détour.

Soit Y de loi de Laplace, c'est-à-dire de densité $y \mapsto \frac{1}{2} \exp(-|y|)$ pour $y \in \mathbb{R}$. La variable aléatoire Y est symétrique ($Y \sim -Y$). Notons $\hat{F}_Y$ la fonction caractéristique de (la loi de) Y .

$$\begin{aligned} \hat{F}_Y(t) &= \mathbb{E}e^{tY} \\ &= \mathbb{E} \cos(tY) \\ &= \int_0^\infty e^{-y} \cos(ty) dy \\ &= [-e^{-y} \cos(ty)]_0^\infty - t \int_0^\infty e^{-ty} \sin(ty) dy \\ &= 1 - t \int_0^\infty e^{-y} \sin(ty) dy \\ &= 1 - t [-e^{-y} \sin(ty)]_0^\infty - t^2 \int_0^\infty e^{-y} \cos(ty) dy \\ &= 1 - t^2 \hat{F}_Y(t) \end{aligned}$$

où nous avons effectué deux intégrations par parties.

La fonction caractéristique $\hat{F}_Y$ satisfait

$$\hat{F}_Y(t) = \frac{1}{1+t^2},$$

qui, à un facteur $\frac{1}{\pi}$ près, est la densité de la loi de Cauchy.

$$\begin{aligned}\hat{F}_X(t) &= \mathbb{E}e^{itX} \\ &= \int_{-\infty}^{\infty} \frac{1}{\pi} \frac{1}{1+x^2} \cos(tx) dx \\ &= \frac{2}{\pi} \int_0^{\infty} \cos(tx) \hat{F}_Y(x) dx \\ &= 2 \times \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \hat{F}_Y(x) dx \\ &= 2 \times \frac{1}{2} e^{-|t|} = e^{-|t|}\end{aligned}$$

où nous avons utilisé la formule d'inversion.

La fonction caractéristique de la loi de Z est

$$\hat{F}_Z(t) = \left(e^{-\frac{|t|}{n}}\right)^n = \hat{F}_X(t)$$

ce qui signifie que $Z \sim X$.

Les outils de base de la théorie des fonctions caractéristiques nous permettent de

- calculer la fonction caractéristique de la loi de Laplace
- calculer la fonction caractéristique de la loi de Cauchy par inversion
- calculer la fonction caractéristique des sommes de variables aléatoires de Cauchy indépendantes
- montrer que la loi de Cauchy est 1-stable.

Remarque 12.5. La densité de la loi de Laplace n'est pas dérivable en 0; cela se reflète dans le fait que sa transformée de Fourier (la fonction caractéristique de la loi de Laplace) n'est pas intégrable.

Réciproquement, le manque d'intégrabilité de la loi de Cauchy se reflète dans la non-dérivabilité de sa fonction caractéristique en 0.

Exercice 12.8. Vérifier que $\int_0^1 \cos(sx)(1-s)ds \geq 0$ pour tout $x \in \mathbb{R}$.

Indication : Vérifier que $t \mapsto \int_0^1 \cos(tw)(1-w)dw$ est la fonction caractéristique de la loi *tente*, de densité $(1-|w|)$ sur $[-1, 1]$. Vérifier que cette fonction caractéristique est le carré du module d'une autre fonction caractéristique.

12.4 Remarques bibliographiques

Wilf (2005) explore l'interaction entre combinatoire, analyse d'algorithmes et théorie des fonctions génératrices.

Widder (2015) est une référence classique sur les transformées de Laplace. Celles-ci jouent un rôle important dans la théorie des processus ponctuels et la théorie des valeurs extrêmes, pour n'en citer que quelques domaines d'application.

12.4. REMARQUES BIBLIOGRAPHIQUES

La première partie du chapitre 9 de Pollard ([2002](#)) décrit les fonctions caractéristiques comme transformées de Fourier. Les propriétés et applications des fonctions caractéristiques sont abondamment traitées dans ([Durrett, 2010](#)), ([Billingsley, 2012](#)).

Chapitre 13

Fonctions quantiles

Jusqu'ici, nous avons vu plusieurs caractérisations des lois de probabilité : fonctions de répartition (FDR), transformées de Laplace pour les lois supportées sur $[0, \infty)$, fonctions caractéristiques. Cette dernière caractérisation est prisee pour son comportement vis-à-vis des sommes de variables aléatoires indépendantes.

Pour les lois univariées, le compagnon de la fonction de répartition est la *fonction quantile*. Elle joue un rôle important en simulation, en statistique et en théorie du risque.

Une fonction de répartition F est non négative, à valeurs dans $[0, 1]$, non décroissante, continue à droite, avec limite à gauche en tout point. La fonction de répartition d'une mesure de probabilité diffuse est continue en tout point.

13.1 Définition

La fonction quantile $F^{\leftarrow}$ est définie comme un inverse étendu de la fonction de répartition F .

Définition 13.1 (Fonction quantile). La fonction quantile $F^{\leftarrow}$ de la variable aléatoire X de loi P (de fonction de répartition F) est définie par

$$\begin{aligned} F^{\leftarrow}(p) &= \inf \left\{ x : P\{X \leq x\} \geq p \right\} \\ &= \inf \left\{ x : F(x) \geq p \right\} \quad \text{for } p \in (0, 1). \end{aligned}$$

La fonction quantile est non décroissante et continue à gauche. L'interaction entre les fonctions quantile et de répartition est résumée dans la proposition suivante.

Proposition 13.1. Si F et $F^{\leftarrow}$ sont la fonction de répartition et la fonction quantile de (la loi de) X , les affirmations suivantes sont vraies pour $p \in]0, 1[$:

1. $p \leq F(x)$ si et seulement si $F^{\leftarrow}(p) \leq x$.
2. $F \circ F^{\leftarrow}(p) \geq p$.

3. $F^{\leftarrow} \circ F(x) \leq x$.
4. Si F est absolument continue, alors $F \circ F^{\leftarrow}(p) = p$

Preuve. D'après la définition de $F^{\leftarrow}$, si $F(x) \geq p$, alors $F^{\leftarrow}(p) \leq x$.

Pour prouver la réciproque, il suffit de vérifier que $F \circ F^{\leftarrow}(p) \geq p$.

En effet, si $x \geq F^{\leftarrow}(p)$, comme F est non décroissante, $F(x) \geq F \circ F^{\leftarrow}(p)$. Si $y = F^{\leftarrow}(p)$, par définition de $y = F^{\leftarrow}(p)$, il existe une suite non croissante $(z_n)_{n \in \mathbb{N}}$ convergeant vers y telle que $F(z_n) \geq p$. Mais comme F est continue à droite, $\lim_n F(z_n) = F(\lim_n z_n) = F(y)$. D'où $F(y) \geq p$.

Nous venons de prouver les points 1. et 2.

3.) est une conséquence immédiate de 1.). Posons $p = F(x)$. Alors $p \leq F(x)$, et d'après 1.), cela équivaut à $F^{\leftarrow}(p) \leq x$, c'est-à-dire $F^{\leftarrow} \circ F(x) \leq x$.

4.) Pour tout p dans $]0, 1[$, l'ensemble $\{x : p = F(x)\}$ est non vide (théorème des valeurs intermédiaires). Posons $y = \inf\{x : p = F(x)\} = F^{\leftarrow}(p)$. D'après 1.), $F(y) \geq p$. Maintenant, si $(z_n)_{n \in \mathbb{N}}$ est une suite croissante convergeant vers y , pour tout n , $F(z_n) < p$, et, par continuité à gauche, $F(y) = F(\lim_n z_n) = \lim_n F(z_n) \leq p$. D'où $F(y) = p$, c'est-à-dire $F \circ F^{\leftarrow}(p) = p$. $\square$

13.2 Fonctions quantiles et simulation stochastique

Proposition 13.2 (Transformation quantile). Si U suit la loi uniforme sur $(0, 1)$ et si F est une fonction de répartition sur $\mathbb{R}$, alors $F^{\leftarrow}(U)$ a pour fonction de répartition F .

Preuve.

$$\begin{aligned} P\{F^{\leftarrow}(U) \leq x\} &= P\{U \leq F(x)\} \\ &= F(x). \end{aligned}$$

$\square$

Remarque 13.1. La transformation quantile fonctionne quelles que soient les propriétés de continuité de F .

La transformation quantile a de nombreuses applications. Elle peut être utilisée pour démontrer des propriétés de domination stochastique.

Exemple 13.1. Dans les Figures 13.1 jusqu'à Figure 13.4, nous illustrons les fonctions quantiles pour des lois discrètes (binomiales) et pour des lois qui ne sont ni discrètes ni continues. La fonction quantile d'une loi discrète est une fonction en escalier qui saute aux probabilités cumulées de chaque issue possible. Si une loi de probabilité est un mélange d'une loi discrète et d'une loi continue, la fonction quantile saute aux probabilités cumulées de chaque issue possible de la composante discrète.

Concluons cette section par une observation importante concernant le comportement de $F(X)$ lorsque $X \sim P$ avec fonction de répartition F .




FIGURE 13.1




FIGURE 13.2 : Quantile functions $\max(X, \tau)$ where $X \sim \mathcal{N}(0, 1)$ for $\tau \in \{0, 2\}$. Let $\Phi^\leftarrow$ denote the quantile function of $\mathcal{N}(0, 1)$. The quantile function of $\max(X, \tau)$ is $\mathbb{I}_{(0, \Phi(\tau)]}(p) \times \tau + \Phi^\leftarrow(p) \times \mathbb{I}_{(\Phi(\tau), 1)}(p) = \Phi^\leftarrow(p \vee \Phi(\tau))$. The two distributions are neither absolutely continuous nor discrete.




FIGURE 13.3 : Cumulative distribution functions for the probability distributions illustrated in Figure 13.2




FIGURE 13.4 : Representation of $F \circ F^{\leftarrow}$ for the probability distributions illustrated in Figures 13.2 and Figure 13.3. The function $F \circ F^{\leftarrow}$ always lies above the line $y = x$ (dotted line) as prescribed in Proposition 13.1. Plateaux that lie strictly above the dotted line are in correspondence with jumps of the quantile function.




FIGURE 13.5

Corollaire 13.1. *Si $X \sim P$ avec fonction de répartition continue F , alors $F(X)$ et $1 - F(X)$ suivent la loi uniforme sur $[0, 1]$.*

Exercice 13.1. Démontrer le Corollaire 13.1

13.3 Statistiques d'ordre

Définition 13.2 (Statistiques d'ordre).

Proposition 13.3 (Densité jointe).

Exercice 13.2 (Représentation de Rényi).

Exercice 13.3 (Statistiques d'ordre d'un échantillon uniforme).

13.4 Remarques bibliographiques

Chapitre 14

Convergences I : presque sûre, L_2 , L_1 , en probabilité

14.1 Motivations

Il nous faut munir le monde des variables aléatoires vivant sur un espace de probabilité d'une structure topologique. Comme les variables aléatoires sont des fonctions (mesurables), nous emprunterons et adapterons les notions utilisées en analyse : convergence ponctuelle (Section 14.2), convergence en L_p , $1 \leq p < \infty$ (Section 14.3).

Enfin, nous définissons et étudions la *convergence en probabilité*. Cette notion affaiblit à la fois la convergence en L_p et la convergence presque sûre (ponctuelle). Comme les convergences en L_p , elle peut se métriser.

La convergence en probabilité et la convergence presque sûre sont illustrées par la loi faible et la loi forte des grands nombres (Sections Section 14.5 et Section 14.6). Les lois des grands nombres affirment que les moyennes empiriques convergent vers les espérances (sous des conditions légères) ; ce sont les chevaux de trait de la théorie de l'apprentissage statistique.

Dans Section 14.7, nous examinons des contreparties non asymptotiques de la loi faible des grands nombres. Nous établissons des bornes exponentielles sur les queues de distribution pour des sommes de variables aléatoires indépendantes (sous des hypothèses d'intégrabilité fortes).

14.2 Convergence presque sûre

La notion de convergence presque sûre reflète celle de convergence ponctuelle en contexte probabiliste.

Rappelons qu'une suite de fonctions à valeurs réelles $(f_n)_n$ définies sur un espace Ω à valeurs dans $\mathbb{R}$ converge ponctuellement vers $f : \Omega \rightarrow \mathbb{R}$ si, pour tout $\omega \in \Omega$, $f_n(\omega) \rightarrow f(\omega)$. Il n'y a aucune condition d'uniformité.

Dans la définition suivante, nous supposons que les variables aléatoires sont à valeurs réelles. La définition s'étend facilement au cas multivarié.

Définition 14.1 (Convergence presque sûre). Soit $(\Omega, \mathcal{F}, P)$ un espace de probabilité. Une suite $(X_n)_n$ de variables aléatoires converge *presque sûrement* (p.s.) vers une variable aléatoire X si l'événement

$$E = \left\{ \omega : \lim_n X_n(\omega) = X(\omega) \right\}$$

est de probabilité P égale à 1.

La convergence presque sûre n'est (que) la convergence ponctuelle avec probabilité 1. Elle n'est pas liée à l'intégrabilité. Notons que toutes les variables aléatoires intervenant ci-dessus vivent sur le même espace de probabilité. On peut se demander s'il est possible de concevoir une métrique pour la convergence presque sûre. La réponse est non, comme pour la convergence ponctuelle, en général.

14.3 Convergence en L_p

Dans cette section, nous considérons des variables aléatoires satisfaisant des hypothèses d'intégrabilité. La portée des convergences en L_p est plus étroite que celle des convergences presque sûres.

Nous avons déjà introduit les convergences en L_p dans la Leçon Chapitre 3. Nous les rappelons pour la lisibilité.

Définition 14.2. Pour $p \in [1, \infty)$, L_p est l'ensemble des variables aléatoires sur $(\Omega, \mathcal{F}, P)$ qui satisfont $\mathbb{E}|X|^p < \infty$. La p -pseudo-norme est définie par $\|X\|_p = (\mathbb{E}|X|^p)^{1/p}$.

La convergence en L_p signifie la convergence pour cette pseudo-norme.

Rappelons que les espaces L_p sont emboîtés (par l'inégalité de Hölder) et complets.

Proposition 14.1. La convergence en L_q $q \geq 1$, implique la convergence en L_p , $1 \leq p \leq q$.

La convergence presque sûre n'est pas liée à l'intégrabilité. On ne peut pas se demander si la convergence presque sûre implique la convergence en L_p . En revanche, on peut se demander si la convergence en L_p implique la convergence presque sûre. L'énoncé suivant est un sous-produit de la preuve de la complétude des espaces L_p , voir Section 4.7).

Théorème 14.1. La convergence en L_p implique la convergence presque sûre le long d'une sous-suite.

Un contre-exemple donné en Section 4.7) montre que la convergence en L_p n'implique pas la convergence presque sûre.

14.4 Convergence en probabilité

Si l'on note $L_0 = L_0(\Omega, \mathcal{F}, P)$ l'ensemble des variables aléatoires à valeurs réelles, la notion de convergence en probabilité concerne toutes les suites de L_0 , comme la convergence presque sûre. Et comme la convergence en L_p , $p \geq 1$, la convergence en probabilité peut se métriser.

Définition 14.3. Soit $(\Omega, \mathcal{F}, P)$ un espace de probabilité.

Une suite $(X_n)_n$ de variables aléatoires converge en probabilité vers une variable aléatoire X si, pour tout $\epsilon > 0$,

$$\lim_n P\{|X_n - X| \geq \epsilon\} = 0.$$

Proposition 14.2. La convergence en L_p , $p \geq 1$, implique la convergence en probabilité.

C'est une conséquence immédiate de l'inégalité de Markov.

Proposition 14.3 (Un critère de convergence en probabilité). La suite $(X_n)_n$ converge en probabilité vers X si et seulement si

$$\lim_n \mathbb{E}[1 \wedge |X_n - X|] = 0$$

Preuve. En supposant la convergence en probabilité,

$$\begin{aligned} \mathbb{E}[1 \wedge |X_n - X|] &\leq \mathbb{E}[(1 \wedge |X_n - X|)\mathbb{1}_{|X - X_n| \geq \epsilon}] + \mathbb{E}[(1 \wedge |X_n - X|)\mathbb{1}_{|X - X_n| < \epsilon}] \\ &\leq P\{|X - X_n| \geq \epsilon\} + \epsilon \end{aligned}$$

la limite du membre de droite n'est pas supérieure à ϵ . Comme on peut prendre ϵ arbitrairement petit, cela entraîne que la limite du membre de gauche est nulle.

Réciproquement, pour tout $0 < \epsilon < 1$,

$$P\{|X - X_n| \geq \epsilon\} \leq \frac{1}{\epsilon} \mathbb{E}[1 \wedge |X - X_n|].$$

Ainsi $\lim_n \mathbb{E}[1 \wedge |X_n - X|] = 0$ entraîne $\lim_n P\{|X - X_n| \geq \epsilon\} = 0$. Comme cela vaut pour tout $\epsilon > 0$, $\lim_n \mathbb{E}[1 \wedge |X_n - X|] = 0$ entraîne la convergence en probabilité. $\square$

Proposition 14.4. La convergence presque sûre implique la convergence en probabilité.

Preuve. Supposons $X_n \rightarrow X$ p.s., c'est-à-dire $|X_n - X| \rightarrow 0$. Alors, par convergence dominée,

$$\lim_n \mathbb{E}[|X_n - X| \wedge 1] = 0$$

ce qui entraîne la convergence en probabilité de $(X_n)_n$ vers X . $\square$

Nous arrivons maintenant à une métrique qui s'accorde parfaitement avec la convergence en probabilité.

Définition 14.4 (Distance de Ky-Fan). La distance de Ky-Fan est définie par

$$d_{\text{KF}}(X, Y) = \inf_{\epsilon \geq 0} P\{|X - Y| > \epsilon\} \leq \epsilon.$$

Il faut vérifier que d_{KF} est bien une distance. C'est le contenu de la Proposition @ref(prp:kyfanprop) ci-dessous.

Proposition 14.5. Dans la définition de la distance de Ky-Fan, l'infimum est atteint.

Preuve. Soit $a > d_{\text{KF}}(X, Y)$. L'événement $A_a = \{|X - Y| > a\}$ a une probabilité inférieure à ϵ . Et si $\epsilon < a < b$, $A_b \subseteq A_a$. Par convergence monotone, $P\left(\bigcap_n A_{\epsilon+1/n}\right) = \lim_n \uparrow P(A_{\epsilon+1/n}) = \epsilon$. $\square$

Proposition 14.6. La distance de Ky-Fan satisfait :

1. $d_{\text{KF}}(X, Y) = 0 \Rightarrow X = Y \quad a.s.$
2. $d_{\text{KF}}(X, Y) = d_{\text{KF}}(Y, X)$
3. $d_{\text{KF}}(X, Z) \leq d_{\text{KF}}(X, Y) + d_{\text{KF}}(Y, Z)$

Preuve. Nous vérifions que d_{KF} satisfait l'inégalité triangulaire. Il existe deux événements B et C de probabilités respectives $d_{\text{KF}}(X, Y)$ et $d_{\text{KF}}(Y, Z)$ tels que

$$|X(\omega) - Y(\omega)| \leq d_{\text{KF}}(X, Y) \quad \text{on } B^c$$

et

$$|Z(\omega) - Y(\omega)| \leq d_{\text{KF}}(Z, Y) \quad \text{on } C^c.$$

Sur $B^c \cap C^c$, par l'inégalité triangulaire sur $\mathbb{R}$:

$$|X(\omega) - Z(\omega)| \leq d_{\text{KF}}(X, Y) + d_{\text{KF}}(Y, Z).$$

Nous concluons en observant

$$\begin{aligned} P(|X(\omega) - Z(\omega)| > d_{\text{KF}}(X, Y) + d_{\text{KF}}(Y, Z)) &\leq P((B^c \cap C^c)^c) \\ &= P(B \cup C) \\ &\leq P(B) + P(C) \\ &= d_{\text{KF}}(X, Y) + d_{\text{KF}}(Y, Z). \end{aligned}$$

$\square$

Proposition 14.7. *Les deux affirmations suivantes sont équivalentes :*

1. $(X_n)_n$ converge en probabilité vers X
2. $d_{KF}(X_n, X)$ tend vers 0 lorsque n tend vers l'infini.

Exercice 14.1. Vérifier la proposition.

Nous laissons les questions suivantes comme exercices :

- $\mathcal{L}_0(\Omega, \mathcal{F}, P)$ est-il complet pour la métrique de Ky-Fan ?
- La convergence en probabilité implique-t-elle la convergence presque sûre ?
- La convergence en probabilité implique-t-elle la convergence en L_p , $p \geq 1$?

Enfin, nous énonçons une définition plus générale de la convergence en probabilité. La notion peut s'adapter aux variables aléatoires à valeurs dans un espace métrique quelconque. Les liens avec la convergence presque sûre et les convergences en L_p restent inchangés.

Définition 14.5 (Convergence en probabilité, cadre multivarié). Une suite $(X_n)_{n \in \mathbb{N}}$ de variables aléatoires à valeurs dans $\mathbb{R}^k$, définies sur le même espace de probabilité $(\Omega, \mathcal{F}, P)$, converge en probabilité (en probabilité $\mathbb{P}$) vers une variable aléatoire X à valeurs dans $\mathbb{R}^k$ si et seulement si, pour tout $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}\{\|X_n - X\| > \epsilon\} = 0.$$

14.5 Loi faible des grands nombres

La loi faible et la loi forte des grands nombres concernent la convergence des moyennes empiriques de variables aléatoires indépendantes, identiquement distribuées et intégrables vers leur espérance commune.

Théorème 14.2 (Loi faible des grands nombres). *Si $X_1, \dots, X_n, \dots$ sont des variables aléatoires indépendantes, identiquement distribuées, intégrables, à valeurs dans $\mathbb{R}^k$, sur $(\Omega, \mathcal{F}, P)$, d'espérance μ , alors la suite $(\bar{X}_n)$ définie par $\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i$ converge en probabilité P vers μ .*

Preuve. Supposons d'abord que $\mathbb{E}[(X_i - \mu)^2] = \sigma^2 < \infty$. Alors, pour tout $\epsilon > 0$, par l'inégalité de Markov-Tchebychev :

$$\begin{aligned} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| > \epsilon\right\} &\leq \frac{\mathbb{E}\left[\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right|^2\right]}{\epsilon^2} \\ &= \frac{\mathbb{E}\left[\left(X_i - \mu\right)^2\right]}{n\epsilon^2} \\ &= \frac{\sigma^2}{n\epsilon^2} \end{aligned}$$

car la variance d'une somme de variables aléatoires indépendantes est la somme des variances des termes.

Le membre de droite converge vers 0 pour tout $\epsilon > 0$. La LFGN vaut pour les variables aléatoires de carré intégrable.

Passons au cas général. Sans perte de généralité, supposons que toutes les X_n sont centrées. Soit $\tau > 0$ un seuil de troncature (dont la valeur sera ajustée plus tard). Pour chaque $i \in \mathbb{N}$, X_i se décompose en une somme :

$$X_i = X_i^\tau + Y_i^\tau$$

avec $X_i^\tau = \mathbb{I}_{|X_i| \leq \tau} X_i$ et $Y_i^\tau = \mathbb{I}_{|X_i| > \tau} X_i$. Pour tout $\epsilon > 0$,

$$\left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i \right| > \epsilon \right\} \subseteq \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i^\tau \right| > \frac{\epsilon}{2} \right\} \cup \left\{ \left| \frac{1}{n} \sum_{i=1}^n Y_i^\tau \right| > \frac{\epsilon}{2} \right\}.$$

En invoquant la borne de l'union, l'inégalité de Markov (deux fois), et la bornitude des variances des X_i^τ , on obtient :

$$\begin{aligned} P\left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| > \epsilon \right\} &\leq P\left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i^\tau \right| > \frac{\epsilon}{2} \right\} + P\left\{ \left| \frac{1}{n} \sum_{i=1}^n Y_i^\tau \right| > \frac{\epsilon}{2} \right\} \\ &\leq 4 \frac{\mathbb{E} \left| \frac{1}{n} \sum_{i=1}^n X_i^\tau \right|^2}{\epsilon^2} + 2 \frac{\mathbb{E} \left| \frac{1}{n} \sum_{i=1}^n Y_i^\tau \right|}{\epsilon} \\ &\leq \frac{4\tau^2}{n\epsilon^2} + 2 \frac{\mathbb{E} \left| \frac{1}{n} \sum_{i=1}^n Y_i^\tau \right|}{\epsilon} \\ &\leq \frac{4\tau^2}{n\epsilon^2} + 2 \frac{1}{n} \sum_{i=1}^n \frac{\mathbb{E} |Y_i^\tau|}{\epsilon} \\ &\leq \frac{4\tau^2}{n\epsilon^2} + 2 \frac{\mathbb{E} |Y_1^\tau|}{\epsilon}. \end{aligned}$$

En faisant tendre n vers l'infini, on obtient

$$\limsup_n P\left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| > \epsilon \right\} \leq 2 \frac{\mathbb{E} |Y_1^\tau|}{\epsilon}.$$

Or, lorsque $\tau \uparrow \infty$, $|Y_1^\tau| \downarrow 0$ tandis que $|Y_1^\tau| \leq |X_1|$; la convergence dominée (ici un cas particulier de convergence monotone) garantit que $\lim_{\tau \uparrow \infty} \frac{\mathbb{E} |Y_1^\tau|}{\epsilon} = 0$.

Ceci achève la preuve de la LFGN. □

14.6 Loi forte des grands nombres

Espace produit infini muni de la tribu cylindrique et de la mesure produit infinie.

Théorème 14.3 (Loi forte des grands nombres, partie directe). *Si $X_1, \dots, X_n, \dots$ sont des variables aléatoires indépendantes, identiquement distribuées, intégrables, à*

valeurs dans $\mathbb{R}$, sur $(\Omega, \mathcal{F}, P)$, d'espérance μ , alors P -p.s.

$$\lim_{n \rightarrow \infty} \bar{X}_n = \mu \quad \text{with} \quad \bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i.$$

Avant d'aborder la preuve de **Théorème 14.4**, nous signalons un résultat général sur les événements qui dépendent du comportement limite de suites de variables aléatoires indépendantes : la loi 0-1. Pour énoncer Théorème 14.4, nous avons besoin d'une nouvelle notion : la tribu terminale.

Définition 14.6 (Tribu terminale). Supposons que $X_1, \dots, X_n, \dots$ sont des variables aléatoires sur un espace mesuré. La tribu terminale (ou tribu des événements terminaux) est définie par :

$$\mathcal{T} = \cap_{n=1}^{\infty} \sigma(X_n, X_{n+1}, \dots).$$

Observons que l'événement

$$\left\{ \omega : \sum_{i=1}^n X_i(\omega)/n \text{ converges towards a finite limit} \right\}$$

appartient à la tribu terminale.

La loi forte des grands nombres ci-dessous nous dit que, sous des hypothèses d'intégrabilité et d'indépendance, cet événement terminal a pour probabilité 1.

Ce n'est pas un hasard. La loi 0-1 affirme que, sous indépendance, les événements terminaux ont des probabilités triviales.

Théorème 14.4 (Loi 0-1). Supposons que $X_1, \dots, X_n, \dots$ sont des variables aléatoires indépendantes. Alors tout événement de la tribu terminale $\mathcal{T}$ a pour probabilité 0 ou 1.

Preuve. Il suffit de vérifier que tout événement $A \in \mathcal{T}$ satisfait $P(A)^2 = P(A)$, ou, de façon équivalente, que $P(A) = P(A \cap A) = P(A) \times P(A)$, c'est-à-dire que A est indépendant de lui-même.

Pour tout n , en tant qu'événement de $\sigma(X_n, X_{n+1}, \dots)$, A est indépendant de tout événement de $\sigma(X_1, \dots, X_n)$. Cela entraîne que A est indépendant de tout événement de $\cup_n \sigma(X_1, \dots, X_n)$.

Observons que $\cup_n \sigma(X_1, \dots, X_n)$ est un π -système qui engendre la tribu cylindrique (rappel des définitions en Section 2.6 autour de Théorème 2.4).

Ainsi, A est indépendant de tout événement de la tribu engendrée par $\cup_n \sigma(X_1, \dots, X_n)$, qui n'est autre que $\mathcal{F}$.

Comme $A \in \mathcal{T} \subset \mathcal{F}$, A est indépendant de lui-même. $\square$

Exercice 14.2. Dédurre le second lemme de Borel-Cantelli comme cas particulier de la loi 0-1.

Lemme 14.1 (Borel-Cantelli I). *Soient $A_1, A_2, \dots, A_n$ des événements d'un espace de probabilité $(\Omega, \mathcal{F}, P)$.*

Si

$$\sum_n P(A_n) < \infty$$

alors :

avec probabilité 1, seulement un nombre fini d'événements parmi $A_1, A_2, \dots, A_n$ se réalisent :

$$P\left\{\omega : \sum_n \mathbb{1}_{A_n}(\omega) < \infty\right\} = 1.$$

Preuve. Un résultat ω appartient à une infinité d'événements A_k si et seulement si $\omega \in \bigcap_n \bigcup_{k \geq n} A_k$. Par convergence monotone,

$$\begin{aligned} P\left\{\omega : \omega \text{ belongs to infinitely many events } A_k\right\} &= P\left\{\bigcap_n \bigcup_{k \geq n} A_k\right\} \\ &= \lim_n \downarrow P\left\{\bigcup_{k \geq n} A_k\right\} \\ &\leq \lim_n \downarrow \sum_{k \geq n} P\{A_k\} \\ &= 0. \end{aligned}$$

□

Définition 14.7.

Théorème 14.5.

Nous pouvons maintenant aborder la preuve de la LFGN forte.

Preuve de la LFGN forte (partie directe). L'événement $\left\{\omega : \lim_n \sum_{i=1}^n \frac{X_i}{n} = \mu\right\}$ appartient à la tribu terminale. Par Théorème 14.5, pour vérifier la loi forte des grands nombres, il suffit de vérifier que cet événement a une probabilité non nulle.

De plus, en utilisant la décomposition usuelle $X = (X)_+ - (X)_-$ où $(X)_+$ et $(X)_-$ sont les parties positive et négative de X , nous observons que l'on peut supposer sans perte de généralité que les X_i sont non négatives.

Rappelons la définition des variables tronquées $X_i^i = \mathbb{1}_{X_i \leq i} X_i$ pour $i \in \mathbb{N}$. Posons $S_n = \sum_{i=1}^n X_i$ et $T_n = \sum_{i=1}^n X_i^i$.

La différence $S_n - T_n = \sum_{i=1}^n (X_i - X_i^i)$ est une somme de variables aléatoires non négatives. Comme

$$P\{X_i - X_i^i > 0\} = P\{X_i > i\} = P\{X_1 > i\},$$

grâce à $\mathbb{E}X_1 < \infty$,

$$\sum_{i \in \mathbb{N}} P\{X_i - X_i^i > 0\} < \infty.$$

Par le premier lemme de Borel-Cantelli, cela implique que, presque sûrement, seulement un nombre fini d'événements $\{X_i - X_i^i > 0\}$ se réalisent. Ainsi, presque sûrement, T_n et S_n diffèrent d'au plus un nombre borné de termes, et $\lim_n \uparrow (S_n - T_n)$ est fini.

Or

$$\lim_n \uparrow \mathbb{E} \frac{T_n}{n} = \mathbb{E} X_1.$$

Nous vérifierons d'abord que $T_{n(k)}/n(k)$ converge presque sûrement vers $\mathbb{E} X_1$ pour une sous-suite $(n(k))_{k \in \mathbb{N}}$ (presque) géométriquement croissante.

Fixons $\alpha > 1$ et posons $n(k) = \lfloor \alpha^k \rfloor$. Si, pour tout $\epsilon > 0$, presque sûrement, seulement un nombre fini d'événements

$$\left\{ \left| T_{n(k)} - \mathbb{E} T_{n(k)} \right| \geq n(k) > \epsilon \right\}$$

se réalisent, alors $\left| T_{n(k)} - \mathbb{E} T_{n(k)} \right| / n(k)$ converge presque sûrement vers 0 et donc $T_{n(k)}/n(k)$ converge presque sûrement vers $\mathbb{E} X_1$.

Posons

$$\Theta = \sum_{k \in \mathbb{N}} P \left\{ \left| T_{n(k)} - \mathbb{E} T_{n(k)} \right| \geq n(k) > \epsilon \right\}.$$

Grâce à la troncature, chaque $T_{n(k)}$ est de carré intégrable. Par l'inégalité de Tchebychev :

$$P \left\{ \left| T_{n(k)} - \mathbb{E} T_{n(k)} \right| \geq n(k) > \epsilon \right\} \leq \frac{\text{var}(T_{n(k)})}{\epsilon^2 n(k)^2}.$$

Comme les X_i^i sont indépendantes,

$$\begin{aligned} \text{var}(T_{n(k)}) &= \sum_{i \leq n(k)} \text{var}(X_i^i) \\ &\leq \sum_{i \leq n(k)} \mathbb{E} \left[(X_i^i)^2 \right] \\ &= \sum_{i \leq n(k)} \int_0^\infty 2t P\{X_i^i > t\} dt \\ &\leq \sum_{i \leq n(k)} \int_0^i 2t P\{X_1 > t\} dt. \end{aligned}$$

$$\begin{aligned} \Theta &\leq \sum_{k \in \mathbb{N}} \frac{1}{\epsilon^2 n(k)^2} \sum_{i \leq n(k)} \int_0^i 2t P\{X_1 > t\} dt \\ &= \frac{1}{\epsilon^2} \sum_{i \in \mathbb{N}} \int_0^i 2t P\{X_1 > t\} dt \sum_{k: n(k) \geq i} \frac{1}{n(k)^2}. \end{aligned}$$

Grâce au fait que $\alpha^k > 1$ pour $k \geq 1$, la relation suivante vaut :

$$\sum_{k: n(k) \geq i} \frac{1}{n(k)^2} = \sum_{k: \lfloor \alpha^k \rfloor \geq i} \frac{1}{[\alpha^k]^2} \leq \frac{4}{i^2} \frac{\alpha^2}{\alpha^2 - 1}.$$

$$\begin{aligned} \Theta &\leq \frac{4\alpha^2}{\epsilon^2(\alpha^2-1)} \sum_{i \in \mathbb{N}} \frac{1}{i^2} \int_0^i 2t P\{X_1 > t\} dt \\ &\leq \frac{4\alpha^2}{\epsilon^2(\alpha^2-1)} \sum_{i \in \mathbb{N}} \frac{1}{i^2} \sum_{j < i} \int_j^{j+1} 2t P\{X_1 > t\} dt \\ &\leq \frac{4\alpha^2}{\epsilon^2(\alpha^2-1)} \sum_{j=0}^\infty \int_j^{j+1} 2t P\{X_1 > t\} dt \sum_{i > j} \frac{1}{i^2} \\ &\leq \frac{4\alpha^2}{\epsilon^2(\alpha^2-1)} \sum_{j=0}^\infty \int_j^{j+1} 2t P\{X_1 > t\} dt \frac{2}{j+1} \\ &\leq 8 \frac{4\alpha^2}{\epsilon^2(\alpha^2-1)} \sum_{j=0}^\infty \int_j^{j+1} P\{X_1 > t\} dt \\ &\leq 8 \frac{4\alpha^2}{\epsilon^2(\alpha^2-1)} \mathbb{E} X_1 \\ &< \infty. \end{aligned}$$

Par le premier lemme de Borel-Cantelli, avec probabilité 1, seulement un nombre fini d'événements

$$\left\{ \left| T_{n(k)} - \mathbb{E}T_{n(k)} \right| \geq n(k) > \epsilon \right\}$$

se réalisent. Comme cela vaut pour chaque $\epsilon > 0$, cela vaut simultanément pour tous les $\epsilon = 1/n$, ce qui implique que $\left| T_{n(k)} - \mathbb{E}T_{n(k)} \right|/n(k)$ converge presque sûrement vers 0. Cela implique aussi que $S_{n(k)}/n(k)$ converge presque sûrement vers $\mathbb{E}X_1$.

Pour achever la preuve, il reste à vérifier que cela vaut pour S_n/n .

Si $n(k) \leq n < n(k+1)$, comme $(S_n)_n$ est non décroissante,

$$\frac{n(k)}{n(k+1)} \frac{S_{n(k)}}{n(k)} \leq \frac{S_n}{n} \leq \frac{n(k+1)}{n(k)} \frac{S_{n(k+1)}}{n(k+1)}$$

avec

$$\frac{1}{\alpha} \left(1 - \frac{1}{\alpha^k} \right) \leq \frac{n(k+1)}{n(k)} \leq \alpha \left(1 + \frac{1}{\alpha^k} \right).$$

En faisant tendre k vers l'infini, presque sûrement

$$\frac{1}{\alpha} \mathbb{E}X_1 \leq \liminf_n \frac{S_n}{n} \leq \limsup_n \frac{S_n}{n} \leq \alpha \mathbb{E}X_1.$$

Enfin, on peut choisir α arbitrairement proche de 1 pour établir le résultat souhaité. $\square$

Remarque 14.1. Dans l'énoncé du théorème, on peut remplacer l'hypothèse d'indépendance par une indépendance deux à deux.

Théorème 14.6) montre que, sous l'hypothèse d'indépendance, les conditions du Théorème 14.3) sont optimales. Avant d'aborder la preuve du Théorème 14.6), nous énonçons et démontrons le second lemme de Borel-Cantelli.

Lemme 14.2 (Borel-Cantelli II). *Soient $A_1, A_2, \dots, A_n$ des événements indépendants d'un espace de probabilité $(\Omega, \mathcal{F}, P)$.*

Si

$$\sum_n P(A_n) = \infty$$

alors

avec probabilité 1, une infinité d'événements parmi $A_1, A_2, \dots, A_n$ se réalisent :

$$P\left\{ \omega : \sum_n \mathbb{I}_{A_n}(\omega) = \infty \right\} = 1.$$

Preuve. Un résultat ω n'appartient pas à une infinité d'événements A_k si et seulement si $\omega \in \bigcup_n \bigcap_{k \geq n} A_k^c$. Par convergence monotone,

$$\begin{aligned}
 P\{\omega : \omega \text{ does not belong to infinitely many events } A_k\} &= P\left\{\omega \in \bigcup_n \bigcap_{k \geq n} A_k^c\right\} \\
 &= \lim_n \uparrow P\left\{\bigcap_{k \geq n} A_k^c\right\} \\
 &= \lim_n \uparrow \lim_{m \uparrow \infty} \downarrow P\left\{\bigcap_{k=n}^m A_k^c\right\} \\
 &= \lim_n \uparrow \lim_{m \uparrow \infty} \downarrow \prod_{k=n}^m (1 - P(A_k)) \\
 &= \lim_n \uparrow \prod_{k=n}^{\infty} (1 - P(A_k)) \\
 &= \lim_n \uparrow \exp\left(-\sum_{k=n}^{\infty} P(A_k)\right) \\
 &= \lim_n \uparrow 0 \\
 &= 0.
 \end{aligned}$$

□

Théorème 14.6 (Loi forte des grands nombres, partie réciproque). Soient $X_1, \dots, X_n, \dots$ des variables aléatoires indépendantes, identiquement distribuées, à valeurs dans $\mathbb{R}$, sur un espace $(\Omega, \mathcal{F}, P)$. Si, pour une constante finie μ ,

$$\lim_{n \rightarrow \infty} \sum_{i \leq n} X_i / n = \mu \quad \text{almost surely,}$$

alors toutes les X_i sont intégrables et $\mathbb{E}X_i = \mu$.

On peut supposer que les X_i sont des variables aléatoires non négatives.

Preuve. Pour vérifier que les X_i sont intégrables, il suffit de montrer que

$$\sum_{n=0}^{\infty} P\{X_1 > n\} = \sum_{n=0}^{\infty} P\{X_n > n\} < \infty.$$

Posons $S_n = \sum_{i=1}^n X_i$. Observons que

$$\begin{aligned}
 \left\{\omega : X_{n+1}(\omega) > n + 1\right\} &= \left\{\omega : S_{n+1}(\omega) - S_n(\omega) > n + 1\right\} \\
 &= \left\{\omega : \frac{S_{n+1}(\omega)}{n+1} - \frac{S_n(\omega)}{n} > 1 + \frac{S_n(\omega)}{n(n+1)}\right\}.
 \end{aligned}$$

Supposons par l'absurde que les X_i ne sont pas intégrables. Alors, par le second lemme de Borel-Cantelli, avec probabilité 1, une infinité d'événements

$$\left\{\omega : \frac{S_{n+1}}{n+1} - \frac{S_n}{n} > 1 + \frac{S_n}{n(n+1)}\right\}$$

se réalisent. Or cela ne peut pas arriver si S_n/n converge vers une limite finie. □

La loi des grands nombres est la pierre angulaire des preuves de consistance.

14.7 Inégalités exponentielles

Les lois des grands nombres sont des énoncés asymptotiques. En application, en statistique, en théorie de l'apprentissage statistique, il est souvent souhaitable d'obtenir des garanties pour n fixé. Les inégalités exponentielles sont des raffinements de l'inégalité de Tchebychev. Sous des hypothèses d'intégrabilité fortes sur les termes de la somme, il est possible et relativement facile d'obtenir des bornes fines sur les queues pour des sommes de variables aléatoires indépendantes.

Lemme de Hoeffding

Soit Y une variable aléatoire prenant ses valeurs dans un intervalle borné $[a, b]$ et posons $\psi_Y(\lambda) = \log \mathbb{E} e^{\lambda(Y - \mathbb{E}Y)}$. Alors

$$\text{var}(Y) \leq \frac{(b-a)^2}{4} \quad \text{and} \quad \psi_Y(\lambda) \leq \frac{1}{2} \frac{(b-a)^2}{4}.$$

Preuve. La borne supérieure sur la variance de Y a été établie en Section 4.4).

Posons P la loi de Y et P_λ la loi de probabilité de densité

$$x \rightarrow e^{-\psi_Y(\lambda)} e^{\lambda(x - \mathbb{E}Y)}$$

par rapport à P .

Comme P_λ est concentrée sur $[a, b]$ ($P_\lambda([a, b]) = P([a, b]) = 1$), la variance d'une variable aléatoire Z de loi P_λ est majorée par $(b-a)^2/4$. Notons que $P_0 = P$.

Des arguments de convergence dominée permettent de calculer les dérivées de $\psi_Y(\lambda)$. À savoir

$$\psi'_Y(\lambda) = \frac{\mathbb{E}[(Y - \mathbb{E}Y)e^{\lambda(Y - \mathbb{E}Y)}]}{\mathbb{E}e^{\lambda(Y - \mathbb{E}Y)}} = \mathbb{E}_{P_\lambda} Z.$$

et

$$\psi''_Y(\lambda) = \frac{\mathbb{E}[(Y - \mathbb{E}Y)^2 e^{\lambda(Y - \mathbb{E}Y)}]}{\mathbb{E}e^{\lambda(Y - \mathbb{E}Y)}} - \left(\frac{\mathbb{E}[(Y - \mathbb{E}Y)e^{\lambda(Y - \mathbb{E}Y)}]}{\mathbb{E}e^{\lambda(Y - \mathbb{E}Y)}} \right)^2 = \text{var}_{P_\lambda}(Z).$$

Ainsi, grâce à la borne sur la variance :

$$\psi''_Y(\lambda) \leq \frac{(b-a)^2}{4}.$$

Notons que $\psi_Y(0) = \psi'_Y(0) = 0$, et par le théorème de Taylor, pour un certain $\theta \in [0, \lambda]$,

$$\psi_Y(\lambda) = \psi_Y(0) + \lambda \psi'_Y(0) + \frac{\lambda^2}{2} \psi''_Y(\theta) \leq \frac{\lambda^2 (b-a)^2}{8}.$$

□

La borne supérieure sur la variance est optimale dans le cas particulier d'une variable aléatoire de *Rademacher* X dont la loi est définie par $P\{X = -1\} = P\{X = 1\} = 1/2$. On peut alors prendre $a = -b = 1$ et $\text{var}(X) = 1 = (b-a)^2/4$.

Nous pouvons maintenant nous appuyer sur le lemme de Hoeffding pour obtenir des bornes sur les queues très pratiques pour des sommes de variables aléatoires indépendantes bornées.

Théorème 14.7 (Inégalité de Hoeffding). Soient $X_1, \dots, X_n$ des variables aléatoires indépendantes telles que X_i prend ses valeurs dans $[a_i, b_i]$ presque sûrement pour tout $i \leq n$. Posons

$$S = \sum_{i=1}^n (X_i - \mathbb{E}X_i) .$$

Alors

$$\text{var}(S) \leq \sum_{i=1}^n \frac{(b_i - a_i)^2}{4} .$$

Notons v la borne supérieure sur la variance. Pour tout $\lambda \in \mathbb{R}$,

$$\log \mathbb{E}e^{\lambda S} \leq \frac{\lambda^2 v}{2} .$$

Alors, pour tout $t > 0$,

$$P\{S \geq t\} \leq \exp\left(-\frac{t^2}{2v}\right) .$$

La preuve repose sur la technique de majoration de Cramér-Chernoff et sur le lemme de Hoeffding.

Preuve. La borne supérieure sur la variance découle de $\text{var}(S) = \sum_{i=1}^n \text{var}(X_i)$ et de la première partie du lemme de Hoeffding.

Pour la borne supérieure sur $\log \mathbb{E}e^{\lambda S}$,

$$\begin{aligned} \log \mathbb{E}e^{\lambda S} &= \log \mathbb{E}e^{\sum_{i=1}^n \lambda(X_i - \mathbb{E}X_i)} \\ &= \log \mathbb{E}\left[\prod_{i=1}^n e^{\lambda(X_i - \mathbb{E}X_i)}\right] \\ &= \log\left(\prod_{i=1}^n \mathbb{E}\left[e^{\lambda(X_i - \mathbb{E}X_i)}\right]\right) \\ &= \sum_{i=1}^n \log \mathbb{E}\left[e^{\lambda(X_i - \mathbb{E}X_i)}\right] \\ &\leq \sum_{i=1}^n \frac{\lambda^2(b_i - a_i)^2}{8} \\ &= \frac{\lambda^2 v}{2} \end{aligned}$$

où la troisième égalité vient de l'indépendance des X_i et l'inégalité découle de l'application du lemme de Hoeffding à chaque terme.

La technique de Cramér-Chernoff consiste à utiliser l'inégalité de Markov avec des moments exponentiels.

$$\begin{aligned} P\{S \geq t\} &\leq \inf_{\lambda \geq 0} \frac{\mathbb{E}e^{\lambda S}}{e^{\lambda t}} \\ &\leq \exp\left(-\sup_{\lambda \geq 0} (\lambda t - \log \mathbb{E}e^{\lambda S})\right) \\ &\leq \exp\left(-\sup_{\lambda \geq 0} \left(\lambda t - \frac{\lambda^2 v}{2}\right)\right) \\ &= e^{-\frac{t^2}{2v}} . \end{aligned}$$

□

L'inégalité de Hoeffding fournit des bornes intéressantes sur les queues pour des variables aléatoires binomiales, qui sont des sommes de variables aléatoires indépendantes à valeurs dans $[0, 1]$. Cependant, dans certains cas, la borne supérieure sur la variance utilisée dans l'inégalité de Hoeffding est excessivement conservative. Pensez par exemple à une variable aléatoire binomiale de paramètres n et μ/n : la borne sur la variance obtenue à partir de la bornitude vaut n alors que la vraie variance est μ . Cela motive les deux inégalités exponentielles suivantes énoncées dans Théorème 14.8) et Théorème 14.9).

Théorème 14.8 (Inégalité de Bennett). *Soient $X_1, \dots, X_n$ des variables aléatoires indépendantes de variance finie telles que $X_i \leq b$ pour un certain $b > 0$ presque sûrement pour tout $i \leq n$. Posons*

$$S = \sum_{i=1}^n (X_i - \mathbb{E}X_i)$$

et $v = \sum_{i=1}^n \mathbb{E}[X_i^2]$. Posons $\phi(u) = e^u - u - 1$ pour $u \in \mathbb{R}$.

Alors, pour tout $\lambda > 0$,

$$\log \mathbb{E}e^{\lambda S} \leq \frac{v}{b^2} \phi(b\lambda),$$

et, pour tout $t > 0$,

$$P\{S \geq t\} \leq \exp\left(-\frac{v}{b^2} h\left(\frac{bt}{v}\right)\right)$$

où $h(u) = \phi^(u) = (1+u) \log(1+u) - u$ pour $u > 0$.*

Remarque 14.2. L'inégalité de Bennett nous fournit des bornes améliorées sur les queues pour la variable aléatoire binomiale de paramètres n et μ/n . Cette variable binomiale a la même loi que la somme de n variables de Bernoulli indépendantes de paramètre μ/n . Cela entre dans le cadre de l'inégalité de Bennett : on peut choisir $b = 1$ et $v = \mu$. La borne obtenue sur la fonction génératrice des moments logarithmique coïncide avec celle d'une variable de Poisson centrée de paramètre μ , voir Théorème 12.3).

Preuve. La preuve combine la technique de Cramér-Chernoff avec une borne *ad hoc* sur $\log \mathbb{E}e^{\lambda(X_i - \mathbb{E}X_i)}$.

Par homogénéité, on peut supposer $b = 1$.

Notons que $\phi(\lambda)/\lambda^2$ est non décroissante sur $\mathbb{R}$. Pour $x \leq 1$, $\lambda \geq 0$, $\phi(\lambda x) \leq x^2 \phi(\lambda)$.

$$\begin{aligned} \log \mathbb{E}e^{\lambda(X_i - \mathbb{E}X_i)} &= \log \mathbb{E}e^{\lambda X_i - \lambda \mathbb{E}X_i} \\ &\leq \mathbb{E}e^{\lambda X_i} - 1 - \lambda \mathbb{E}X_i \\ &= \mathbb{E}\phi(\lambda X_i) \\ &= \mathbb{E}X_i^2 \phi(\lambda). \end{aligned}$$

□

Alors que la borne de Bennett convient bien aux variables de type Poisson, notre dernière borne est adaptée aux variables de type Gamma. C'est l'un des piliers de la théorie de l'apprentissage statistique.

Théorème 14.9 (Inégalité de Bernstein). Soient $X_1, \dots, X_n$ des variables aléatoires indépendantes à valeurs réelles. Supposons qu'il existe des nombres positifs v et c tels que $\sum_{i=1}^n \mathbb{E}[X_i^2] \leq v$ et

$$\sum_{i=1}^n \mathbb{E}[(X_i)_+^q] \leq \frac{q!}{2} v c^{q-2} \quad \text{for all integers } q \geq 3.$$

Posons $S = \sum_{i=1}^n (X_i - \mathbb{E}X_i)$.

Alors, pour tout $\lambda \in (0, 1/c)$,

$$\log \mathbb{E} e^{\lambda(S - \mathbb{E}S)} \leq \frac{v\lambda^2}{2(1 - c\lambda)}.$$

Pour $t > 0$,

$$P\{S > t\} \leq \exp\left(-\frac{v}{c^2} h_1\left(\frac{ct}{v}\right)\right)$$

avec $h_1(x) = 1 + x - \sqrt{1 + 2x}$.

Preuve. La preuve combine encore la technique de Cramér-Chernoff avec une borne *ad hoc* sur $\log \mathbb{E} e^{\lambda(S - \mathbb{E}S)}$.

Posons à nouveau $\phi(u) = e^u - u - 1$ pour $u \in \mathbb{R}$.

Pour $\lambda > 0$,

$$\begin{aligned} \phi(\lambda X_i) &= \sum_{k=2}^{\infty} \frac{\lambda^k X_i^k}{k!} \\ &\leq \frac{\lambda^2 X_i^2}{2!} + \sum_{k=3}^{\infty} \frac{\lambda^k (X_i)_+^k}{k!}. \end{aligned}$$

Pour $c > \lambda > 0$,

$$\begin{aligned} \log \mathbb{E} e^{\lambda S} &= \sum_{i=1}^n \log \mathbb{E} e^{\lambda(X_i - \mathbb{E}X_i)} \\ &\leq \sum_{i=1}^n \mathbb{E} \phi(\lambda X_i) \\ &\leq \frac{\lambda^2 \sum_{i=1}^n \mathbb{E} X_i^2}{2!} + \sum_{k=3}^{\infty} \frac{\lambda^k \sum_{i=1}^n \mathbb{E} (X_i)_+^k}{k!} \\ &\leq \frac{\lambda^2 v}{2} + \sum_{k=3}^{\infty} \frac{\lambda^k v c^{k-2}}{2} \\ &= \frac{\lambda^2 v}{2(1 - c\lambda)}. \end{aligned}$$

La borne sur la queue découle en maximisant

$$\sup_{\lambda \in [0, 1/c)} \lambda t - \frac{\lambda^2 v}{2(1 - c\lambda)} = \frac{v}{c^2} \sup_{\eta \in [0, 1)} \eta \frac{ct}{v} - \frac{\eta^2}{2(1 - \eta)}.$$

□

14.8 Remarques bibliographiques

(Dudley, 2002) contient une discussion approfondie des différents types de convergences que l'on peut définir pour les variables aléatoires. En particulier, (Dudley, 2002) offre une perspective générale sur les questions topologiques dans les espaces de probabilité. (Dudley,

[2002](#)) aborde aussi le problème posé par les variables aléatoires à valeurs dans des espaces métriques (éventuellement de dimension infinie).

Les lois des grands nombres et les lois 0-1 s'inscrivent dans le cadre plus général des théorèmes ergodiques, voir ([Dudley, 2002](#)) ou ([Durrett, 2010](#)). Un exemple important de loi des grands nombres est la propriété d'équipartition asymptotique (PEA) en théorie de l'information. Notons qu'elle vaut pour une classe de sources bien plus large que l'ensemble des sources sans mémoire (espaces produits de probabilité infinis). Voir ([Cover & Thomas, 1991](#)) ou [[csiszar:korner:1981](#)].

Une introduction aux inégalités exponentielles et à leurs applications se trouve dans ([Massart, 2007](#)), ([Boucheron et al., 2013](#)).

Chapitre 15

Convergence en loi

15.1 Motivation

Rappelons [Leçon 1](#). Considérons des lois binomiales de paramètres $(n, \lambda/n)$ et une loi de Poisson de paramètre λ . L'inspection graphique des fonctions de masse suggère que, lorsque n croît, les lois binomiales de paramètres $(n, \lambda/n)$ ressemblent de plus en plus à la loi de Poisson de paramètre λ . La comparaison des fonctions génératrices des probabilités est plus convaincante. La fonction génératrice des probabilités de la loi binomiale de paramètres $(n, \lambda/n)$ est $s \mapsto (1 + \lambda(s-1)/n)^n$. Lorsque n tend vers l'infini, les fonctions génératrices des probabilités des binomiales convergent ponctuellement vers la fonction génératrice des probabilités de la loi de Poisson de moyenne λ : $s \mapsto \exp(\lambda(s-1))$. Dans [Leçon 1](#), nous avons vu d'autres exemples de lois qui tendent à ressembler à certaines lois limites lorsque certains paramètres varient.

Dans [Leçon 14](#), nous avons muni l'ensemble $L_0(\Omega, \mathcal{F}, P)$ de topologies (L_p , convergence presque sûre, convergence en probabilité). Dans cette leçon, nous considérons l'ensemble des lois de probabilité sur un espace mesurable $(\Omega, \mathcal{F})$. Cet ensemble peut être muni de diverses topologies. Nous nous concentrerons sur la topologie définie par la *convergence en loi*, également appelée *convergence faible*.

Dans [Section 15.2](#), nous introduisons les convergences faible et vague pour des suites de lois de probabilité. Dans [Section 15.3](#), la convergence faible induit la définition de la convergence en loi pour des variables aléatoires pouvant vivre sur des espaces de probabilité différents (comme nos scores d'occupation dans [Leçon 1](#)).

[Section 15.4](#) est consacrée au théorème de Portmanteau. Ce théorème énumère plusieurs caractérisations alternatives et équivalentes de la convergence en loi. Des caractérisations alternatives sont utiles à deux titres : elles peuvent être plus faciles à vérifier que la caractérisation utilisée dans la définition ; elles peuvent offrir un champ d'applications plus large.

Dans [Section 15.5](#), nous énonçons et démontrons le théorème de continuité de Lévy. Le théorème de continuité de Lévy relie la convergence en loi à la convergence ponctuelle des fonctions caractéristiques : les fonctions caractéristiques nous permettent non seulement d'identifier les lois de probabilité, elles sont aussi déterminantes pour la convergence. Cela pourrait constituer une ligne de plus dans l'énoncé du [Théorème 15.1](#). Mais le théorème

de continuité de Lévy se distingue car il fournit une preuve concise du théorème central limite pour des sommes normalisées de variables aléatoires i.i.d. centrées. C'est le contenu de Section 15.8).

15.2 Convergence faible, convergence vague

La convergence faible de mesures de probabilité évalue la proximité de mesures de probabilité en comparant leur action sur une collection de fonctions tests.

Définition 15.1 (Convergence faible). Une suite de lois de probabilité $(P_n)_{n \in \mathbb{N}}$ sur $\mathbb{R}^k$ converge *faiblement* vers la loi de probabilité P (sur $\mathbb{R}^k$) si et seulement si pour toute fonction f bornée et continue de $\mathbb{R}^k$ vers $\mathbb{R}$, la suite $(\mathbb{E}_{P_n}[f])_{n \in \mathbb{N}}$ converge vers $\mathbb{E}_P[f]$.

Remarque 15.1. Nous verrons qu'il existe une certaine flexibilité dans le choix de la classe de fonctions tests.

Mais ce choix n'est pas illimité.

Si nous restreignons la collection de fonctions tests aux fonctions continues à *support compact* (qui sont toujours bornées), nous obtenons une notion de convergence différente.

Définition 15.2 (Convergence vague). Une suite de lois de probabilité $(P_n)_{n \in \mathbb{N}}$ sur $\mathbb{R}^k$ converge *vaguement* vers la mesure μ (sur $\mathbb{R}^k$) si et seulement si pour toute fonction f continue à support compact de $\mathbb{R}^k$ vers $\mathbb{R}$, la suite $(\mathbb{E}_{P_n}[f])_{n \in \mathbb{N}}$ converge vers $\mathbb{E}_\mu[f]$.

Exemple 15.1. Considérons la suite de masses de probabilité sur les entiers $(\delta_n)_{n \in \mathbb{N}}$. Cette suite converge vaguement vers la mesure nulle. Elle ne converge pas faiblement.

La question suivante mérite réflexion.

Exercice 15.1. Si une suite de lois de probabilité sur $\mathbb{R}^k$ converge vaguement vers une mesure de probabilité, converge-t-elle aussi faiblement vers cette mesure de probabilité ?

15.3 Convergence en loi

Définition 15.3 (Convergence en loi). Une suite $(X_n)_{n \in \mathbb{N}}$ de variables aléatoires à valeurs dans $\mathbb{R}^k$, définies sur une suite d'espaces de probabilité $(\Omega_n, \mathcal{F}_n, P_n)$, converge en loi si la suite $(P_n \circ X_n^{-1})_{n \in \mathbb{N}}$ converge faiblement. On note

$$X_n \rightsquigarrow X \quad \text{ou} \quad X_n \rightsquigarrow \mathcal{L}$$

($\mathcal{L}$ désigne une loi de probabilité), les espaces de probabilité sont définis implicitement

Pour vérifier ou utiliser la convergence en loi, de nombreuses caractérisations équivalentes sont disponibles. Certaines d'entre elles sont énumérées dans le théorème de Portmanteau.

15.4 Théorème de Portmanteau

La liste suivante de caractérisations équivalentes de la convergence faible n'est pas exhaustive.

Théorème 15.1 (Théorème de Portmanteau). *Une suite de lois de probabilité $(P_n)_{n \in \mathbb{N}}$ sur $\mathbb{R}^k$ converge faiblement vers une loi de probabilité P (sur $\mathbb{R}^k$) si et seulement si l'une des propriétés équivalentes suivantes est satisfaite :*

1. *Pour toute fonction f bornée continue de $\mathbb{R}^k$ vers $\mathbb{R}$, la suite $\mathbb{E}_{P_n}[f]$ converge vers $\mathbb{E}_P[f]$.*
2. *Pour toute fonction f bornée uniformément continue de $\mathbb{R}^k$ vers $\mathbb{R}$, la suite $\mathbb{E}_{P_n}[f]$ converge vers $\mathbb{E}_P[f]$.*
3. *Pour toute fonction f bornée lipschitzienne de $\mathbb{R}^k$ vers $\mathbb{R}$, la suite $\mathbb{E}_{P_n}[f]$ converge vers $\mathbb{E}_P[f]$.*
4. *Pour toute fonction f bornée P -presque sûrement et continue de $\mathbb{R}^k$ vers $\mathbb{R}$, la suite $(\mathbb{E}_{P_n}[f])$ converge vers $\mathbb{E}_P[f]$.*
5. *Pour tout fermé F de $\mathbb{R}^k$, $\limsup P_n(F) \leq P(F)$.*
6. *Pour tout ouvert O de $\mathbb{R}^k$, $\liminf P_n(O) \geq P(O)$.*
7. *Pour tout borélien A tel que $P(A^\circ) = P(\bar{A})$ (la frontière de A est P -négligeable), $\lim_n P_n(A) = P(A)$.*

En anglais comme en français, un *portemanteau* est une valise.

Preuve. Les implications $1) \Rightarrow 2) \Rightarrow 3)$ sont évidentes. Le théorème de continuité de Lévy, résultat majeur de Section 15.5) entraîne que $3) \Rightarrow 1)$.

4).

Le fait que $5) \Leftrightarrow 6)$ découle du fait que le complémentaire d'un fermé est un ouvert.

5) et 6) impliquent 7) :

$$\limsup_n P_n(\bar{A}) \leq P(\bar{A}) = P(A^\circ) \leq \liminf_n P_n(A^\circ).$$

Par monotonie :

$$\liminf_n P_n(A^\circ) \leq \liminf_n P_n(A) \leq \limsup_n P_n(A) \leq \limsup_n P_n(\bar{A}).$$

En combinant, on obtient

$$\lim_n P_n(A) = \liminf_n P_n(A) = \limsup_n P_n(A) = P(A^\circ) = P(\bar{A}).$$

Vérifions que 3) $\Rightarrow$ 5). Soit F un fermé de $\mathbb{R}^k$. Pour $x \in \mathbb{R}^k$, notons $d(x, F)$ la distance de x à F . Pour $m \in \mathbb{N}$, posons $f_m(x) = (1 - md(x, F))_+$. La fonction f_m est m -lipschitzienne, minorée par $\mathbb{I}_F$, et pour tout $x \in \mathbb{R}^k$, $\lim_m \downarrow f_m(x) = \mathbb{I}_F(x)$.

La convergence faible de P_n vers P implique

$$\lim_n \mathbb{E}_{P_n} f_m = \mathbb{E}_P f_m$$

d'où, pour tout $m \in \mathbb{N}$,

$$\limsup_n \mathbb{E}_{P_n} \mathbb{I}_F \leq \mathbb{E}_P f_m.$$

En prenant la limite du côté droit, on obtient

$$\limsup_n P_n(F) = \limsup_n \mathbb{E}_{P_n} \mathbb{I}_F \leq \lim_m \downarrow \mathbb{E}_P f_m = \mathbb{E}_P \mathbb{I}_F = P(F).$$

Supposons maintenant que 7) soit vérifiée. Montrons que cela entraîne 1).

Soit f une fonction bornée continue. Sans perte de généralité, supposons que f est non négative et majorée par 1. Rappelons que pour toute mesure μ σ -finie

$$\int f d\mu = \int_{[0, \infty)} \mu\{f > t\} dt.$$

Cela vaut pour toutes les P_n et P . Ainsi

$$\mathbb{E}_{P_n} f = \int_{[0, \infty)} P_n\{f > t\} dt$$

Comme $\overline{\{f > t\}} = \{f \geq t\}$, $\overline{\{f > t\} \setminus \{f > t\}^\circ} = \{f = t\}$. L'ensemble des valeurs t telles que $P\{f = t\} > 0$ est au plus dénombrable et donc de mesure de Lebesgue négligeable. Soit E son complémentaire. Pour $t \in E$, $\lim_n P_n\{f > t\} = P\{f > t\}$.

$$\begin{aligned} \lim_n \mathbb{E}_{P_n} f &= \lim_n \int_{[0, 1]} P_n\{f > t\} dt \\ &= \lim_n \int_{[0, 1]} P_n\{f > t\} \mathbb{I}_E(t) dt \\ &= \int_{[0, 1]} \lim_n P_n\{f > t\} \mathbb{I}_E(t) dt \\ &= \int_{[0, 1]} P\{f > t\} \mathbb{I}_E(t) dt \\ &= \int_{[0, 1]} P\{f > t\} dt \\ &= \mathbb{E}_P f. \end{aligned}$$

□

Pour des mesures de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, la convergence faible est déterminée par les fonctions de répartition cumulatives. C'est parfois pris comme définition de la convergence faible dans les ouvrages élémentaires.

Corollaire 15.1. *Une suite de mesures de probabilité définies par leurs fonctions de répartition cumulatives $(F_n)_n$ converge faiblement vers une mesure de probabilité définie par la fonction de répartition cumulative F si et seulement si $\lim_n F_n(x) = F(x)$ en tout point x de continuité de F .*

Pour des mesures de probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, la convergence faible est également déterminée par les fonctions quantiles.

Proposition 15.1. *Une suite de mesures de probabilité définies par leurs fonctions quantiles $(F_n^{\leftarrow})_n$ converge faiblement vers une mesure de probabilité définie par la fonction quantile $F^{\leftarrow}$ si et seulement si $\lim_n F_n^{\leftarrow}(x) = F^{\leftarrow}(x)$ en tout point x de continuité de $F^{\leftarrow}$.*

Démontrer la proposition Proposition 15.1.

Proposition 15.2 (Représentation presque sûre). *Si $(X_n)_n$ converge en loi vers X , alors il existe un espace de probabilité $(\Omega, \mathcal{F}, P)$ avec des variables aléatoires $(Y_n)_n$ et Y telles que $X_n \sim Y_n$ pour tout n , $X \sim Y$, et*

$$Y_n \rightarrow Y \quad P\text{-p.s.}$$

Remarque 15.2. Les variables aléatoires $(X_n)_n$ et X peuvent vivre sur des espaces de probabilité différents.

Lorsque les variables aléatoires X_n sont réelles, Proposition 15.2 découle facilement de la proposition Proposition 15.1.

Preuve. Posons $\Omega = [0, 1]$, $\mathcal{F} = \mathcal{B}(\mathbb{R})$ et soit ω uniformément distribué sur $\Omega = [0, 1]$. Posons $Y_n = F_n^{\leftarrow}(\omega)$ et $Y = F^{\leftarrow}(\omega)$.

Alors, pour chaque n ,

$$P\{Y_n \leq t\} = P\{\omega : F_n^{\leftarrow}(\omega) \leq t\} = P\{\omega : \omega \leq F_n(t)\} = F_n(t)$$

de sorte que $Y_n \sim F_n$. Et par le même argument, $Y \sim F$.

Comme une fonction non décroissante admet au plus dénombrablement de discontinuités,

$$P\{\omega : F^{\leftarrow} \text{ est continue en } \omega\} = 1.$$

Supposons maintenant que ω soit un point de continuité de $F^{\leftarrow}$. Alors, par la proposition Proposition 15.1, $\lim_n F_n^{\leftarrow}(\omega) = F^{\leftarrow}(\omega)$. Cela se traduit par

$$P\{\omega : \lim_n Y_n(\omega) = Y(\omega)\} = 1.$$

□

15.5 Théorème de continuité de Lévy

Théorème 15.2 (Théorème de continuité de Lévy). *Une suite $(P_n)_n$ de lois de probabilité sur $\mathbb{R}^d$ converge faiblement vers une loi de probabilité P sur $\mathbb{R}^d$ si et seulement si la suite des fonctions caractéristiques converge ponctuellement vers la fonction caractéristique de P .*

Remarque 15.3. Le Théorème 15.2 affirme que la convergence faible de mesures de probabilité est caractérisée par un très petit sous-ensemble de fonctions bornées continues. Pour garantir la convergence faible de $(P_n)_n$ vers P , il suffit de vérifier que $\mathbb{E}_{P_n} f \rightarrow \mathbb{E}_P f$ pour les fonctions f de la famille $\{\cos(t \cdot), \sin(t \cdot) : t \in \mathbb{R}\}$. Ces fonctions sont bornées et infiniment dérivables.

Soient $(X_n)_n$, X et Z définies sur le même espace de probabilité. Si $(X_n)_n$, X et Z sont des variables aléatoires telles que pour tout $\sigma > 0$, $X_n + \sigma Z \rightsquigarrow X + \sigma Z$, alors $X_n \rightsquigarrow X$.

Preuve. Soit h bornée par 1 et 1-lipschitzienne

$$\begin{aligned} \left| \mathbb{E}h(X_n) - h(X) \right| &\leq \left| \mathbb{E}h(X_n) - h(X_n + \sigma Z) \right| \\ &\quad + \left| \mathbb{E}h(X_n + \sigma Z) - h(X + \sigma Z) \right| \\ &\quad + \left| \mathbb{E}h(X + \sigma Z) - h(X) \right| \end{aligned}$$

Le premier et le troisième terme se traitent de la même manière.

Soit $\epsilon > 0$,

$$\begin{aligned} \left| \mathbb{E}h(X_n) - h(X_n + \sigma Z) \right| &\leq \left| \mathbb{E}(h(X_n) - h(X_n + \sigma Z)) \mathbb{1}_{\sigma|Z| > \epsilon} \right| \\ &\quad + \left| \mathbb{E}(h(X_n) - h(X_n + \sigma Z)) \mathbb{1}_{\sigma|Z| \leq \epsilon} \right| \\ &\leq 2P\{\sigma|Z| > \epsilon\} + \epsilon. \end{aligned}$$

En combinant les différentes majorations, on obtient

$$\left| \mathbb{E}h(X_n) - h(X) \right| \leq 2P\{\sigma|Z| > \epsilon\} + \epsilon + \left| \mathbb{E}h(X_n + \sigma Z) - h(X + \sigma Z) \right|$$

Le dernier terme du membre de droite tend vers 0 lorsque n tend vers l'infini. Le premier terme tend vers 0 lorsque σ tend vers 0.

Ainsi

$$\limsup_n \left| \mathbb{E}h(X_n) - h(X_n + \sigma Z) \right| \leq \epsilon.$$

□

Lemme 15.1 (Lemme de Scheffé). *Soit $(P_n)_n$ une suite de lois de probabilité absolument continues de densités $(f_n)_n$. Si les densités $(f_n)_n$ convergent ponctuellement vers*

la densité f d'une certaine loi de probabilité P , alors $P_n \rightsquigarrow P$.

Preuve.

$$\begin{aligned} \int_{\mathbb{R}} |f_n(x) - f(x)| dx &= \int_{\mathbb{R}} (f(x) - f_n(x))_+ dx + \int_{\mathbb{R}} (f(x) - f_n(x))_- dx \\ &= 2 \int_{\mathbb{R}} (f(x) - f_n(x))_+ dx. \end{aligned}$$

Observons que $(f - f_n)_+ \leq f$, qui appartient à $\mathcal{L}_1(\mathbb{R}, \mathcal{B}(\mathbb{R}), \text{Lebesgue})$. Et $(f - f_n)_+$ converge ponctuellement vers 0. Par le théorème de convergence dominée, $\lim_n \int_{\mathbb{R}} |f_n - f| dx = 0$.

Pour tout $A \in \mathcal{B}(\mathbb{R})$,

$$P_n(A) - P(A) = \int_{\mathbb{R}} \mathbb{I}_A(f_n - f) \leq \int_{\mathbb{R}} |f_n - f|.$$

Nous avons prouvé plus que la convergence faible, à savoir

$$\lim_n \sup_{A \in \mathcal{B}(\mathbb{R})} |P_n(A) - P(A)| = 0.$$

□

Preuve du théorème de continuité. Supposons que les fonctions caractéristiques de $(X_n)_n$ convergent ponctuellement vers la fonction caractéristique de X .

Soit Z une variable aléatoire gaussienne standard, indépendante de toutes les $(X_n)_n$ et de X . Pour $\sigma > 0$, les lois de $X_n + \sigma Z$ et $X + \sigma Z$ ont des densités uniquement déterminées par les fonctions caractéristiques de X_n et X . De plus, un argument de convergence dominée montre que les densités de $X_n + \sigma Z$ convergent ponctuellement vers la densité de $X + \sigma Z$. Par le lemme de Scheffé, cela entraîne que $X_n + \sigma Z \rightsquigarrow X + \sigma Z$.

Comme cela vaut pour tout $\sigma > 0$, cela entraîne que $X_n \rightsquigarrow X$.

□

15.6 Affiner le théorème de continuité

Dans certaines situations, nous pouvons prouver qu'une suite de fonctions caractéristiques converge ponctuellement vers une certaine fonction, mais nous n'avons aucun candidat pour la loi limite. La question se pose de savoir si la limite ponctuelle des fonctions caractéristiques est la fonction caractéristique d'une certaine loi de probabilité ou autre chose.

La réponse peut être négative : si $P_n = \mathcal{N}(0, n)$, la suite de fonctions caractéristiques est $(t \mapsto \exp(-nt^2/2))_n$, qui converge ponctuellement vers 0 sauf en 0 où elle vaut 1 tout au long. La limite n'est pas la fonction caractéristique d'une mesure de probabilité : elle n'est pas continue en 0.

Le théorème suivant tranche la question.

Théorème 15.3 (Théorème de continuité de Lévy, deuxième forme). *Une suite $(P_n)_n$ de lois de probabilité sur $\mathbb{R}$ converge faiblement vers une loi de probabilité sur $\mathbb{R}$ si et seulement si la suite de fonctions caractéristiques converge ponctuellement vers une fonction continue en 0. La fonction limite est la fonction caractéristique d'une certaine loi de probabilité.*

Définition 15.4 (Compacité uniforme). Une suite de mesures de probabilité $(P_n)_n$ sur $\mathbb{R}$ est *uniformément tendue* si pour tout $\epsilon > 0$, il existe un compact $K \subseteq \mathbb{R}$ tel que

$$\forall n, \quad P_n(K) \geq 1 - \epsilon.$$

Exercice 15.2. Pour établir la compacité uniforme de $(P_n)_n$, il suffit de montrer que pour tout $\epsilon > 0$, il existe un certain $n_0(\epsilon)$ et un compact $K \subseteq \mathbb{R}$ tels que

$$\forall n \geq n_0(\epsilon), \quad P_n(K) \geq 1 - \epsilon.$$

Nous admettons le théorème (important) suivant.

Théorème 15.4 (Prokhorov-Le Cam). *Si $(P_n)_n$ est une suite uniformément tendue de mesures de probabilité sur $\mathbb{R}$, alors il existe une mesure de probabilité P et une sous-suite $(P_{n(k)})_{k \in \mathbb{N}}$ telle que*

$$P_{n(k)} \rightsquigarrow P.$$

Puis

Lemme 15.2 (Lemme de compacité uniforme). *Soit $(P_n)_n$ une suite de lois de probabilité sur $\mathbb{R}$, de fonctions caractéristiques $\hat{F}_n$. Si la suite $(\hat{F}_n)_n$ converge ponctuellement vers une fonction continue en 0, alors la suite $(P_n)_n$ est uniformément tendue.*

Nous utiliserons la majoration technique suivante, illustrée dans Figure 15.1 :

$$\forall t \in \mathbb{R} \setminus [-1, 1], \quad \frac{\sin(t)}{t} \leq \sin(1) \leq \frac{6}{7}.$$

Proposition 15.3 (Lemme de troncature). *Soit $\hat{F}$ la fonction caractéristique d'une mesure de probabilité P sur la droite réelle, alors pour tout $u > 0$:*

$$\frac{1}{u} \int_0^u (1 - \operatorname{Re} \hat{F}(v)) dv \geq \frac{1}{7} P\left[\frac{-1}{u}, \frac{1}{u}\right]^c.$$




FIGURE 15.1 : The proof of the truncation inequality takes advantage on easy bounds satisfied by the sinc function.

Preuve du lemme de troncature.

$$\begin{aligned}
 \frac{1}{u} \int_0^u (1 - \operatorname{Re} \hat{F}_n(v)) dv &= \frac{1}{u} \int_0^u \left(\int_{\mathbb{R}} (1 - \cos(vw)) dF(w) \right) dv \\
 &= \int_{\mathbb{R}} \int_0^u \frac{1}{u} (1 - \cos(vw)) dv dF(w) \\
 &= \int_{\mathbb{R}} \left(1 - \frac{\sin(uw)}{uw} \right) dF(w) \\
 &\geq \int_{|uw| \geq 1} \left(1 - \frac{\sin(uw)}{uw} \right) dF_n(w) \\
 &\geq (1 - \sin(1)) P \left[\frac{-1}{u}, \frac{1}{u} \right]^c
 \end{aligned}$$

où les deux inégalités découlent des bornes sur la fonction sinc. $\square$

Preuve du lemme de compacité uniforme. Supposons que la suite $(\hat{F}_n)_n$ converge ponctuellement vers une fonction $\hat{F}$ continue en 0.

Notons que $\hat{F}_n(0) = 1$ pour tout n , d'où, trivialement, $1 = \lim_n \hat{F}_n(0) = \hat{F}(0)$.

Comme $|\operatorname{Re} \hat{F}_n(t)| \leq 1$, on a aussi $|\operatorname{Re} \hat{F}(t)| \leq 1$.

Fixons $\epsilon > 0$. Comme $\hat{F}$ est continue en 0, pour un certain $u > 0$, pour tout $v \in [-u, u]$, $0 \geq 1 - \hat{F}(v) \leq \epsilon/2$. Ainsi,

$$0 \leq \frac{1}{u} \int_0^u (1 - \operatorname{Re} \hat{F}(v)) dv \leq \epsilon/2.$$

Par convergence dominée,

$$\lim_n \frac{1}{u} \int_0^u (1 - \operatorname{Re} \hat{F}_n(v)) dv = \frac{1}{u} \int_0^u (1 - \operatorname{Re} \hat{F}(v)) dv \leq \epsilon/2.$$

Pour n suffisamment grand, $0 \leq \frac{1}{u} \int_0^u (1 - \operatorname{Re} \hat{F}_n(v)) dv \leq \epsilon$.

En appliquant le lemme de troncature, pour n suffisamment grand, nous avons

$$P_n \left[\frac{-1}{u}, \frac{1}{u} \right]^c \leq 7\epsilon.$$

L'intervalle $\left[\frac{-1}{u}, \frac{1}{u} \right]$ est compact. □

Preuve de la deuxième forme du théorème de continuité. Nous combinons le lemme de compacité uniforme et le théorème de Prokhorov-Le Cam. Sous les hypothèses de la deuxième forme du théorème de continuité, il existe une mesure de probabilité P (de fonction caractéristique $\hat{F}$) et une sous-suite $(P_{n(k)})_{k \in \mathbb{N}}$ telle que $P_{n(k)} \rightsquigarrow P$ lorsque $k \rightarrow \infty$. Cela entraîne $\hat{F}_{n(k)} \rightarrow \hat{F}$ lorsque $k \rightarrow \infty$ ponctuellement. Cela entraîne aussi que $\hat{F}_n \rightarrow \hat{F}$ ponctuellement pour toute la suite. Enfin, nous pouvons invoquer le Théorème 15.2) pour conclure $P_n \rightsquigarrow P$ lorsque $n \rightarrow \infty$. □

Remarque 15.4. Toutes les définitions et résultats de cette section peuvent être étendus au cadre k -dimensionnel pour tout $k \in \mathbb{N}$.

15.7 Relations entre convergences

Les caractérisations alternatives de la convergence faible fournies par le théorème de Portmanteau (Théorème 15.1) facilitent la preuve de la proposition suivante.

La convergence en probabilité implique la convergence en loi.

Preuve. Supposons que $(X_n)_n$ converge en probabilité vers X .

Soit h une fonction bornée lipschitzienne. Sans perte de généralité, supposons que $|f(x)| \leq 1$ pour tout x et $|f(x) - f(y)| \leq d(x, y)$.

Soit $\epsilon > 0$.

$$\begin{aligned} \left| \mathbb{E}h(X_n) - \mathbb{E}h(X) \right| &= \left| \mathbb{E} \left[(h(X_n) - h(X)) \mathbb{1}_{d(X, X_n) > \epsilon} \right] \right. \\ &\quad \left. + \mathbb{E} \left[(h(X_n) - h(X)) \mathbb{1}_{d(X, X_n) \leq \epsilon} \right] \right| \\ &\leq \mathbb{E} \left[2 \mathbb{1}_{d(X, X_n) > \epsilon} \right] \\ &\quad + \mathbb{E} \left[|h(X_n) - h(X)| \mathbb{1}_{d(X, X_n) \leq \epsilon} \right] \\ &\leq 2P\{d(X, X_n) > \epsilon\} + \epsilon. \end{aligned}$$

La convergence en probabilité entraîne que

$$\limsup_n \left| \mathbb{E}h(X_n) - \mathbb{E}h(X) \right| \leq \epsilon.$$

Comme cela vaut pour tout $\epsilon > 0$, pour toute fonction bornée lipschitzienne h , $\lim_n \left| \mathbb{E}h(X_n) - \mathbb{E}h(X) \right| = 0$. Cela suffit à établir la convergence en loi de $(X_n)_n$. □

15.8 Théorème central limite

Le théorème de continuité de Lévy (Théorème 15.2) est la pierre angulaire d'une preuve très concise de la version la plus simple du théorème central limite (TCL). Sous l'hypothèse d'intégrabilité au carré, le TCL affine les lois des grands nombres. Il affirme que, lorsque n tend vers l'infini, les fluctuations de la moyenne empirique $\sum_{i=1}^n X_i/n$ autour de son espérance sont d'ordre $1/\sqrt{n}$ et, une fois renormalisées, suivent une loi normale.

Théorème 15.5. Soient $X_1, \dots, X_n, \dots$ i.i.d. de variance finie σ^2 et d'espérance μ . Posons $S_n = \sum_{i=1}^n X_i$.

$$\sqrt{n} \left(\frac{S_n}{n} - \mu \right) \rightsquigarrow \mathcal{N}(0, \sigma^2).$$

Preuve. Notons $\hat{F}$ la fonction caractéristique de la loi (commune) des variables aléatoires $((X_i - \mu)/\sigma)_i$. Rappelons de Leçon 12, que les hypothèses de centrage et d'intégrabilité au carré impliquent que

$$\hat{F}(t) = \hat{F}(0) + \hat{F}'(0)t + \frac{\hat{F}''(0)}{2}t^2 + t^2 R(t) = 1 - \frac{t^2}{2} + t^2 R(t)$$

où $\lim_{t \rightarrow 0} R(t) = 0$. Notons $\hat{F}_n$ la fonction caractéristique de $\sqrt{n} \left(\frac{S_n}{n} - \mu \right) / \sigma$. Fixons $t \in \mathbb{R}$,

$$\hat{F}_n(t) = \left(\hat{F}(t/\sqrt{n}) \right)^n = \left(1 - \frac{t^2}{2n} + \frac{t^2}{n} R(t/\sqrt{n}) \right)^n.$$

Lorsque $n \rightarrow \infty$,

$$\lim_n \left(1 - \frac{t^2}{2n} + \frac{t^2}{n} R(t/\sqrt{n}) \right)^n = e^{-\frac{t^2}{2}}.$$

Au membre de droite, nous reconnaissons la fonction caractéristique de $\mathcal{N}(0, 1)$. $\square$

Remarque 15.5. Les conditions de l'énoncé du théorème permettent une preuve courte. Elles ne sont nullement nécessaires. Les termes de la somme n'ont pas besoin d'être identiquement distribués. Les termes de la somme n'ont pas besoin d'être indépendants. Une version du théorème de Lindeberg-Feller affirme que, sous des hypothèses légères, des sommes centrées et normalisées de variables aléatoires indépendantes intégrables au carré convergent en loi vers une loi gaussienne.

15.9 Dispositif de Cramér-Wold

Jusqu'ici, nous avons discuté des fonctions caractéristiques pour des variables aléatoires réelles. Mais les fonctions caractéristiques peuvent être définies pour des variables aléatoires vectorielles. Si X est une variable aléatoire à valeurs dans $\mathbb{R}^k$, sa fonction caractéristique applique $\mathbb{R}^k$ dans $\mathbb{C}$:

$$\begin{aligned} \mathbb{R}^k &\rightarrow \mathbb{C} \\ t &\mapsto \mathbb{E} e^{i\langle t, X \rangle}. \end{aligned}$$

L'importance des fonctions caractéristiques multivariées se reflète dans le dispositif suivant, dont la preuve est laissée au lecteur. Il consiste à adapter la preuve du Théorème 12.4).

Théorème 15.6 (Cramér-Wold). *La loi d'un vecteur aléatoire à valeurs dans $\mathbb{R}^k$, $X = (X_1, \dots, X_k)^T$, est entièrement déterminée par la collection des lois des variables aléatoires univariées $\langle t, X \rangle = \sum_{i=1}^n t_i X_i$ où $(t_1, \dots, t_n)^T$ appartient à $\mathbb{R}^n$.*

Le Théorème 15.6) fournit un chemin court vers le théorème central limite multivarié.

Théorème 15.7. *Soient $X_1, \dots, X_n, \dots$ des variables aléatoires vectorielles i.i.d. de covariance finie Γ et d'espérance μ . Posons $S_n = \sum_{i=1}^n X_i$.*

$$\sqrt{n} \left(\frac{S_n}{n} - \mu \right) \rightsquigarrow \mathcal{N}(0, \Gamma) .s$$

15.10 Convergence faible et transformations

Dans Lesson Chapitre 12, nous avons introduit différentes caractérisations des lois de probabilité : fonctions génératrices des probabilités, transformées de Laplace, transformées de Fourier (fonctions caractéristiques), fonctions de répartition cumulatives, fonctions quantiles. Dans leur domaine de validité, toutes ces transformations sont *déterminantes pour la convergence* : si une suite de lois de probabilité converge faiblement, il en est de même (ponctuellement) de la suite correspondante de transformations, au moins aux points de continuité de la transformation limite.

Dans les deux théorèmes suivants, chaque variable aléatoire est supposée vivre sur un espace de probabilité (implicite).

Une suite de variables aléatoires *non négatives* $(X_n)_n$ converge en loi vers la variable aléatoire *non négative* X si et seulement si la suite des transformées de Laplace converge ponctuellement vers la transformée de Laplace de la loi de X .

La preuve suit la dérivation du Théorème 15.2).

Comme les fonctions génératrices des probabilités permettent de retrouver les transformées de Laplace, le théorème suivant est un cas particulier de l'énoncé concernant les transformées de Laplace.

Une suite de variables aléatoires à valeurs entières $(X_n)_n$ converge en loi vers la variable aléatoire à valeurs entières X si et seulement si la suite des transformées de Laplace converge ponctuellement vers la transformée de Laplace de la loi de X .

15.11 Remarques bibliographiques

Dudley (2002) traite de la convergence en loi en deux chapitres : le premier est consacré aux lois sur $\mathbb{R}^d$ et au théorème central limite; le second aborde des univers plus généraux. Dans le premier chapitre, le théorème central limite est étendu aux tableaux triangulaires,

c'est-à-dire aux suites de variables aléatoires pas nécessairement identiquement distribuées (théorème de Lindeberg).

Dudley (2002) étudie la convergence en loi comme *convergence de lois sur des espaces métriques séparables*, c'est-à-dire dans un cadre beaucoup plus large que celui de ces notes. Le lecteur y trouvera une preuve complète du théorème de Prokhorov-Le Cam et une discussion approfondie de ses corollaires. Dans (Dudley, 2002), une grande partie de l'effort est consacrée à la métrisation de la topologie de convergence faible. Le lecteur y trouvera aussi un panorama complet des arguments de représentation presque sûre.

La preuve du théorème de continuité de Lévy donnée ici est tirée de (Pollard, 2002).

L'utilisation de métrisations pour la convergence faible permet d'étudier la vitesse de convergence dans les théorèmes limites. Cela remonte au moins au théorème de Berry-Esseen (1942). Les approches quantitatives de la convergence faible ont pris un nouvel élan avec la popularisation de la méthode de Stein. Cette méthode vise des versions générales et quantitatives du théorème central limite (Chen, Goldstein, & Shao, 2011). Une introduction complète mais accessible à la méthode de Stein est (Nathan Ross, 2011).

Chapitre 16

Vecteurs gaussiens

16.1 Loi gaussienne univariée

La densité gaussienne standard est notée ϕ :

$$\phi(x) = \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}}.$$

La fonction de répartition correspondante est notée Φ . La fonction de survie $1 - \Phi$ est notée $\bar{\Phi}$.

$$\Phi(x) = \int_{-\infty}^x \phi(u) du.$$

Notons $\mathcal{N}(0, 1)$ (espérance 0, variance 1) la loi gaussienne standard, c'est-à-dire la loi de probabilité définie par ϕ .

Toute transformation affine d'une variable aléatoire gaussienne standard suit une loi gaussienne univariée. Si $X \sim \mathcal{N}(0, 1)$, alors $\sigma X + \mu \sim \mathcal{N}(\mu, \sigma^2)$, de densité $\frac{1}{\sigma} \phi\left(\frac{\cdot - \mu}{\sigma}\right)$ et de fonction de répartition $\Phi\left(\frac{\cdot - \mu}{\sigma}\right)$.

La loi gaussienne standard est caractérisée par l'identité suivante.

Lemme 16.1 (Lemme de Stein). *Soit $X \sim \mathcal{N}(0, 1)$, soit g une fonction absolument continue de dérivée g' telle que $\mathbb{E}[|Xg(X)|] < \infty$. Alors $g'(X)$ est intégrable et*

$$\mathbb{E}[g'(X)] = \mathbb{E}[Xg(X)].$$

Preuve. La preuve repose sur une intégration par parties. Notons d'abord que remplacer g par $g - g(0)$ ne modifie ni g' , ni $\mathbb{E}[Xg(X)]$. On peut supposer que $g(0) = 0$.

$$\begin{aligned}
\mathbb{E}[Xg(X)] &= \int_{\mathbb{R}} xg(x)\phi(x)\mathrm{d}x \\
&= \int_0^\infty xg(x)\phi(x)\mathrm{d}x + \int_{-\infty}^0 xg(x)\phi(x)\mathrm{d}x \\
&= \int_0^\infty x \int_0^\infty g'(y)\mathbb{I}_{y\leq x}\mathrm{d}y\phi(x)\mathrm{d}x - \int_{-\infty}^0 x \int_{-\infty}^0 g'(y)\mathbb{I}_{y\geq x}\mathrm{d}y\phi(x)\mathrm{d}x \\
&= \int_0^\infty g'(y) \int_0^\infty \mathbb{I}_{y\leq x}x\phi(x)\mathrm{d}x\mathrm{d}y - \int_{-\infty}^0 g'(y) \int_{-\infty}^0 x\phi(x)\mathbb{I}_{y\geq x}\mathrm{d}x\mathrm{d}y \\
&= \int_0^\infty g'(y) \int_y^\infty x\phi(x)\mathrm{d}x\mathrm{d}y - \int_{-\infty}^0 g'(y) \int_{-\infty}^y x\phi(x)\mathrm{d}x\mathrm{d}y \\
&= \int_0^\infty g'(y)\phi(y)\mathrm{d}y - \int_{-\infty}^0 -g'(y)\phi(y)\mathrm{d}y \\
&= \int_{-\infty}^\infty g'(y)\phi(y)\mathrm{d}y.
\end{aligned}$$

La dernière égalité est justifiée par le théorème de Tonelli-Fubini. On utilise ensuite $\phi'(x) = -x\phi(x)$. $\square$

La fonction caractéristique est un outil très efficace pour manipuler les lois gaussiennes.

Proposition 16.1. *La fonction caractéristique de $\mathcal{N}(\mu, \sigma^2)$ est*

$$\widehat{\Phi}(t) := \mathbb{E}[e^{itX}] = e^{it\mu - \frac{t^2\sigma^2}{2}}.$$

Preuve. Il suffit de vérifier la proposition pour $\mathcal{N}(0, 1)$. Comme ϕ est paire,

$$\begin{aligned}
\widehat{\Phi}(t) &= \int_{-\infty}^\infty e^{itx} \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} \mathrm{d}x \\
&= \int_{-\infty}^\infty \cos(tx) \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} \mathrm{d}x.
\end{aligned}$$

En dérivant par rapport à t , en intervertissant dérivation et espérance (pourquoi peut-on le faire ?)

$$\widehat{\Phi}'(t) = \int_{-\infty}^\infty -x \sin(tx) \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} \mathrm{d}x.$$

On applique ensuite l'identité de Stein avec $g(x) = -\sin(tx)$ et $g'(x) = -t \cos(tx)$

$$\begin{aligned}
\widehat{\Phi}'(t) &= -t \int_{-\infty}^\infty \cos(tx) \phi(x) \mathrm{d}x \\
&= -t \widehat{\Phi}(t).
\end{aligned}$$

On obtient immédiatement $\widehat{\Phi}(0) = 1$, et la résolution de l'équation différentielle donne

$$\log \widehat{\Phi}(t) = -\frac{t^2}{2}.$$

□

Le fait que la fonction caractéristique détermine entièrement la loi de probabilité fournit une réciproque de Lemme 16.1.

Lemme 16.2 (Lemme de Stein (bis)). *Soit X une variable aléatoire réelle sur un espace de probabilité. Si, pour toute fonction différentiable g telle que g' et $x \mapsto xg(x)$ sont intégrables, on a*

$$\mathbb{E}[g'(X)] = \mathbb{E}[Xg(X)]$$

alors la loi de X est gaussienne standard.

Preuve. Considérons la partie réelle $\widehat{F}$ et la partie imaginaire $\widehat{G}$ de la fonction caractéristique de la loi de X . L'identité entraîne que $\widehat{F}'(t) = -t\widehat{F}(t)$ et $\widehat{G}'(t) = -t\widehat{G}(t)$, avec $\widehat{F}(0) = 1$ et $\widehat{G}(0) = 0$. La résolution des deux équations différentielles donne $\widehat{F}(t) = e^{-t^2/2}$ et $\widehat{G}(t) = 0$. On vient de vérifier que la fonction caractéristique de la loi de X est celle de $\mathcal{N}(0, 1)$. □

Il est maintenant facile de vérifier que la somme de deux variables aléatoires gaussiennes indépendantes est une variable aléatoire gaussienne.

Si X et Y sont deux variables aléatoires indépendantes de lois $\mathcal{N}(\mu, \sigma^2)$ et $\mathcal{N}(\mu', \sigma'^2)$, alors $X + Y$ suit la loi $\mathcal{N}(\mu + \mu', \sigma^2 + \sigma'^2)$.

Vérifier et justifier.

La fonction génératrice des moments d'une variable aléatoire gaussienne est

$$s \mapsto \mathbb{E}[e^{sX}] = e^{\frac{s^2}{2}}.$$

De l'inégalité de Markov, on obtient des majorations intéressantes de la queue gaussienne. Un calcul permet d'affiner ces bornes.

Proposition 16.2 (Probabilités de queue pour la loi gaussienne). *Pour $x \geq 0$,*

$$\frac{\phi(x)}{x} \left(1 - \frac{1}{x^2}\right) \leq \overline{\Phi}(x) \leq \min \left(e^{-\frac{x^2}{2}}, \frac{\phi(x)}{x} \right).$$

Preuve. La preuve se réduit à des intégrations par parties répétées.

$$\begin{aligned} \overline{\Phi}(x) &= \int_x^\infty \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du \\ &= \left[-\frac{1}{\sqrt{2\pi}u} e^{-\frac{u^2}{2}} \right]_x^\infty - \int_x^\infty \frac{1}{\sqrt{2\pi}} \frac{1}{u^2} e^{-\frac{u^2}{2}} du. \end{aligned}$$

Comme le second terme est non positif,

$$\bar{\Phi}(x) \leq \left[-\frac{1}{\sqrt{2\pi}u} e^{-\frac{u^2}{2}} \right]_x^\infty = \frac{\phi(x)}{x}.$$

C'est la première partie de l'inégalité de droite; l'autre partie provient de l'inégalité de Markov. Pour l'inégalité de gauche, il faut majorer $\int_x^\infty \frac{1}{\sqrt{2\pi}} \frac{1}{u^2} e^{-\frac{u^2}{2}} du$.

$$\begin{aligned} \int_x^\infty \frac{1}{\sqrt{2\pi}} \frac{1}{u^2} e^{-\frac{u^2}{2}} du &= \left[\frac{-1}{\sqrt{2\pi}} \frac{1}{u^3} e^{-\frac{u^2}{2}} \right]_x^\infty - \int_x^\infty \frac{1}{\sqrt{2\pi}} \frac{3}{u^4} e^{-\frac{u^2}{2}} du \\ &\leq \frac{1}{\sqrt{2\pi}} \frac{1}{x^3} e^{-\frac{x^2}{2}}. \end{aligned}$$

□

Proposition 16.3 (Moments). *Pour une variable aléatoire gaussienne standard,*

$$\mathbb{E}[X^k] = \begin{cases} 0 & \text{if } k \text{ is odd} \\ \frac{k!}{2^{k/2}(k/2)!} = \frac{\Gamma(k+1)}{2^{k/2}\Gamma(k/2+1)} & \text{if } k \text{ is even.} \end{cases}$$

Preuve. Grâce à la symétrie de la loi, $\mathbb{E}[X^k] = 0$ pour tout k impair. On traite les puissances paires par intégration par parties :

$$\mathbb{E}[X^{k+2}] = (k+1)\mathbb{E}[X^k].$$

Une récurrence sur k donne,

$$\mathbb{E}[X^{2k}] = \prod_{j=1}^k (2j-1) = \frac{(2k)!}{2^k k!}.$$

□

Notons que $(2k)!/(2^k k!)$ est aussi le nombre de partitions de $\{1, \dots, 2k\}$ en parties de cardinal 2.

Le *coefficient d'asymétrie* est nul; le kurtosis (rapport du quatrième moment centré au carré de la variance) vaut 3 :

$$\mathbb{E}[X^4] = 3 \times \mathbb{E}[X^2]^2.$$

16.2 Vecteurs gaussiens

Un vecteur gaussien est une collection de variables aléatoires gaussiennes univariées qui vérifie une propriété très exigeante :

Définition 16.1 (Vecteur gaussien). Un vecteur aléatoire $(X_1, \dots, X_n)^\top$ est un *vecteur gaussien* si et seulement si, pour tout vecteur réel $(\lambda_1, \lambda_2, \dots, \lambda_n)^\top$, la loi de la variable aléatoire univariée $\sum_{i=1}^n \lambda_i X_i$ est gaussienne.

Remarque 16.1. Toute collection de variables aléatoires gaussiennes ne forme pas un vecteur gaussien.

Le vecteur aléatoire $(X, \epsilon X)$ avec $X \sim \mathcal{N}(0,1)$, indépendante de ϵ valant ± 1 avec probabilité $1/2$, n'est pas un vecteur gaussien, bien que X et ϵX soient des variables aléatoires gaussiennes univariées.

Exercice 16.1. Vérifier que ϵX est une variable aléatoire gaussienne.

Il existe pourtant des vecteurs gaussiens ! Une manière simple d'en obtenir un est fournie par la proposition suivante (vérifiée par un argument de fonction caractéristique).

Proposition 16.4. Si $X_1, \dots, X_n$ est une suite de variables aléatoires gaussiennes indépendantes, alors $(X_1, \dots, X_n)^\top$ est un vecteur gaussien.

Par la suite, un *vecteur gaussien standard* est un vecteur aléatoire à coordonnées indépendantes, chaque coordonnée suivant la loi $\mathcal{N}(0,1)$.

Nous verrons comment construire des vecteurs gaussiens généraux. Auparavant, vérifions que la loi jointe d'un vecteur aléatoire gaussien est entièrement caractérisée par sa matrice de covariance et son vecteur d'espérance.

Rappelons que la *covariance* du vecteur aléatoire $X = (X_1, \dots, X_n)^\top$ est la matrice K de dimension $n \times n$ de coefficients

$$K[i, j] = \text{Cov}(X_i, X_j) = \mathbb{E}[X_i X_j] - \mathbb{E}[X_i] \mathbb{E}[X_j].$$

Sans perte de généralité, on peut supposer que le vecteur aléatoire X est centré. Pour tout $\lambda = (\lambda_1, \dots, \lambda_n)^\top \in \mathbb{R}^n$, on a :

$$\text{var}(\langle \lambda, X \rangle) = \lambda^\top K \lambda = \text{trace}(K \lambda \lambda^\top)$$

(ceci ne dépend d'aucune hypothèse de gaussianité).

En effet,

$$\begin{aligned} \text{var}(\langle \lambda, X \rangle) &= \mathbb{E} \left[\left(\sum_{i=1}^n \lambda_i X_i \right)^2 \right] \\ &= \sum_{i,j=1}^n \mathbb{E} [\lambda_i \lambda_j X_i X_j] \\ &= \sum_{i,j=1}^n \lambda_i \lambda_j K[i, j] \\ &= \lambda^\top K \lambda. \end{aligned}$$

CHAPITRE 16. VECTEURS GAUSSIENS

La fonction caractéristique d'un vecteur gaussien X de vecteur d'espérance μ et de covariance K vérifie

$$\mathbb{E}e^{i\langle \lambda, X \rangle} = e^{i\langle \lambda, \mu \rangle - \frac{\lambda^\top K \lambda}{2}}.$$

Une transformation linéaire d'un vecteur gaussien est un vecteur gaussien.

Proposition 16.5. *Si $Y = (Y_1, \dots, Y_n)^\top$ est un vecteur gaussien de covariance K et si A est une matrice réelle de dimensions $p \times n$, alors $A \times Y$ est un vecteur gaussien d'espérance $A \times \mathbb{E}Y$ et de matrice de covariance*

$$AKA^\top.$$

Preuve. Sans perte de généralité, on suppose Y centré.

Pour tout $\lambda \in \mathbb{R}^p$, $\langle \lambda, AY \rangle = \langle A^\top \lambda, Y \rangle$; ainsi $A \times Y$ est gaussien de variance

$$\lambda^\top AKA^\top \lambda.$$

La covariance de $A \times Y$ est déterminée par cette observation. □

Pour fabriquer des vecteurs gaussiens de matrices de covariance générales, on s'appuie sur une notion importante de l'analyse matricielle.

Définition 16.2 (Matrices définies positives). Une matrice symétrique M de dimensions $k \times k$ est *définie positive* (respectivement *semi-définie positive*) si et seulement si, pour tout vecteur non nul $v \in \mathbb{R}^k$,

$$v^\top Mv > 0 \quad (\text{resp.} \quad v^\top Mv \geq 0).$$

On note $\text{dp}(k)$ (resp. $\text{sdp}(k)$) les cônes des matrices définies positives (resp. semi-définies positives).

Proposition 16.6. *Si K est la matrice de covariance d'un vecteur aléatoire, K est symétrique et semi-définie positive.*

Preuve. Si X est un vecteur aléatoire à valeurs dans $\mathbb{R}^k$, de covariance K , pour tout vecteur $\lambda \in \mathbb{R}^n$,

$$\lambda^\top K \lambda = \sum_{i,j \leq k} K_{i,j} \lambda_i \lambda_j = \text{cov}(\langle \lambda, X \rangle, \langle \lambda, X \rangle)$$

soit $\lambda^\top K \lambda = \text{var}(\langle \lambda, X \rangle)$. La variance d'une variable aléatoire univariée est toujours non négative. □

L'observation suivante est la clé de la construction de vecteurs gaussiens généraux.

Proposition 16.7 (Factorisation de Cholesky). *Si A est une matrice symétrique semi-définie positive, il existe (au moins) une matrice réelle B telle que $A = B^\top B$.*

Nous ne démontrons pas cette proposition. C'est un théorème de base de l'analyse matricielle. Il peut s'établir à partir du *théorème de décomposition spectrale* pour les matrices symétriques. Il peut aussi s'établir par une approche constructive simple : une matrice définie positive K admet une *décomposition de Cholesky*, autrement dit, il existe une matrice triangulaire inférieure L telle que $K = L \times L^\top$.

La proposition suivante est un corollaire de la formule générale pour les densités d'image.

Proposition 16.8. *Si A est une matrice symétrique définie positive ($A \in \text{dp}(n)$), alors la loi du vecteur gaussien centré de matrice de covariance A est absolument continue par rapport à la mesure de Lebesgue sur $\mathbb{R}^n$:*

$$\frac{1}{(2\pi)^{n/2} \det(A)^{1/2}} \exp\left(-\frac{x^\top A^{-1}x}{2}\right).$$

Preuve. La formule de densité est trivialement correcte pour les vecteurs gaussiens standards. Dans le cas général, il suffit d'invoquer la formule de densité d'image appliquée à l'image du vecteur gaussien standard par la transformation linéaire bijective définie par la factorisation de Cholesky de A . Le déterminant du facteur de Cholesky est la racine carrée du déterminant de A . $\square$

Exercice 16.2. La loi d'un vecteur gaussien X de matrice de covariance *singulière* est-elle absolument continue par rapport à la mesure de Lebesgue ?

Définition 16.3 (Espace gaussien). Si $X = (X_1, \dots, X_n)^\top$ est un vecteur gaussien centré de matrice de covariance K , l'ensemble $\left\{\sum_{i=1}^n \lambda_i X_i = \langle \lambda, X \rangle; \lambda \in \mathbb{R}^n\right\}$ est l'espace gaussien engendré par $X = (X_1, \dots, X_n)^\top$.

L'espace gaussien est un espace vectoriel réel. Si $(\Omega, \mathcal{F}, P)$ désigne l'espace de probabilité sur lequel vit X , l'espace gaussien est un sous-espace de $L^2_{\mathbb{R}}(\Omega, \mathcal{F}, P)$. Il hérite de la structure de produit scalaire de $L^2_{\mathbb{R}}(\Omega, \mathcal{F}, P)$.

Ce produit scalaire est entièrement défini par la matrice de covariance K .

$$\begin{aligned}
\left\langle \sum_{i=1}^n \lambda_i X_i, \sum_{i=1}^n \lambda'_i X_i \right\rangle &\equiv \mathbb{E}_P \left[\left(\sum_{i=1}^n \lambda_i X_i \right) \left(\sum_{i=1}^n \lambda'_i X_i \right) \right] \\
&= \sum_{i,i'=1}^n \lambda_i \lambda'_{i'} K[i, i'] \\
&= (\lambda_1, \dots, \lambda_n) K \begin{pmatrix} \lambda'_1 \\ \vdots \\ \lambda'_n \end{pmatrix} \\
&= \text{trace} \left(K \begin{pmatrix} \lambda_1 \\ \vdots \\ \lambda_n \end{pmatrix} \begin{pmatrix} \lambda'_1 & \dots & \lambda'_n \end{pmatrix} \right).
\end{aligned}$$

Remarque 16.2. Des vecteurs gaussiens différents peuvent engendrer le même espace gaussien. Expliquer comment et pourquoi.

Les espaces gaussiens jouissent de propriétés remarquables. L'indépendance de variables aléatoires appartenant au même espace gaussien se vérifie très facilement.

Proposition 16.9. *Deux variables aléatoires Z et Y , appartenant au même espace gaussien, sont indépendantes si et seulement si elles sont orthogonales (ou décorrélées), c'est-à-dire si et seulement si*

$$\text{Cov}_P[Y, Z] = \mathbb{E}_P[YZ] = 0.$$

Sans perte de généralité, on suppose que la matrice de covariance K est définie positive.

Preuve. L'indépendance implique toujours l'orthogonalité.

Sans perte de généralité, on suppose que l'espace gaussien est engendré par un vecteur gaussien standard; posons $Z = \sum_{i=1}^n \lambda_i X_i$ et $Y = \sum_{i=1}^n \lambda'_i X_i$.

Si Z et Y sont orthogonales (ou non corrélées),

$$\mathbb{E}[ZY] = \sum_{i=1}^n \lambda_i \lambda'_i = 0.$$

Pour montrer que Z et Y sont indépendantes, il suffit de vérifier que, pour tout μ et μ' dans $\mathbb{R}$,

$$\mathbb{E} [e^{i\mu Z} e^{i\mu' Y}] = \mathbb{E} [e^{i\mu Z}] \times \mathbb{E} [e^{i\mu' Y}].$$

$$\begin{aligned}
\mathbb{E} \left[e^{i\mu Z} e^{i\mu' Y} \right] &= \mathbb{E} \left[e^{i\mu \sum_i \lambda_i X_i} e^{i\mu' \sum_i \lambda'_i X_i} \right] \\
&= \mathbb{E} \left[\prod_{i=1}^n e^{i(\mu \lambda_i + \mu' \lambda'_i) X_i} \right] \\
&\quad X_i \text{ sont indépendantes ...} \\
&= \prod_{i=1}^n \mathbb{E} \left[e^{i(\mu \lambda_i + \mu' \lambda'_i) X_i} \right] \\
&= \prod_{i=1}^n e^{-(\mu \lambda_i + \mu' \lambda'_i)^2 / 2} \\
&= \exp \left(-\frac{1}{2} \sum_{i=1}^n \mu^2 \lambda_i^2 + 2\mu \mu' \lambda_i \lambda'_i + \mu'^2 \lambda_i'^2 \right) \\
&\quad \text{orthogonalité} \\
&= \exp \left(-\frac{1}{2} \sum_{i=1}^n \mu^2 \lambda_i^2 + \mu'^2 \lambda_i'^2 \right) \\
&\quad \dots \\
&= \mathbb{E} \left[e^{i\mu Z} \right] \times \mathbb{E} \left[e^{i\mu' Y} \right].
\end{aligned}$$

□

La proposition suivante en est une conséquence directe.

Corollaire 16.1. *Si E et E' sont deux sous-espaces linéaires de l'espace gaussien engendré par le vecteur gaussien à coordonnées indépendantes $X_1, \dots, X_n$, les variables aléatoires (gaussiennes) appartenant au sous-espace E et les variables aléatoires (gaussiennes) appartenant au sous-espace E' sont indépendantes si et seulement si ces deux sous-espaces sont orthogonaux.*

16.3 Convergence des vecteurs gaussiens

Rappelons le théorème de continuité de Lévy (Théorème 15.2), qui relie convergence faible des lois de probabilité et convergence simple des fonctions caractéristiques.

Théorème 16.1. *Une suite de lois de probabilité $(P_n)_{n \in \mathbb{N}}$ sur $\mathbb{R}^k$ converge faiblement vers P si et seulement si, pour tout $\vec{s} \in \mathbb{R}^k$:*

$$\mathbb{E}_{P_n} \left[e^{i\langle \vec{s}, \vec{X} \rangle} \right] \rightarrow \mathbb{E}_P \left[e^{i\langle \vec{s}, \vec{X} \rangle} \right].$$

Pour tout $\vec{s} \in \mathbb{R}^k$, les fonctions $\vec{x} \mapsto \cos(\langle \vec{s}, \vec{x} \rangle)$ et $\vec{x} \mapsto \sin(\langle \vec{s}, \vec{x} \rangle)$ sont continues et bornées; elles sont aussi infiniment dérivables.

Il est remarquable et utile que la convergence faible puisse se vérifier sur ce petit ensemble de fonctions.

Théorème 16.2 (Théorème de continuité de Lévy (bis)). *Une suite de lois de probabilité $(P_n)_{n \in \mathbb{N}}$ sur $\mathbb{R}^k$ converge faiblement vers une loi de probabilité si et seulement si il existe une fonction f sur $\mathbb{R}^k$, continue en $\vec{0}$, telle que, pour tout $\vec{s} \in \mathbb{R}^k$:*

$$\mathbb{E}_{P_n} [e^{i\langle \vec{s}, \vec{X} \rangle}] \rightarrow f(\vec{s}).$$

Alors, la fonction f est la fonction caractéristique d'une certaine loi de probabilité P .

La condition de continuité en 0 est nécessaire. La fonction caractéristique d'une loi de probabilité est toujours continue en 0. La continuité en 0 garantit la tension de la suite de lois de probabilité.

Proposition 16.10. *Si une suite de vecteurs gaussiens de dimension k (X_n) est définie par une suite à valeurs dans $\mathbb{R}^k$ $(\vec{\mu}_n)_n$ et une suite à valeurs dans $SDP(k)$ $(K_n)_n$ et si*

$$\begin{aligned} \lim_n \vec{\mu}_n &= \mu \in \mathbb{R}^k \\ \lim_n K_n &= K \in SDP(k) \end{aligned}$$

alors la suite $(X_n)_n$ converge en loi vers $\mathcal{N}(\vec{\mu}, K)$ (si $K = 0$, la loi limite est δ_μ).

16.4 Conditionnement gaussien

Soit $(X_1, \dots, X_n)^\top$ un vecteur gaussien de loi $\mathcal{N}(\mu, K)$ où $K \in DP(n)$. La matrice de covariance K est partitionnée en blocs

$$K = \begin{bmatrix} A & B^\top \\ B & W \end{bmatrix}$$

où $A \in DP(k)$, $1 \leq k < n$, et $W \in DP(n - k)$.

Nous nous intéressons à l'espérance conditionnelle de $(X_1, \dots, X_k)^\top$ par rapport à $\sigma(X_{k+1}, \dots, X_n)$ et à la loi conditionnelle de $(X_1, \dots, X_k)^\top$ par rapport à $\sigma(X_{k+1}, \dots, X_n)$.

Le complément de Schur de A dans K est défini par

$$W - BA^{-1}B^\top.$$

Cette définition a un sens pour les matrices symétriques lorsque A est inversible.

Si $K \in DP(n)$, alors le complément de Schur de A dans K appartient aussi à $DP(n - k)$.

Dans l'énoncé des théorèmes suivants, $A^{-1/2}$ désigne le facteur de Cholesky de A^{-1} : $A^{-1} = A^{-1/2} \times (A^{-1/2})^\top$.

Théorème 16.3. *L'espérance conditionnelle de $(X_{k+1}, \dots, X_n)^\top$ sachant $(X_1, \dots, X_k)^\top$ est une transformation affine de $(X_1, \dots, X_k)^\top$:*

$$\mathbb{E} \left[\begin{pmatrix} X_{k+1} \\ \vdots \\ X_n \end{pmatrix} \middle| \begin{pmatrix} X_1 \\ \vdots \\ X_k \end{pmatrix} \right] = \begin{pmatrix} \mu_{k+1} \\ \vdots \\ \mu_n \end{pmatrix} + (BA^{-1}) \times \left(\begin{pmatrix} X_1 \\ \vdots \\ X_k \end{pmatrix} - \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_k \end{pmatrix} \right).$$

Théorème 16.4. *La loi conditionnelle de $(X_{k+1}, \dots, X_n)^\top$ par rapport à $\sigma(X_1, \dots, X_k)$ est gaussienne; son espérance est l'espérance conditionnelle de $(X_{k+1}, \dots, X_n)^\top$ par rapport à $\sigma(X_1, \dots, X_k)$, et sa variance est le complément de Schur de la covariance de $(X_1, \dots, X_k)^\top$ dans la matrice de covariance de $(X_1, \dots, X_n)^\top$.*

Nous étudions d'abord la densité conditionnelle et, avec un minimum de calcul, établissons qu'elle est gaussienne. L'espérance conditionnelle sera calculée comme espérance sous la loi conditionnelle.

Pour caractériser la densité conditionnelle, nous nous appuyons sur un argument de représentation distributionnelle (tout vecteur gaussien a la loi de l'image d'un vecteur gaussien standard par une transformation affine) et sur un résultat d'analyse matricielle au cœur de la factorisation de Cholesky des matrices semi-définies positives.

$(X_1, \dots, X_n)^\top$ a la loi de l'image d'un vecteur gaussien standard par une matrice triangulaire par blocs; nous utilisons ensuite des propriétés des lois conditionnelles pour établir les deux résultats.

Proposition 16.11. *Soit K une matrice symétrique définie positive de dimensions $n \times n$*

$$K = \begin{bmatrix} A & B^\top \\ B & W \end{bmatrix}$$

où A a dimensions $k \times k$, $1 \leq k < n$.

Alors, le complément de Schur de A par rapport à K

$$W - BA^{-1}B^\top$$

est définie positive. Les sous-matrices A et $W - BA^{-1}B^\top$ admettent toutes deux une décomposition de Cholesky $A = L_1 L_1^\top$, $W - BA^{-1}B^\top = L_2 L_2^\top$ où L_1, L_2 sont triangulaires inférieures, et la factorisation de K s'écrit :

$$K = \begin{bmatrix} L_1 & 0 \\ B(L_1^\top)^{-1} & L_2 \end{bmatrix} \times \begin{bmatrix} L_1^\top & L_1^{-1}B^\top \\ 0 & L_2^\top \end{bmatrix}.$$

Preuve. Sans perte de généralité, on vérifie l'énoncé sur des vecteurs centrés. La factorisation de Cholesky de K permet d'écrire

$$\begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix} \sim \begin{bmatrix} L_1 & 0 \\ B(L_1^\top)^{-1} & L_2 \end{bmatrix} \times \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}$$

où $(Y_1, \dots, Y_n)^\top$ est un vecteur gaussien standard centré.

Par la suite, on suppose $(X_1, \dots, X_n)^\top$ et $(Y_1, \dots, Y_n)^\top$ définis sur le même espace de probabilité. Comme L_1 est inversible, les tribus engendrées par $(X_1, \dots, X_k)^\top$ et $(Y_1, \dots, Y_k)^\top$ coïncident. Posons $\mathcal{G} = \sigma(X_1, \dots, X_k)$. Les espérances et lois conditionnelles coïncident également.

$$\begin{aligned} \mathbb{E} \left[\begin{pmatrix} X_{k+1} \\ \vdots \\ X_n \end{pmatrix} \mid \mathcal{G} \right] &= \mathbb{E} \left[B(L_1^\top)^{-1} \begin{pmatrix} Y_1 \\ \vdots \\ Y_k \end{pmatrix} \mid \mathcal{G} \right] + \mathbb{E} \left[L_2 \begin{pmatrix} Y_{k+1} \\ \vdots \\ Y_n \end{pmatrix} \mid \mathcal{G} \right] \\ &= B(L_1^\top)^{-1} L_1^{-1} \begin{pmatrix} X_1 \\ \vdots \\ X_k \end{pmatrix} = BA^{-1} \begin{pmatrix} X_1 \\ \vdots \\ X_k \end{pmatrix}, \end{aligned}$$

car $(Y_{k+1}, \dots, Y_n)^\top$ est centré et indépendant de $\mathcal{G}$.

Notons que les résidus

$$\begin{pmatrix} X_{k+1} \\ \vdots \\ X_n \end{pmatrix} - \mathbb{E} \left[\begin{pmatrix} X_{k+1} \\ \vdots \\ X_n \end{pmatrix} \mid \mathcal{G} \right] = L_2 \begin{pmatrix} Y_{k+1} \\ \vdots \\ Y_n \end{pmatrix}$$

sont indépendants de $\mathcal{G}$. C'est une propriété gaussienne. Pour des variables aléatoires carré-intégrables générales, on ne peut qu'affirmer que les résidus sont orthogonaux aux variables aléatoires $\mathcal{G}$ -mesurables.

La loi conditionnelle de $(X_{k+1}, \dots, X_n)^\top$ sachant $(X_1, \dots, X_k)^\top$ coïncide avec la loi conditionnelle de

$$B(L_1^\top)^{-1} \times \begin{pmatrix} Y_1 \\ \vdots \\ Y_k \end{pmatrix} + L_2 \times \begin{pmatrix} Y_{k+1} \\ \vdots \\ Y_n \end{pmatrix}$$

conditionnellement à $(Y_1, \dots, Y_k)^\top$. Comme $(Y_1, \dots, Y_k)^\top = L_1^{-1}(X_1, \dots, X_k)^\top$, la loi conditionnelle recherchée est gaussienne, d'espérance

$$BA^{-1} \times \begin{pmatrix} X_1 \\ \vdots \\ X_k \end{pmatrix}$$

(l'espérance conditionnelle) et de variance $L_2 \times L_2^\top = W - BA^{-1}B^\top$. □

Exemple 16.1. Si $(X, Y)^\top$ est un vecteur gaussien centré avec $\text{var}(X) = \sigma_x^2$, $\text{var}(Y) = \sigma_y^2$ et $\text{cov}(X, Y) = \rho\sigma_x\sigma_y$, la loi conditionnelle de Y sachant X est

$$\mathcal{N}(\rho\sigma_y/\sigma_x X, \sigma_y^2(1-\rho^2)) .$$

La quantité ρ est appelée le *coefficient de corrélation linéaire* entre X et Y . Par l'inégalité de Cauchy-Schwarz, $\rho \in [-1, 1]$.

Ces deux théorèmes sont habituellement traités dans l'ordre où ils sont énoncés. L'espérance conditionnelle se caractérise en adoptant le point de vue L^2 (prédictif) : l'espérance conditionnelle du vecteur aléatoire Y sachant X est définie comme le meilleur prédicteur de Y mesurable par rapport à X au sens de l'erreur quadratique (le vecteur aléatoire Z , mesurable par rapport à X , qui minimise $\mathbb{E}[\|Y - Z\|^2]$).

Pour caractériser l'espérance conditionnelle, on calcule d'abord le prédicteur affine optimal de $(X_{k+1}, \dots, X_n)^\top$ à partir de $(X_1, \dots, X_k)^\top$. Ce prédicteur affine optimal est

$$\begin{pmatrix} \mu_{k+1} \\ \vdots \\ \mu_n \end{pmatrix} + (BA^{-1}) \times \left(\begin{pmatrix} X_1 \\ \vdots \\ X_k \end{pmatrix} - \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_k \end{pmatrix} \right) ,$$

(Si les vecteurs gaussiens sont centrés, cela revient à déterminer la matrice P de dimensions $(n-k) \times k$ qui minimise $\text{trace}(PAP^\top - 2BP^\top)$). Le prédicteur affine optimal est un vecteur gaussien; on vérifie que le vecteur résiduel

$$\begin{pmatrix} X_{k+1} \\ \vdots \\ X_n \end{pmatrix} - \left\{ \begin{pmatrix} \mu_{k+1} \\ \vdots \\ \mu_n \end{pmatrix} + (BA^{-1}) \times \left(\begin{pmatrix} X_1 \\ \vdots \\ X_k \end{pmatrix} - \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_k \end{pmatrix} \right) \right\}$$

est aussi gaussien et orthogonal au prédicteur affine. Le vecteur résiduel est indépendant du prédicteur affine.

Cela suffit à établir que le prédicteur affine est la projection orthogonale de $(X_{k+1}, \dots, X_n)^\top$ sur le sous-espace vectoriel fermé des variables aléatoires carré-intégrables mesurables par rapport à $(X_1, \dots, X_k)^\top$.

On en déduit que le prédicteur affine est l'espérance conditionnelle.

Dans ces notes, nous traitons un cas particulier de conditionnement linéaire.

Pour aborder le conditionnement linéaire général, considérons $X \sim \mathcal{N}(0, K)$ (on suppose le centrage pour alléger les notations et les calculs; une translation ne modifie pas les tribus pertinentes et donc le conditionnement), où $K \in \text{DP}(n)$, et une transformation linéaire définie par la matrice H de dimensions $m \times n$. On suppose que H est de rang m . Posons $Y = HX$. Considérons le vecteur gaussien $[X^\top : Y^\top]$ de matrice de covariance

$$\begin{bmatrix} K & KH^\top \\ HK & HKH^\top \end{bmatrix}$$

et en adaptant les calculs précédents (la matrice de covariance n'est plus définie positive), on vérifie que la loi conditionnelle de X sachant Y est gaussienne d'espérance

$$KH^\top (HKH^\top)^{-1}$$

et de variance

$$K - KH^\top (HKH^\top)^{-1} HK.$$

La linéarité de l'espérance conditionnelle est une propriété des vecteurs gaussiens et du conditionnement linéaire. Si l'on conditionne par rapport à la norme $\|X\|_2$, la loi conditionnelle n'est plus gaussienne.

16.5 À propos des lois Gamma

L'étude de la norme des vecteurs gaussiens nous amène à introduire les lois χ^2 , une sous-famille des lois Gamma.

Définition 16.4 (Lois Gamma). Une loi Gamma de paramètres (p, λ) ($\lambda \in \mathbb{R}_+$ et $p \in \mathbb{R}_+$) est une loi sur $(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+))$ de densité

$$g_{p,\lambda}(x) \equiv \frac{\lambda^p}{\Gamma(p)} \mathbf{1}_{x \geq 0} x^{p-1} e^{-\lambda x}$$

où $\Gamma(p) \equiv \int_0^\infty t^{p-1} e^{-t} dt$.

Le paramètre p est appelé paramètre de *forme*, λ est appelé paramètre de *taux* ou d'*intensité*; $1/\lambda$ est appelé paramètre d'*échelle*.

Si $X \sim \text{Gamma}(p, 1)$, alors $\sigma X \sim \text{Gamma}(p, 1/\sigma)$ pour $\sigma > 0$.

La fonction Γ d'Euler interpole la factorielle. Pour tout réel p strictement positif, $\Gamma(p+1) = p\Gamma(p)$. Si p est entier, $\Gamma(p+1) = p!$

Exercice 16.3. Vérifier que $\Gamma(1/2) = \sqrt{\pi}$.

Proposition 16.12. Si $X \sim \text{Gamma}(p, \lambda)$, $\mathbb{E}X = \frac{p}{\lambda}$ et $\text{var}(X) = \frac{p}{\lambda^2}$.

La proposition suivante est une pierre angulaire du calcul Gamma. La somme de deux variables aléatoires indépendantes de loi Gamma est de loi Gamma si elles ont le même paramètre d'intensité (ou d'échelle).

Proposition 16.13. Si X et Y sont des variables aléatoires indépendantes de loi Gamma de même paramètre d'intensité λ , $X \sim \text{Gamma}(p, \lambda)$, $Y \sim \text{Gamma}(q, \lambda)$, alors $X + Y \sim \text{Gamma}(p + q, \lambda)$.

Preuve. La densité de la loi de $X + Y$ est la convolution des densités $g_{p,\lambda}$ et $g_{q,\lambda}$.

$$\begin{aligned}
 g_{p,\lambda} * g_{q,\lambda}(x) &= \int_{\mathbb{R}} g_{p,\lambda}(z) g_{q,\lambda}(x-z) dz \\
 &= \int_0^x g_{p,\lambda}(z) g_{q,\lambda}(x-z) dz \\
 &= \int_0^x \frac{\lambda^p}{\Gamma(p)} z^{p-1} e^{-\lambda z} \frac{\lambda^q}{\Gamma(q)} (x-z)^{q-1} e^{-\lambda(x-z)} dz \\
 &= \frac{\lambda^{p+q}}{\Gamma(p)\Gamma(q)} e^{-\lambda x} \int_0^x z^{p-1} (x-z)^{q-1} dz \\
 &\quad \text{changement de variable } z = xu \\
 &= \frac{\lambda^{p+q}}{\Gamma(p)\Gamma(q)} e^{-\lambda x} x^{p+q-1} \int_0^1 u^{p-1} (1-u)^{q-1} du \\
 &= g_{p+q,\lambda}(x) \frac{\Gamma(p+q)}{\Gamma(p)\Gamma(q)} \int_0^1 u^{p-1} (1-u)^{q-1} du.
 \end{aligned}$$

Retenons l'observation suivante :

$$B(p, q) := \int_0^1 u^{p-1} (1-u)^{q-1} du$$

$$\text{satisfait } B(p, q) = \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}.$$

□

Les lois Gamma de paramètres $(k/2, 1/2)$ pour $k \in \mathbb{N}$ méritent un nom : ce sont les lois χ^2 à k degrés de liberté.

Proposition 16.14 (Lois du chi-deux). *La loi χ^2 à k degrés de liberté (notée χ_k^2) a pour densité sur $[0, \infty)$,*

$$\frac{x^{\frac{1}{2}(k-2)} e^{-\frac{x}{2}}}{2^{k/2} \Gamma(k/2)}.$$

Proposition 16.15. *La somme de k carrés de variables aléatoires gaussiennes standards indépendantes suit la loi du chi-deux à k degrés de liberté χ_k^2 .*

Preuve. D'après la proposition Proposition 9.2, il suffit d'établir la proposition pour $k = 1$.

Soit $X \sim \mathcal{N}(0, 1)$; pour $t \geq 0$,

$$\begin{aligned}
 \mathbb{P}\{X^2 \leq t\} &= \Phi(\sqrt{t}) - \Phi(-\sqrt{t}) \\
 &= 2\Phi(\sqrt{t}) - 1.
 \end{aligned}$$

En dérivant par rapport à t et en appliquant la règle de la chaîne, on obtient une formule pour la densité :

$$2 \frac{1}{2\sqrt{t}} \phi(\sqrt{t}) = \frac{1}{\sqrt{2\pi t}} e^{-\frac{t}{2}} = \left(\frac{1}{2}\right)^{1/2} \frac{t^{-1/2}}{\Gamma(1/2)} e^{-\frac{t}{2}}.$$

□

16.6 Normes de vecteurs gaussiens centrés

La loi du carré de la norme euclidienne d'un vecteur gaussien centré ne dépend que du spectre de sa matrice de covariance.

Théorème 16.5. Si $X := (X_1, X_2, \dots, X_n)^\top \sim \mathcal{N}(0, A)$ avec $A = LL^\top$ (L triangulaire inférieure), si $M \in \text{SDP}(n)$, alors $X^\top MX$ a la même loi que $\sum_{i=1}^n \lambda_i Z_i^2$ où $(\lambda_i)_{i \in \{1, \dots, n\}}$ désignent les valeurs propres de $L^\top \times M \times L$ et où les Z_i sont des variables aléatoires indépendantes de loi χ_1^2 .

C'est un corollaire d'une propriété importante des vecteurs gaussiens standards : l'invariance par rotation. La loi gaussienne standard est invariante par transformation orthogonale (une matrice O est orthogonale si et seulement si $OO^\top = \text{Id}$).

Preuve. La matrice A se factorise sous la forme $A = LL^\top$ (Cholesky), et X a la même loi que LY où Y est gaussien standard. La forme quadratique $X^\top MX$ a donc la même loi que $Y^\top L^\top ML Y$. Il existe une transformation orthogonale O telle que $L^\top ML = O^\top \text{diag}(\lambda_i) O$. Le vecteur aléatoire OY a la loi $\mathcal{N}(0, I_n)$. $\square$

16.7 Norme de vecteurs gaussiens non centrés

La loi du carré de la norme d'un vecteur gaussien de matrice de covariance $\sigma^2 \text{Id}$ dépend de la norme du vecteur d'espérance mais non de sa direction. De plus, cette loi se compare stochastiquement à la loi du carré de la norme d'un vecteur gaussien centré de même covariance.

Définition 16.5 (Ordre stochastique). Sur un espace de probabilité muni de la loi $\mathbb{P}$, une variable aléatoire réelle X est *stochastiquement plus petite* que la variable aléatoire Y si

$$\mathbb{P}\{X \leq Y\} = 1.$$

On dit que la loi de Y domine stochastiquement la loi de X .

Si X est stochastiquement plus petite que Y et si F et G désignent les fonctions de répartition de X et Y , alors pour tout $x \in \mathbb{R}$, $F(x) \geq G(x)$. Les fonctions quantiles $F^{\leftarrow}, G^{\leftarrow}$ vérifient $F^{\leftarrow}(p) \leq G^{\leftarrow}(p)$ pour $p \in (0, 1)$.

Réciproquement.

Proposition 16.16. Si F et G sont deux fonctions de répartition telles que $\forall x \in \mathbb{R}$, $F(x) \geq G(x)$, alors il existe un espace de probabilité muni d'une loi $\mathbb{P}$ et deux variables aléatoires X et Y de fonctions de répartition F, G telles que :

$$\mathbb{P}\{X \leq Y\} = 1.$$

La preuve repose sur un argument de *couplage quantile*.

Preuve. Il suffit de munir $([0, 1], \mathcal{B}([0, 1]))$ de la loi uniforme. Posons $X(\omega) = F^{\leftarrow}(\omega)$, $Y(\omega) = G^{\leftarrow}(\omega)$. Alors la loi de X (resp. Y) a pour fonction de répartition F (resp. G) et l'on a :

$$\mathbb{P}\{X \leq Y\} = \mathbb{P}\{F^{\leftarrow}(U) \leq G^{\leftarrow}(U)\} = 1.$$

□

Théorème 16.6. Si $X \sim \mathcal{N}(0, \sigma^2 \text{Id})$ et $Y \sim \mathcal{N}(\theta, \sigma^2 \text{Id})$ avec $\theta \in \mathbb{R}^d$, alors

$$\|Y\|^2 \sim \left((Z_1 + \|\theta\|_2)^2 + \sum_{i=1}^d Z_i^2 \right)$$

où les Z_i sont i.i.d. de loi $\mathcal{N}(0, \sigma^2)$.

Pour tout $x \geq 0$,

$$\mathbb{P}\{\|Y\| \leq x\} \leq \mathbb{P}\{\|X\| \leq x\}.$$

La loi de $\|Y\|^2/\sigma^2$ (chi-deux non centré de paramètre $\|\theta\|_2/\sigma$) domine stochastiquement la loi de $\|X\|^2/\sigma^2$ (chi-deux centré avec le même nombre de degrés de liberté).

Preuve. Le vecteur gaussien Y a la même loi que $\theta + X$. Il existe une transformation orthogonale O telle que

$$O\theta = \begin{pmatrix} \|\theta\|_2 \\ 0 \\ \vdots \\ 0 \end{pmatrix}.$$

Les vecteurs OY et OX ont respectivement les mêmes normes que Y et X .

Le carré de la norme de Y a la même loi que le carré de la norme de OY , c'est-à-dire $(Z_1 + \|\theta\|_2)^2 + \sum_{i=2}^d Z_i^2$. Cela prouve la première partie du théorème.

Pour établir la seconde partie du théorème, il suffit de vérifier que, pour tout $x \geq 0$,

$$\mathbb{P}\{(Z_1 + \|\theta\|_2)^2 \leq x\} \leq \mathbb{P}\{X_1^2 \leq x\},$$

c'est-à-dire

$$\mathbb{P}\{|Z_1 + \|\theta\|_2| \leq \sqrt{x}\} \leq \mathbb{P}\{|X_1| \leq \sqrt{x}\},$$

ou

$$\Phi(\sqrt{x} - \|\theta\|_2) - \Phi(-\sqrt{x} - \|\theta\|_2) \leq \Phi(\sqrt{x}) - \Phi(-\sqrt{x}).$$

Pour $y > 0$, l'application de $[0, \infty)$ dans $\mathbb{R}$, définie par $a \mapsto \Phi(y - a) - \Phi(-y - a)$, est décroissante en a : sa dérivée par rapport à a vaut $-\phi(y - a) + \phi(-y - a) = \phi(y + a) - \phi(y - a) \leq 0$. La conclusion s'ensuit. □

La dernière étape de la preuve s'écrit

$$\mathbb{P}\{X \in \theta + C\} \leq \mathbb{P}\{X \in C\}$$

où $X \sim \mathcal{N}(0, \text{Id}_1)$, $\theta \in \mathbb{R}$ et $C = [-\sqrt{x}, \sqrt{x}]$. Cette inégalité vaut en dimension $d \geq 1$ si C est compact, convexe et symétrique. Ce résultat (subtil) s'appelle le lemme d'Anderson.

16.8 Théorème de Cochran et conséquences

Théorème 16.7 (Cochran). Soit $X \sim \mathcal{N}(0, I_n)$ et $\mathbb{R}^n = \bigoplus_{j=1}^k E_j$ où les E_j sont des sous-espaces vectoriels deux à deux orthogonaux de $\mathbb{R}^n$. Notons π_{E_j} la projection orthogonale sur E_j .

La collection de vecteurs gaussiens $(\pi_{E_j} X)_{j \leq k}$ est indépendante et, pour chaque j ,

$$\|\pi_{E_j} X\|_2^2 \sim \chi_{\dim(E_j)}^2.$$

Preuve. La matrice de covariance de $\pi_{E_j} X$ est $\pi_{E_j} \pi_{E_j}^\top = \pi_{E_j}$. Les valeurs propres de π_{E_j} valent 1 avec multiplicité $\dim(E_j)$ et 0. L'assertion sur la loi de $\|\pi_{E_j} X\|_2^2$ est un corollaire de [@prp-normgauss](#) et [@prp-normspectre](#).

Pour prouver l'indépendance stochastique, considérons $\mathcal{I}, \mathcal{J} \subset \{1, \dots, k\}$ avec $\mathcal{I} \cap \mathcal{J} = \emptyset$. Il suffit de vérifier que, pour tout $(\alpha)_{j \in \mathcal{I}}, (\beta)_{j \in \mathcal{J}}$, les fonctions caractéristiques de

$$\left(\sum_{j \in \mathcal{I}} \langle \alpha_j, \pi_{E_j} X \rangle, \sum_{j \in \mathcal{J}} \langle \beta_j, \pi_{E_j} X \rangle \right)$$

se factorisent. Il suffit de vérifier que les deux gaussiennes sont orthogonales.

$$\mathbb{E} \left[\left(\sum_{j \in \mathcal{I}} \langle \alpha_j, \pi_{E_j} X \rangle \right) \times \left(\sum_{j' \in \mathcal{J}} \langle \beta_{j'}, \pi_{E_{j'}} X \rangle \right) \right] = \sum_{j \in \mathcal{I}, j' \in \mathcal{J}} \alpha_j^\top \pi_{E_j} \pi_{E_{j'}} \beta_{j'} = 0.$$

□

Le résultat suivant est une pierre angulaire de l'inférence statistique dans les modèles gaussiens. C'est un corollaire du théorème de Cochran.

Théorème 16.8 (Student).

Si $(X_1, \dots, X_n)$ sont i.i.d. de loi $\mathcal{N}(\mu, \sigma^2)$, si $\bar{X}_n := \sum_{i=1}^n X_i/n$ et $V := \sum_{i=1}^n (X_i - \bar{X}_n)^2$, alors

1. $\bar{X}_n$ suit la loi $\mathcal{N}(\mu, \sigma^2/n)$,
2. V est indépendante de $\bar{X}_n$
3. V/σ^2 suit la loi χ_{n-1}^2 .

Preuve. Sans perte de généralité, on peut supposer que $\mu = 0$ et $\sigma = 1$.

Comme

$$\begin{pmatrix} \bar{X}_n \\ \vdots \\ \bar{X}_n \end{pmatrix} = \frac{1}{n} \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \times (1 \quad \dots \quad 1) X$$

le vecteur $(\bar{X}_n, \dots, \bar{X}_n)^\top$ est la projection orthogonale du vecteur gaussien standard X sur la droite engendrée par $(1, \dots, 1)^\top$.

Le vecteur $(X_1 - \bar{X}_n, \dots, X_n - \bar{X}_n)^\top$ est la projection orthogonale du vecteur gaussien X sur l'hyperplan orthogonal à $(1, \dots, 1)^\top$.

D'après le théorème de Cochran (Section 16.8), les vecteurs aléatoires $(\bar{X}_n, \dots, \bar{X}_n)^\top$ et $(X_1 - \bar{X}_n, \dots, X_n - \bar{X}_n)^\top$ sont indépendants.

La loi de $\bar{X}_n$ est trivialement gaussienne.

La loi de V se caractérise à l'aide du théorème de Cochran. $\square$

Définition 16.6 (Loi de Student). Si $X \sim \mathcal{N}(0, 1)$, $Y \sim \chi_p^2$ et si X et Y sont indépendantes, alors $Z = X / \sqrt{Y/p}$ suit une loi de Student (centrée) à p degrés de liberté.

16.9 Concentration gaussienne

La définition même des vecteurs gaussiens caractérise la loi de toute fonction affine d'un vecteur gaussien standard. Si la partie linéaire de la fonction affine est définie par un vecteur λ , on sait que la variance vaut $\|\lambda\|_2^2$. Que se passe-t-il si l'on s'intéresse à des fonctions assez régulières d'un vecteur gaussien standard? Par exemple si l'on considère des fonctions L -lipschitziennes? Ce sont des généralisations des fonctions affines. On ne peut donc pas espérer, en général, une croissance de la variance des fonctions L -lipschitziennes d'un vecteur gaussien standard inférieure à L^2 (dans le cas linéaire, la constante de Lipschitz est la norme euclidienne de λ). Il est remarquable que la borne obtenue pour les fonctions linéaires s'étende aux fonctions lipschitziennes. Il est encore plus remarquable que cette borne ne dépende pas de la dimension de l'espace ambiant.

Théorème 16.9. Soit $X \sim \mathcal{N}(0, Id_d)$.

— si f est différentiable sur $\mathbb{R}^d$,

$$\text{var}(f(X)) \leq \mathbb{E} \|\nabla f\|^2 \quad (\text{Poincaré's inequality})$$

— si f est L -lipschitzienne sur $\mathbb{R}^d$,

$$\text{var}(f(X)) \leq L^2$$

et, pour $\lambda > 0$,

$$\log \mathbb{E} e^{\lambda(f(X) - \mathbb{E}f)} \leq \frac{\lambda^2 L^2}{2}.$$

Pour tout $t \geq 0$,

$$\mathbb{P}\{f(X) - \mathbb{E}f(X) \geq t\} \leq e^{-\frac{t^2}{2L^2}}.$$

La preuve repose sur l'identité suivante.

Proposition 16.17 (Identité de covariance). *Soient X, Y deux vecteurs gaussiens standards indépendants à valeurs dans $\mathbb{R}^d$; soient f, g deux fonctions différentiables de $\mathbb{R}^d$ dans $\mathbb{R}$.*

$$\text{cov}(f(X), g(X)) = \int_0^1 \mathbb{E} \langle \nabla f(X), \nabla g(\alpha X + \sqrt{1-\alpha^2}Y) \rangle d\alpha$$

On commence par vérifier cette proposition sur les fonctions $x \mapsto e^{i\langle \lambda, x \rangle}$, $x \in \mathbb{R}^d$.

Preuve. Vérifions d'abord l'inégalité de Poincaré.

On choisit $f = g$. En partant de l'identité de covariance, grâce à l'inégalité de Cauchy-Schwarz :

$$\begin{aligned} \text{var}(f(X)) &= \text{cov}(f(X), f(X)) \\ &= \int_0^1 \mathbb{E} \langle \nabla f(X), \nabla f(\alpha X + \sqrt{1-\alpha^2}Y) \rangle d\alpha \\ &\leq \int_0^1 (\mathbb{E} \|\nabla f(X)\|^2)^{1/2} \times (\mathbb{E} \|\nabla f(\alpha X + \sqrt{1-\alpha^2}Y)\|^2)^{1/2} d\alpha. \end{aligned}$$

Le résultat souhaité s'obtient en remarquant que X et $\alpha X + \sqrt{1-\alpha^2}Y$ ont tous deux la loi $\mathcal{N}(0, \text{Id})$.

Pour obtenir l'inégalité exponentielle, choisissons f différentiable et L -lipschitzienne, et $g = \exp(\lambda f)$ pour $\lambda \geq 0$. Sans perte de généralité, supposons $\mathbb{E}f(X) = 0$. L'identité de covariance et la règle de la chaîne donnent

$$\begin{aligned} \text{cov}(f(X), e^{\lambda f(X)}) &= \lambda \int_0^1 \mathbb{E} \left[\langle \nabla f(X), \nabla f(\alpha X + \sqrt{1-\alpha^2}Y) \rangle e^{\lambda f(\alpha X + \sqrt{1-\alpha^2}Y)} \right] d\alpha \\ &\leq \lambda L^2 \int_0^1 \mathbb{E} \left[e^{\lambda f(\alpha X + \sqrt{1-\alpha^2}Y)} \right] d\alpha \\ &= \lambda L^2 \mathbb{E} \left[e^{\lambda f(X)} \right] \end{aligned}$$

Posons $F(\lambda) := \mathbb{E} [e^{\lambda f(X)}]$. On vient d'établir une inégalité différentielle pour F , en vérifiant que $\text{cov}(f, e^{\lambda f}) = F'(\lambda)$ puisque f est centré :

$$F'(\lambda) \leq \lambda L^2 F(\lambda).$$

En résolvant cette inégalité différentielle sous la condition $F(0) = 1$, pour $\lambda \geq 0$,

$$F(\lambda) \leq e^{\frac{\lambda^2 L^2}{2}}.$$

La même approche fonctionne pour $\lambda < 0$. Il suffit d'invoquer l'inégalité exponentielle de Markov et d'optimiser par rapport à $\lambda = t/L^2$. $\square$

Les inégalités de concentration décrivent le comportement de la norme de vecteurs gaussiens de grande dimension.

Corollaire 16.2. *Si X est un vecteur gaussien standard de dimension d , alors*

$$\text{var}(\|X\|_2) \leq 1$$

and

$$\sqrt{d-1} \leq \mathbb{E}\|X\|_2 \leq \sqrt{d}.$$

Preuve. La norme euclidienne est 1-lipschitzienne (inégalité triangulaire). La première inégalité découle de l'inégalité de Poincaré.

La majoration de l'espérance suit de l'inégalité de Jensen.

La minoration de l'espérance suit de $(\mathbb{E}\|X\|_2)^2 = \mathbb{E}\|X\|_2^2 - \text{var}(\|X\|_2) = d - \text{var}(\|X\|_2)$ et de la borne sur la variance. $\square$

Exercice 16.4. Soit $X \sim \mathcal{N}(0, K)$ où $K \in \text{DP}(d)$ et $Z = \max_{i \leq d} X_i$.

Montrer que

$$\text{Var}(Z) \leq \max_{i \leq d} K_{i,i} := \max_{i \leq d} \text{Var}(X_i).$$

Exercice 16.5. Soient $X, Y \sim \mathcal{N}(0, \text{Id}_n)$, avec X, Y indépendants.

Montrer que

$$\sqrt{2n-1} \leq \mathbb{E}\|X - Y\| \leq \sqrt{2n}$$

et

$$\mathbb{P}\{\|X - Y\| - \mathbb{E}\|X - Y\| \geq t\} \leq e^{-t^2}.$$

16.10 Remarques bibliographiques

La littérature gaussienne est très abondante; voir par exemple (?). Une grande partie de cette littérature est pertinente pour la statistique.

Les lemmes **?@lem-stein** et **?@lem-steinbis** qui caractérisent la loi gaussienne standard sont le point de départ de la méthode de Stein (Charles) pour démontrer le théorème central

limite (et bien d'autres résultats). Ce développement relativement récent est décrit dans (N. Ross, 2011).

L'analyse matricielle et l'algorithmique jouent un rôle important dans l'analyse gaussienne et la statistique. Les ouvrages (Horn & Johnson, 1990), et pour aller plus loin (Bhatia, 1997), introduisent les concepts et techniques de factorisation matricielle et des éléments de théorie des perturbations.

Il existe une version multidimensionnelle des lois du χ^2 qui interviennent lors de la détermination de la loi de la variance empirique. Ce sont les lois de Wishart. Elles ont fait l'objet d'études intensives en théorie des matrices aléatoires; voir par exemple (Anderson, Guionnet, & Zeitouni, 2010).

La concentration gaussienne joue un rôle important en statistique non paramétrique et inspire l'apprentissage statistique. L'ouvrage de M. Ledoux (Ledoux, 2001) offre une perspective élégante sur cette question.

- Anderson, G. W., Guionnet, A., & Zeitouni, O. (2010). *An introduction to random matrices* (Vol. 118). Cambridge : Cambridge University Press.
- Bhatia, R. (1997). *Matrix analysis*. Springer-Verlag.
- Billingsley, P. (2012). *Probability and measure*. John Wiley & Sons, Inc., Hoboken, NJ.
- Boucheron, S., Lugosi, G., & Massart, P. (2013). *Concentration inequalities*. Oxford University Press.
- Chen, L. H. Y., Goldstein, L., & Shao, Q.-M. (2011). *Normal approximation by Stein's method* (p. xii+405). Springer, Heidelberg. <https://doi.org/10.1007/978-3-642-15007-4>
- Cover, T., & Thomas, J. (1991). *Elements of information theory*. John Wiley & sons.
- Dudley, R. M. (2002). *Real analysis and probability* (Vol. 74, p. x+555). Cambridge : Cambridge University Press.
- Durrett, R. (2010). *Probability : theory and examples*. Cambridge University Press.
- Hiriart-Urruty, J.-B., & Lemaréchal, C. (1993). *Convex analysis and minimization algorithms. I* (Vol. 305, p. xviii+417). Springer-Verlag, Berlin.
- Horn, R. A., & Johnson, C. R. (1990). *Matrix analysis*. Cambridge University Press.
- Ledoux, M. (2001). *The concentration of measure phenomenon*. AMS.
- Massart, P. (2007). *Concentration inequalities and model selection. Ecole d'Eté de Probabilité de Saint-Flour xxxiv* (Vol. 1896). Springer-Verlag.
- McDiarmid, C. (1998). Concentration. In M. Habib, C. McDiarmid, J. Ramirez-Alfonsin, & B. Reed (Éd.), *Probabilistic Methods for Algorithmic Discrete Mathematics* (p. 195-248). Springer, New York.
- Pollard, D. (2002). *A user's guide to measure theoretic probability* (Vol. 8, p. xiv+351). Cambridge University Press, Cambridge.
- Ross, N. (2011). Fundamentals of Stein's method. *ArXiv e-prints*. Consulté à l'adresse <https://arxiv.org/abs/1109.1880>
- Ross, Nathan. (2011). Fundamentals of Stein's method. *Probab. Surv.*, 8, 210-293. <https://doi.org/10.1214/11-PS182>
- Widder, D. V. (2015). *Laplace transform (PMS-6)*. Princeton university press.
- Wilf, H. S. (2005). *generatingfunctionology*. AK Peters/CRC Press.
- Williams, D. (1991). *Probability with martingales* (p. xvi+251). Cambridge University Press, Cambridge. <https://doi.org/10.1017/CBO9780511813658>

